Fondements de l’apprentissage statistique

Oumoukelthoum Sidenna

7 novembre 2025



École supérieure polytechnique

SID34: Apprentissage statistique

Vue d'ensemble SID34

- **Chapitre 1 :** Fondements de l'apprentissage statistique
- **Chapitre 2 :** Algorithmes linéaires
- **Chapitre 3 :** Algorithmes non linéaires
- **Chapitre 4 :** Agrégation
- **Chapitre 5 :** Cycle ML & Métriques d'évaluation

Plan du cours

1. Introduction générale
   - Motivation
   - Contexte
2. Cadre mathématique de l'apprentissage statistique supervisé
   - Régression vs Discrimination
   - Fonction de perte
   - Risque
   - Décomposition de l'erreur
   - Compromis Bias-Variance
   - Estimation du risque
3. Catégorisation

Introduction générale

Motivation



IN GOD WE TRUST ALL OTHERS BRING DATA

–William Edwards Deming
(1900-1993)

We are drowning in information and starving for knowledge.



–John Naisbitt
(1929-2021)

ESP

Contexte

L'apprentissage statistique (Statistical learning) s'entend comme :

- "... explores way of estimating functional dependency from a given collection of data" [Vapnik, 2000].
- ".... a set of tools for modelling and understanding complex datasets" [James et al., 2013].

Deux approches

- Selon l'objectif :
  - En statistique $\rightarrow$ **modèle interprétable** (complexité minimale).
  - En ML $\rightarrow$ **bonne prédiction** (complexité souvent secondaire).
- Cependant complémentaires :
  - Bien expliquer $\Rightarrow$ bien prédire.
  - Interprétation des modèles ML : scores d'importance des variables.
  - Un bon algorithme doit avoir de bonnes propriétés statistiques (biais, variance, convergence...).

Apprentissage Statistique vs Machine Learning

- Le **machine learning** est né comme un sous-domaine de l'**intelligence artificielle**.
- L'**apprentissage statistique** est né comme un sous-domaine de la **statistique**.
- Il existe un fort chevauchement, les deux approches traitent des problèmes supervisés et non supervisés :
  - Le **machine learning** met davantage l'accent sur les applications à grande échelle et la précision prédictive.
  - L'**apprentissage statistique** met l'accent sur les modèles et leur interprétabilité, ainsi que sur la précision.
- Cependant, la distinction est devenue de plus en plus floue, avec une forte **interaction** entre les deux domaines.
- Le **machine learning** a un avantage important en termes de marketing.

Problématiques associées à l'apprentissage

- **Apprentissage supervisé** : prédire une sortie $y \in \mathcal{Y}$ à partir d'entrées $x \in \mathcal{X}$.
- **Apprentissage non supervisé** : établir une typologie des observations.
- **Règles d'association** : identifier des liens entre produits ou événements.
- **Systèmes de recommandation** : prédire les produits susceptibles d'intéresser un utilisateur.

Notations et significations

- $\mathcal{X}$: **espace des entrées (features, prédicteurs)**.
- $\mathcal{Y}$: **espace des sorties (réponse, étiquette)**.
- X : variable aléatoire prenant ses valeurs dans $\mathcal{X}$.
- Y : variable aléatoire prenant ses valeurs dans $\mathcal{Y}$.
- (X, Y) : un **couple aléatoire** décrivant un individu observé.
- $D_n = \{(X_1, Y_1), \ldots, (X_n, Y_n)\}$: **échantillon d'apprentissage** composé de n couples i.i.d.
- (x_i, y_i) : **réalisation observée** du couple (X_i, Y_i).
- $f : \mathcal{X} \to \mathcal{Y}$: **fonction de prévision** (ou modèle).
- $\ell(Y, f(X))$: **fonction de perte**, mesure l'erreur de prédiction.
- $\mathcal{R}(f) = \mathbb{E}[\ell(Y, f(X))]$: **risque** (*erreur moyenne*).

Problème d'apprentissage supervisé

Point de départ :

- Une variable de sortie Y (appelée aussi **variable dépendante**, **réponse**, **cible**).
- Un vecteur de p variables explicatives X (aussi appelées **entrées**, **prédicteurs**, **covariables**, **features**, **variables indépendantes**).
- Dans un **problème de régression**, Y est **quantitative** (ex : prix, tension artérielle).
- Dans un **problème de discrimination**, Y prend des valeurs dans un ensemble **fini et non ordonné** (ex : survie/mort, chiffre 0–9, classe de tissu cancéreux).
- On dispose de données d'apprentissage :

$$(x_1, y_1), \ldots, (x_n, y_n)$$

qui représentent des **observations** (ou **exemples**, **instances**) de ces mesures.

Apprentissage non supervisé

- Pas de variable de sortie Y, seulement un ensemble de **mesures** ou **features** sur les observations.
- L'objectif est plus **exploratoire** :
  - trouver des groupes d'observations qui se ressemblent,
  - trouver des variables qui se comportent de manière similaire,
  - trouver des combinaisons linéaires de variables capturant la plus grande variance.
- Il est **difficile d'évaluer** la qualité des résultats (absence de vérité terrain).
- Différent du supervisé, mais peut servir de **pré-traitement** (ex : réduction de dimension avant classification supervisée).

Le prix Netflix

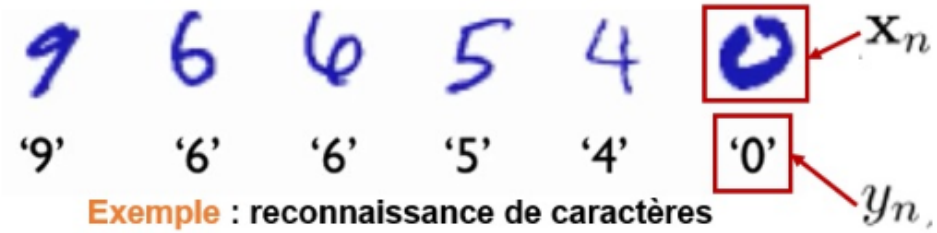
- La compétition a commencé en octobre 2006. Les données d'entraînement contiennent les notes de 400 000 clients Netflix pour 18 000 films, chaque note étant comprise entre 1 et 5.
- Les données d'entraînement sont très creuses — environ 98 % des valeurs sont manquantes.
- L'objectif est de prédire la note pour un ensemble d'un million de couples client–film qui manquent dans les données d'entraînement.
- L'algorithme original de Netflix atteignait une erreur quadratique moyenne (RMSE) de 0.953. La première équipe à améliorer cette performance de 10% remportait un million de dollars.

S'agit-il d'un problème supervisé ou non supervisé ?

Cadre mathématique de l'apprentissage statistique supervisé

Régression vs Discrimination

- **Données** de type **entrée-sortie** : $d_n = (x_1, y_1), \ldots, (x_n, y_n)$ où $x_i \in \mathcal{X}$ représente l'entrée et $y_i \in \mathcal{Y}$ la sortie et n le nombre de données disponibles dans l'ensemble .



Exemple : reconnaissance de caractères

Objectifs

1. Expliquer le(s) mécanisme(s) liant les entrée x_i aux sorties y_i.
2. Prédire « au mieux » la sortie y associée à une nouvelle entrée $x \in \mathcal{X}$.

Régression vs Discrimination

Vocabulaire

- Lorsque la variable à expliquer est quantitative ($\mathcal{Y} \subseteq \mathbb{R}$), on parle de régression.
- Lorsqu'elle est qualitative (Card($\mathcal{Y}$) fini), on parle de discrimination ou de classification supervisée (Classification).

y_i	x_i	
Chiffre	image	Discri.
Prix de voiture	features du véhicule	Régression

Remarque

La nature des variables associées aux entrées x_i est variée (quanti, quali, ordinale, images,...).

Un début de formalisation mathématique

- On suppose que les données $d_n = \{(x_1, y_1), \ldots, (x_n, y_n)\}$ sont des *réalisations d'un n-échantillon* $D_n = \{(X_1, Y_1), \ldots, (X_n, Y_n)\}$ de *loi inconnue*.
- Le plus souvent on supposera que les couples (X_i, Y_i), $i = 1, \ldots, n$ sont *i.i.d. de loi* $\mathbb{P}$.
- Étant données des observations $d_n = \{(x_1, y_1), \ldots, (x_n, y_n)\}$, on cherche à expliquer/prédire les sorties $y_i \in \mathcal{Y}$ à partir des entrées $x_i \in \mathcal{X}$.
- Il s'agit donc de trouver une fonction de prévision $f : \mathcal{X} \to \mathcal{Y}$ telle que
$$f(x_i) \approx y_i, \quad i = 1, \ldots, n.$$
- Nécessité de se donner un critère qui permette de mesurer la qualité des fonctions de prévision f.

Critère $\Rightarrow$ Une fonction de perte

En outre..

La **fonction de prévision** (ou de prédiction) permet au modèle de produire une sortie y' à partir d'une entrée x en fonction des paramètres du modèle θ :

$$y' = f_\theta(x)$$

Exemple :

Modèle	**Fonction de prévision**	**Paramètres θ**
Régression linéaire	$y' = w^T x + b$	$\theta = (w, b)$
SVM	$y' = \text{sign}(w^T x + b)$	$\theta = (w, b)$

Fonction de perte

Définition

Une fonction (mesurable) $\ell : \mathcal{Y} \times \mathcal{Y} \to \mathbb{R}^+$ est une fonction de perte si

$$\ell(y, y') = 0 \quad \text{et} \quad \ell(y, y') > 0 \text{ pour } y \neq y'.$$

En régression réelle : on définit les pertes L^p $(p \geq 1)$

$$\ell(y, y') = \frac{1}{p}|y - y'|^p.$$

- Si $p = 1$, on parle de *perte absolue*.
- Si $p = 2$, de *perte quadratique*.

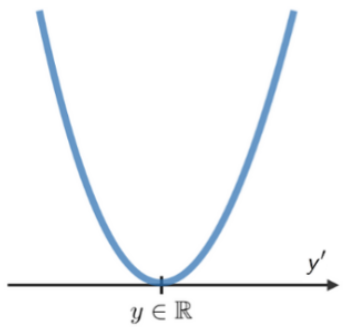
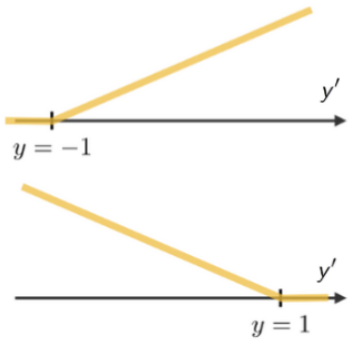
En discrimination binaire : $\mathcal{Y} = \{-1, 1\}$

$$\ell(y, y') = \mathbf{1}_{y \neq y'}.$$

Choix de la fonction de perte

Modèle	Fonction de prévision	Fonction de perte
Régression linéaire	$y' = w^T x + b$	$\frac{1}{2}(y - y')^2$
SVM	$y' = \text{sign}(w^T x + b)$	$\max(0, 1 - yy')$

Exemples :

Least squared error	Hinge loss
$\frac{1}{2}(y - y')^2$	$max(0, 1 - yy')$
	
Linear regression	SVM

Risque

On va s'intéresser au comportement moyen de cette fonction de perte, il s'agit de la notion de **risque**.

Définition

- Étant donnée une *fonction de perte* $\ell : \mathcal{Y} \times \mathcal{Y} \to \mathbb{R}^+$, la performance d'une *fonction de prévision* $f : \mathcal{X} \to \mathcal{Y}$ est mesurée par

$$\mathcal{R}(f) = \mathbb{E}[\ell(Y, f(X))]$$

où (X, Y) est iid et de même loi $\mathbb{P}$.

- $\mathcal{R}(f)$ est appelée *risque* ou *erreur de généralisation* de f.

Fonction de prévision optimale

Idée : trouver f qui a la plus petite erreur $\mathcal{R}(f)$.

Aspect théorique

- Pour une fonction de perte $\ell : \mathcal{Y} \times \mathcal{Y} \to \mathbb{R}^+$ donnée, le problème *théorique* consiste à trouver

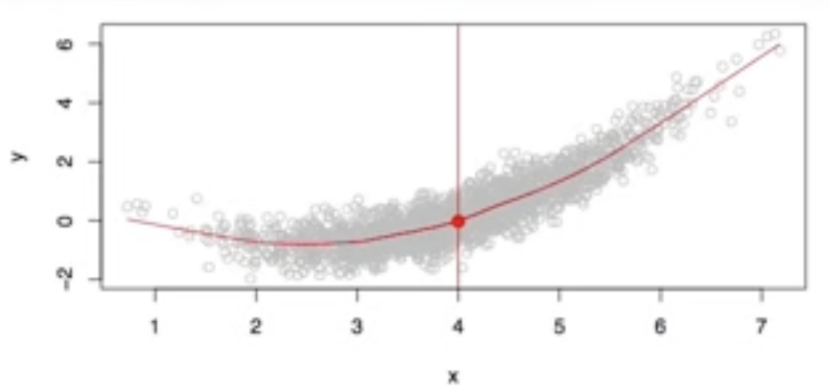
$$f^* \in \arg\min_f \mathcal{R}(f) \quad \Longleftrightarrow \quad \mathcal{R}(f^*) \leq \mathcal{R}(f) \; \forall f$$

- Une telle fonction f^* (si elle existe) est appelée *fonction de prévision optimale* pour la perte ℓ.

Aspect pratique

- La fonction de prévision optimale f^* dépend le plus souvent de la loi $\mathbb{P}$ des (X, Y) qui est en pratique *inconnue*.
- Solution : Trouver un estimateur $f_n = f_n(., D_n)$ tel que $\mathcal{R}(f_n) \approx \mathcal{R}(f^*)$.

Intuition

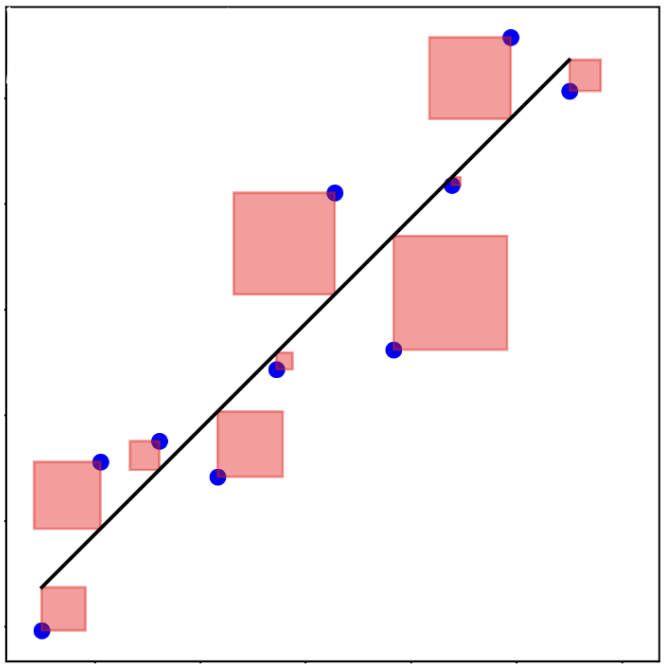


- Pour une valeur donnée de X, il peut exister plusieurs valeurs possibles de Y.
- Quel est alors une bonne valeur de prédiction pour $f(X)$ lorsque $X = x$?
- Une valeur « idéale » est :

$$f(x) = \mathbb{E}(Y \mid X = x)$$

- $\mathbb{E}(Y \mid X = x)$ signifie valeur moyenne (ou espérée) de Y sachant que $X = x$.

Cas de la régression



- $\mathcal{Y} = \mathbb{R}$, une prévision = un réel
  $\Longrightarrow m : \mathcal{X} \to \mathbb{R}$;
- Le **risque (risque quadratique)** est alors donné par :

$$\mathcal{R}(m) = \mathbb{E}[(Y - m(X))^2]$$

- et la *fonction optimale (inconnue)*, appelée **fonction de régression**, par :

$$m^*(x) = \mathbb{E}[Y|X = x].$$

$\Rightarrow$ Comment est celui de la discrimination ?

Recap

- **Données** $d_n = \{(x_1, y_1), \ldots, (x_n, y_n)\}$ i.i.d. de loi inconnue $\mathbf{P}$.
- **Prédicteur** : une fonction $f : \mathcal{X} \to \mathcal{Y}$.
- **Coût** : $\ell(Y, f(X)) \Longrightarrow$ ensemble des erreurs de prévision.
- **Risque** : $\mathcal{R}(f) = \mathbb{E}[\ell(Y, f(X))] \Longrightarrow$ coût "moyen".

Oracle

f^* qui vérifie $\mathcal{R}(f^*) \leq \mathcal{R}(f)$ pour tout $f : \mathcal{X} \to \mathcal{Y} \Longrightarrow$ dépend de $\mathbf{P}$, donc inconnu.

Objectif

Construire une algorithme de prévision $f_n(\cdot) = f_n(\cdot, D_n)$ tel que $\mathcal{R}(f_n) \approx \mathcal{R}(f^*)$.

c'est-à-dire que f_n généralise bien sur de nouvelles données.

Conséquence : les performances de f_n dépendent :

- du **choix du modèle** (complexité),
- de la **quantité de données** disponibles,
- du **compromis biais–variance**.

Décomposition de l'erreur : biais, variance et bruit

- Pour une valeur donnée $X = x$, on considère l'erreur quadratique moyenne :

$$\mathbb{E}\big((Y - \hat{f}(X))^2 \mid X = x\big)$$

- Cette erreur se décompose en :

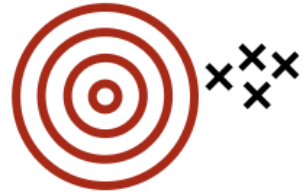
$$\underbrace{\big(f(x) - \mathbb{E}[\hat{f}(x)]\big)^2}_{Biais^2} + \underbrace{\mathbb{E}\big[(\hat{f}(x) - \mathbb{E}[\hat{f}(x)])^2\big]}_{Variance} + \underbrace{\mathrm{Var}(\varepsilon)}_{Bruit(irrductible)}$$

Compromis Bias-Variance

Biais – Le *biais* d'un modèle est la différence entre la prédiction moyenne du modèle et la vraie valeur qu'il cherche à estimer.



Low bias



High bias

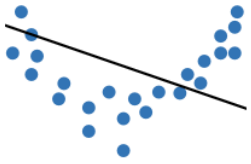
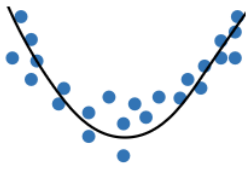
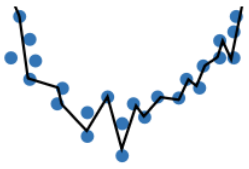
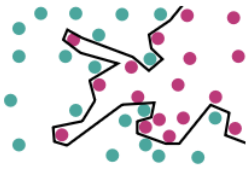
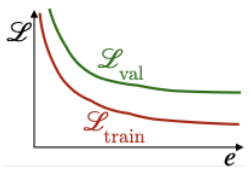
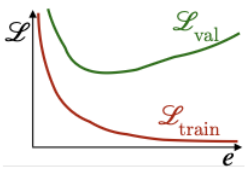
Variance – La *variance* d'un modèle mesure à quel point ses prédictions changeraient si l'on modifiait légèrement les données d'apprentissage.



Low variance



High variance

	Underfitting	Just right	Overfitting
Symptoms	• High training error • Training error close to test error • High bias	Training error slightly lower than test error	• Low training error • Training error much lower than test error • High variance
Intuition			
Regression			
Classification			
Evolution of the loss			
Possible remedies	• Complexify model • Add more features • Train longer		• Regularize • Get more data

Estimation du risque

Risque empirique

La loi de (X, Y) étant inconnue, on ne peut pas calculer $\mathcal{R}(f_n) = \mathbb{E}[\ell(Y, f_n(X))]$.

Première approche : on estime cette espérance par la version empirique :

$$\mathcal{R}_n(f_n) = \frac{1}{n} \sum_{i=1}^{n} \ell(Y_i, f_n(X_i)).$$

Mais : l'échantillon $\mathcal{D}_n$ a déjà été utilisé pour construire $f_n \rightarrow$ sous-estimation de $\mathcal{R}(f_n)$.

Solution

Utiliser des méthodes de type validation croisée.

Validation ou hold out

❑ **Principe :** On sépare l'échantillon $\mathcal{D}_n$ en :

1. un échantillon d'apprentissage $\mathcal{D}_{n,\text{app}}$ pour construire f_n ;
2. un échantillon de validation $\mathcal{D}_{n,\text{valid}}$ utilisé pour estimer le risque de f_n.

Algorithme 1 : Validation ou Hold-Out

Entrées : $\{\mathcal{A}, \mathcal{T}\}$: une partition de $\{1, \ldots, n\}$ en deux sous-ensembles

Ajuster l'algorithme de prévision en utilisant uniquement les données d'apprentissage :

$$\mathcal{D}_{\text{app}} = \{(x_i, y_i) : i \in \mathcal{A}\}.$$

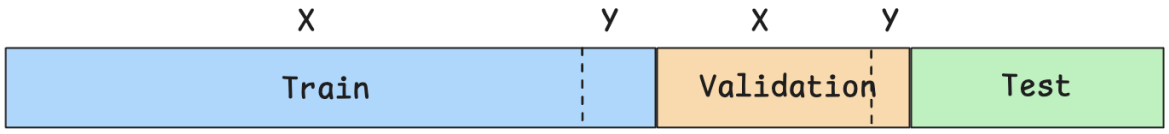
On note $f_{\text{app}}(\cdot, \mathcal{D}_{\text{app}})$ l'algorithme obtenu.;

Calculer les valeurs prédites $f_{\text{app}}(x_i, \mathcal{D}_{\text{app}})$ pour chaque observation du jeu de validation :

$$\mathcal{D}_{\text{valid}} = \{(x_i, y_i) : i \in \mathcal{T}\}.$$

Output : $\dfrac{1}{|\mathcal{T}|} \sum_{i \in \mathcal{T}} \ell(y_i, f_{\text{app}}(x_i, \mathcal{D}_{\text{app}}))$

Illustration



Commentaires :

- Nécessite d'avoir un nombre suffisant d'observations dans :
  1. $\mathcal{D}_{\text{app}}$ pour bien ajuster l'algorithme de prévision ;
  2. $\mathcal{D}_{\text{valid}}$ pour bien estimer l'erreur de l'algorithme et ajuster.

Validation croisée K-blocs

❑ **Principe :** répéter la hold out sur différentes partitions.

Algorithme 2 : Validation croisée K-blocs (CV)

Entrées : $\{B_1, \ldots, B_K\}$ une partition de $\{1, \ldots, n\}$ en K blocs
pour $k = 1$ **à** K **faire**

Ajuster l'algorithme de prévision en utilisant l'ensemble des données privé du k^e bloc :

$$\mathcal{B}_k = \{(x_i, y_i) : i \in \{1, \ldots, n\} \setminus B_k\}.$$

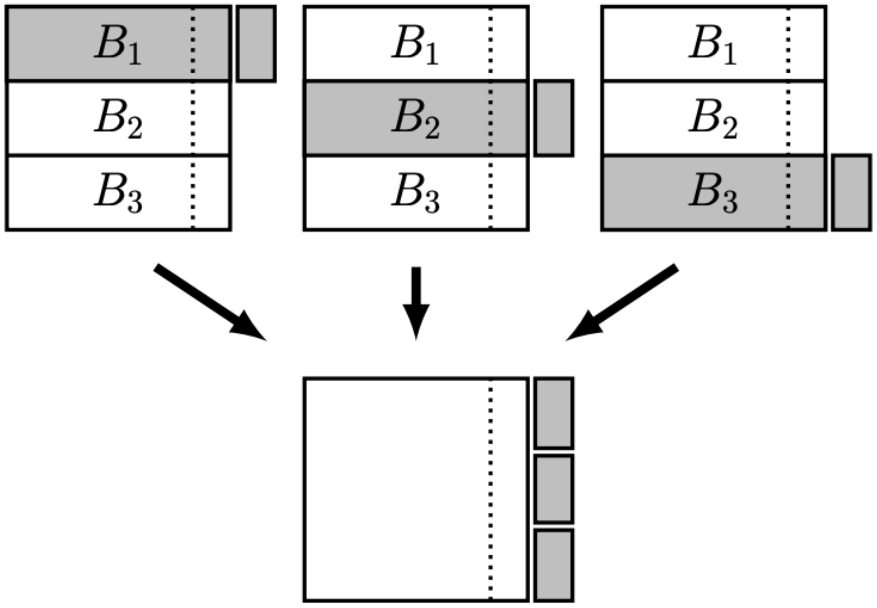
On note $f_k(\cdot) = f_k(\cdot, \mathcal{B}_k)$ l'algorithme obtenu.;
Calculer les valeurs prédites sur le bloc k :

$$f_k(x_i), \quad i \in B_k,$$

puis le risque sur le bloc k :

$$\widehat{\mathcal{R}}(f_k) = \frac{1}{|B_k|} \sum_{i \in B_k} \ell(y_i, f_k(x_i)).$$

Output : $\dfrac{1}{K} \sum_{k=1}^{K} \widehat{\mathcal{R}}(f_k)$



Commentaires

— Le *choix de K* doit être fait par l'utilisateur (souvent $K = 10$).

— *Avantage* : plus adapté que la technique apprentissage/validation $\Longrightarrow$ plus stable et précis.

— *Inconvénient* : plus coûteux en temps de calcul.

Leave-One-Out

❑ **LOO**

- Lorsque $K = n$, on parle de validation croisée *leave one out* ;
- Le risque est alors estimé par :

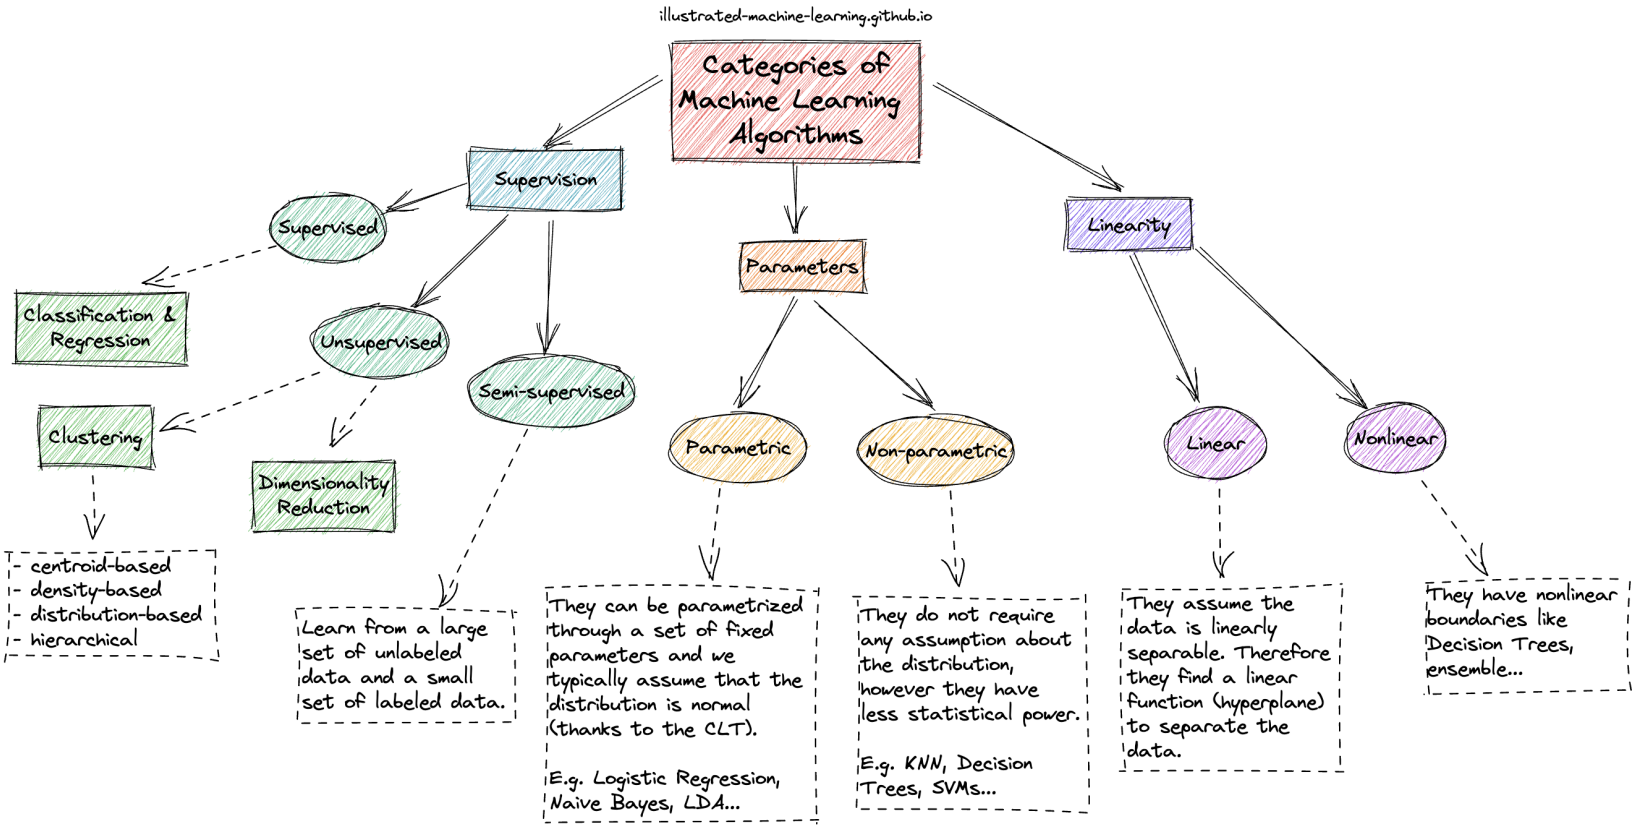
$$\widehat{\mathcal{R}}_n(f_n) = \frac{1}{n} \sum_{i=1}^{n} \ell(Y_i, f_n^i(X_i))$$

où f_n^i désigne l'algorithme de prévision construit sur D_n *amputé de la i-ème observation.*

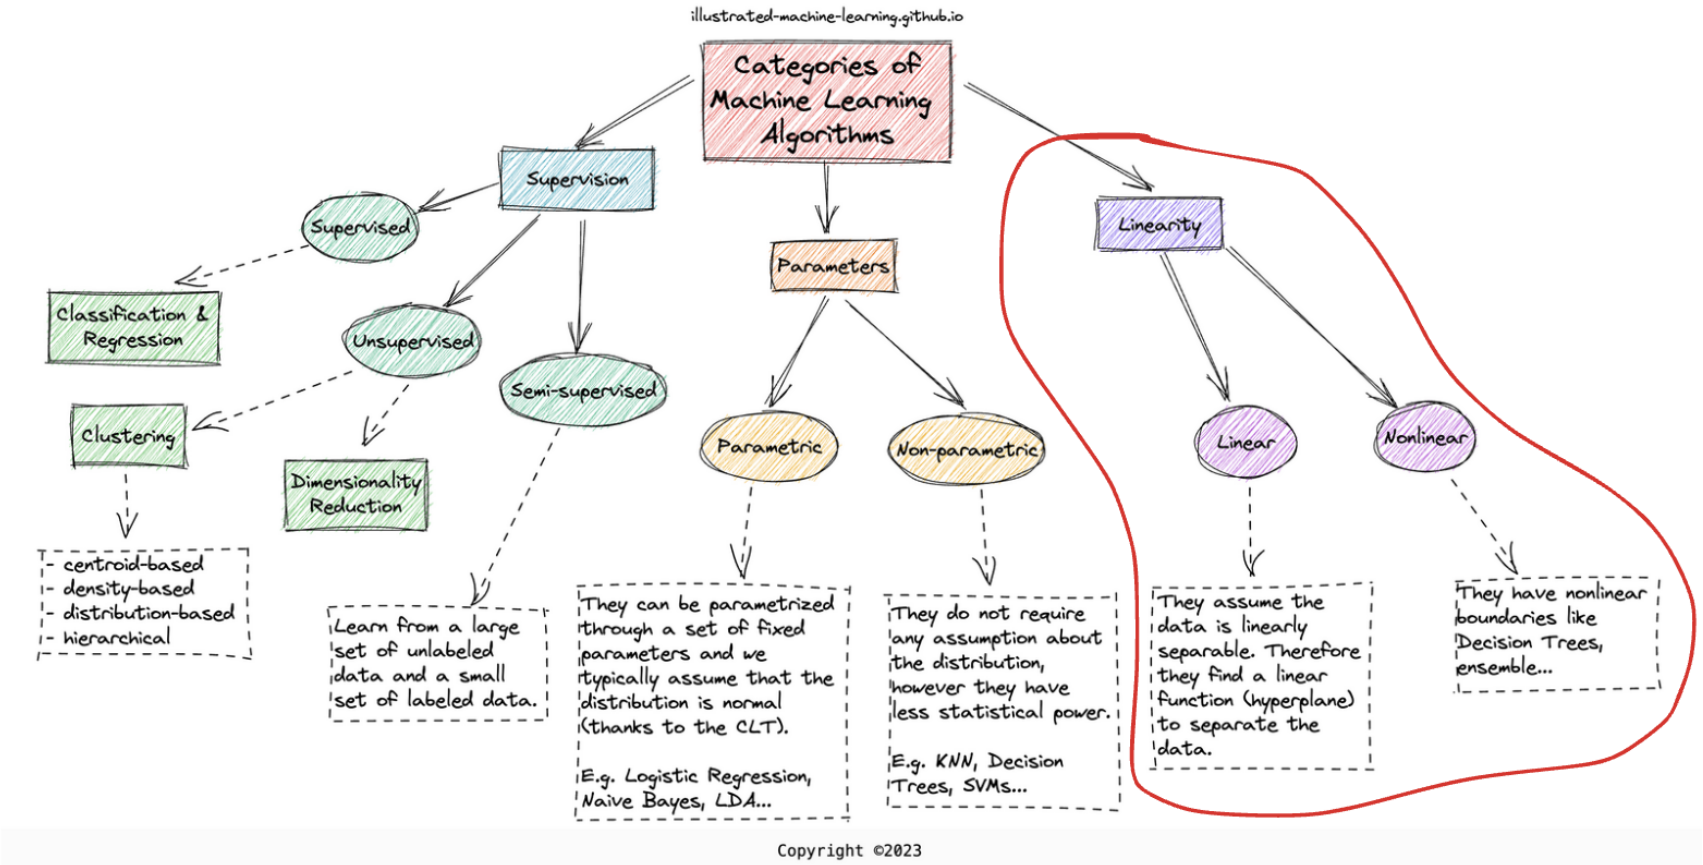
$\Longrightarrow$ recommandé uniquement lorsque n est petit.

Catégorisation

Catégorisation



Notre perspective

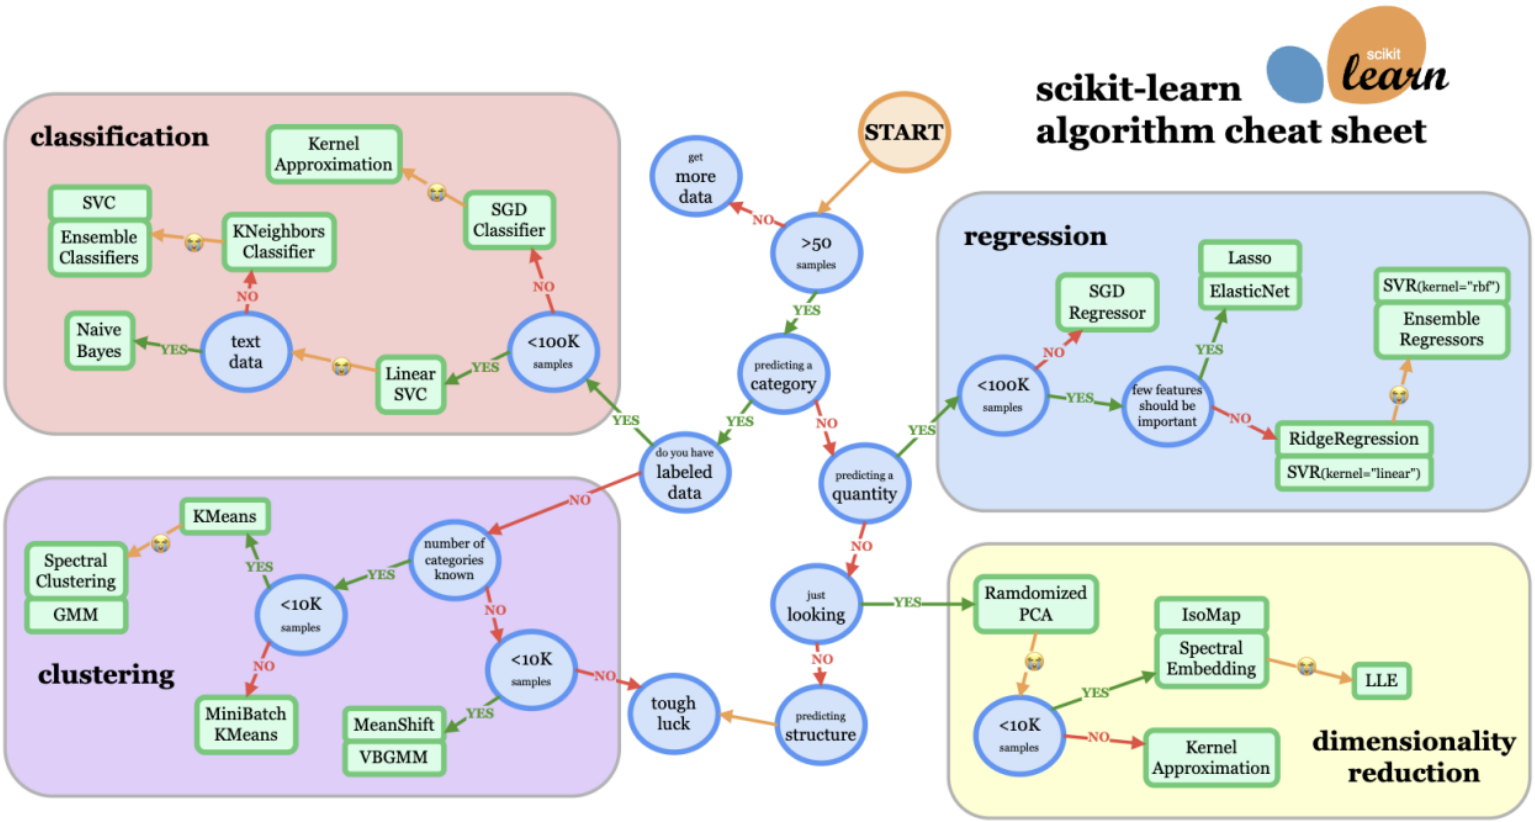


Pourquoi cet choix ?

Ce classement (*linéaire / non linéaire*) aide à :

- comprendre le **compromis biais–variance** des modèles ;
- choisir la **complexité appropriée** selon la taille et la structure des données ;
- bâtir une **démarche progressive** :
  - → commencer par un modèle linéaire simple pour poser les bases ;
  - → puis aller vers un modèle non linéaire si les données le justifient.

Guide selon Scikit-learn



Références

- **James, G., Witten, D., Hastie, T., Tibshirani, R.** *An Introduction to Statistical Learning*, Springer, 2023.
- **Afshine Amidi et Shervine Amidi** *CS 229 - Machine Learning* , Fall 2018.
- **Laurent Rouvière** *Introduction au machine learning*, Université Rennes 2, 2021.
- **Trevor Hastie, Robert Tibshirani, Jerome Friedman** *The Elements of Statistical Learning*, Springer, 2001.
- The Illustrated Machine Learning website

Next : Algorithmes linéaires