Algorithmes linéaires

Oumoukelthoum Sidenna

7 novembre 2025



École supérieure polytechnique

SID34: Apprentissage statistique

Plan du cours

1. Linéarité et modèles
2. Modèles linéaires supervisés
3. Modèles linéaires non supervisés

Linéarité et modèles

Linéarité et modèles

Idée générale

De nombreux algorithmes reposent sur une approximation linéaire :

$$y \approx w \cdot x + b$$

ou bien, en absence de Y, on cherche une représentation linéaire des données.

Intuition géométrique

- En **régression** : on ajuste un hyperplan aux observations.
- En **discrimination binaire** : l'hyperplan sépare deux classes.
- En **non supervisé** : on cherche des axes linéaires expliquant la variance.

$\rightarrow$ *La linéarité simplifie l'apprentissage, mais impose des hypothèses fortes.*

Hyperplan

Définition

Un **hyperplan** de E est un sous-espace affine de dimension $\dim(E) - 1$, défini par une équation linéaire :

$$w \cdot x + b = 0,$$

où $w \in \mathbb{R}^n$ est un vecteur normal à l'hyperplan et $b \in \mathbb{R}$ un biais.

Exemples :

- Dans $\mathbb{R}^2$: un hyperplan est une droite vectorielle $\text{Vect}(a)$ avec $a \neq 0_E$.
- Dans $\mathbb{R}^3$: un hyperplan est un plan vectoriel $\text{Vect}(a, b)$ avec a, b non colinéaires.
- Dans $\mathbb{R}^1$?

Hyperplan

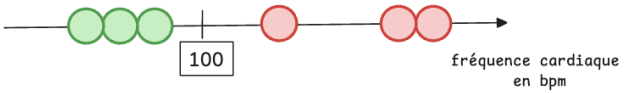
Lien avec les modèles linéaires

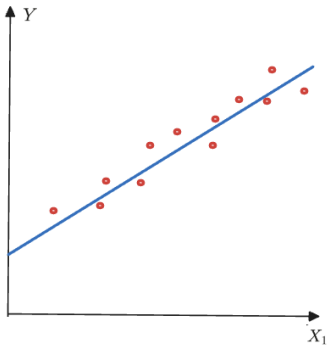
Apprendre un **modèle linéaire** revient à déterminer les paramètres (w, b) définissant un hyperplan.

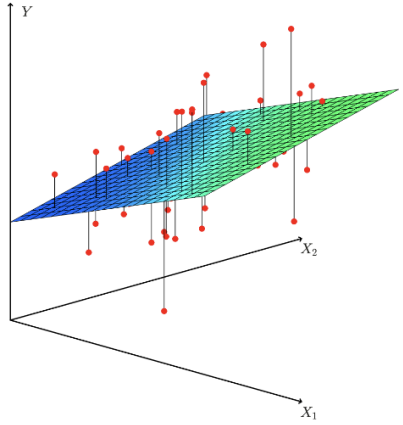
Interprétation géométrique en cas de discrimination

Le vecteur w détermine l'orientation de l'hyperplan, tandis que le biais b contrôle son positionnement (décalage par rapport à l'origine). Le signe de $w \cdot x + b$ indique de quel côté de l'hyperplan se trouve un point x :

$$\begin{cases} w \cdot x + b > 0 & \rightarrow \text{un côté de l'hyperplan,} \\ w \cdot x + b < 0 & \rightarrow \text{l'autre côté.} \end{cases}$$







À faire

On considère le vecteur normal :

$$w = (2, -1)$$

et un hyperplan passant par l'origine.

1. Écrire l'équation de la droite correspondante.
2. Vérifier de quel côté de cette droite se trouvent les points :

$$x_1 = (1, 1) \quad \text{et} \quad x_2 = (1, 3).$$

3. Interpréter le signe de $w \cdot x + b$.

Théorème du *No Free Lunch*

Essentiel

Tout modèle simplifie la réalité à partir d'hypothèses. Un modèle linéaire, par exemple, suppose que la relation est linéaire et que les écarts sont du bruit.

Résultat de Wolpert (1996)

Sans hypothèse sur les données, aucun modèle n'est meilleur qu'un autre.
$\rightarrow$ Le *No Free Lunch Theorem* : chaque modèle n'est efficace que dans son contexte.

Aucun modèle universel : il faut choisir selon les données.

Modèles linéaires supervisés

Modèles linéaires supervisés

Objectif

Prédire une variable Y à partir d'un vecteur X en apprenant une combinaison linéaire :

$$Y \approx \beta_0 + \beta_1 X_1 + \cdots + \beta_d X_d.$$

Exemples

- **Régression linéaire** : $Y \in \mathbb{R}$.
- **Régression logistique** : $Y \in \{0, 1\}$, probabilité linéaire dans la logit.
- **SVM linéaire** : frontière linéaire à marge maximale.

$\rightarrow$ *Même principe : apprendre les coefficients d'un hyperplan optimal.*

Régression

Idée

La régression linéaire repose sur une **approximation affine de la relation** entre Y et X :

$$\hat{y} = f_\beta(x) = \beta_0 + \beta_1 x_1 + \cdots + \beta_d x_d.$$

Le modèle cherche les coefficients β qui rendent cette approximation la plus fidèle possible.

Vision abstraite

- $f_\beta(x)$ est une projection linéaire de X sur l'espace des réponses possibles.
- L'apprentissage consiste à minimiser une fonction de perte :

$$\min_\beta \ \mathcal{L}(Y, f_\beta(X)).$$

- Le choix de $\mathcal{L}$ définit la nature du modèle : MSE, log-vraisemblance, marge, etc.

Discrimination binaire

Idée

En discrimination binaire, on cherche une **fonction de décision linéaire** :

$$g(x) = w \cdot x + b,$$

dont le signe prédit la classe :

$$\hat{y} = \text{sign}(g(x)).$$

Vision abstraite

- $g(x)$ définit une frontière linéaire entre deux régions de l'espace.
- L'apprentissage consiste à ajuster (w, b) pour séparer au mieux les classes.
- Différents modèles se distinguent par :
  - la fonction de perte (logistique, hinge, etc.),
  - la régularisation (L1, L2, marge, etc.).

Minimiser les erreurs

Principe

Apprendre un modèle linéaire revient à **minimiser l'erreur** entre les valeurs observées et les valeurs prédites :

$$\min_{\beta_0,\dots,\beta_d} \sum_{i=1}^{n} (y_i - \hat{y}_i)^2 \quad \text{où} \quad \hat{y}_i = \beta_0 + \sum_{j=1}^{d} \beta_j x_{ij}.$$

Erreur quadratique moyenne (MSE)

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^{n} (y_i - \hat{y}_i)^2$$

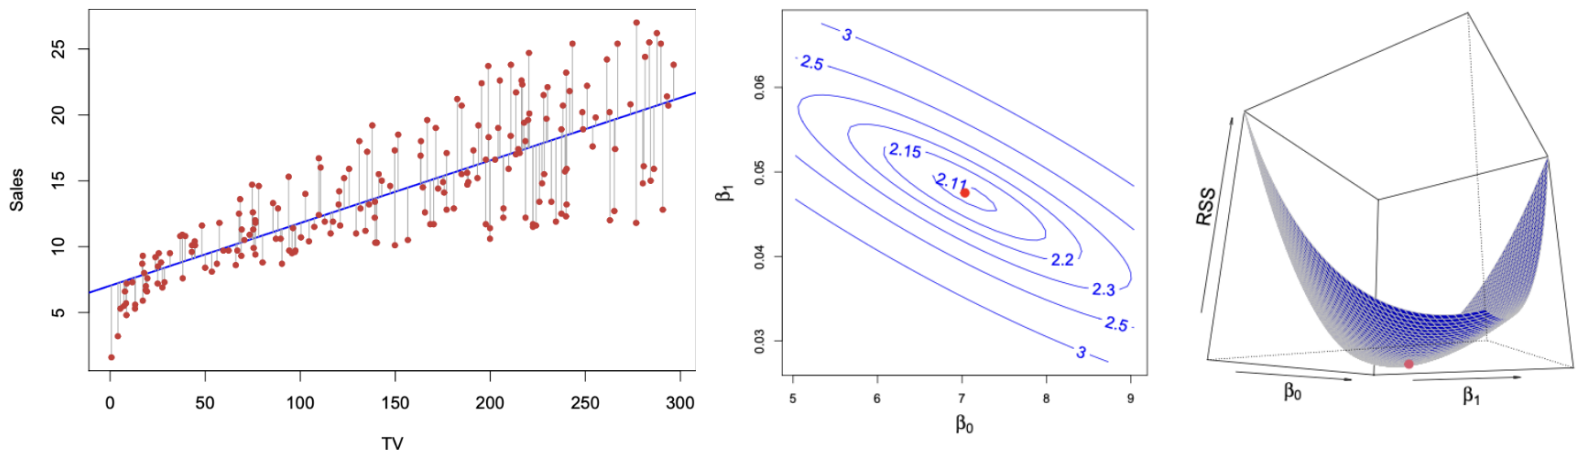
C'est la mesure la plus utilisée pour la régression linéaire.

$\rightarrow$ *On cherche les coefficients minimisant la MSE.*

Exemple

$$\texttt{sales} \approx \beta_0 + \beta_1 \times \texttt{TV}$$

	Coefficient	Std. error	t-statistic	p-value
`Intercept`	7.0325	0.4578	15.36	< 0.0001
`TV`	0.0475	0.0027	17.67	< 0.0001



Source : *An Introduction to Statistical Learning*, Gareth James et al. 2013

Support Vector Machines

Idée

Les **SVMs** apprennent une frontière linéaire optimale :

$$f(x) = w \cdot x + b$$

en maximisant la marge entre les données et cette frontière.

Deux variantes principales

- **SVM de discrimination (SVC)** : séparer deux classes ($Y \in \{-1, +1\}$).
- **SVM de régression (SVR)** : approximer une fonction $Y = f(x)$ dans une bande de tolérance.

Principe géométrique du SVM linéaire

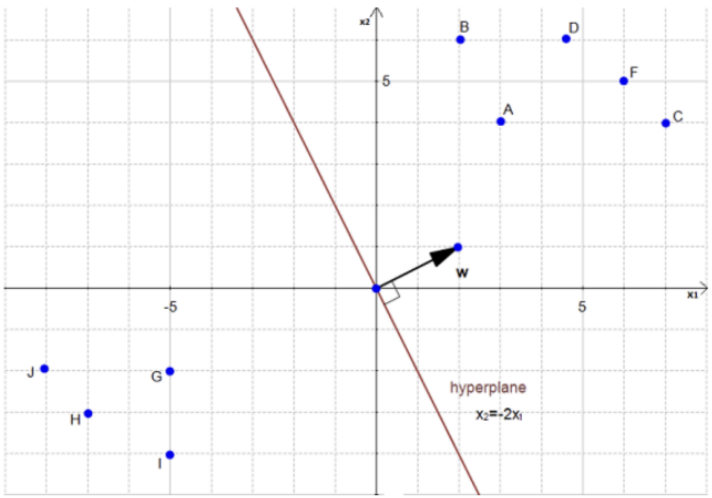
Rappel

La distance entre un point (x_0, y_0) et une droite (ou hyperplan) d'équation :

$$ax + by + c = 0$$

se calcule par :

$$d = \frac{|ax_0 + by_0 + c|}{\sqrt{a^2 + b^2}}.$$



Exemple : droite $y = -2x$

On réécrit : $2x + y = 0 \Rightarrow a = 2, b = 1, c = 0$.
Pour le point $A(3, 4)$:

$$d = \frac{|2(3) + 1(4) + 0|}{\sqrt{2^2 + 1^2}} = \frac{10}{\sqrt{5}} = 2\sqrt{5}.$$

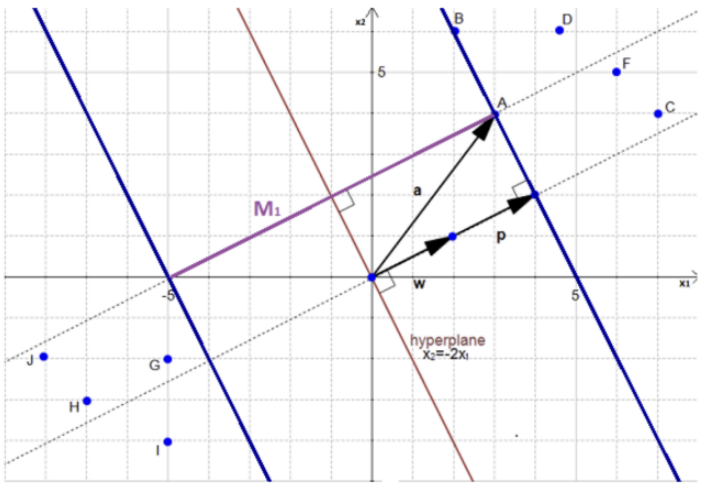
Notion de marge

Principe

La **marge** correspond au **double de la distance d** :

$$\text{marge} = 2 \times d.$$

Elle représente une zone neutre (no man's land) aucun point d'apprentissage ne doit se trouver à l'intérieur.



Exemple

Si $d = 2\sqrt{5}$, alors :

$$\text{marge} = 2 \times 2\sqrt{5} = 4\sqrt{5}.$$

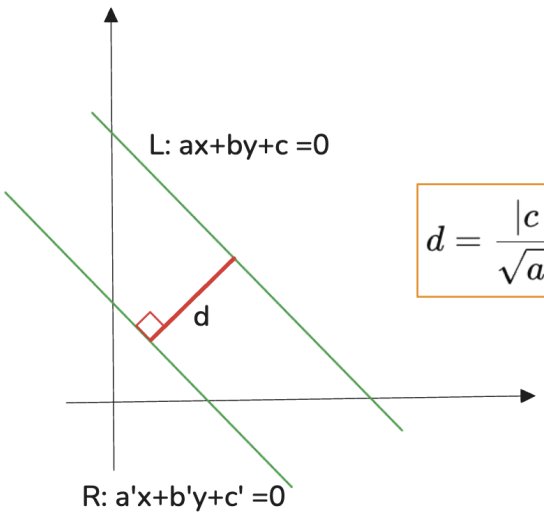
⚠ *Mais cette marge n'est pas forcément optimale : l'hyperplan optimal est celui qui* ***maximise la marge*** *sur l'ensemble des données.*

Marge maximale dans les SVM

Objectif

Trouver l'**hyperplan optimal** qui maximise la marge entre les deux classes :

$$H_1 : w \cdot x + b = 1 \quad \text{et} \quad H_2 : w \cdot x + b = -1.$$



$$d = \frac{|c - c'|}{\sqrt{a^2 + b^2}}$$

Rappel : Distance entre deux droites parallèles

$$m = \frac{2}{\|w\|}$$

Maximiser la marge $\Longleftrightarrow$ **minimiser** $\|w\|$.

Formulation du problème

Pour des données séparables

On veut trouver w et b tels que :

$$y_i(w \cdot x_i + b) \geq 1 \quad \forall i$$

et maximiser la marge $\frac{2}{\|w\|}$.

Problème d'optimisation équivalent

$$\min_{w,b} \frac{1}{2}\|w\|^2 \quad \text{sous les contraintes} \quad y_i(w \cdot x_i + b) \geq 1.$$

$\rightarrow$ *Problème quadratique convexe, à solution unique.*

Cas non parfaitement séparables

Données bruitées ou non linéaires

On introduit des variables de relâchement $\xi_i \geq 0$:

$$y_i(w \cdot x_i + b) \geq 1 - \xi_i.$$

Elles mesurent combien chaque point viole la marge.

Problème régularisé (SVM souple)

$$\min_{w,b,\xi} \frac{1}{2}\|w\|^2 + C\sum_{i=1}^{n} \xi_i \quad \text{sous contraintes} \quad y_i(w \cdot x_i + b) \geq 1 - \xi_i,\ \xi_i \geq 0.$$

→ L' hyperparamètre C contrôle le compromis entre marge et erreurs.

Vecteurs de support et solution duale

Principe du Lagrangien

On introduit des multiplicateurs de Lagrange $\alpha_i \geq 0$ et on résout :

$$L(w, b, \alpha) = \frac{1}{2}\|w\|^2 - \sum_i \alpha_i [y_i(w \cdot x_i + b) - 1].$$

Problème dual

$$\max_{\alpha} \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j (x_i \cdot x_j)$$

sous $\alpha_i \geq 0$ et $\sum_i \alpha_i y_i = 0$.

Seuls les points avec $\alpha_i > 0$ interviennent dans la solution :

$$w = \sum_i \alpha_i y_i x_i.$$

$\rightarrow$ *Ce sont les vecteurs de support.*

Hard margin vs. Soft Margin

- L'hyperplan du SVM est déterminé uniquement par les **vecteurs de support**.
- Maximiser la marge revient à **minimiser la complexité du modèle**.
- Le paramètre C règle le compromis :
  - grand $C \rightarrow$ peu d'erreurs, marge étroite ;
  - petit $C \rightarrow$ plus d'erreurs tolérées, marge large.

$\rightarrow$ *En pratique, on distingue :*

Hard margin SVM

$$\min_{w,b} \ \frac{1}{2}\|w\|^2$$

sous contraintes :

$$y_i(w \cdot x_i + b) \geq 1, \quad \forall i.$$

Soft margin SVM

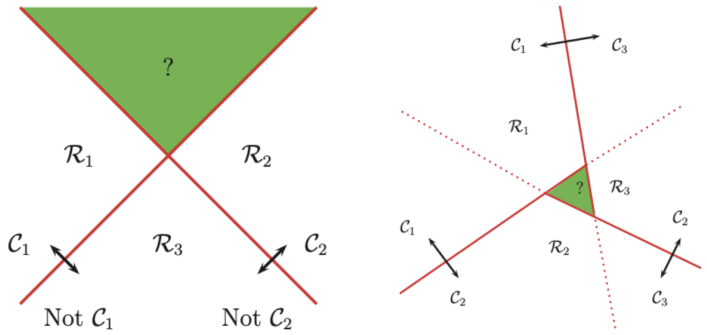
$$\min_{w,b,\xi} \ \frac{1}{2}\|w\|^2 + C\sum_{i=1}^{m} \xi_i$$

sous contraintes :

$$y_i(w \cdot x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0, \ \forall i.$$

Et si on a plusieurs classes ?

SVMs pour la discrimination multi-class



Stratégies classiques

- **One vs Rest (OvR)** :
  Pour chaque classe k, on entraîne un SVM qui sépare « classe k » vs « toutes les autres ».
  $\Rightarrow$ On obtient K SVM. La prédiction correspond au score le plus élevé.
- **One vs One (OvO)** :
  On entraîne un SVM pour chaque paire de classes (k, l).
  $\Rightarrow$ On obtient $\frac{K(K-1)}{2}$ modèles. La classe prédite est celle qui gagne le plus de duels (vote majoritaire).

Modèles linéaires non supervisés