APPRENTISSAGE STATISTIQUE · 2026–2027

Fondements de l’apprentissage statistique

Oumoukelthoum Sidenna

2e année du cycle ingénieur · 90 min · Notes de cours complètes

Plan du chapitre

1. Introduction générale · 10 min
2. Régression vs Discrimination · 12 min
3. Fonction de perte · 15 min
4. Risque · 15 min
5. Décomposition de l’erreur et compromis biais–variance · 18 min
6. Estimation du risque · 15 min
7. Catégorisation · 5 min

DIAPO 01 · NOTION

Vue d'ensemble du cours

Chapitre	Contenu
1	Fondements de l'apprentissage statistique
2	Algorithmes linéaires
3	Algorithmes non linéaires
4	Agrégation
5	Cycle ML & Métriques d'évaluation

DIAPO 02 · NOTION

Plan du cours

1. **Introduction générale :** contexte, vocabulaire.
2. **Cadre mathématique de l'apprentissage statistique supervisé :** perte, risque, biais–variance, estimation du risque.
3. **Catégorisation :** organiser les méthodes.

DIAPO 03 · NOTION

Contexte

L'**apprentissage statistique** (*statistical learning*) : estimer des dépendances, modéliser et comprendre des données complexes.

> « … explores way of estimating functional dependency from a given collection of data » — Vapnik, 2000.
>
> « … a set of tools for modelling and understanding complex datasets » — James et al., 2013.

DIAPO 04 · NOTION

Deux approches

- Un **modèle interprétable** : complexité maîtrisée.
- Une **bonne précision prédictive** : modèle plus complexe si besoin.

Approches complémentaires : importance des variables pour interpréter ; biais, variance, convergence pour étudier un prédicteur.

▼ Précision

Bien expliquer ne garantit pas de bien prédire de nouvelles données : évaluer les deux séparément.

Chapitre 01 · Introduction générale

DIAPO 05 · NOTION

Apprentissage statistique et machine learning

Apprentissage Statistique vs Machine Learning

- Le **machine learning** (issu de l'IA) : grande échelle, précision prédictive.
- L'**apprentissage statistique** (issu de la statistique) : modèles, interprétabilité, précision.

Mêmes problèmes ; la frontière est devenue floue.

Chapitre 01 · Introduction générale

DIAPO 06 · NOTION

Problématiques associées à l'apprentissage

Type	Problématique	Objectif
Supervisé	Régression	Prédire une sortie numérique à partir d'entrées.
Supervisé	Discrimination	Prédire une classe à partir d'entrées.
Non supervisé	Typologie (clustering)	Regrouper des observations semblables.
Non supervisé	Règles d'association	Relier produits ou événements.
Les deux	Systèmes de recommandation	Prédire une note (supervisé) ou suggérer des produits souvent associés (non supervisé).

DIAPO 07 · FORMULE

Notations et significations

Notation	Signification
$\mathcal{X}$	Espace des entrées (features).
$\mathcal{Y}$	Espace des sorties (étiquettes).
$X,\ Y$	Variables aléatoires à valeurs dans $\mathcal{X}$ et $\mathcal{Y}$.
(X, Y)	Couple aléatoire : un individu.
D_n	Échantillon d'apprentissage de n couples.
(x_i, y_i)	Réalisation du couple (X_i, Y_i).
f	Prévision candidate ; $\hat{f}$: apprise sur les données.
$y_i,\ \hat{y}_i$	Sortie observée, sortie prédite $\hat{y}_i = \hat{f}(x_i)$.
$g(x)$	Score d'un classifieur, converti en classe $\hat{y}$.
ℓ	Perte : coût d'une erreur.
$\mathcal{R}(f)$	Risque : perte moyenne sur la population.

$$
\begin{gathered}
X \in \mathcal{X}, \qquad Y \in \mathcal{Y}, \\
D_n = \{(X_1, Y_1), \ldots, (X_n, Y_n)\}, \\
f : \mathcal{X} \longrightarrow \mathcal{Y}, \\
\mathcal{R}(f) = \mathbb{E}[\ell(Y, f(X))].
\end{gathered}
$$

Lire la formule –
Majuscules : aléatoires ; minuscules : observées. Couples de D_n i.i.d.

DIAPO 08 · NOTION

Problème d'apprentissage supervisé

On observe des couples **entrée** x (p variables explicatives) et **sortie** y (la cible). But : prédire y pour une nouvelle entrée.

- **Régression** : y quantitative (prix, tension artérielle).
- **Discrimination** : y parmi des classes (survie/mort, chiffre de 0 à 9).

DIAPO 09 · NOTION

Apprentissage non supervisé

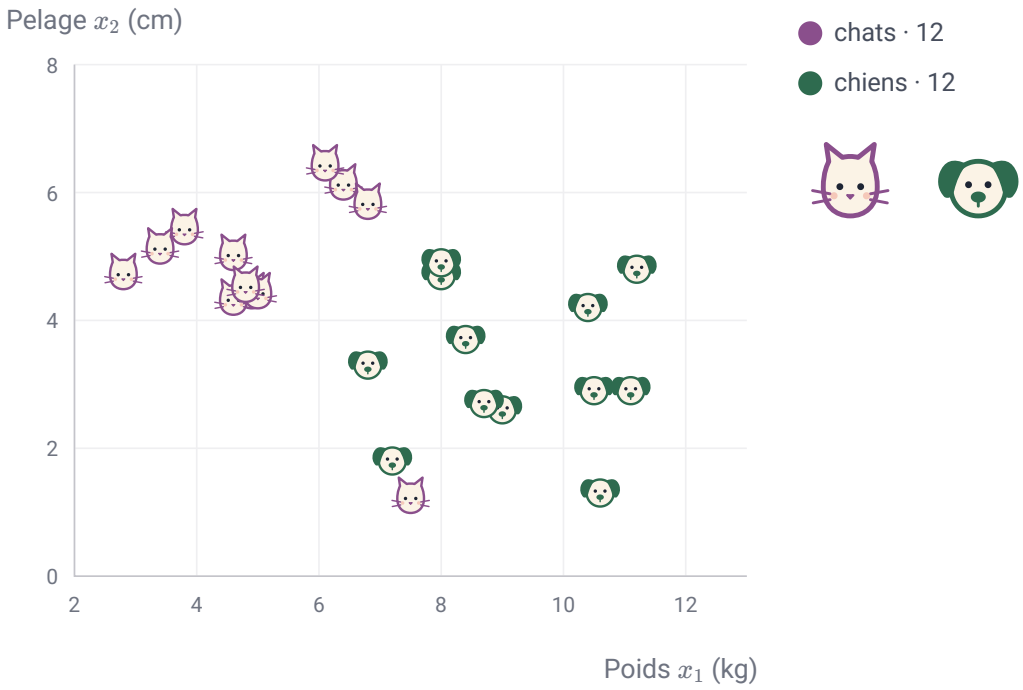
Seulement des entrées x, **sans sortie** : on explore.

- **Regrouper** les observations semblables (clustering).
- **Résumer** les variables redondantes (réduction de dimension).

Sans vérité terrain, l'évaluation est plus difficile.

NOUVEAU EXPÉRIENCE

Avec étiquettes



Apprentissage supervisé

Des couples (x_i, y_i) : on apprend à prédire y.

Chaque animal arrive avec son **étiquette** : chat ou chien.

On peut apprendre une règle qui prédit l'étiquette d'un nouvel animal : c'est l'**apprentissage supervisé**.

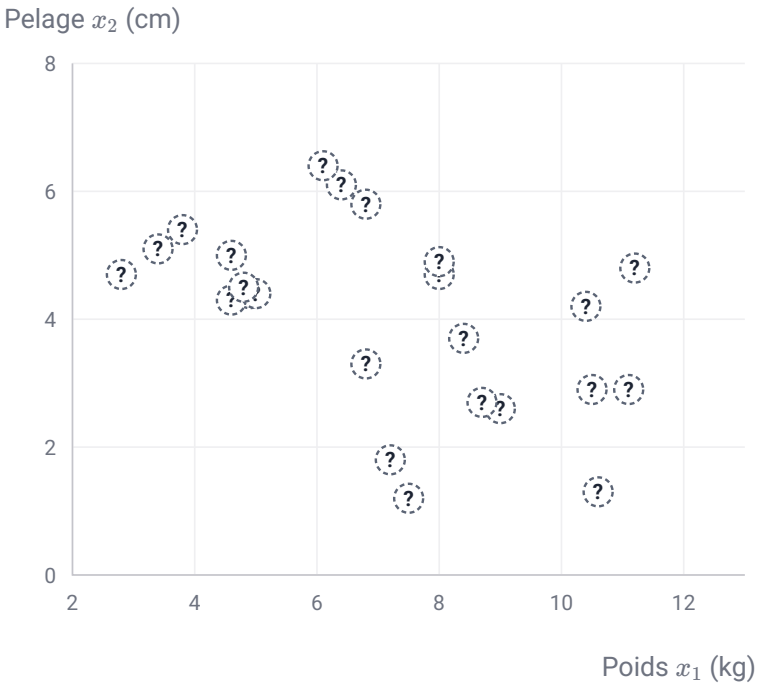
Détails · Entrée, sortie, exemple

Entrée $x_i = (x_{i1}, x_{i2})$: poids et pelage. Sortie y_i : l'espèce. Un exemple étiqueté est un couple (x_i, y_i).

Les 24 animaux d'apprentissage du fil rouge. Les groupes sont obtenus par la méthode des k-moyennes (deux groupes), présentée plus tard dans le cours.

NOUVEAU EXPÉRIENCE

Sans étiquettes



24 animaux, aucune étiquette : seulement des mesures.

Apprentissage non supervisé

Seulement des x_i : on cherche une structure.

Mêmes mesures, mais **sans étiquette**.

Il n'y a plus de « bonne réponse » à apprendre : on peut seulement chercher une structure, par exemple des groupes.

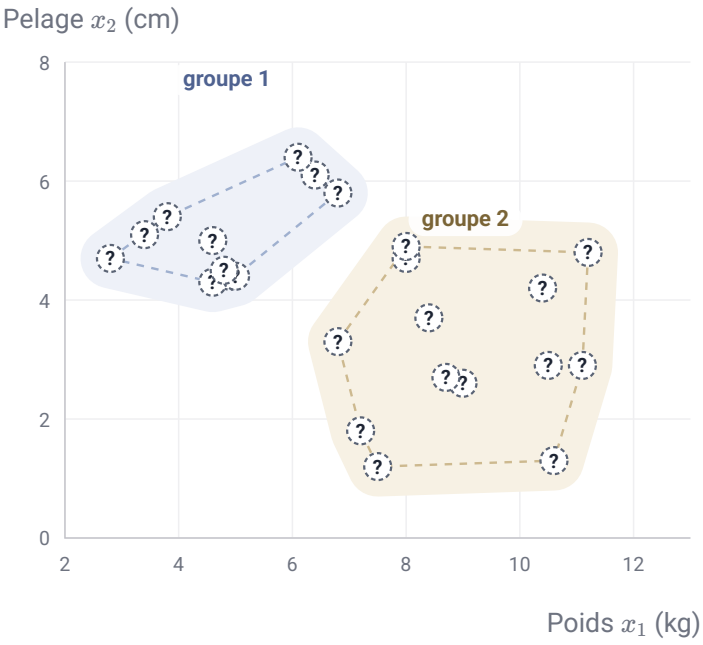
Détails · Apprentissage non supervisé

On dispose seulement des x_i. L'objectif est exploratoire : regrouper des observations semblables, réduire la dimension, repérer des anomalies.

Les 24 animaux d'apprentissage du fil rouge. Les groupes sont obtenus par la méthode des k-moyennes (deux groupes), présentée plus tard dans le cours.

NOUVEAU EXPÉRIENCE

Des groupes, sans noms



Groupe	Animaux
groupe 1	11
groupe 2	13

Les groupes n'ont pas de nom.

Deux groupes : 11 et 13 animaux

Trouvés à partir des mesures seules.

Un algorithme trouve **deux groupes** d'animaux qui se ressemblent.

Il ne sait pas ce qu'ils représentent : il n'a jamais vu d'étiquette.

À votre avis ?

L'algorithme a trouvé deux groupes. Peut-il dire lequel est celui des chats ?

- Oui : le groupe des plus légers
- ✓ **Non : il sait seulement que les animaux d'un groupe se ressemblent**
- Oui : le plus grand groupe

Sans étiquette, les groupes n'ont pas de nom. Les nommer demande une information extérieure : c'est toute la différence avec l'apprentissage supervisé.

Les 24 animaux d'apprentissage du fil rouge. Les groupes sont obtenus par la méthode des k-moyennes (deux groupes), présentée plus tard dans le cours.

DIAPO 10 · EXERCICE

Le prix Netflix

- Lancement : **octobre 2006**.
- Environ **100 millions de notes** (de **1 à 5**), **480 000 clients**, près de **18 000 films** ; matrice vide à près de **99 %**.
- À prédire : environ **3 millions de notes réservées**, moitié classement public, moitié **test final**.
- Réduire de **10 %** l'erreur de Netflix (**0,9525**) : **un million de dollars**.



À VOUS DE JOUER

Le prix Netflix · question du cours

S'agit-il d'un problème supervisé ou non supervisé ? Identifier les entrées, la sortie et les exemples observés.

▼ Solution commentée

Tâche **supervisée** : chaque note connue est une sortie observée pour un couple client–film. Entrées : client et film ; sortie : note numérique (régression). Les couples sans note ne la rendent pas non supervisée.

▼ Précision

Sources : Bennett et Lanning, Netflix, 2007 ; analyse statistique du concours.

films →

clients →

	1	5	5	5	?	4	1		5	2	
	5			2		1				5	
		1									?
	3						4	?			
	5										
	3							4			
?						?			4		
				2	2	5	?		5		

note connue (1 à 5) note à prédire

Matrice clients × films presque vide.



21 septembre 2009 : BellKor’s Pragmatic Chaos remporte le million. Photo : Netflix.

DIAPO 11 · FORMULE

Régression vs discrimination · données et objectifs

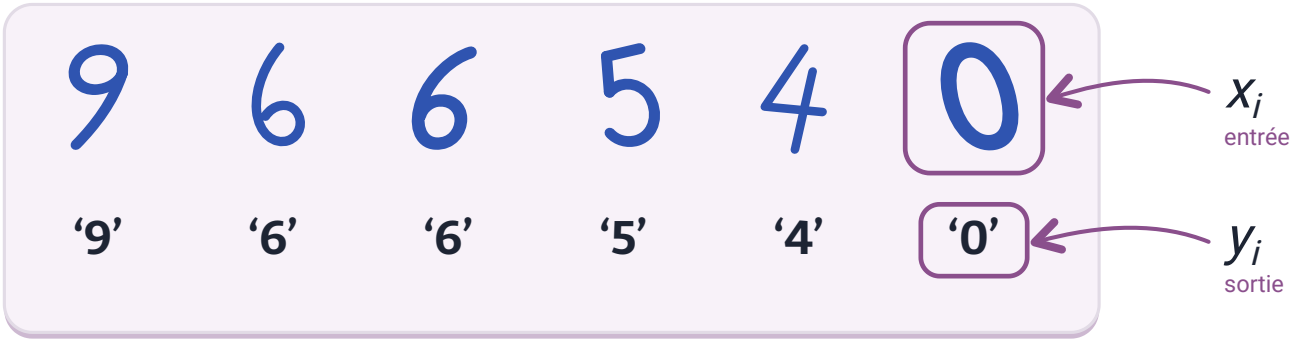
$$d_n = \{(x_1, y_1), \ldots, (x_n, y_n)\},$$
$$x_i \in \mathcal{X}, \qquad y_i \in \mathcal{Y}.$$

Lire la formule –
d_n : n exemples observés, chaque entrée x_i avec sa sortie y_i.

Objectifs

1. **Expliquer** le lien entrées–sorties.
2. **Prédire « au mieux »** la sortie d'une nouvelle entrée.

« Au mieux » : selon une fonction de perte.



Reconnaissance de caractères : image en entrée, chiffre en sortie.

DIAPO 12 · NOTION

Régression vs discrimination · vocabulaire

Vocabulaire

- Sortie **quantitative** : **régression**.
- Sortie qualitative (classes en nombre fini) : **discrimination** ou **classification supervisée**.

Entrées de toute nature ; c'est la **sortie** qui décide.

Sortie y_i	Entrée x_i	Problème
Chiffre	Image	Discrimination
Prix de voiture	Caractéristiques du véhicule	Régression

NOUVEAU NOTION

Fil rouge · chats et chiens

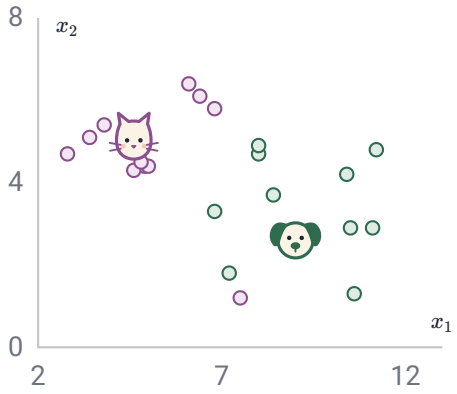
Un animal est décrit par deux mesures : son poids x_{i1} et la longueur de son pelage x_{i2}. Prédire l'**espèce** $y_i \in \{\text{chat}, \text{chien}\}$ est un problème de **discrimination**. Prédire le **poids** à partir du pelage serait une **régression**.

ANIMAL → MESURES → ÉTIQUETTE

→ $x = (4{,}6\,;\,5{,}0)$ → $y = 0$ · **chat**

→ $x = (9{,}0\,;\,2{,}6)$ → $y = 1$ · **chien**

Le dessin sert seulement à reconnaître l'animal à l'écran ; le modèle ne reçoit que les nombres x_1 et x_2.



Chaque animal devient un point du plan ; la couleur porte l'étiquette.

DIAPO 13 · FORMULE

Un début de formalisation mathématique

Données : réalisation d'un n-**échantillon**, en général i.i.d. de loi inconnue $\mathbb{P}$.

On compare les fonctions candidates avec une **fonction de perte**.

$$D_n = \{(X_i, Y_i) : i = 1, \dots, n\},$$
$$(X_i, Y_i) \overset{\text{i.i.d.}}{\sim} \mathbb{P},$$
$$f : \mathcal{X} \longrightarrow \mathcal{Y}, \qquad f(x_i) \approx y_i.$$

Lire la formule –

$\mathbb{P}$ est inconnue. Ajuster les exemples ne suffit pas : l'objectif est de généraliser.

DIAPO 14 · FORMULE

Fonction de prévision et paramètres

En outre…

Une prévision dépend de paramètres θ ; dans les **exemples affines ci-dessous**, $\theta = (w, b)$.

$$\hat{y} = \hat{f}(x), \qquad \hat{f} = f_\theta, \quad \theta = (w, b)$$

Lire la formule –
w : coefficients ; b : terme constant. SVM : $\hat{y} = +1$ si $g(x) = 0$.

Modèle	Fonction de prévision	Paramètres
Régression linéaire	$\hat{y} = w^\top x + b$	$\theta = (w, b)$
SVM binaire	$\hat{y} = \operatorname{sign}(g(x)), \quad g(x) = w^\top x + b$; score nul : $+1$.	$\theta = (w, b)$

DIAPO 15 · FORMULE

Fonction de perte

Définition

Une **fonction de perte** mesure le coût d'une prévision : mesurable, non négative, ici nulle si la prévision est exacte.

$$\ell : \mathcal{Y} \times \mathcal{Y} \longrightarrow \mathbb{R}^+,$$
$$\ell(y, y) = 0, \qquad \ell(y, \hat{y}) > 0 \text{ si } y \neq \hat{y}.$$

Lire la formule –
y observé, $\hat{y}$ prédit. La perte charnière, elle, compare l'étiquette au score $g(x)$.

▼ Précision
$\ell(y, y) = 0$: perte nulle pour une prévision exacte, pas pour toute paire.

$$\ell_p(y, \hat{y}) = \frac{1}{p}|y - \hat{y}|^p, \qquad p \geq 1$$

Lire la formule –
Régression : pertes L^p, facteur $1/p$ conservé ci-dessous.

Perte	Expression	Tâche
Perte absolue ($p = 1$)	$\lvert y - \hat{y}\rvert$	Régression
Perte quadratique ($p = 2$)	$\frac{1}{2}(y - \hat{y})^2$	Régression
Perte 0-1	$\mathbf{1}_{\{y \neq \hat{y}\}}$	Discrimination

$$\mathcal{Y} = \{-1, +1\}, \qquad \ell_{0\text{-}1}(y, \hat{y}) = \mathbf{1}_{\{y \neq \hat{y}\}}$$

Lire la formule –

Perte 0-1, en discrimination binaire : 0 si la classe est correcte, 1 sinon.

DIAPO 16 · FORMULE

Choix de la fonction de perte

Modèle	**Prévision à partir du score** $g(x) = w^\top x + b$	**Perte d'entraînement**	**Tâche**
Régression linéaire	$\hat{y} = g(x)$	$\frac{1}{2}\big(y - g(x)\big)^2$	Régression
Régression logistique (chapitre 2), $y \in \{0, 1\}$	$\hat{p} = \sigma(g(x)), \hat{y} = \mathbf{1}_{\{\hat{p} \geq t\}}$	$-y \log \hat{p} - (1 - y) \log(1 - \hat{p})$	Discrimination
SVM, $y \in \{-1, +1\}$	$\hat{y} = \operatorname{sign}(g(x))$	$\max(0,\, 1 - y\, g(x))$	Discrimination

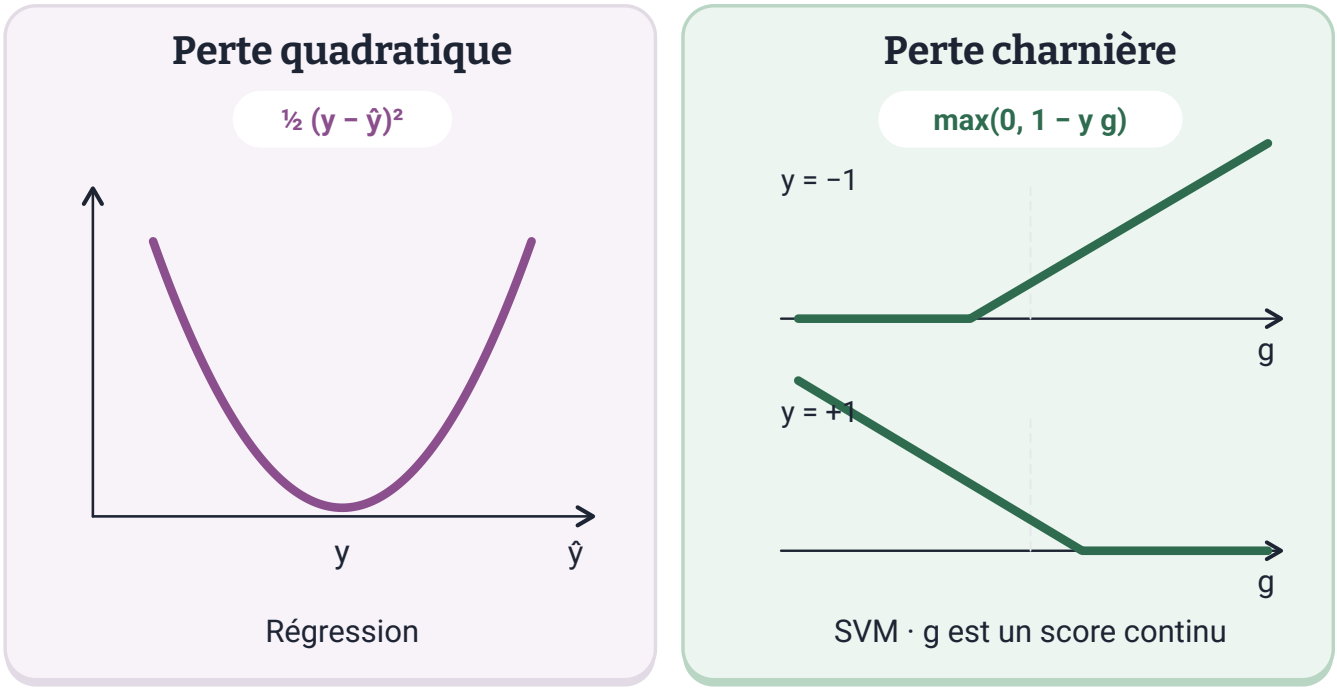
$$g(x) = w^\top x + b, \qquad \hat{y} = \operatorname{sign}(g(x)),$$
$$\ell_{\text{hinge}}(y, g(x)) = \max(0, 1 - y\, g(x)).$$

Lire la formule –

$g(x)$: score ; $\hat{y} \in \{-1, +1\}$: prédiction, $+1$ si le score est nul.

▼ Précision

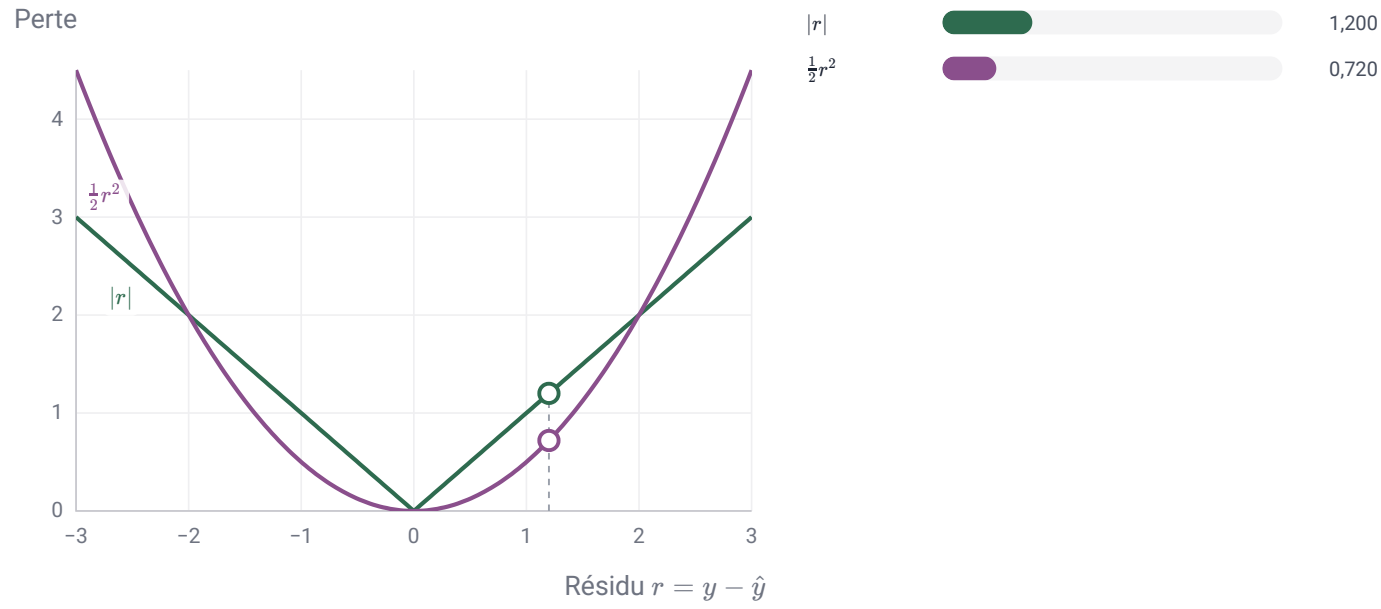
Chaque perte du tableau utilise le score $g(x)$; la prévision $\hat{y}$ en découle : identité, seuil sur la probabilité logistique ou signe.



Demi-perte quadratique en régression et perte charnière appliquée au score continu g du SVM.

NOUVEAU EXPÉRIENCE

Deux façons de compter l'erreur



$r = 1{,}2 : |r| = 1{,}20,\ \frac{1}{2}r^2 = 0{,}72$

Les deux pertes sont nulles seulement en $r = 0$.

L'erreur d'une prévision est le **résidu** $r = y - \hat{y}$.

La perte **absolue** compte $|r|$; la perte **quadratique** compte $\frac{1}{2}r^2$. Faites varier r.

Détails · Mêmes zéros, formes différentes

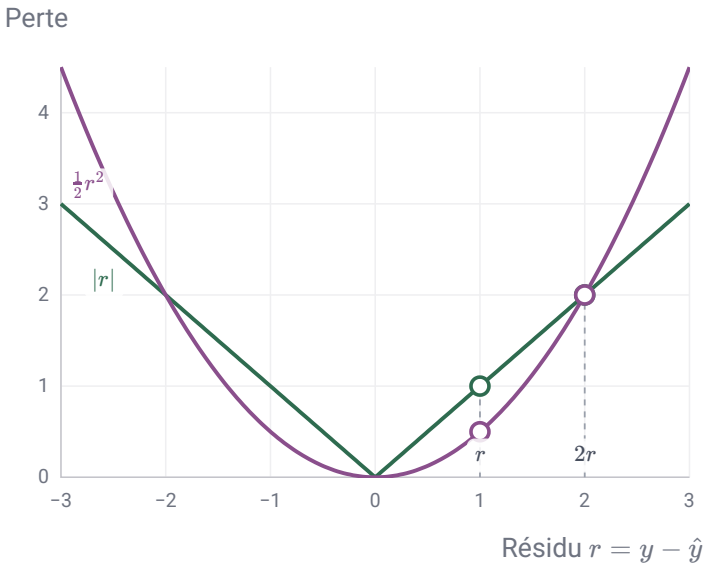
Les deux pertes sont nulles si et seulement si $\hat{y} = y$. La quadratique est plus douce près de 0, puis croît beaucoup plus vite.

Perte absolue $|y - \hat{y}|$ et perte quadratique $\frac{1}{2}(y - \hat{y})^2$, comme dans le tableau du cours ($p = 1$ et $p = 2$).

Chapitre 01 · Fonction de perte

NOUVEAU EXPÉRIENCE

Doubler l'erreur



	r	$2r$	rapport
absolue	1,00	2,00	× 2
quadratique	0,500	2,000	× 4

Erreur doublée : absolue × 2, quadratique × 4

$r = 1{,}0$ puis $2r = 2{,}0$.

Comparez une erreur r et une erreur deux fois plus grande, $2r$.

À votre avis ?

Si l'erreur double, la perte quadratique…

- double aussi
- ne change pas

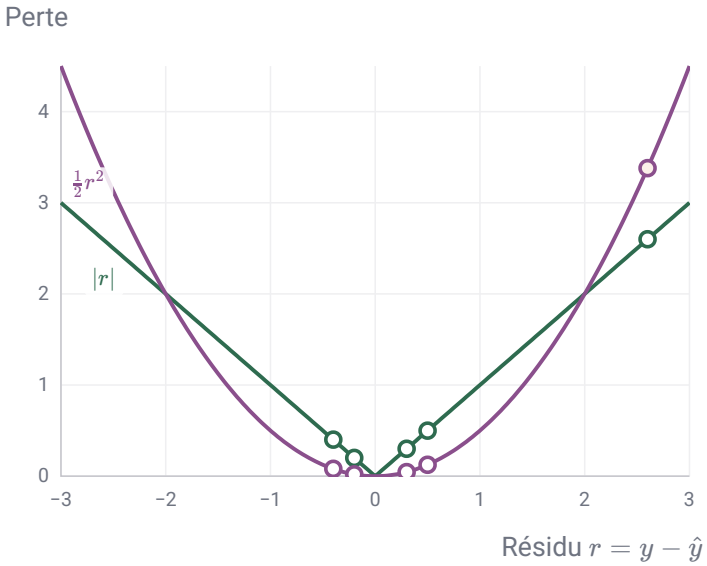
✓ **est multipliée par 4**

$\frac{1}{2}(2r)^2 = 4 \times \frac{1}{2}r^2$: les grosses erreurs pèsent beaucoup plus avec la perte quadratique.

Perte absolue $|y - \hat{y}|$ et perte quadratique $\frac{1}{2}(y - \hat{y})^2$, comme dans le tableau du cours ($p = 1$ et $p = 2$).

NOUVEAU EXPÉRIENCE

Une grosse erreur domine



r	$\lvert r\rvert$	$\frac{1}{2}r^2$
−0,4	0,40	0,08
0,3	0,30	0,05
0,5	0,50	0,13
−0,2	0,20	0,02
2,6	2,60	3,38
part de la grosse erreur	**65 %**	**93 %**

Une seule erreur : 93 % de la perte quadratique totale

contre 65 % de la perte absolue totale.

Cinq prévisions, dont une très mauvaise : $r = 2{,}6$.

Avec la perte quadratique, elle représente presque toute la perte totale.

Détails · Sensibilité aux valeurs extrêmes

Minimiser une perte quadratique moyenne tire le modèle vers les points extrêmes. La perte absolue y est moins sensible.

Perte absolue $|y - \hat{y}|$ et perte quadratique $\frac{1}{2}(y - \hat{y})^2$, comme dans le tableau du cours ($p = 1$ et $p = 2$).

DIAPO 17 · FORMULE

Risque

Le **comportement moyen** de la perte, pour une prévision fixée : son espérance sur la population.

$$\mathcal{R}(f) = \mathbb{E}\big[\ell(Y, f(X))\big]$$

Lire la formule –
Risque, ou erreur de généralisation. Couple futur (X, Y) : même loi $\mathbb{P}$, indépendant de l'échantillon.

DIAPO 18 · FORMULE

Fonction de prévision optimale

Aspect théorique : à perte donnée, la fonction de risque minimal, si elle existe, est optimale.

$$f^* \in \arg\min_f \mathcal{R}(f),$$
$$\mathcal{R}(f^*) \leq \mathcal{R}(f) \quad \text{pour toute } f.$$

Lire la formule –
Dépend de la perte et, souvent, de la loi inconnue $\mathbb{P}$: référence théorique.

Aspect pratique

Loi inconnue : l'optimum n'est en général pas calculable directement. On cherche, à partir des données, un estimateur de risque proche de l'oracle.

$$\hat{f} = \hat{f}(\cdot; D_n),$$
$$\mathcal{R}(\hat{f}) \approx \mathcal{R}(f^*).$$

Lire la formule –
$\hat{f}$: apprise sur D_n ; f^* : référence. Autre échantillon, autre $\hat{f}$.

DIAPO 19 · FORMULE

Intuition

À entrée fixée, plusieurs sorties possibles : laquelle prédire ? Sous perte quadratique, la **moyenne conditionnelle**.

$$m^*(x) = \mathbb{E}[Y \mid X = x]$$

Lire la formule –

Moyenne de Y sachant $X = x$: optimale sous perte quadratique, pas pour toute perte.

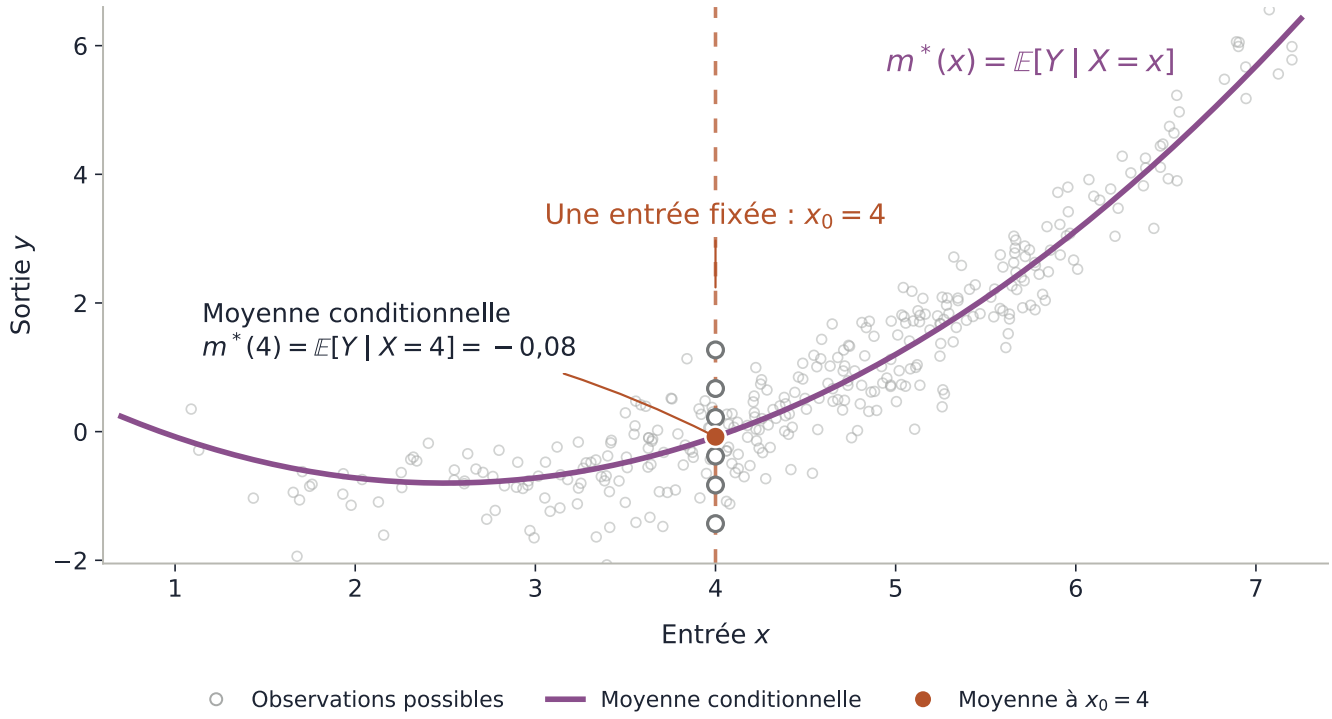


Illustration synthétique : la courbe est la vraie moyenne conditionnelle, pas une estimation.

Illustration synthétique redessinée : à $x_0 = 4$, plusieurs sorties sont possibles. La courbe mauve représente $m^*(x) = \mathbb{E}[Y \mid X = x]$, optimale sous perte quadratique.

Chapitre 01 · Risque

DIAPO 20 · FORMULE

Cas de la régression

$$\begin{aligned} \mathcal{Y} = \mathbb{R}, \qquad f : \mathcal{X} \longrightarrow \mathbb{R}, \\ \mathcal{R}(f) = \mathbb{E}[(Y - f(X))^2], \\ m^*(x) = \mathbb{E}[Y \mid X = x]. \end{aligned}$$

Lire la formule –

Sous perte quadratique, l'optimum f^* est m^*, en général inconnue. Moments d'ordre deux finis.

▼ Précision

Risque quadratique écrit **sans le facteur** $\frac{1}{2}$: une constante positive change le risque, pas son minimiseur.

À VOTRE AVIS ?

Question du cours

Comment écrire le risque en discrimination ? Utiliser la perte 0–1.

Réponse

Avec la perte 0–1 :

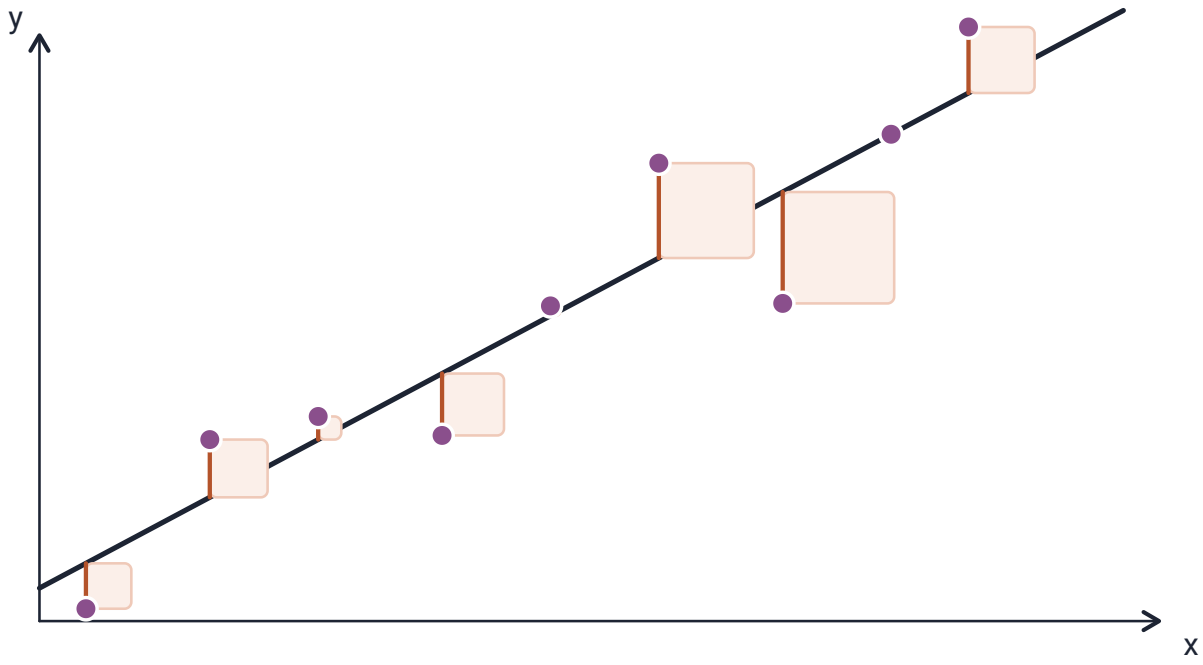
$$\mathcal{R}(f) = \mathbb{E}[\mathbf{1}_{\{f(X)\neq Y\}}] = \mathbb{P}(f(X) \neq Y).$$

Optimum : une classe de probabilité conditionnelle maximale :

$$f^*(x) \in \operatorname*{argmax}_{k\in\mathcal{Y}} \mathbb{P}(Y = k \mid X = x).$$

Égalité : convention de départage.

Résidus et coût quadratique

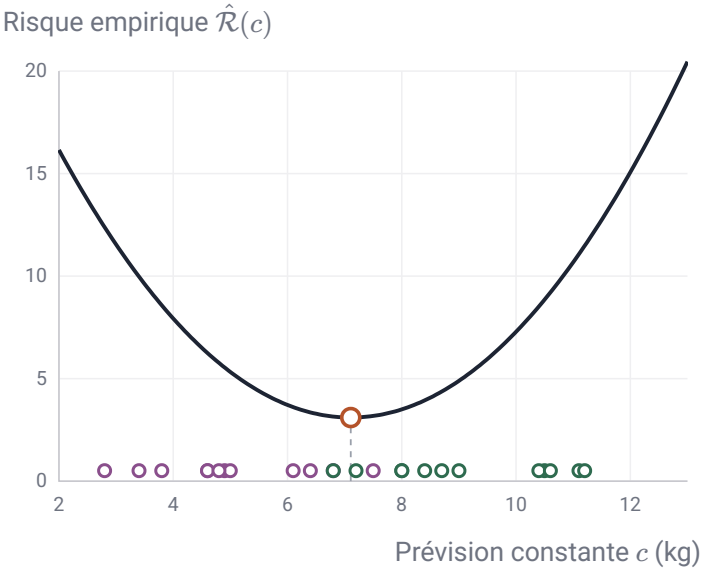


Chaque carré représente un résidu au carré.

Schéma illustratif redessiné : chaque carré représente le carré d'un résidu vertical.

NOUVEAU EXPÉRIENCE

Une seule prévision pour tous



c	7,1 kg
$\hat{\mathcal{R}}(c)$	3,10

$\hat{\mathcal{R}}(7{,}1) = 3{,}10$

Vous êtes au minimum.

On prévoit le **poids** d'un animal par une même constante c, sans rien savoir de lui.

Le risque empirique $\hat{\mathcal{R}}(c)$ est la perte quadratique moyenne. Cherchez son minimum.

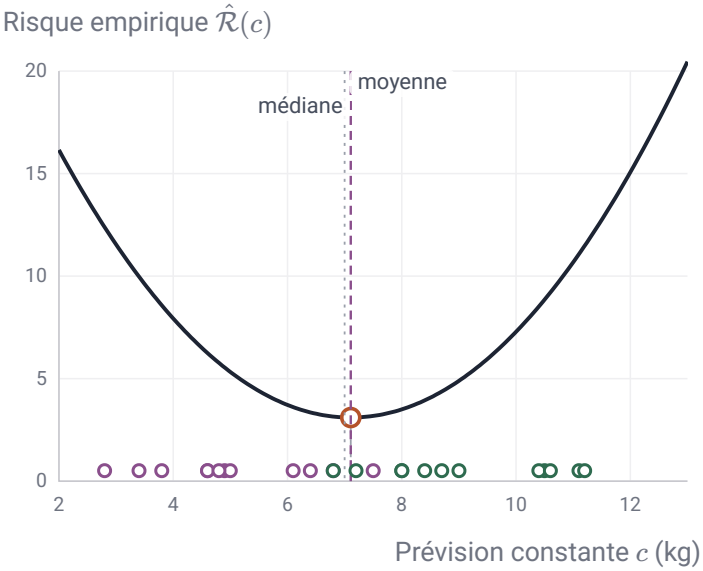
Détails · Risque et risque empirique

Le risque $\mathcal{R}(c) = \mathbb{E}\left[\frac{1}{2}(Y - c)^2\right]$ est inconnu ; on l'estime par la moyenne sur les données, $\hat{\mathcal{R}}(c) = \frac{1}{n}\sum_i \frac{1}{2}(y_i - c)^2$.

Poids des 24 animaux d'apprentissage. Perte quadratique $\frac{1}{2}(y - c)^2$, moyennée sur les animaux. Les petits ronds sous l'axe sont les poids observés.

NOUVEAU EXPÉRIENCE

Le minimum



c	7,1 kg
$\hat{\mathcal{R}}(c)$	3,10
moyenne $\bar{y}$	7,11 kg
médiane	7,00 kg
risque minimal	3,10

$\hat{\mathcal{R}}(7{,}1) = 3{,}10$

Vous êtes au minimum.

La courbe est une parabole. Son minimum est atteint en un point remarquable des poids.

À votre avis ?

Quelle constante c minimise la perte quadratique moyenne ?

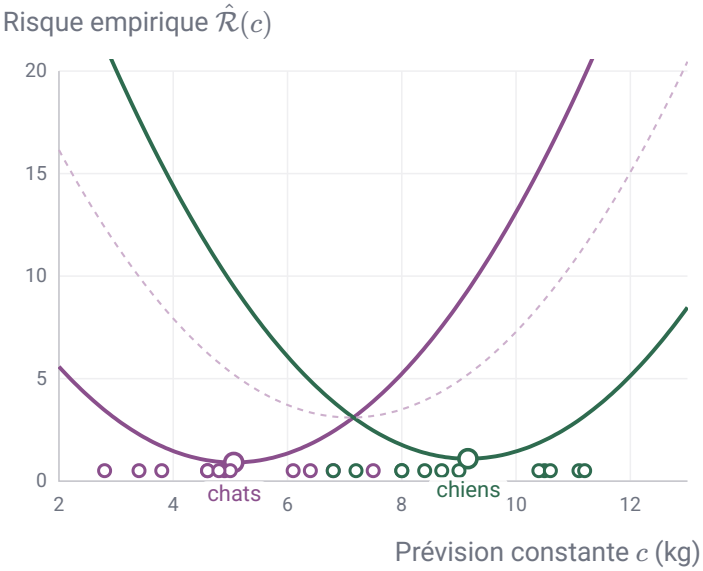
- la médiane des poids
- ✓ **la moyenne des poids**
- le poids le plus fréquent

$\hat{\mathcal{R}}'(c) = c - \bar{y}$ s'annule en $c = \bar{y}$: la moyenne des poids minimise la perte quadratique moyenne.

Poids des 24 animaux d'apprentissage. Perte quadratique $\frac{1}{2}(y - c)^2$, moyennée sur les animaux. Les petits ronds sous l'axe sont les poids observés.

NOUVEAU EXPÉRIENCE

Sachant l'espèce



	prévision	risque
sans l'espèce	7,11 kg	3,10
chat	5,06 kg	1,00
chien	9,16 kg	

Connaître l'espèce divise le risque minimal par 3,1.

$m^*(\text{chat}) = 5{,}06$, $m^*(\text{chien}) = 9{,}16$

La moyenne conditionnelle : la meilleure prévision quand on connaît x.

Si l'on connaît l'espèce x, on choisit une constante **par espèce**.

La meilleure est la **moyenne conditionnelle** $m^*(x) = \mathbb{E}[Y \mid X = x]$: la moyenne des chats pour un chat, celle des chiens pour un chien.

Détails · Le prédicteur optimal

Pour la perte quadratique, la fonction de prévision optimale est $m^*(x) = \mathbb{E}[Y \mid X = x]$. Connaître x réduit le risque minimal.

Poids des 24 animaux d'apprentissage. Perte quadratique $\frac{1}{2}(y - c)^2$, moyennée sur les animaux. Les petits ronds sous l'axe sont les poids observés.

DIAPO 21 · NOTION

Récapitulatif

Recap

Objet	Rôle
Données d_n	Observations i.i.d. de loi inconnue $\mathbb{P}$.
Prédicteur f	Transformer une entrée en prévision.
Coût $\ell(Y, f(X))$	Mesurer la perte sur un couple.
Risque $\mathcal{R}(f)$	Moyenner ce coût sur la population.
Oracle f*	Minimiser le risque ; dépend de $\mathbb{P}$.

DIAPO 22 · NOTION

Objectif d'apprentissage

Objectif

Objectif : un algorithme qui **généralise bien sur de nouvelles données**, de risque proche de l'optimum.

Facteurs : **choix du modèle et de sa complexité**, **quantité de données disponibles**, **compromis biais–variance**.

DIAPO 23 · FORMULE

Décomposition de l'erreur : biais, variance et bruit

À entrée fixée, l'erreur quadratique attendue se décompose en **biais au carré**, **variance** et **bruit**.

Hypothèses : bruit de variance constante, moments d'ordre deux finis, cible future indépendante de l'apprentissage.

$$m^*(x) = \mathbb{E}[Y \mid X = x],$$
$$Y = m^*(X) + \varepsilon, \qquad \mathbb{E}[\varepsilon \mid X] = 0.$$

Lire la formule –
Y : sortie aléatoire ; $m^*(x)$: moyenne théorique ; $\hat{f}(x)$: prédiction apprise.

$$\mathbb{E}\Big[(Y-\hat{f}(X))^2 \mid X=x\Big] = \underbrace{\Big(m^*(x)-\mathbb{E}[\hat{f}(x)]\Big)^2}_{\text{biais au carré}} + \underbrace{\mathbb{E}\Big[(\hat{f}(x)-\mathbb{E}[\hat{f}(x)])^2\Big]}_{\text{variance}} + \underbrace{\mathrm{Var}(\varepsilon)}_{\text{bruit}}.$$

Lire la formule –
Espérances en $\hat{f}$: sur les échantillons d'apprentissage possibles.

▼ Précision
Bruit dépendant de l'entrée : le terme vaut $\mathrm{Var}(Y \mid X=x)$; $\mathrm{Var}(\varepsilon)$ suppose une variance constante.

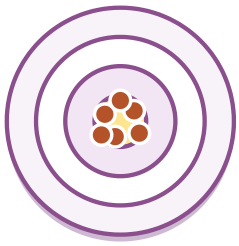
Chapitre 01 · Décomposition de l'erreur et compromis biais–variance

DIAPO 24 · NOTION

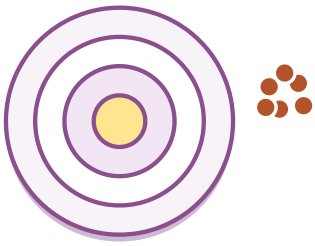
Compromis biais–variance

Compromis Bias-Variance · Biais

Le **biais** : écart entre prévision moyenne et vraie valeur. Un modèle trop restrictif peut le garder, même en répétant l'apprentissage.



Biais faible

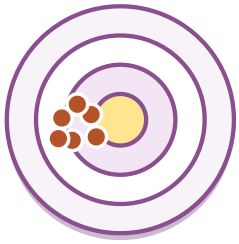


Biais élevé

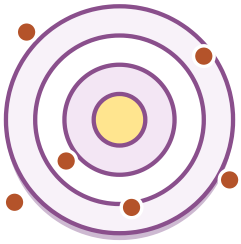
Biais : position moyenne des impacts par rapport au centre.

Compromis Bias-Variance · Variance

La **variance** : combien les prévisions changent quand l'échantillon d'apprentissage change.



Variance faible

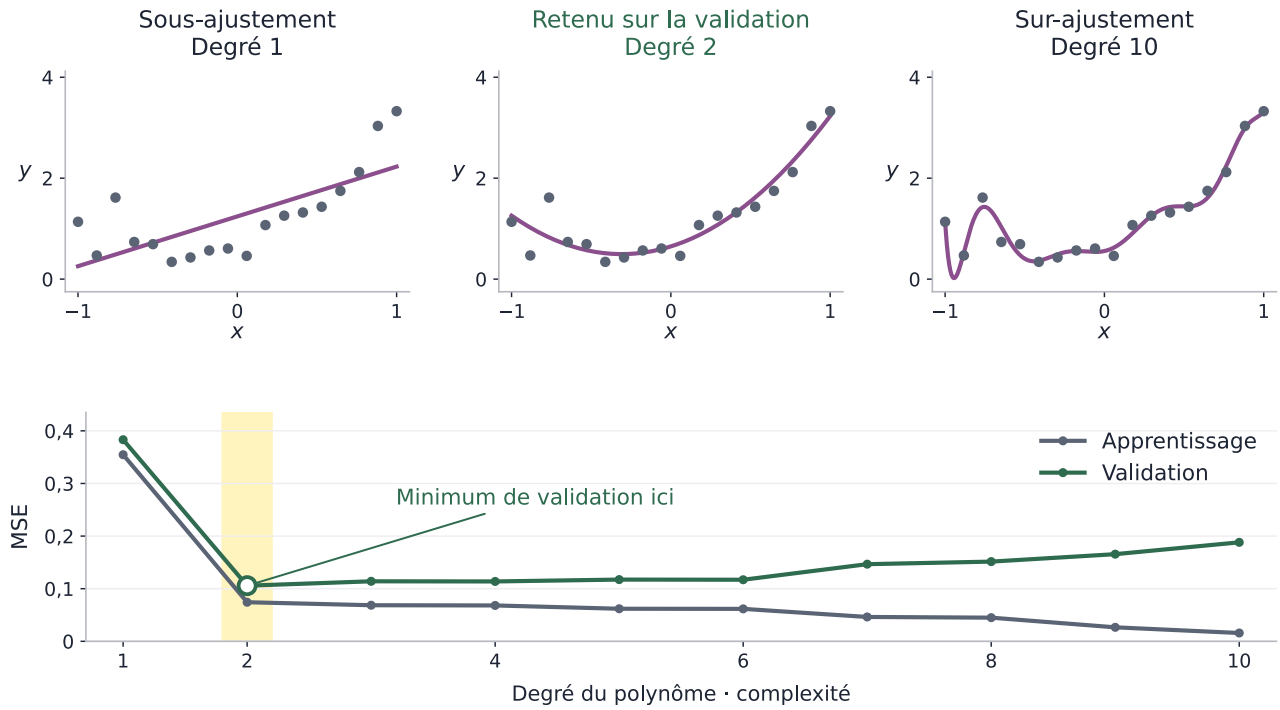


Variance élevée

Variance : dispersion des impacts, quel que soit le centrage.

DIAPO 25 · NOTION

Sous-ajustement et sur-ajustement



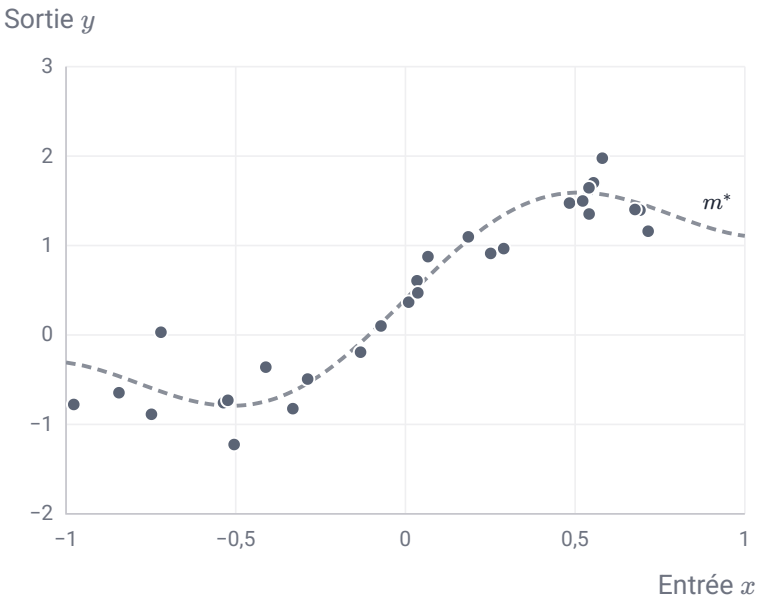
Mêmes 18 observations d’apprentissage dans les trois ajustements · 90 observations de validation

Exemple synthétique : ces courbes illustrent un cas, pas une règle de diagnostic universelle.

Exemple synthétique : trois polynômes appris sur les mêmes données. La validation retient ici le degré 2 ; une faible erreur d’apprentissage ne suffit pas.

NOUVEAU EXPÉRIENCE

Une relation, du bruit



MODÈLE DES DONNÉES

$$y = m^*(x) + \varepsilon$$

BRUIT

$$\sigma^2 = 0{,}078$$

Erreur quadratique attendue sur une nouvelle réponse : au moins σ^2.

Un échantillon de 28 points

Les pointillés représentent m^*, la relation moyenne réelle, inconnue en pratique.

Les 28 points suivent la relation moyenne réelle m^* (pointillés), avec du bruit. Un autre tirage donnerait d'autres points.

Cette relation est connue ici parce que les données sont simulées.

Détails · Le modèle des données

On simule $y = m^*(x) + \varepsilon$, avec $m^*(x) = 0{,}4 + 1{,}2x + 0{,}65\sin(4x)$. Le bruit est gaussien, centré, indépendant de x, et sa variance vaut $\sigma^2 = 0{,}28^2$.

Chaque échantillon contient 28 points. En pratique, la relation m^* et le bruit ne sont pas connus.

À votre avis ?

Avec un autre échantillon, obtiendrait-on le même modèle ?

- Oui : la relation m^* est la même

✓ **Non**

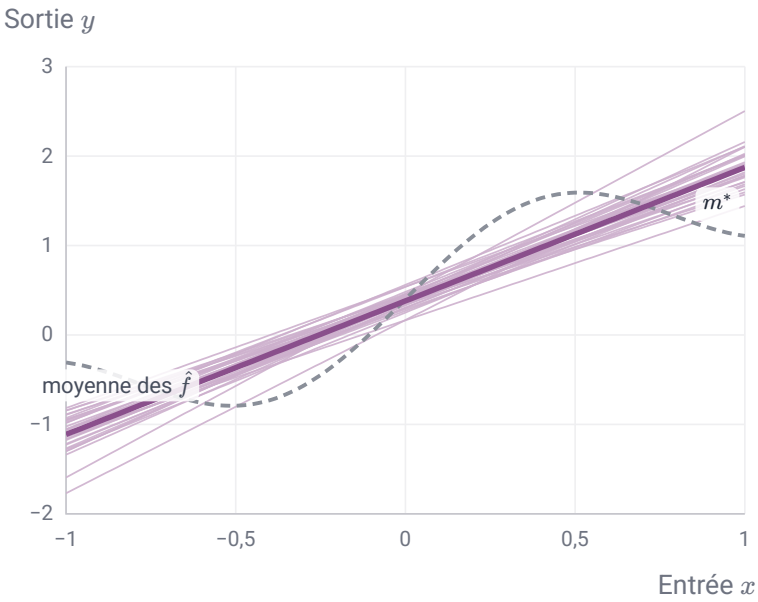
- Oui, si le modèle est assez souple

Non : le modèle appris dépend des points tirés. La variance mesure cette dépendance.

Mêmes données que l'expérience « Répéter l'apprentissage » : 30 échantillons indépendants de 28 points, $m^*(x) = 0{,}4 + 1{,}2x + 0{,}65\sin(4x)$, bruit gaussien d'écart type $0{,}28$. Variance calculée avec division par 30.

NOUVEAU EXPÉRIENCE

Un modèle simple, trente fois





En $x_0 = 0{,}25$, degré 1.

Degré 1 : $\text{biais}^2 = 0{,}243$**, variance** $0{,}011$

Au point $x_0 = 0{,}25$, sur 30 apprentissages.

Trente échantillons, trente droites apprises $\hat{f}$. Elles se ressemblent : **variance faible**.

Leur moyenne (trait épais) reste loin de m^* : **biais élevé**. Comparez le trait épais aux pointillés.

Détails · Pourquoi la droite reste biaisée

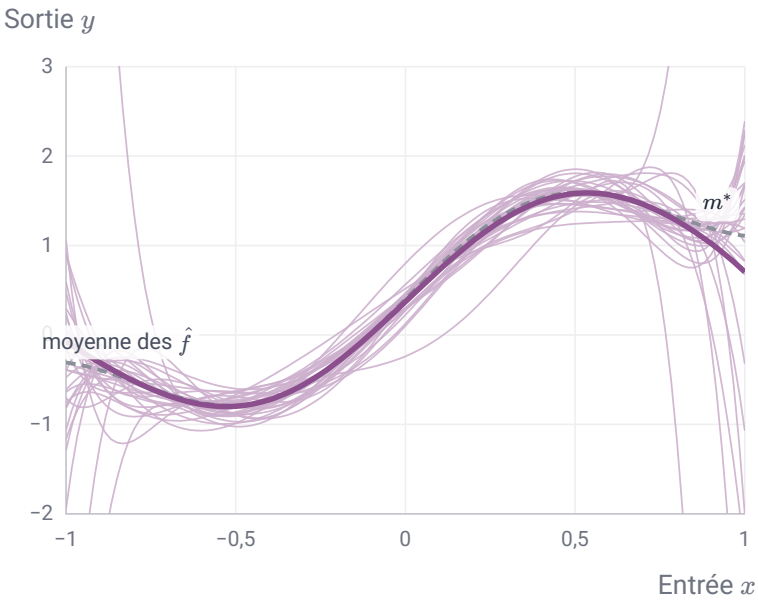
Le degré 1 ne peut pas représenter la relation non linéaire m^*. Davantage de données stabilisent la droite apprise, mais ne donnent pas à ce modèle la souplesse nécessaire pour reproduire m^*.

La moyenne et la dispersion affichées sont estimées sur 30 apprentissages.

Mêmes données que l'expérience « Répéter l'apprentissage » : 30 échantillons indépendants de 28 points, $m^*(x) = 0{,}4 + 1{,}2x + 0{,}65\sin(4x)$, bruit gaussien d'écart type $0{,}28$. Variance calculée avec division par 30.

NOUVEAU EXPÉRIENCE

Un modèle souple, trente fois



biais^2 0,003

variance 0,035

En $x_0 = 0{,}25$, degré 7.

Degré 7 : $\text{biais}^2 = 0{,}003$**, variance** $0{,}035$

Au point $x_0 = 0{,}25$, sur 30 apprentissages.

Au degré 7, la moyenne suit mieux m^* : le **biais baisse**.

Les trente courbes apprises $\hat{f}$ s'écartent davantage, surtout aux bords : la **variance augmente**. Comparez leur dispersion.

Détails · Lire la variance

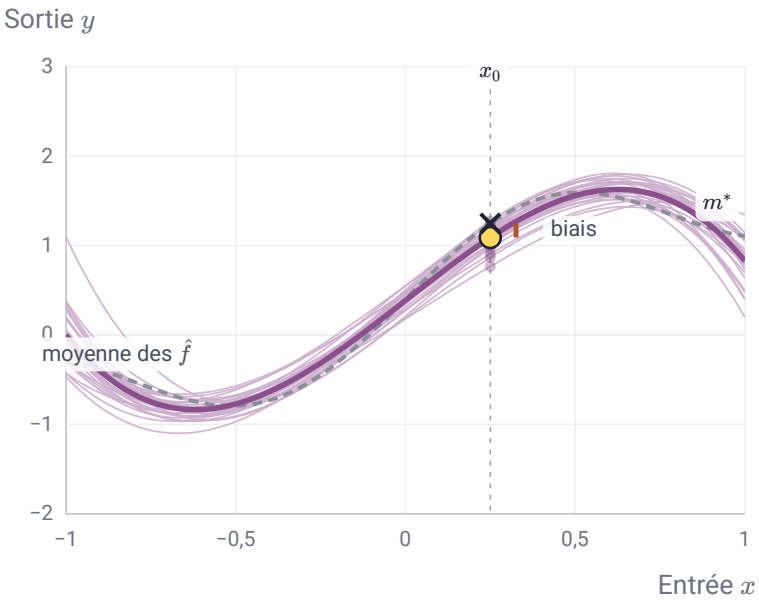
Chaque courbe $\hat{f}$ est apprise sur son propre échantillon. La variance mesure la dispersion des prévisions $\hat{f}(x)$ entre ces apprentissages, pour une même entrée x.

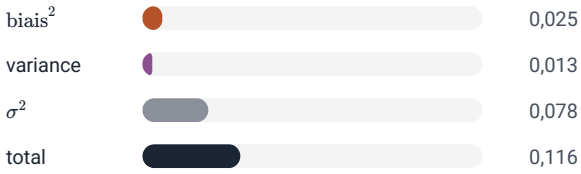
Une faible erreur d'apprentissage ne suffit pas à conclure que la variance est faible.

Mêmes données que l'expérience « Répéter l'apprentissage » : 30 échantillons indépendants de 28 points, $m^*(x) = 0{,}4 + 1{,}2x + 0{,}65\sin(4x)$, bruit gaussien d'écart type $0{,}28$. Variance calculée avec division par 30.

NOUVEAU EXPÉRIENCE

Décomposer l’erreur en un point





Le bruit σ^2 reste le même pour tous les degrés.

Degré 3 : $\text{biais}^2 = 0{,}025$**, variance** $0{,}013$

Au point $x_0 = 0{,}25$, sur 30 apprentissages.

En $x_0 = 0{,}25$, l’erreur attendue réunit **biais au carré, variance et bruit**.

Changez le degré et comparez les barres. Les valeurs affichées sont estimées avec trente modèles.

Détails · La décomposition et les valeurs

Pour une nouvelle sortie $Y = m^*(x_0) + \varepsilon$, indépendante de l’échantillon d’apprentissage, avec un bruit centré de variance σ^2 :

$$\mathbb{E}\big[(Y - \hat{f}(x_0))^2\big] = \text{biais}^2 + \text{variance} + \sigma^2.$$

Le biais compare $\mathbb{E}[\hat{f}(x_0)]$ à $m^*(x_0)$. La variance mesure la dispersion de $\hat{f}(x_0)$ entre les échantillons.

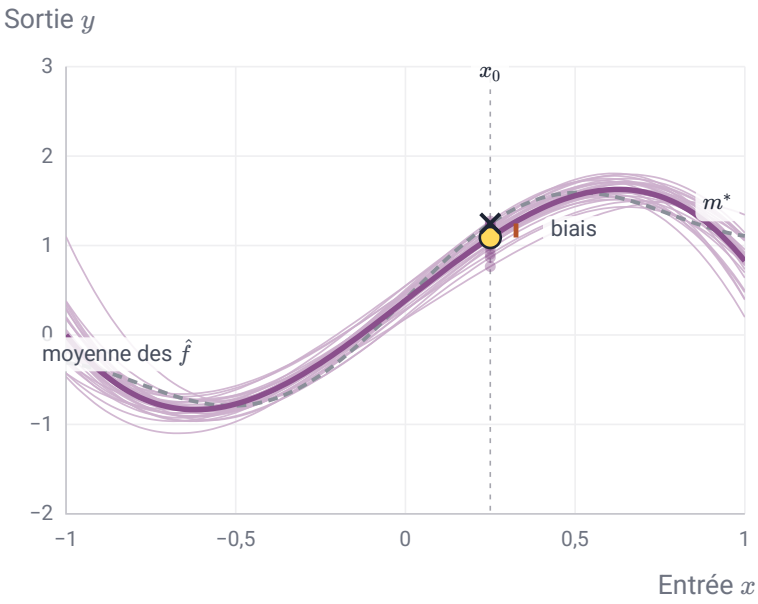
Degré 1 : $\text{biais}^2 = 0{,}243$, variance $0{,}011$. Degré 7 : $0{,}003$ et $0{,}035$. Le bruit reste $\sigma^2 = 0{,}28^2$.

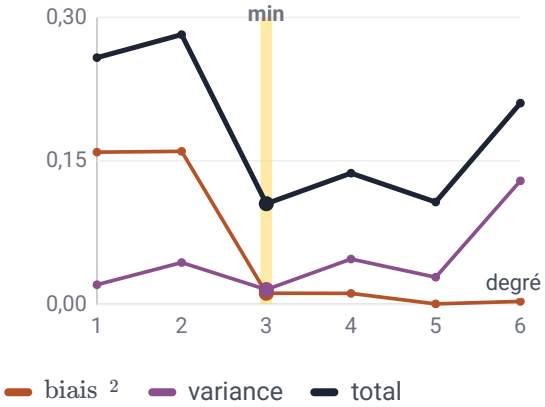
Ces estimations sur 30 modèles ne varient pas nécessairement de façon monotone avec le degré.

Mêmes données que l’expérience « Répéter l’apprentissage » : 30 échantillons indépendants de 28 points, $m^*(x) = 0{,}4 + 1{,}2x + 0{,}65\sin(4x)$, bruit gaussien d’écart type $0{,}28$. Variance calculée avec division par 30.

NOUVEAU EXPÉRIENCE

Le compromis





Moyennes sur $x \in [-0{,}95\,;\,0{,}95]$.

Défi réussi Le degré 3 donne la plus faible erreur moyenne.

Degré 3 : erreur moyenne $0{,}105$

biais^2 $0{,}011$ + variance $0{,}015$ + bruit $0{,}078$, moyennés sur x.

Changez le degré et cherchez la plus faible **erreur moyenne** : elle combine biais, variance et bruit.

Avec trente tirages, les courbes ne sont pas monotones.

Détails · Ce que moyenne le graphique

Pour chaque degré, on moyenne le biais au carré et la variance sur 39 positions $x \in [-0{,}95\,;\,0{,}95]$, puis on ajoute σ^2.

Un modèle plus souple peut réduire le biais tout en augmentant la variance. Le compromis dépend des données ; les estimations obtenues avec 30 tirages ne garantissent pas une baisse ou une hausse à chaque degré.

À votre avis ?

Comment choisir le degré sans connaître m^* ?

- Prendre la plus petite erreur d'apprentissage
- Prendre le plus grand degré possible

✓ **Mesurer l'erreur sur des données non utilisées pour apprendre**

En estimant l'erreur sur des données non utilisées pour apprendre : validation, ou validation croisée (partie suivante).

Mêmes données que l'expérience « Répéter l'apprentissage » : 30 échantillons indépendants de 28 points, $m^*(x) = 0{,}4 + 1{,}2x + 0{,}65\sin(4x)$, bruit gaussien d'écart type $0{,}28$. Variance calculée avec division par 30.

DIAPO 26 · FORMULE

Estimation du risque

Loi inconnue : on remplace l'espérance par une moyenne sur les observations, le **risque empirique**.

$$\mathcal{R}_n(\hat{f}) = \frac{1}{n}\sum_{i=1}^{n} \ell(y_i, \hat{f}(x_i))$$

Lire la formule –
Sur D_n, qui a servi à construire $\hat{f}$, l'erreur peut être trop optimiste.

> **Solution**
>
> Évaluer sur des observations non utilisées pour l'ajustement : principe de la validation simple et croisée.

DIAPO 27 · FORMULE

Validation ou hold-out

On sépare : **apprentissage** $\mathcal{A}$ pour ajuster, **validation** $\mathcal{V}$ pour comparer.

- Prétraitements appris sur l'apprentissage seulement.
- Données liées (sujet, date) : découper par groupe ou dans le temps.

$$\begin{aligned}
\mathcal{A} \cap \mathcal{V} &= \varnothing, \\
\mathcal{A} \cup \mathcal{V} &= \{1, \dots, n\}, \\
\mathcal{D}_{\text{app}} &= \{(x_i, y_i) : i \in \mathcal{A}\}, \\
\mathcal{D}_{\text{valid}} &= \{(x_i, y_i) : i \in \mathcal{V}\}.
\end{aligned}$$

Lire la formule –
Parties disjointes. Le test final reste réservé à l'évaluation.

Algorithme · Validation ou Hold-Out

1. **Ajuster le modèle et les prétraitements** sur l'apprentissage : $\hat{f}_{\text{app}} = \hat{f}(\cdot; \mathcal{D}_{\text{app}})$.
2. **Prédire** la validation, modèle et prétraitements fixés.
3. **Calculer** la perte moyenne.

$$\widehat{\mathcal{R}}_{\text{valid}} = \frac{1}{|\mathcal{V}|} \sum_{i \in \mathcal{V}} \ell\big(y_i, \hat{f}_{\text{app}}(x_i)\big).$$

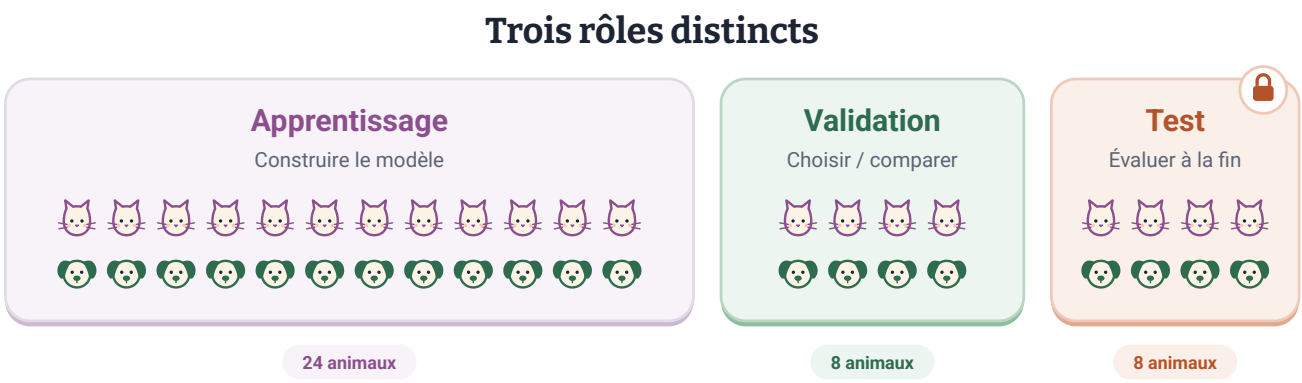
Lire la formule –
Prévisions faites sans les réponses de validation. Précision liée à la taille de la validation.

Chapitre 01 · Estimation du risque

DIAPO 28 · NOTION

Illustration de la séparation des données

Illustration



Apprentissage : ajuster ; validation : choisir ; test final : évaluer.

> **Commentaires**
>
> Assez de données pour ajuster, assez pour estimer l'erreur, sur un même total.

Chapitre 01 · Estimation du risque

DIAPO 29 · FORMULE

Validation croisée K-blocs

À chaque pli : apprendre sans un bloc, mesurer la perte sur ce bloc. Moyenner les K pertes.

Réapprendre aussi les prétraitements dans chaque pli, sinon fuite d'information.

$$\{B_1, \dots, B_K\} \text{ partitionne } \{1, \dots, n\},$$
$$\mathcal{B}_k = \{(x_i, y_i) : i \notin B_k\},$$
$$\hat{f}^{(-k)} = \hat{f}(\cdot; \mathcal{B}_k).$$

Lire la formule –
$\hat{f}^{(-k)}$: appris sans B_k (exposant $(-k)$), évalué sur B_k.

$$\widehat{\mathcal{R}}_k = \frac{1}{|B_k|} \sum_{i \in B_k} \ell(y_i, \hat{f}^{(-k)}(x_i)),$$

$$\widehat{\mathcal{R}}_{\mathrm{CV}} = \frac{1}{K} \sum_{k=1}^{K} \widehat{\mathcal{R}}_k.$$

Lire la formule –
Même poids par bloc. Blocs de même taille : moyenne des pertes de toutes les observations, chacune prédite hors apprentissage.

Chapitre 01 · Estimation du risque

DIAPO 30 · NOTION

Illustration et choix de K

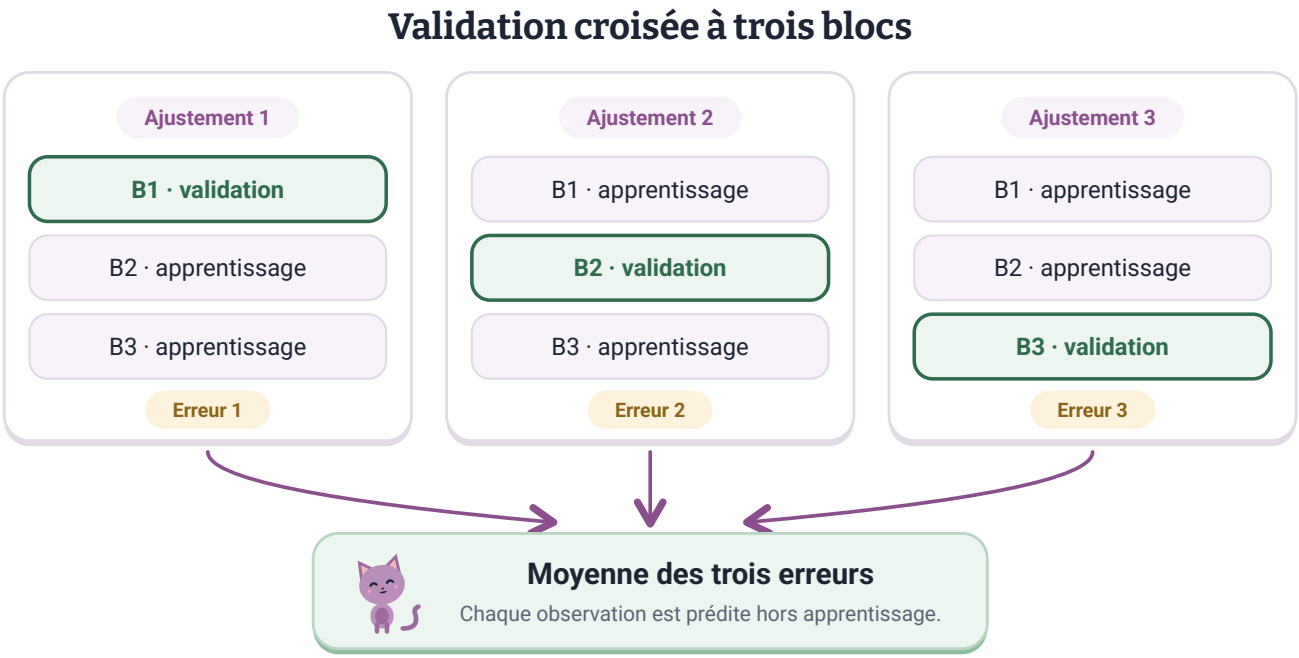
Commentaires

- K au choix, par exemple $K = 10$.
- Ne dépend pas d'une seule séparation.
- Plus de **temps de calcul** : un ajustement par bloc.

▼ Précision

Pas toujours plus stable ni plus précise qu'une séparation simple : cela dépend de K, des données, de l'algorithme.

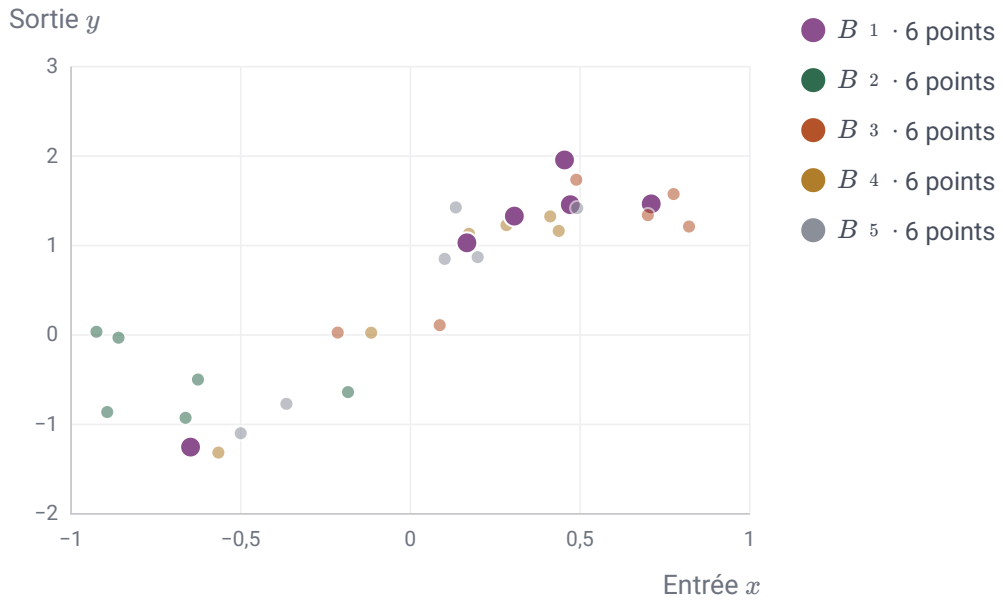
Si elle sert à choisir, son score ne remplace pas un test final réservé.



Apprendre sans B_1, puis sans B_2, puis sans B_3 ; agréger les pertes.

NOUVEAU EXPÉRIENCE

Découper en cinq blocs



$K = 5$ blocs de 6 observations

Chaque observation appartient à un seul bloc.

Les 30 points forment **cinq blocs de six**, repérés par leur couleur.

Le découpage reste fixe. Chaque bloc servira une fois à valider.

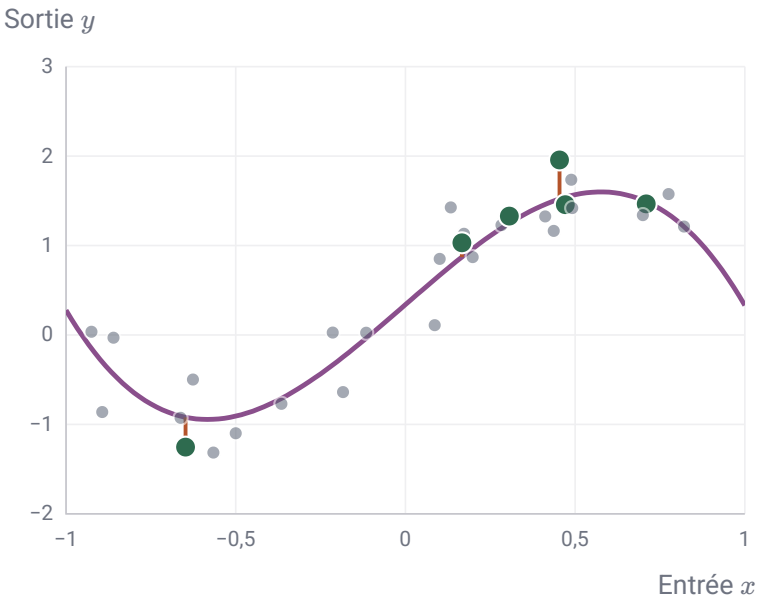
Détails · Les blocs de validation

On note les blocs $B_1, \ldots, B_5$, avec $K = 5$. Ils sont disjoints et réunissent les 30 observations. Leur composition est fixée avant l'apprentissage.

Mêmes 30 observations que l'expérience « Parcourir les blocs » ; blocs fixés avant tout apprentissage (6 observations chacun). Perte : erreur quadratique moyenne (MSE).

NOUVEAU EXPÉRIENCE

Apprendre sans B 1, valider sur B 1





MSE de validation par pli, degré 3.

Pli 1 : MSE de validation $0{,}057$

Modèle de degré 3 appris sur 24 points, évalué sur les 6 points de B_1.

Le modèle apprend sur **24 points**, sans B_1. Il est évalué sur les **six points de** B_1.

Les segments brique montrent leurs erreurs de prévision.

Détails · Calculer l'erreur du premier pli

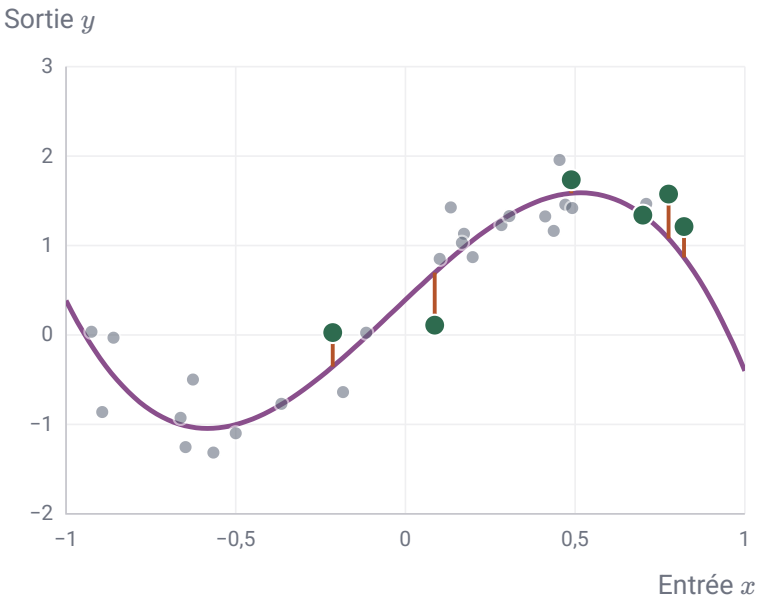
Le modèle $\hat{f}^{(-1)}$ est appris sans B_1, sur $B_2, \ldots, B_5$. Les résidus $y_i - \hat{f}^{(-1)}(x_i)$ du bloc B_1 donnent sa MSE de validation :

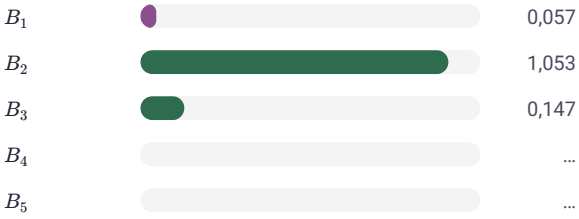
$$\widehat{\mathcal{R}}_1 = \frac{1}{6} \sum_{i \in B_1} (y_i - \hat{f}^{(-1)}(x_i))^2.$$

Mêmes 30 observations que l'expérience « Parcourir les blocs » ; blocs fixés avant tout apprentissage (6 observations chacun). Perte : erreur quadratique moyenne (MSE).

NOUVEAU EXPÉRIENCE

Chaque bloc à son tour





MSE de validation par pli, degré 3.

Pli 3 : MSE de validation $0{,}147$

Modèle de degré 3 appris sur 24 points, évalué sur les 6 points de B_3.

Choisissez un autre bloc : il devient la validation, les quatre autres servent à apprendre.

Le modèle est **réappris à chaque pli** : cinq modèles, cinq erreurs.

Détails · Pourquoi réapprendre cinq fois

Au pli k, on apprend sans B_k, puis on évalue sur B_k. Les points d'apprentissage et de validation changent : les cinq erreurs peuvent donc différer.



À votre avis ?

Pourquoi les cinq erreurs diffèrent-elles ?

✓ **Chaque pli apprend et valide sur des points différents**

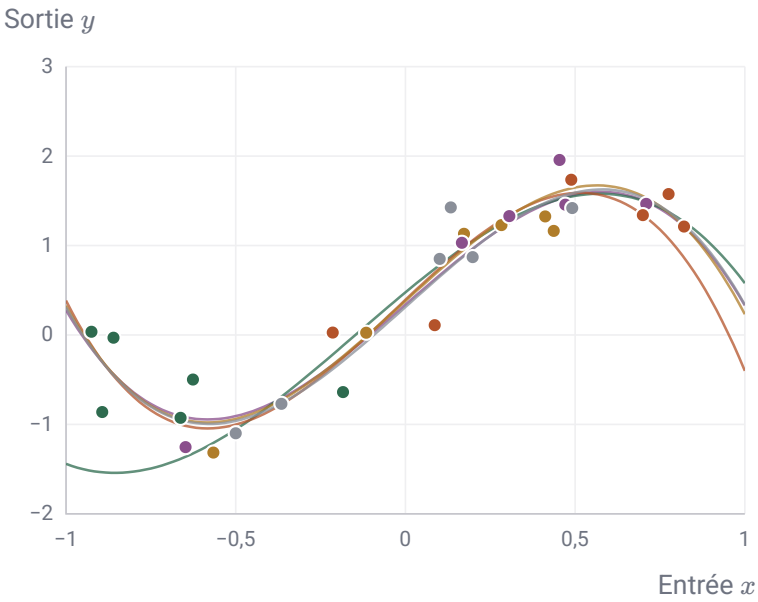
- Le degré change d'un pli à l'autre
- Un des blocs est mal choisi

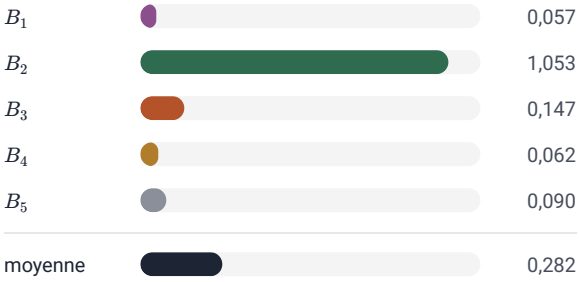
Chaque pli apprend et valide sur des points différents : l'estimation dépend du découpage.

Mêmes 30 observations que l'expérience « Parcourir les blocs » ; blocs fixés avant tout apprentissage (6 observations chacun). Perte : erreur quadratique moyenne (MSE).

NOUVEAU EXPÉRIENCE

Moyenner les cinq erreurs





MSE de validation par pli, degré 3.

$\widehat{\mathcal{R}}_{\mathrm{CV}} = 0{,}282$

Moyenne des cinq MSE, degré 3.

La moyenne des cinq erreurs estime le risque. Chaque bloc pèse autant puisqu'il contient six points.

Chaque observation est prédite par un modèle qui **ne l'a pas vue**.

Détails · La formule de validation croisée

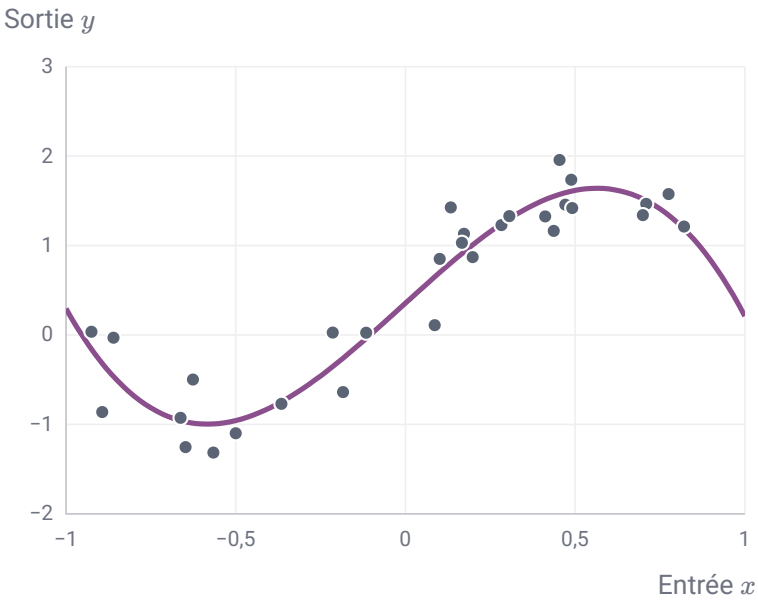
$$\widehat{\mathcal{R}}_{\mathrm{CV}} = \frac{1}{K}\sum_{k=1}^{K} \widehat{\mathcal{R}}_k.$$

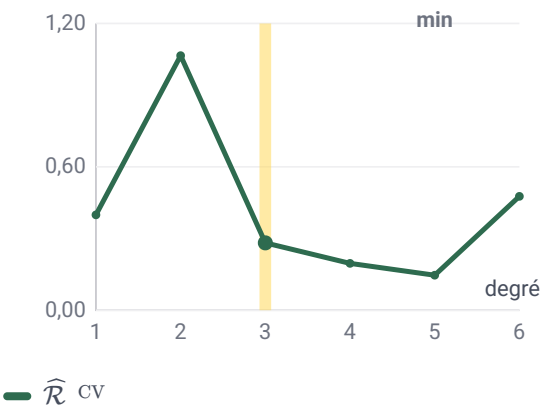
Ici, $K = 5$ et les blocs ont la même taille : cette moyenne correspond aussi à la MSE des 30 prévisions hors apprentissage.

Mêmes 30 observations que l'expérience « Parcourir les blocs » ; blocs fixés avant tout apprentissage (6 observations chacun). Perte : erreur quadratique moyenne (MSE).

NOUVEAU EXPÉRIENCE

Choisir le degré





Erreur de validation croisée selon le degré.

Défi Trouvez le degré au plus petit $\widehat{\mathcal{R}}_{\mathrm{CV}}$.

Degré 3 : $\widehat{\mathcal{R}}_{\mathrm{CV}} = 0{,}282$

Le trait mauve est réappris sur les 30 points.

Comparez les degrés et retenez la plus faible erreur de validation croisée. Réapprenez ce degré sur les 30 points.

Un test final reste nécessaire : le score ayant servi au choix peut être optimiste.

Détails · Sélection et évaluation finale

Chaque degré est évalué sur les mêmes cinq blocs. On sélectionne celui qui minimise $\widehat{\mathcal{R}}_{\mathrm{CV}}$, puis on le réapprend sur toutes les données d'apprentissage.

Le score retenu a participé à la sélection : il peut sous-estimer l'erreur future. L'évaluation finale utilise des données réservées, absentes des apprentissages et des choix.

Mêmes 30 observations que l'expérience « Parcourir les blocs » ; blocs fixés avant tout apprentissage (6 observations chacun). Perte : erreur quadratique moyenne (MSE).

DIAPO 31 · FORMULE

Leave-One-Out

$K = n$: validation croisée **leave one out** (LOO). Chaque observation est prédite par un modèle appris sans elle.

$$K = n, \qquad D_n^{(-i)} = D_n \setminus \{(x_i, y_i)\},$$
$$\hat{f}^{(-i)} = \hat{f}(\cdot; D_n^{(-i)}),$$
$$\widehat{\mathcal{R}}_{\mathrm{LOO}} = \frac{1}{n} \sum_{i=1}^{n} \ell(y_i, \hat{f}^{(-i)}(x_i)).$$

Lire la formule –
$\hat{f}^{(-i)}$: appris sans l'observation i. n ajustements : pour petits échantillons.

Chapitre 01 · Catégorisation

DIAPO 32 · NOTION

Catégorisation

Catégories des méthodes d'apprentissage

Supervision

- **Supervisé**
  Entrées et sorties connues
  Classification · régression
- **Non supervisé**
  Sans étiquette de sortie
  Clustering · réduction de dimension
  Clustering : centroïdes, densité, hiérarchie…
- **Semi-supervisé**
  Quelques observations étiquetées
  et de nombreuses non étiquetées

Paramétrisation

- **Paramétrique**
  Nombre de paramètres fixé
  Pas nécessairement gaussien
  Ex. : régression logistique, Bayes naïf, LDA
- **Non paramétrique**
  Complexité pouvant croître
  avec les données
  Des hypothèses restent nécessaires
  Ex. : kNN, arbres ; SVM selon le noyau

Linéarité

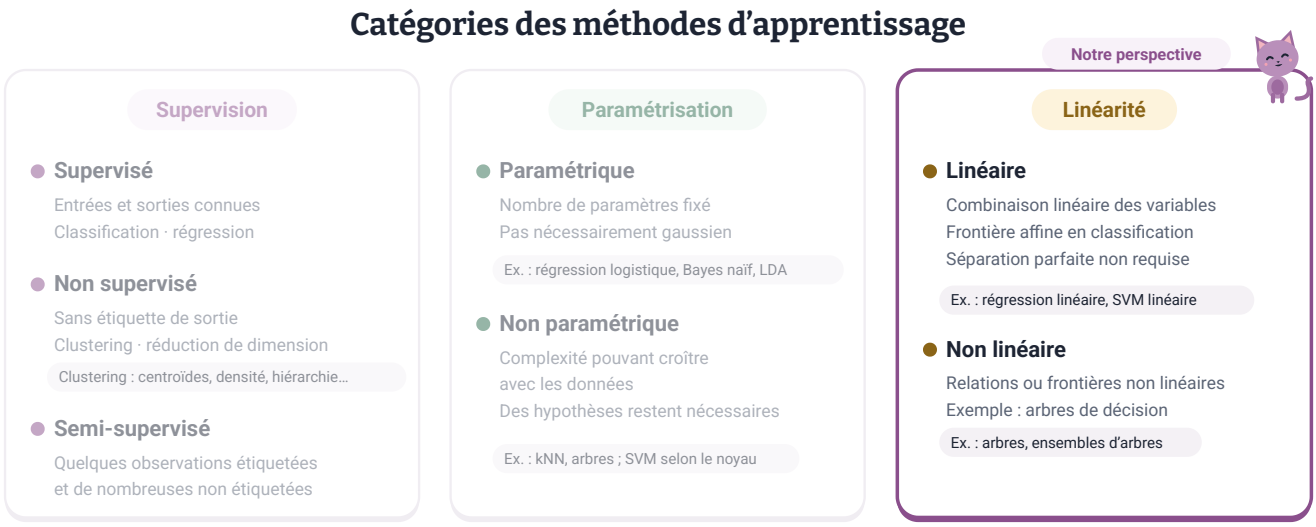
- **Linéaire**
  Combinaison linéaire des variables
  Frontière affine en classification
  Séparation parfaite non requise
  Ex. : régression linéaire, SVM linéaire
- **Non linéaire**
  Relations ou frontières non linéaires
  Exemple : arbres de décision
  Ex. : arbres, ensembles d'arbres

Ces trois axes de classement se combinent : ils ne sont pas exclusifs.

Carte redessinée d'après le support et The Illustrated Machine Learning (2023), avec les définitions précisées.

DIAPO 33 · NOTION

Notre perspective



Notre perspective : commencer par le linéaire, puis étudier le non linéaire.

Carte redessinée d'après le support et The Illustrated Machine Learning (2023), avec les définitions précisées.

▼ Précision

- **Paramétrique** : nombre fixé de paramètres, pas forcément gaussien.
- **Non paramétrique** : ni sans hypothèses, ni moins puissant par principe.
- Un **modèle linéaire** n'exige pas une séparation parfaite.

DIAPO 34 · NOTION

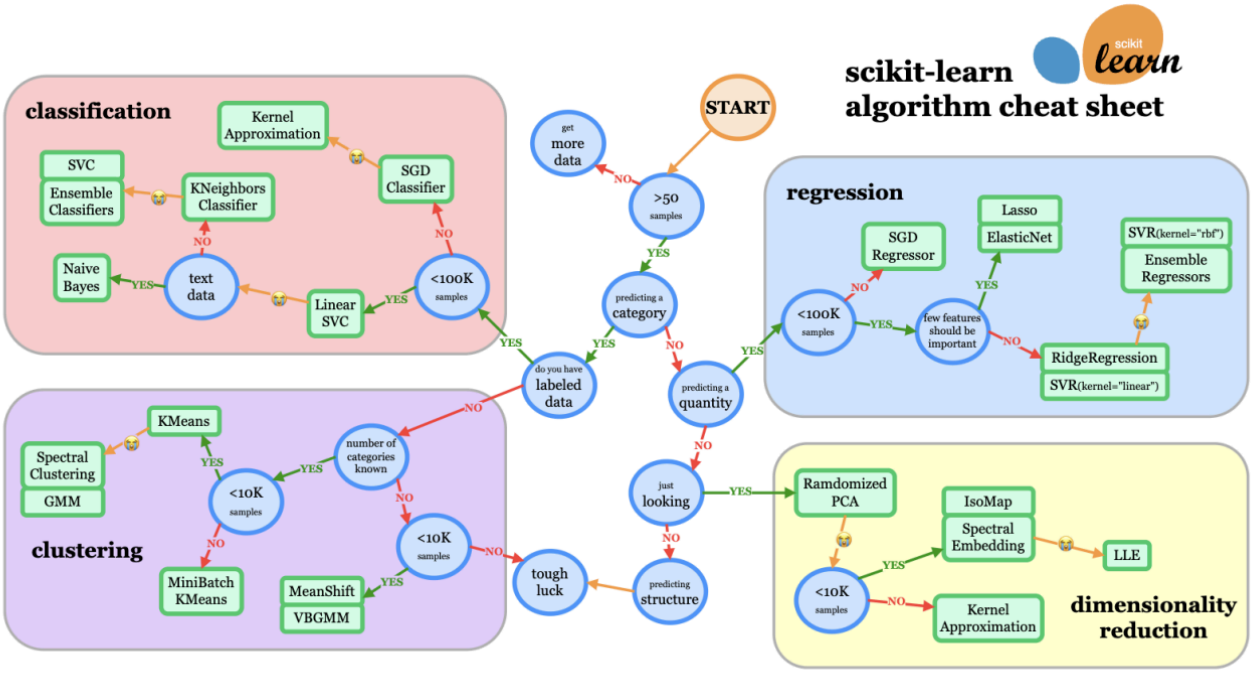
Pourquoi ce choix ?

L'axe **linéaire / non linéaire** éclaire le compromis biais–variance et le choix d'une complexité adaptée aux données.

Commencer par un **modèle linéaire simple** ; passer à un **modèle non linéaire** si les données le justifient.

DIAPO 35 · NOTION

Guide selon scikit-learn



Familles de méthodes selon la tâche et les données ; valider ensuite le choix.

DIAPO 36 · NOTION

Références

- **James, G., Witten, D., Hastie, T., Tibshirani, R., Taylor, J.** *An Introduction to Statistical Learning: with Applications in Python*, Springer, 2023. Site des auteurs et PDF.
- **Afshine Amidi et Shervine Amidi.** *CS229 — fiches de machine learning*, Fall 2018.
- **Laurent Rouvière.** *Introduction au machine learning*, Université Rennes 2, 2021.
- **Trevor Hastie, Robert Tibshirani, Jerome Friedman.** *The Elements of Statistical Learning*, Springer, 2001.

Pour approfondir

ISL avec Python · édition 2023, site des auteurs et PDF ↗

The Illustrated Machine Learning website ↗

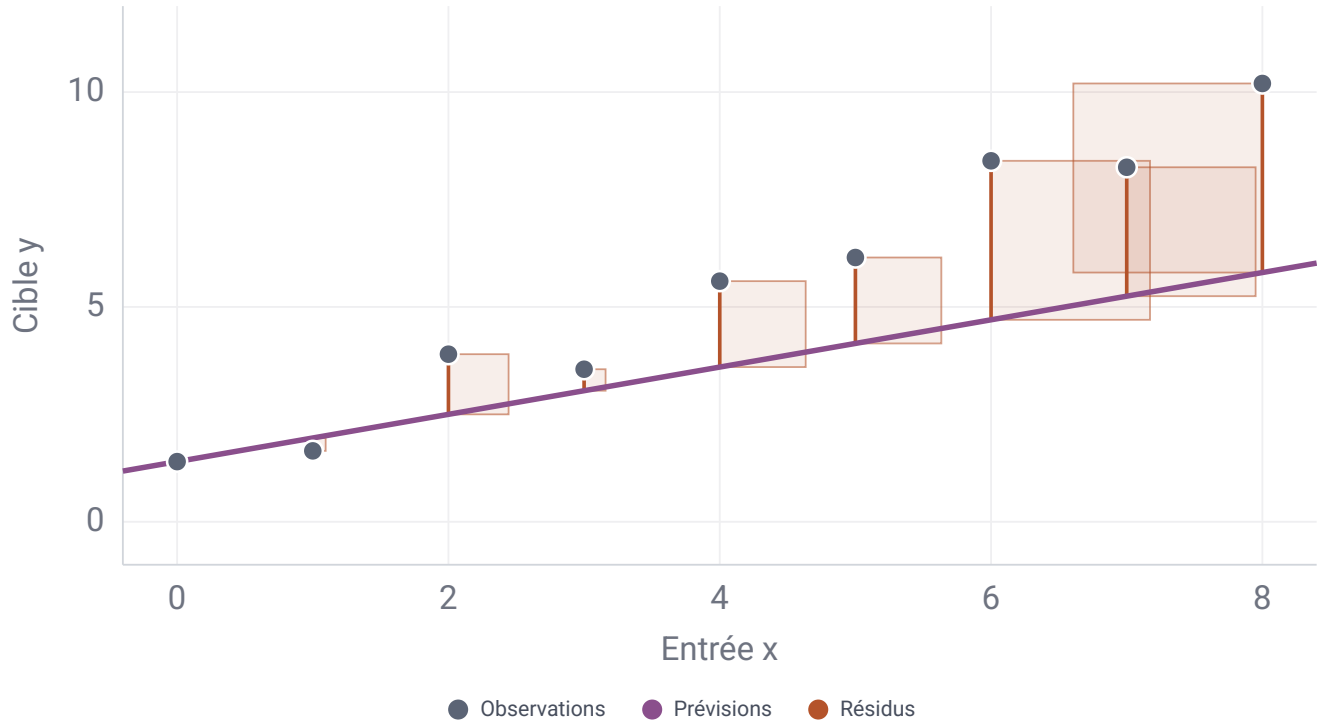
DIAPO 37 · NOTION

Algorithmes linéaires : la suite

> **Next : Algorithmes linéaires**
>
> Chapitre suivant : les **algorithmes linéaires** (géométrie, prévision, critères d'apprentissage).

COMPLÉMENT · EXPÉRIENCE

Manipuler la perte quadratique



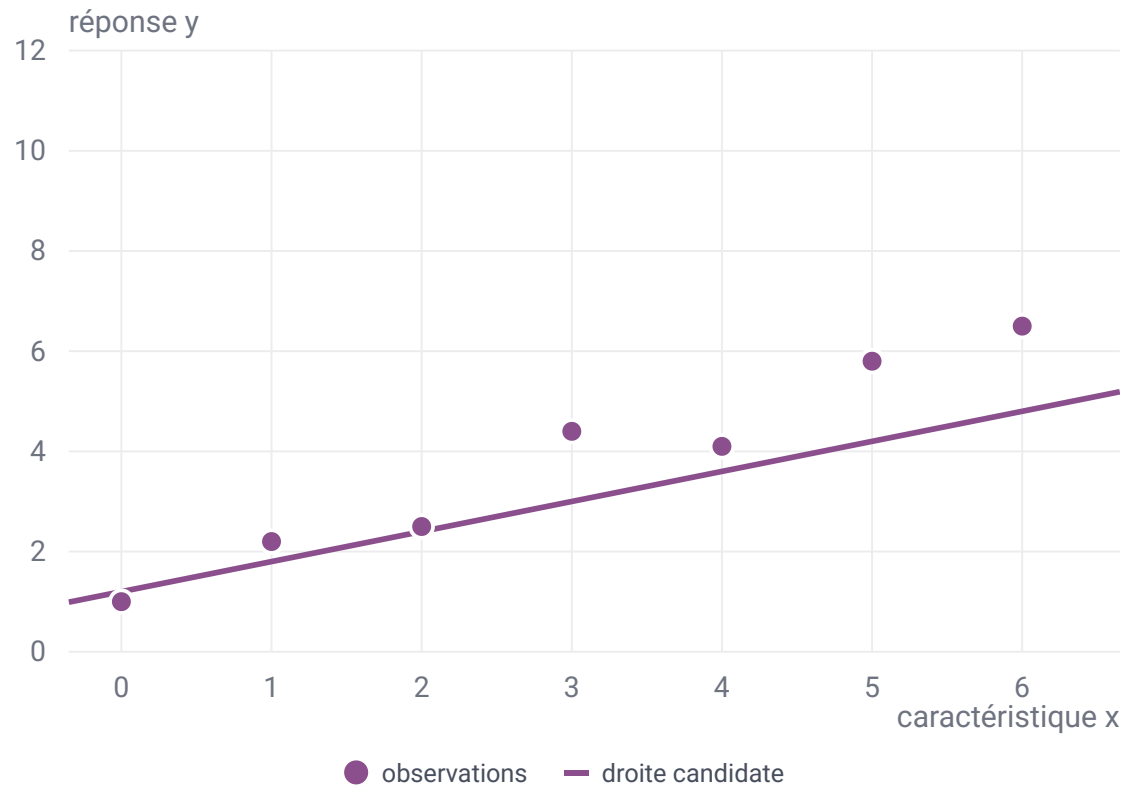
2,908	5,817	0,55	1,40
Risque empirique $= \frac{1}{2}\,\mathrm{MSE}$	$\mathrm{MSE} = \mathrm{RSS}/9$	Pente w	Ordonnée b

Déplacez la droite. Les segments sont les résidus verticaux ; la MSE est leur carré moyen ; avec la perte $\frac{1}{2}(y-\hat{y})^2$, le risque empirique vaut $\frac{1}{2}\,\mathrm{MSE}$. Chaque carré a pour aire le carré d'un résidu.

Données synthétiques. Déplacer la droite pour observer les résidus et leur coût moyen. La perte quadratique de cette partie utilise le facteur $\frac{1}{2}$; la MSE usuelle, lorsqu'elle est affichée séparément, utilise les carrés sans ce facteur.

COMPLÉMENT · EXPÉRIENCE

Une droite, deux paramètres



$\hat{y} \approx 0{,}60\,x + 1{,}20$

Changer b déplace toutes les prédictions du même écart.

La pente a règle l'inclinaison ; b décale la droite. Point mauve : observation ; trait mauve : prédiction.

Comment augmenter toutes les prédictions de la même quantité ?

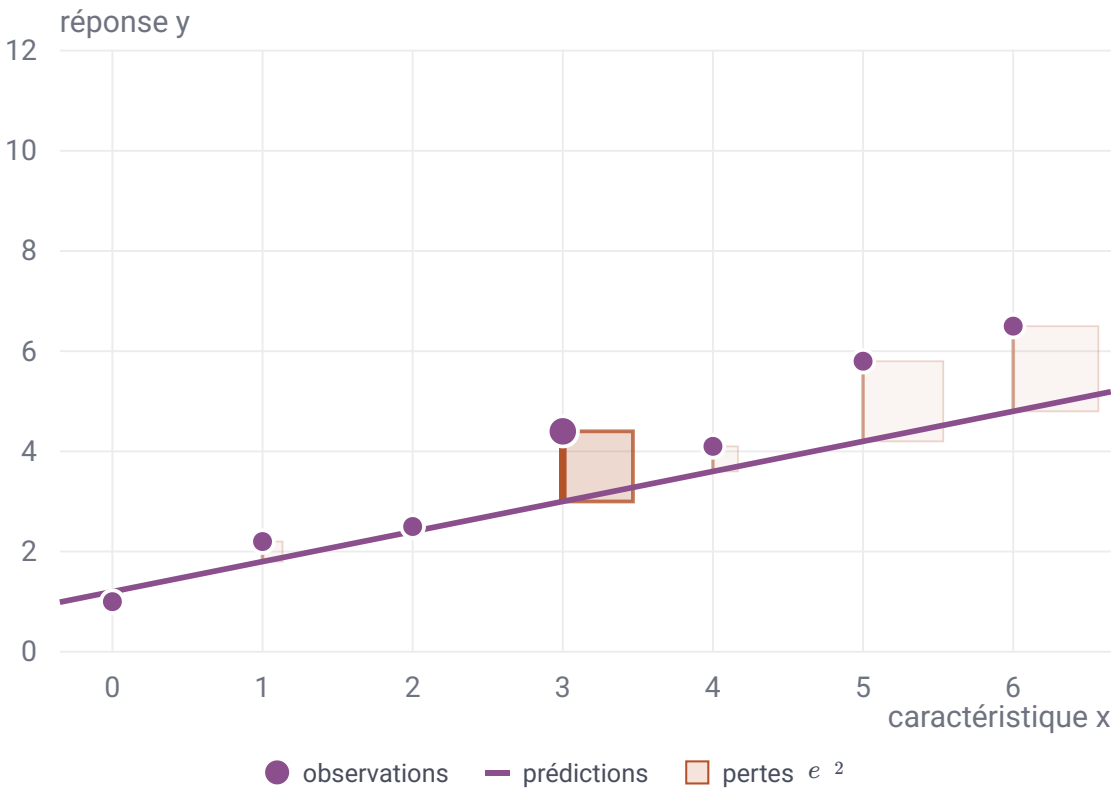
$$\widehat{y}_i = ax_i + b$$

Incliner ou déplacer : quel paramètre faut-il changer ?

Sept observations synthétiques, conservées d'une étape à l'autre. Les carrés sont schématiques ; leurs aires sont proportionnelles aux résidus au carré.

COMPLÉMENT · EXPÉRIENCE

Du résidu à la perte



Observation 4 : e **= 1,40** ; e^2 **= 1,96**.

1,124
MSE · moyenne des e²

0,562
½MSE · risque du cours

Le résidu est l'écart vertical entre observation et prédiction. Chaque carré représente sa perte. La MSE moyenne ces pertes ; le risque du cours vaut $\frac{1}{2}\,\mathrm{MSE}$.

Détails

Le résidu peut être positif ou négatif ; sa perte au carré est positive ou nulle. Chaque carré a une aire proportionnelle à cette perte.

Dans le cours, la perte $\frac{1}{2}e^2$ donne un risque empirique égal à $\frac{1}{2}\,\mathrm{MSE}$.

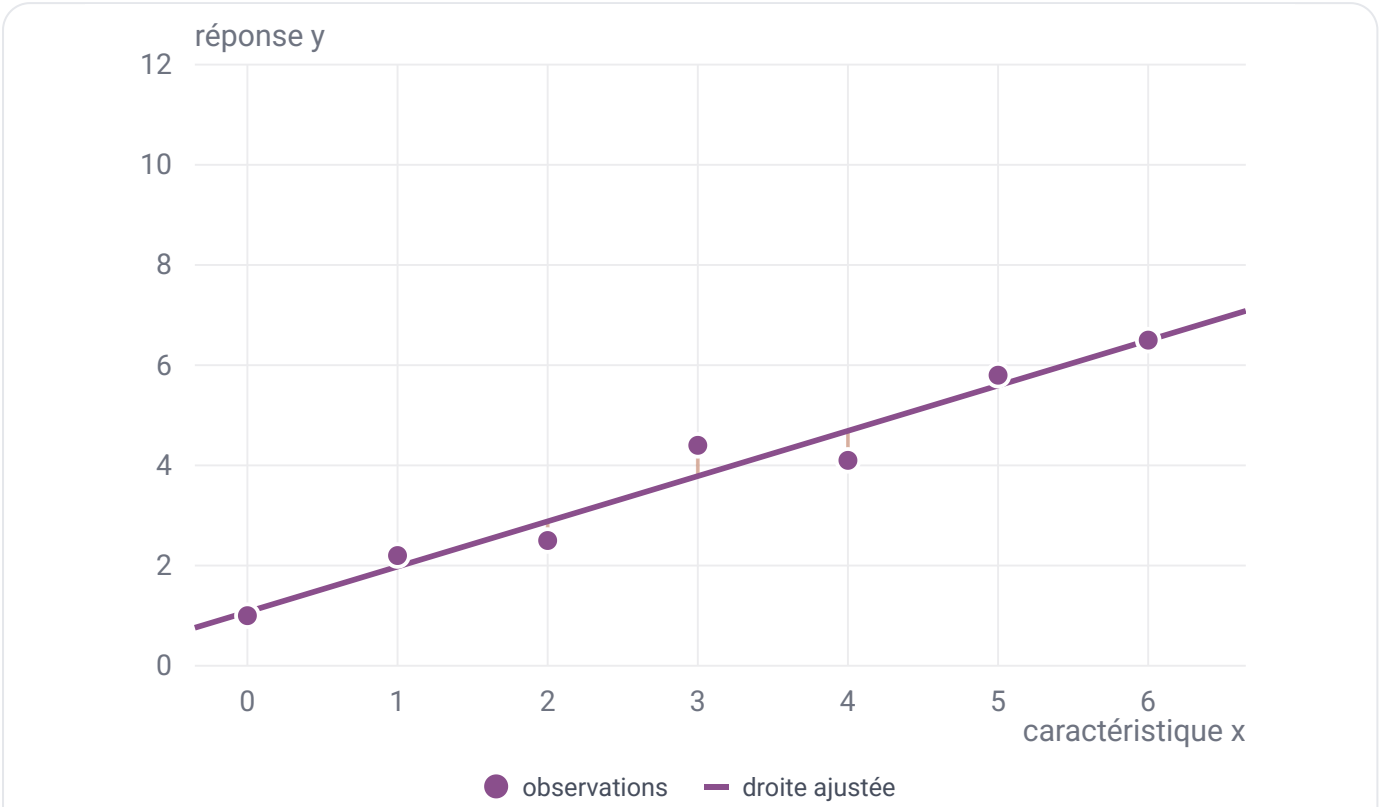
$$e_i = y_i - \hat{y}_i, \qquad \ell_i = e_i^2$$

Un résidu deux fois plus grand produit quelle perte ?

Sept observations synthétiques, conservées d'une étape à l'autre. Les carrés sont schématiques ; leurs aires sont proportionnelles aux résidus au carré.

COMPLÉMENT · EXPÉRIENCE

Révéler les moindres carrés



$\hat{y} \approx 0{,}90\,x + 1{,}08$

0,138
MSE de la droite

0,069
½MSE · risque du cours

Révélez la droite qui minimise la somme des carrés sur sept observations. Diviser la perte par n, ou par $2n$, conserve la droite optimale.

Détails

On ajuste les deux paramètres pour minimiser la somme des carrés. Les facteurs changent la valeur de la perte, pas son minimiseur.

L'animation relie la droite candidate à la solution calculée, sans simuler une descente de gradient.

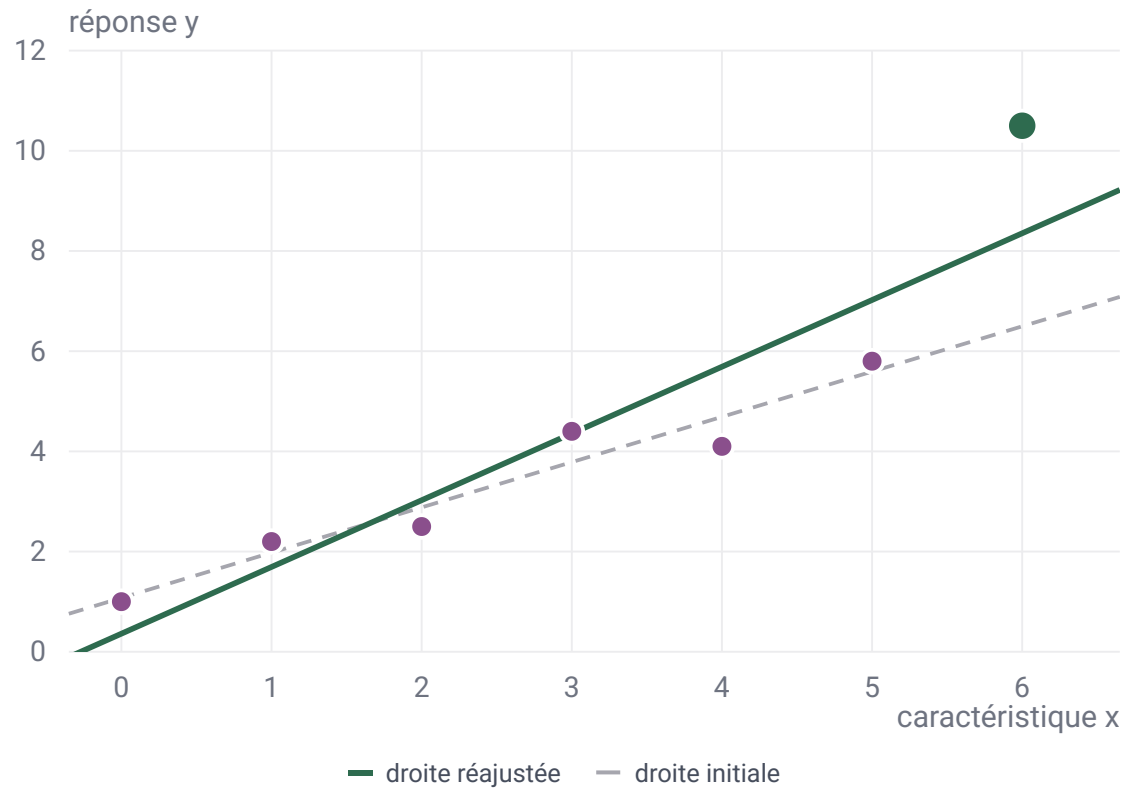
$$a^* = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sum_i (x_i - \bar{x})^2}$$
$$b^* = \bar{y} - a^* \bar{x}$$

Faut-il modifier la pente, l'ordonnée à l'origine, ou les deux ?

Sept observations synthétiques, conservées d'une étape à l'autre. Les carrés sont schématiques ; leurs aires sont proportionnelles aux résidus au carré.

COMPLÉMENT · EXPÉRIENCE

Un point peut tirer la droite



$\hat{y} \approx 1{,}33\,x + 0{,}36$

1,367
MSE de la droite

0,683
½MSE · risque du cours

Déplacez la dernière observation : la droite est réajustée à chaque mouvement. La droite grise garde l'ajustement initial. Un grand résidu peut fortement modifier la pente.

Détails

Le carré amplifie les grands résidus : ce point extrême peut modifier fortement la pente. Une faible MSE d'apprentissage ne garantit pas la généralisation.

$$\mathrm{MSE} = \frac{1}{n}\sum_{i}(y_i - \hat{y}_i)^2$$

Avant de déplacer le point : la droite montera-t-elle partout autant ?

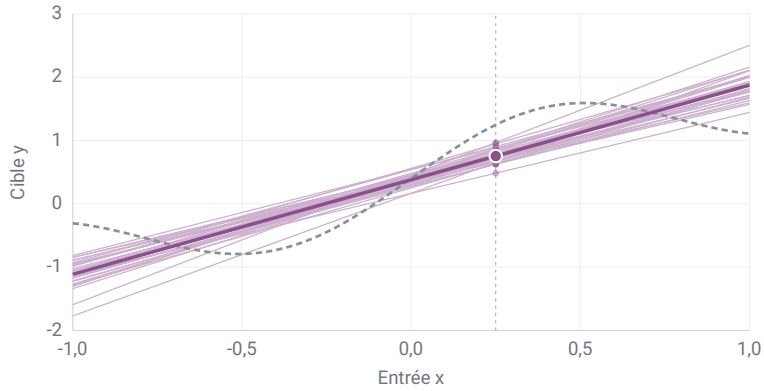
Sept observations synthétiques, conservées d'une étape à l'autre. Les carrés sont schématiques ; leurs aires sont proportionnelles aux résidus au carré.

COMPLÉMENT · EXPÉRIENCE

Répéter l’apprentissage

Simulation synthétique où la vraie relation est connue. Les courbes sont apprises sur plusieurs échantillons ; comparer leur moyenne et leur dispersion aux illustrations du support.

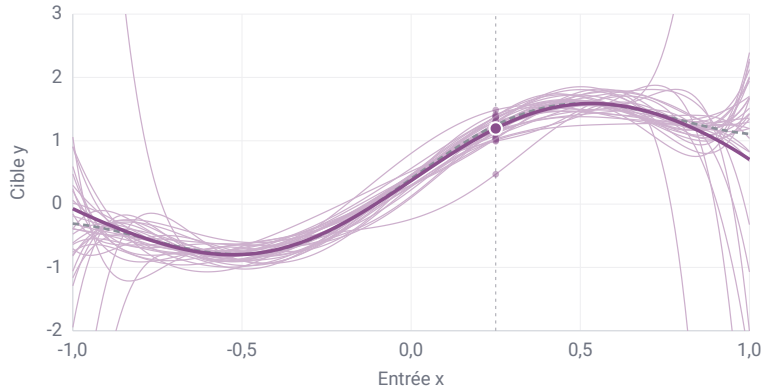
Degré 1



0,243	0,011	0,078	0,333
Biais^2 estimé	Variance estimée	Bruit σ^2	Somme des trois termes

Au point fixé $x = 0{,}25$, degré 1. Biais^2 et variance sont des estimations Monte-Carlo sur 30 apprentissages, avec division par 30. Le bruit vaut $0{,}28^2$. La somme estime l’erreur sur une nouvelle cible ; elle n’est pas une mesure sur les données d’apprentissage.

Degré 7



0,003	0,035	0,078	0,116
Biais^2 estimé	Variance estimée	Bruit σ^2	Somme des trois termes

Au point fixé $x = 0{,}25$, degré 7. Biais^2 et variance sont des estimations Monte-Carlo sur 30 apprentissages, avec division par 30. Le bruit vaut $0{,}28^2$. La somme estime l’erreur sur une nouvelle cible ; elle n’est pas une mesure sur les données d’apprentissage.

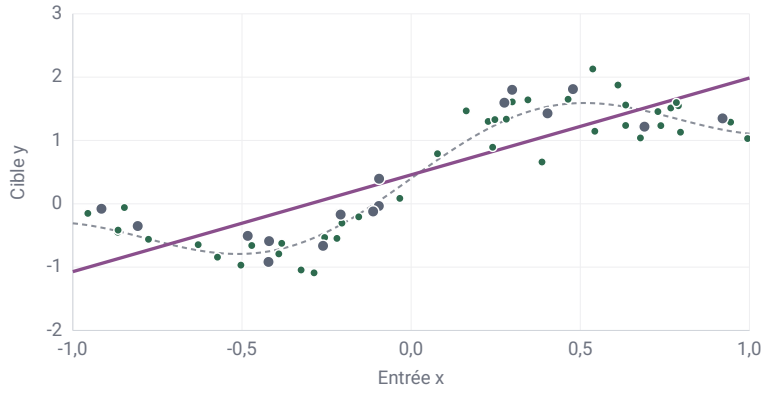
30 modèles appris · Prévision moyenne · Relation réelle m^*

COMPLÉMENT · EXPÉRIENCE

Faire varier la complexité

Données synthétiques. Comparer l’erreur d’apprentissage et l’erreur de validation lorsque le degré change. Le jeu utilisé pour comparer les degrés sert à la validation, pas au test final.

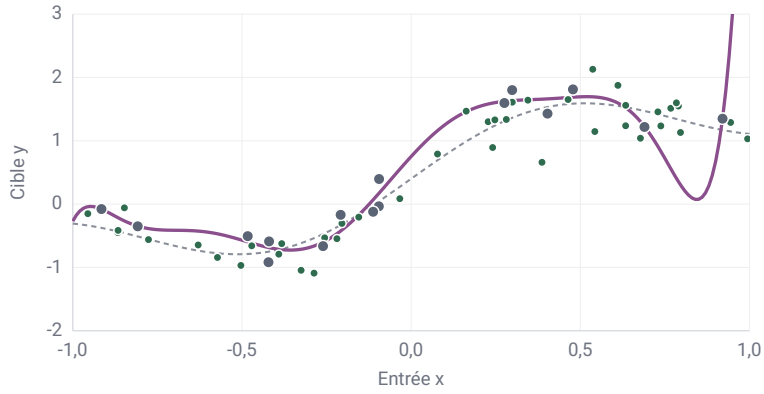
Degré 1



0,297	0,292	1
MSE apprentissage	MSE validation	Degré polynomial

16 observations d’apprentissage, 45 de validation ; degré 1, soit 2 coefficients. La courbe peut sortir du cadre : les scores utilisent toutes les valeurs, sans tronquer les prévisions.

Degré 9



0,023	1,255	9
MSE apprentissage	MSE validation	Degré polynomial

16 observations d’apprentissage, 45 de validation ; degré 9, soit 10 coefficients. La courbe peut sortir du cadre : les scores utilisent toutes les valeurs, sans tronquer les prévisions.

Apprentissage · Validation · Modèle · Relation réelle m^*

À retenir pour le complément visuel

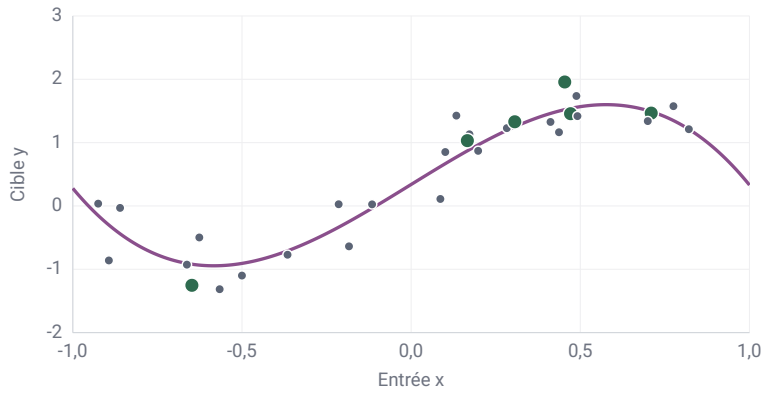
- Erreurs propres à cet échantillon synthétique.
- Moins d’erreur d’apprentissage n’implique pas moins d’erreur de validation.
- Validation parfois en U, pas toujours.

COMPLÉMENT · EXPÉRIENCE

Parcourir les blocs

Exemple synthétique à cinq blocs de même taille. Changer le bloc tenu à l’écart et observer le modèle appris sur les quatre autres. Chaque observation est évaluée une fois hors apprentissage.

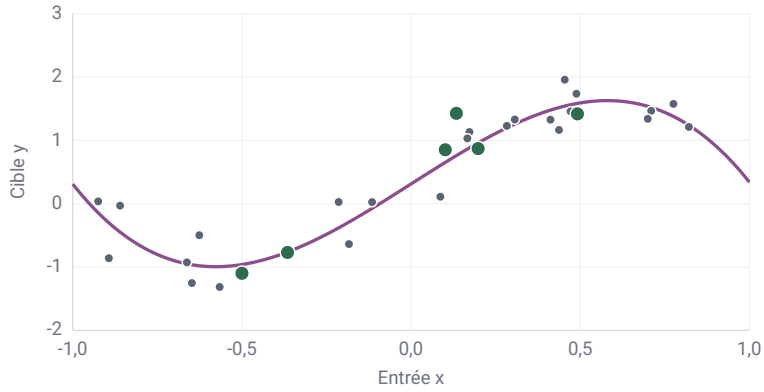
Pli 1 · degré 3



0,057	0,282	24 / 6
MSE du pli 1	MSE CV moyenne	Apprentissage / validation

Degré 3. MSE par pli : 1 : 0,057 · 2 : 1,053 · 3 : 0,147 · 4 : 0,062 · 5 : 0,090. Plis égaux : leur moyenne correspond à l’erreur sur les 30 prévisions hors apprentissage. Choisir le degré sur ces scores demande ensuite une évaluation finale réservée.

Pli 5 · degré 3



0,090
MSE du pli 5

0,282
MSE CV moyenne

24 / 6
Apprentissage / validation

Degré 3. MSE par pli : 1 : 0,057 · 2 : 1,053 · 3 : 0,147 · 4 : 0,062 · 5 : 0,090. Plis égaux : leur moyenne correspond à l'erreur sur les 30 prévisions hors apprentissage. Choisir le degré sur ces scores demande ensuite une évaluation finale réservée.

24 points d'apprentissage · 6 points de validation · Modèle réappris

Chapitre 01 · Estimation du risque

COMPLÉMENT · EXPÉRIENCE

Séparer avant d'apprendre



36 / 12 / 12

Une observation appartient à un seul lot.

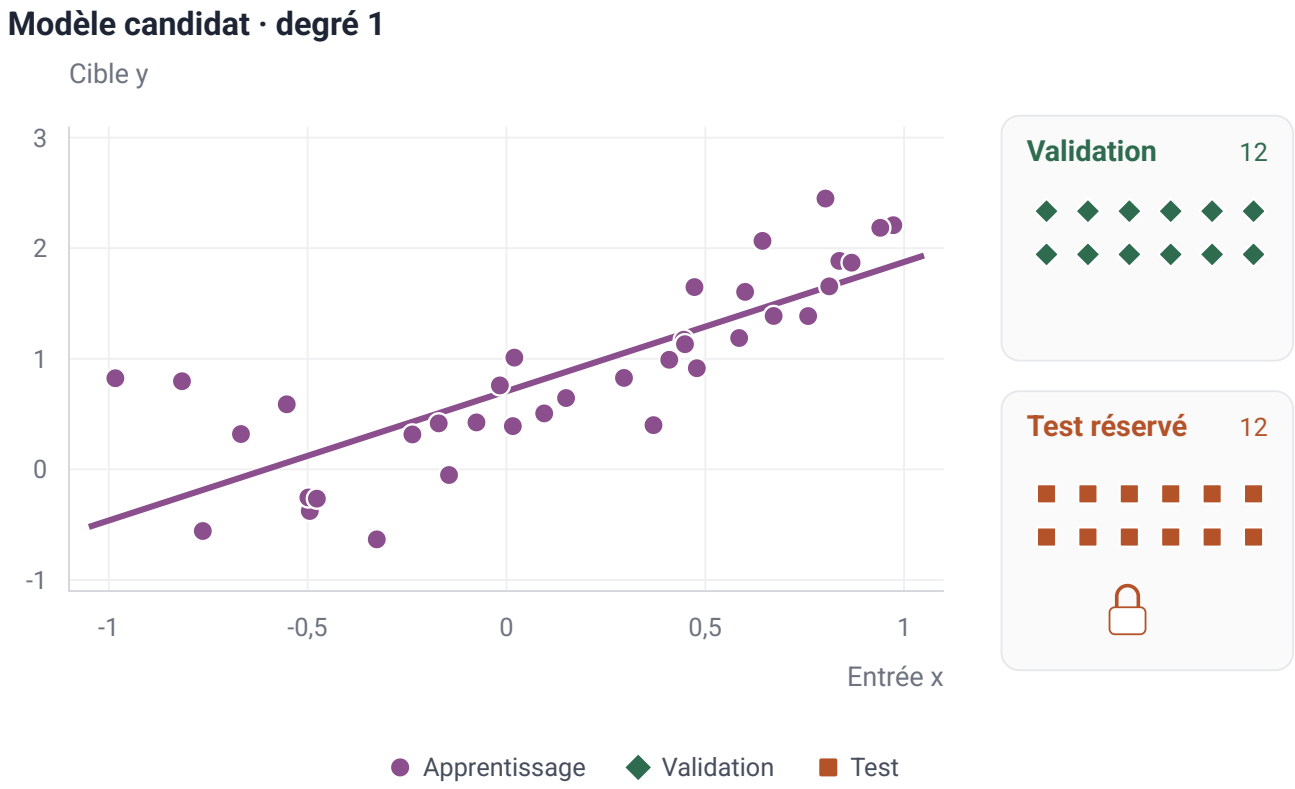
Les mêmes 60 observations sont réparties une fois : 36 pour apprendre, 12 pour choisir, 12 pour évaluer à la fin.

> **Quel lot doit rester fermé jusqu'au choix du modèle ?**

Exemple synthétique i.i.d. : même population, lots disjoints et fixes. Pour des séries temporelles ou des groupes liés, adapter la séparation.

COMPLÉMENT · EXPÉRIENCE

Apprendre sur un seul lot



MSE apprentissage : 0,220

Degré 1 · paramètres ajustés sur 36 points.

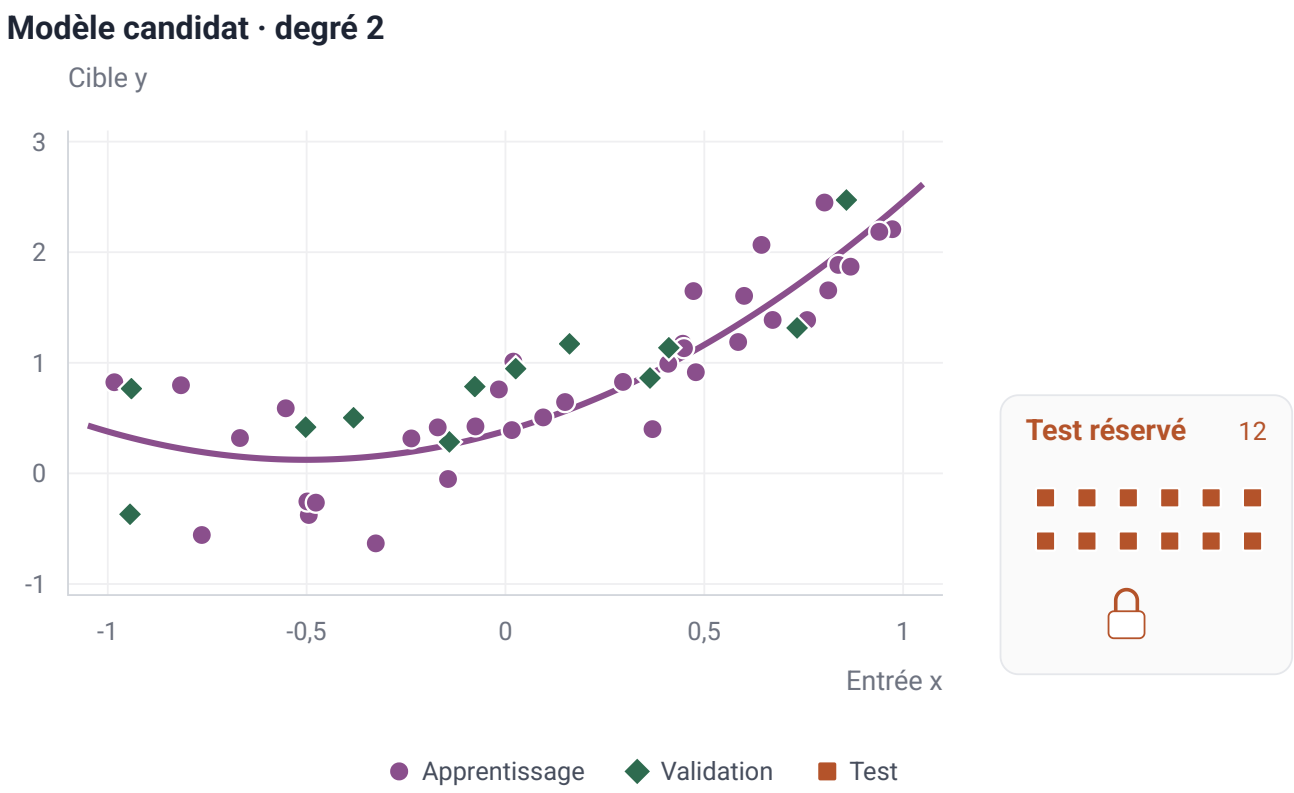
Chaque courbe minimise l'erreur sur les 36 points d'apprentissage. Le degré est encore un candidat, pas un choix définitif.

> **Une petite erreur d'apprentissage suffit-elle pour choisir ?**

Exemple synthétique i.i.d. : même population, lots disjoints et fixes. Pour des séries temporelles ou des groupes liés, adapter la séparation.

COMPLÉMENT · EXPÉRIENCE

La validation choisit le degré



MSE validation : 0,177

Degré 2 retenu sur la validation.

Les trois modèles déjà appris prédisent les 12 nouveaux points de validation. Comparez leurs MSE, puis figez un choix.

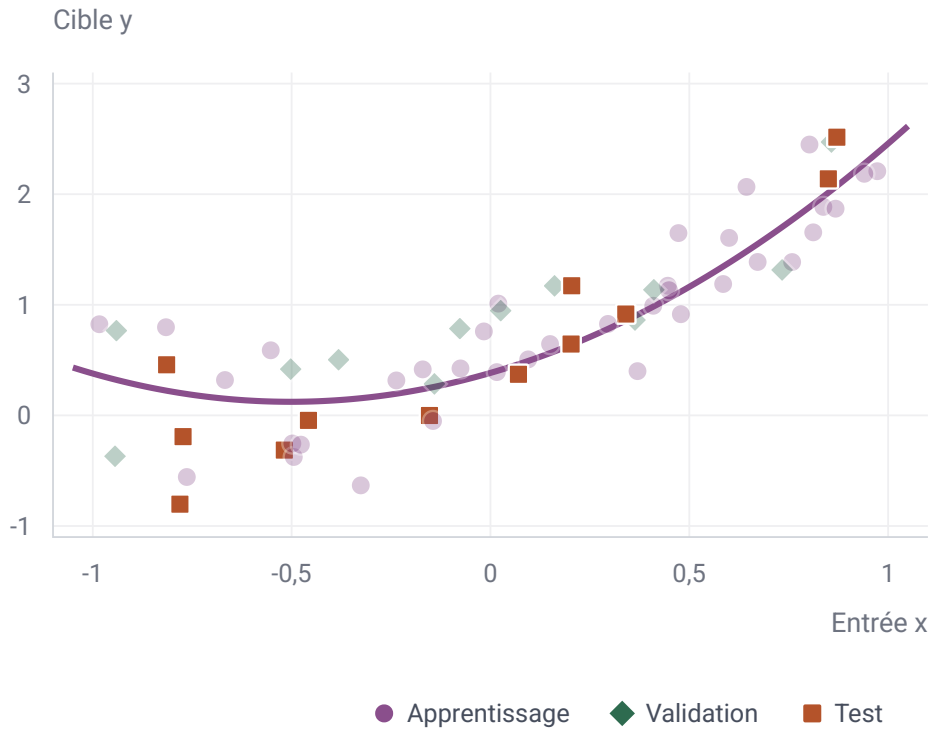
> **Quel degré a la plus petite MSE de validation ?**

Exemple synthétique i.i.d. : même population, lots disjoints et fixes. Pour des séries temporelles ou des groupes liés, adapter la séparation.

COMPLÉMENT · EXPÉRIENCE

Ouvrir le test une seule fois

Évaluation finale · degré 2



MSE test : 0,167

Degré 2 figé · estimation sur 12 nouveaux points.

Le modèle choisi reste fixe. Les 12 points de test servent maintenant à estimer son erreur sur de nouvelles observations.

> **Pourquoi ne faut-il plus changer de degré après avoir vu ce score ?**

Exemple synthétique i.i.d. : même population, lots disjoints et fixes. Pour des séries temporelles ou des groupes liés, adapter la séparation.