APPRENTISSAGE STATISTIQUE · 2026–2027

Fondements de l’apprentissage statistique

Oumoukelthoum Sidenna

2e année du cycle ingénieur · 90 min · 24 vues en classe

Plan du chapitre

1. Introduction générale · 10 min
2. Régression vs Discrimination · 12 min
3. Fonction de perte · 15 min
4. Risque · 15 min
5. Décomposition de l’erreur et compromis biais–variance · 18 min
6. Estimation du risque · 15 min
7. Catégorisation · 5 min

DIAPO 08 · NOTION

Problème d'apprentissage supervisé

On dispose d'une variable de sortie — **variable dépendante, réponse ou cible** — et d'un vecteur de p **variables explicatives**, également appelées entrées, prédicteurs, covariables ou features.

- En **régression**, la cible est quantitative : un prix ou une tension artérielle, par exemple.
- En **discrimination**, elle prend des valeurs dans un ensemble fini et non ordonné : survie/mort, chiffre de 0 à 9, classe de tissu.

Les couples entrée–sortie disponibles sont les observations, exemples ou instances à partir desquels l'algorithme apprend.

DIAPO 09 · NOTION

Apprentissage non supervisé

Il n’y a pas de variable de sortie fournie : seules les mesures ou caractéristiques des observations sont disponibles. L’objectif est exploratoire.

- Trouver des groupes d’observations qui se ressemblent.
- Trouver des variables qui se comportent de manière similaire.
- Trouver des combinaisons linéaires de variables capturant une grande part de la variance.

L’absence de vérité terrain rend l’évaluation plus difficile. Une méthode non supervisée peut aussi servir de prétraitement, par exemple une réduction de dimension avant une classification supervisée.

NOUVEAU NOTION

Fil rouge · chats et chiens

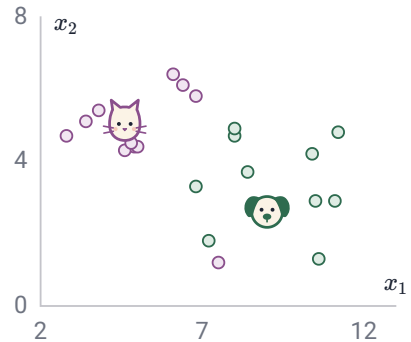
Un animal est décrit par deux mesures : son poids x_{i1} et la longueur de son pelage x_{i2}. Prédire l'**espèce** $y_i \in \{\text{chat}, \text{chien}\}$ est un problème de **discrimination**. Prédire le **poids** à partir du pelage serait une **régression**.

ANIMAL → MESURES → ÉTIQUETTE

→ $x = (4{,}6\,;\,5{,}0)$ → $y = 0$ · **chat**

→ $x = (9{,}0\,;\,2{,}6)$ → $y = 1$ · **chien**

Le dessin sert seulement à reconnaître l'animal à l'écran ; le modèle ne reçoit que les nombres x_1 et x_2.



Chaque animal devient un point du plan ; la couleur porte l'étiquette.

DIAPO 13 · FORMULE

Un début de formalisation mathématique

Les données observées sont une réalisation d'un n**-échantillon** de loi inconnue. Le plus souvent, nous supposerons les couples indépendants et identiquement distribués selon une même loi, notée $\mathbb{P}$.

À partir de ces observations, on cherche une fonction qui relie les entrées aux sorties. Il faut ensuite préciser un critère permettant de comparer les fonctions de prévision : une **fonction de perte**.

$$D_n = \{(X_i, Y_i) : i = 1, \dots, n\},$$
$$(X_i, Y_i) \overset{\text{i.i.d.}}{\sim} \mathbb{P},$$
$$f : \mathcal{X} \longrightarrow \mathcal{Y}, \qquad f(x_i) \approx y_i.$$

DIAPO 14 · FORMULE

Fonction de prévision et paramètres

En outre…

Une fonction de prévision dépend des paramètres du modèle, notés θ. Dans les **exemples affines ci-dessous**, $\theta = (w, b)$: coefficients et terme constant.

$$\hat{y} = \hat{f}(x), \qquad \hat{f} = f_\theta, \quad \theta = (w, b)$$

Modèle	Fonction de prévision	Paramètres
Régression linéaire	$\hat{y} = w^\top x + b$	$\theta = (w, b)$
SVM binaire	$\hat{y} = \operatorname{sign}(g(x)), \quad g(x) = w^\top x + b$; à score nul, choisir $+1$.	$\theta = (w, b)$

DIAPO 15 · FORMULE · 1/3

Ce que mesure une perte

Définition

Une **fonction de perte** mesure le coût d'une prévision. Elle est mesurable, non négative et, dans les exemples suivants, nulle lorsque la prévision est exacte.

$$\ell : \mathcal{Y} \times \mathcal{Y} \longrightarrow \mathbb{R}^{+},$$
$$\ell(y, y) = 0, \qquad \ell(y, \hat{y}) > 0 \text{ si } y \neq \hat{y}.$$

DIAPO 15 · FORMULE · 2/3

Perte absolue et perte quadratique

$$\ell_p(y, \hat{y}) = \frac{1}{p}|y - \hat{y}|^p, \qquad p \geq 1$$

Valeur de p	Perte	Expression
$p = 1$	Perte absolue	$\lvert y - \hat{y}\rvert$
$p = 2$	Perte quadratique	$\frac{1}{2}(y - \hat{y})^2$

DIAPO 15 · FORMULE · 3/3

Perte de classification

$$\mathcal{Y} = \{-1, +1\}, \qquad \ell(y, \hat{y}) = \mathbf{1}_{\{y \neq \hat{y}\}}$$

DIAPO 17 · FORMULE

Risque

On s’intéresse au **comportement moyen** de la fonction de perte. Pour une fonction de prévision fixée, sa performance est mesurée par l’espérance de la perte sur un couple entrée–sortie de la population cible.

$$\mathcal{R}(f) = \mathbb{E}\big[\ell(Y, f(X))\big]$$

DIAPO 18 · FORMULE · 1/2

Le meilleur prédicteur théorique

Fonction de prévision optimale

Aspect théorique : pour une perte donnée, chercher la fonction ayant le plus petit risque. Une telle fonction, si elle existe, est une fonction de prévision optimale.

$$f^* \in \arg\min_f \mathcal{R}(f),$$

$$\mathcal{R}(f^*) \leq \mathcal{R}(f) \quad \text{pour toute } f.$$

DIAPO 18 · FORMULE · 2/2

Pourquoi il faut des données

Aspect pratique

La loi étant inconnue, nous ne pouvons généralement pas calculer directement la fonction optimale. Nous cherchons un estimateur construit à partir des données dont le risque est proche de celui de l'oracle.

$$\hat{f} = \hat{f}(\cdot; D_n),$$
$$\mathcal{R}(\hat{f}) \approx \mathcal{R}(f^*).$$

DIAPO 19 · FORMULE

Intuition

À une valeur d'entrée fixée, plusieurs valeurs de la sortie peuvent être observées. Quelle prévision représente alors une bonne valeur ? Pour la perte quadratique, la réponse est la **moyenne conditionnelle** de la sortie sachant cette entrée.

$$m^*(x) = \mathbb{E}[Y \mid X = x]$$

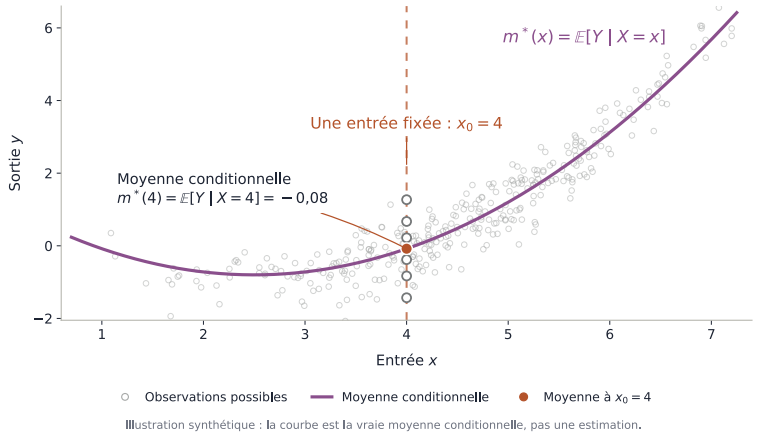


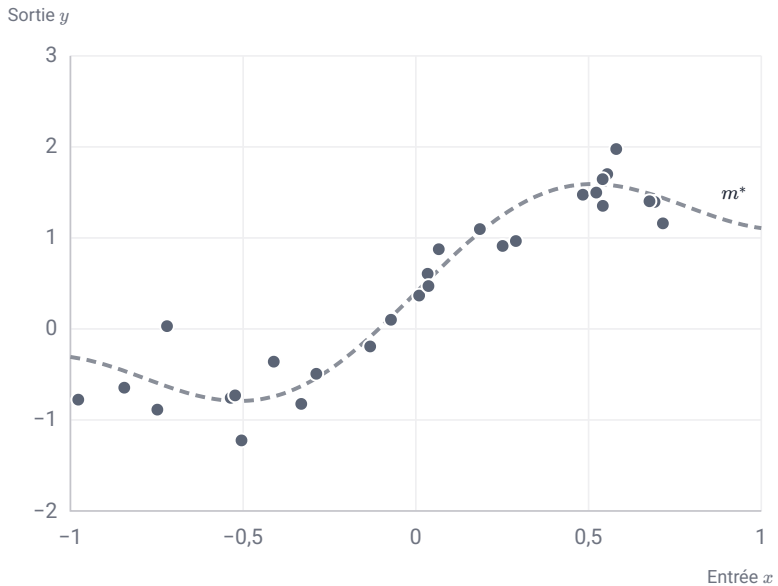
Illustration synthétique redessinée : à $x_0 = 4$, plusieurs sorties sont possibles. La courbe mauve représente $m^*(x) = \mathbb{E}[Y \mid X = x]$, optimale sous perte quadratique.

NOUVEAU EXPÉRIENCE

Une relation, du bruit

Les 28 points suivent la relation moyenne réelle m^* (pointillés), avec du bruit. Un autre tirage donnerait d’autres points.

Cette relation est connue ici parce que les données sont simulées.



Un échantillon de 28 points

Les pointillés représentent m^*, la relation moyenne réelle, inconnue en pratique.

MODÈLE DES DONNÉES

$$y = m^*(x) + \varepsilon$$

BRUIT

$$\sigma^2 = 0{,}078$$

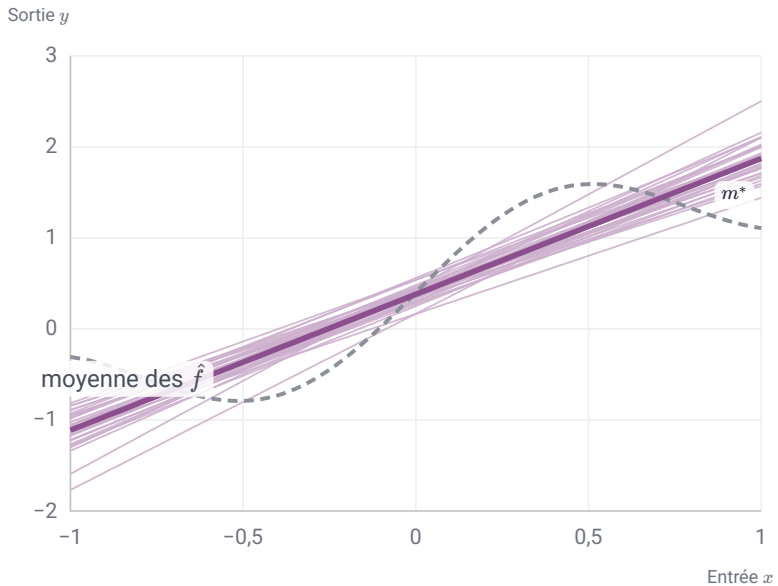
Erreur quadratique attendue sur une nouvelle réponse : au moins σ^2.

NOUVEAU EXPÉRIENCE

Un modèle simple, trente fois

Trente échantillons, trente droites apprises $\hat{f}$. Elles se ressemblent : **variance faible**.

Leur moyenne (trait épais) reste loin de m^* : **biais élevé**. Comparez le trait épais aux pointillés.



biais^2 0,243

variance 0,011

En $x_0 = 0{,}25$, degré 1.

Degré 1 : $\text{biais}^2 = 0{,}243$**, variance** $0{,}011$

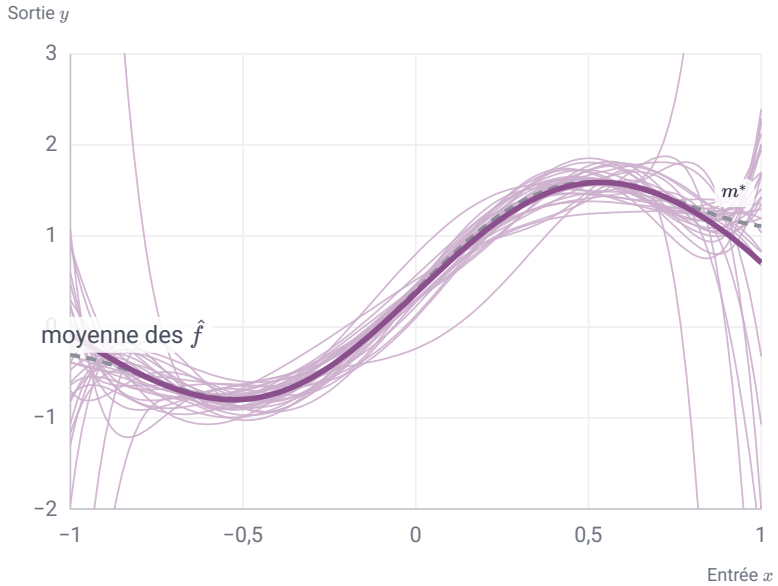
Au point $x_0 = 0{,}25$, sur 30 apprentissages.

NOUVEAU EXPÉRIENCE

Un modèle souple, trente fois

Au degré 7, la moyenne suit mieux m^* : le **biais baisse**.

Les trente courbes apprises $\hat{f}$ s’écartent davantage, surtout aux bords : la **variance augmente**. Comparez leur dispersion.



biais^2 0,003

variance 0,035

En $x_0 = 0{,}25$, degré 7.

Degré 7 : $\text{biais}^2 = 0{,}003$**, variance** $0{,}035$

Au point $x_0 = 0{,}25$, sur 30 apprentissages.

NOUVEAU EXPÉRIENCE

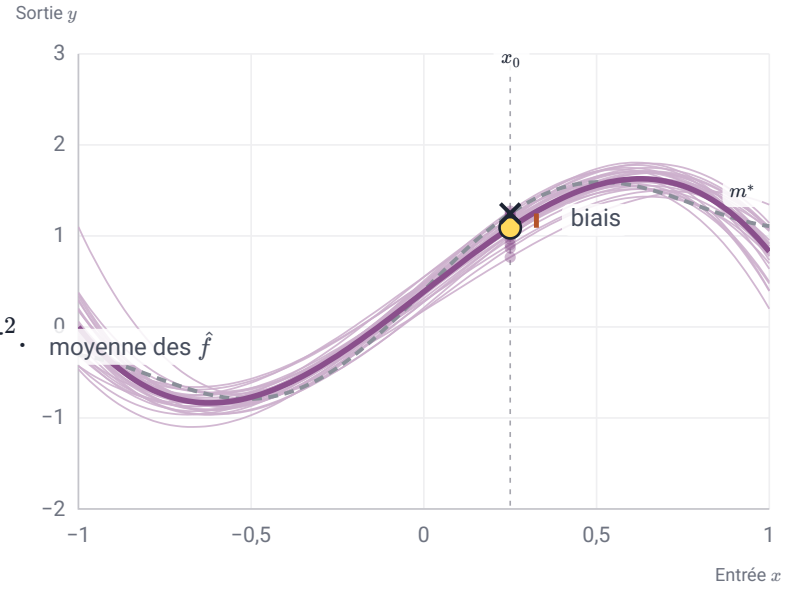
Décomposer l’erreur en un point

En $x_0 = 0{,}25$, l’erreur attendue réunit **biais au carré, variance et bruit**.

Changez le degré et comparez les barres. Les valeurs affichées sont estimées avec trente modèles.

$$\mathbb{E}[(Y - \hat{f}(x_0))^2] = \text{biais}^2 + \text{variance} + \sigma^2.$$

Nouvelle sortie Y, indépendante de l’apprentissage ; bruit centré, de variance σ^2.



biais^2		0,025
variance		0,013
σ^2		0,078
total		0,116

Le bruit σ^2 reste le même pour tous les degrés.

Degré 3 : $\text{biais}^2 = 0{,}025$**, variance** $0{,}013$

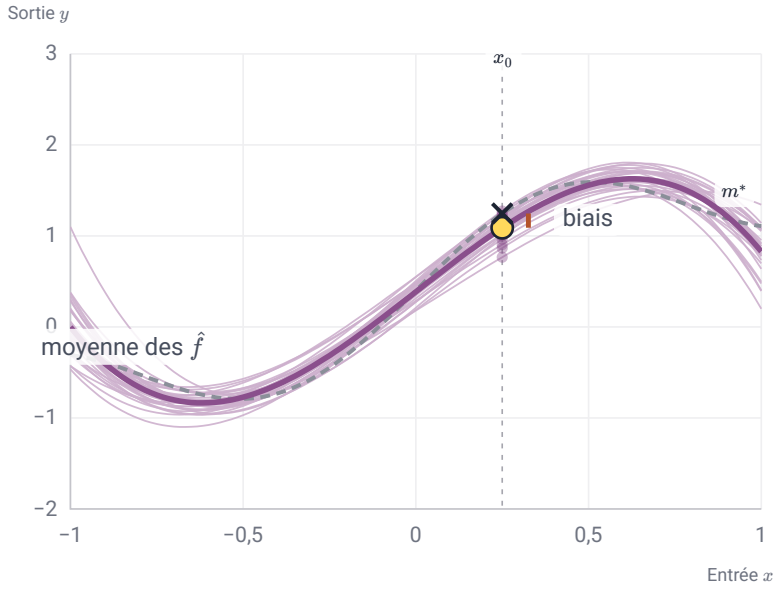
Au point $x_0 = 0{,}25$, sur 30 apprentissages.

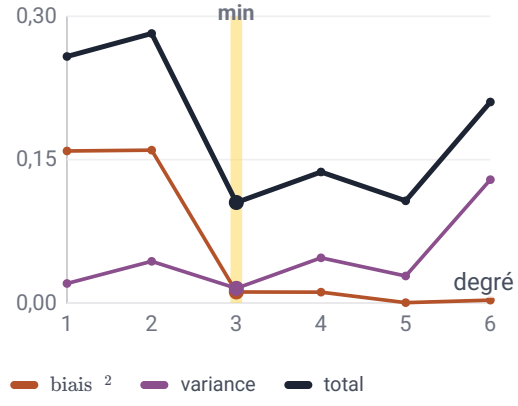
NOUVEAU EXPÉRIENCE

Le compromis

Changez le degré et cherchez la plus faible **erreur moyenne** : elle combine biais, variance et bruit.

Avec trente tirages, les courbes ne sont pas monotones.





Moyennes sur $x \in [-0{,}95\,;\,0{,}95]$.

Degré 3 : erreur moyenne $0{,}105$

biais^2 $0{,}011$ + variance $0{,}015$ + bruit $0{,}078$, moyennés sur x.

DIAPO 27 · FORMULE · 1/2

Apprendre puis valider

Validation ou hold out

On sépare les données : **apprentissage** pour ajuster, **validation** pour comparer. Les indices sont notés $\mathcal{A}$ et $\mathcal{V}$.

Les prétraitements sont appris sur l'apprentissage seulement. Pour des observations liées par sujet ou par date, le découpage doit respecter ces groupes ou l'ordre du temps.

$$
\begin{aligned}
\mathcal{A} \cap \mathcal{V} &= \varnothing, \\
\mathcal{A} \cup \mathcal{V} &= \{1, \dots, n\}, \\
\mathcal{D}_{\text{app}} &= \{(x_i, y_i) : i \in \mathcal{A}\}, \\
\mathcal{D}_{\text{valid}} &= \{(x_i, y_i) : i \in \mathcal{V}\}.
\end{aligned}
$$

DIAPO 27 · FORMULE · 2/2

Choisir le modèle sur la validation

Algorithme · Validation ou Hold-Out

1. **Ajuster le modèle et les prétraitements** sur l'apprentissage seulement.
2. Noter le prédicteur appris $\hat{f}_{\text{app}} = \hat{f}(\cdot; \mathcal{D}_{\text{app}})$.
3. **Prédire** les observations de validation avec ces prétraitements et ce modèle fixes.
4. **Calculer** leur perte moyenne.

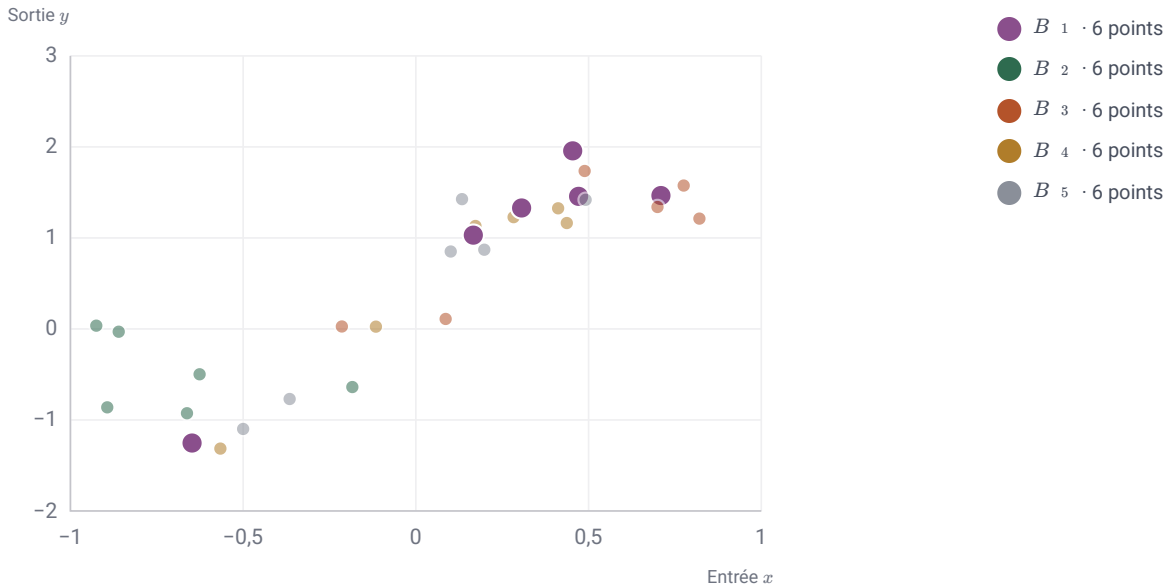
$$\widehat{\mathcal{R}}_{\text{valid}} = \frac{1}{|\mathcal{V}|} \sum_{i \in \mathcal{V}} \ell\big(y_i, \hat{f}_{\text{app}}(x_i)\big).$$

NOUVEAU EXPÉRIENCE

Découper en cinq blocs

Les 30 points forment **cinq blocs de six**, repérés par leur couleur.

Le découpage reste fixe. Chaque bloc servira une fois à valider.



$K = 5$ blocs de 6 observations

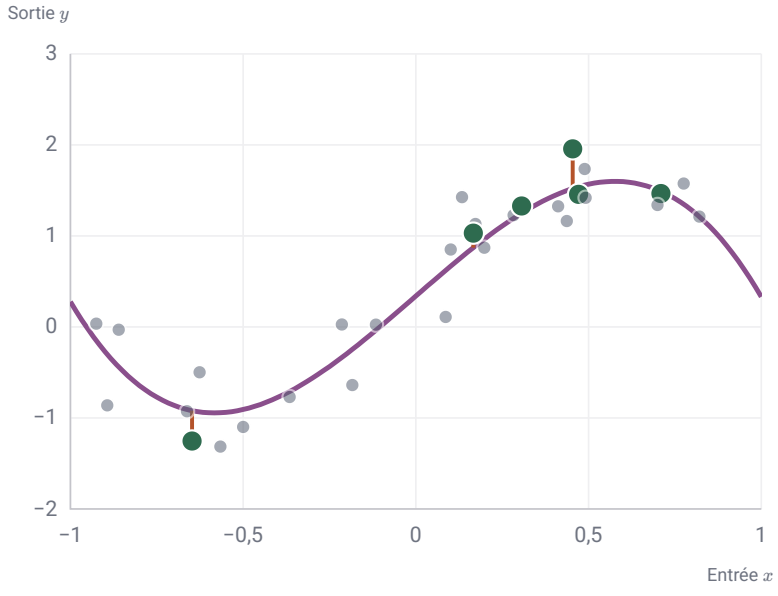
Chaque observation appartient à un seul bloc.

NOUVEAU EXPÉRIENCE

Apprendre sans B_1, valider sur B_1

Le modèle apprend sur **24 points**, sans B_1. Il est évalué sur les **six points de B_1**.

Les segments brique montrent leurs erreurs de prévision.





MSE de validation par pli, degré 3.

Pli 1 : MSE de validation $0{,}057$

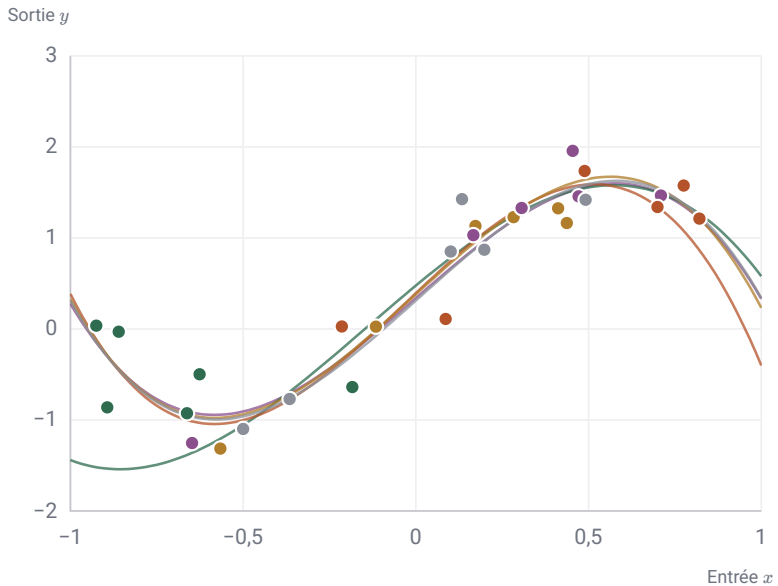
Modèle de degré 3 appris sur 24 points, évalué sur les 6 points de B_1.

NOUVEAU EXPÉRIENCE

Moyenner les cinq erreurs

La moyenne des cinq erreurs estime le risque. Chaque bloc pèse autant puisqu'il contient six points.

Chaque observation est prédite par un modèle qui **ne l'a pas vue**.



B_1		0,057
B_2		1,053
B_3		0,147
B_4		0,062
B_5		0,090
moyenne		0,282

MSE de validation par pli, degré 3.

$\widehat{\mathcal{R}}_{\mathrm{CV}} = 0{,}282$

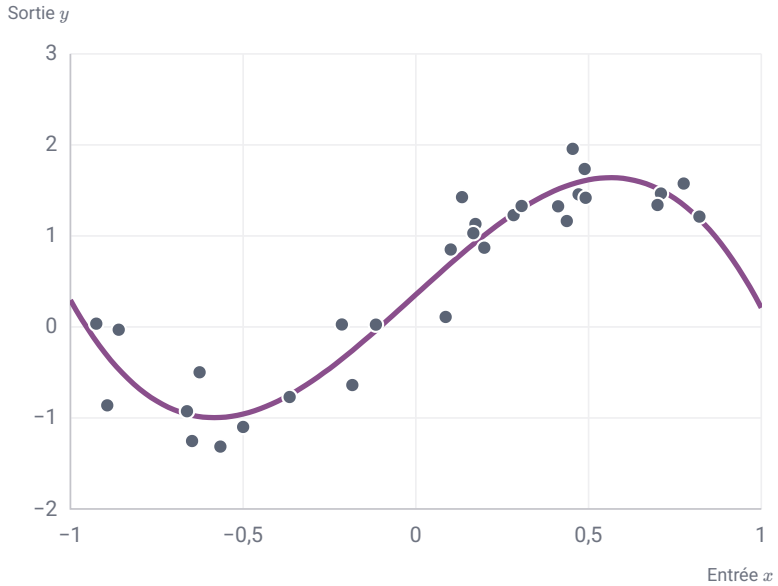
Moyenne des cinq MSE, degré 3.

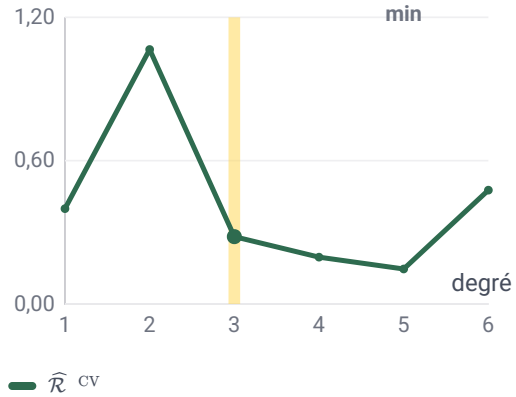
NOUVEAU EXPÉRIENCE

Choisir le degré

Comparez les degrés et retenez la plus faible erreur de validation croisée. Réapprenez ce degré sur les 30 points.

Un test final reste nécessaire : le score ayant servi au choix peut être optimiste.





Erreur de validation croisée selon le degré.

Degré 3 : $\widehat{\mathcal{R}}_{\mathrm{CV}} = 0{,}282$

Le trait mauve est réappris sur les 30 points.

DIAPO 37 · NOTION

Algorithmes linéaires : la suite

> **Next : Algorithmes linéaires**
>
> Le chapitre suivant reprend ces notions pour étudier les **algorithmes linéaires** : leur géométrie, leurs fonctions de prévision et les critères utilisés pour apprendre.