APPRENTISSAGE STATISTIQUE · 2026–2027

Fondements de l’apprentissage statistique

Oumoukelthoum Sidenna

2e année du cycle ingénieur · 90 min · Notes de cours complètes

Plan du chapitre

1. Introduction générale · 10 min
2. Régression vs Discrimination · 12 min
3. Fonction de perte · 15 min
4. Risque · 15 min
5. Décomposition de l’erreur et compromis biais–variance · 18 min
6. Estimation du risque · 15 min
7. Catégorisation · 5 min

DIAPO 01 · NOTION

Vue d’ensemble du cours

Chapitre	Contenu
1	Fondements de l’apprentissage statistique
2	Algorithmes linéaires
3	Algorithmes non linéaires
4	Agrégation
5	Cycle ML & Métriques d’évaluation

DIAPO 02 · NOTION

Plan du cours

1. **Introduction générale :** contexte, problématiques et vocabulaire.
2. **Cadre mathématique de l’apprentissage statistique supervisé :** régression et discrimination, perte, risque, décomposition de l’erreur et estimation du risque.
3. **Catégorisation :** organiser les méthodes et comprendre la progression du cours.

DIAPO 03 · NOTION

Contexte

L’**apprentissage statistique** (*statistical learning*) étudie comment estimer des dépendances à partir d’un ensemble de données et comment modéliser ou comprendre des jeux de données complexes.

> « … explores way of estimating functional dependency from a given collection of data » — Vapnik, 2000.
>
> « … a set of tools for modelling and understanding complex datasets » — James et al., 2013.

DIAPO 04 · NOTION

Deux approches

Selon l’objectif, on peut privilégier un **modèle interprétable**, avec une complexité maîtrisée, ou une **bonne précision prédictive**, quitte à employer un modèle plus complexe.

Ces perspectives sont complémentaires : l'interprétation des modèles peut s'appuyer sur des scores d'importance des variables, et un algorithme de prévision doit aussi être étudié à travers ses propriétés statistiques — biais, variance, convergence.

▼  Précision

Bien expliquer une relation ne garantit pas, à lui seul, une bonne prédiction sur de nouvelles données. L'explication et la prévision sont des objectifs complémentaires dont la qualité doit être évaluée séparément.

Chapitre 01 · Introduction générale

DIAPO 05 · NOTION

Apprentissage statistique et machine learning

Apprentissage Statistique vs Machine Learning

Le **machine learning** s'est développé au sein de l'intelligence artificielle ; l'**apprentissage statistique** au sein de la statistique. Les deux domaines se recouvrent largement et traitent des problèmes supervisés et non supervisés.

- Le machine learning met souvent l'accent sur les applications à grande échelle et la précision prédictive.
- L'apprentissage statistique met souvent l'accent sur les modèles, leur interprétabilité et leur précision.

La frontière est devenue floue et les interactions sont fortes. Le terme « machine learning » bénéficie également d'une forte visibilité.

Chapitre 01 · Introduction générale

DIAPO 06 · NOTION

Problématiques associées à l'apprentissage

Problématique	Objectif
Apprentissage supervisé	Prédire une sortie à partir d'entrées.
Apprentissage non supervisé	Établir une typologie des observations.
Règles d'association	Identifier des liens entre produits ou événements.
Systèmes de recommandation	Prédire les produits susceptibles d'intéresser un utilisateur.

DIAPO 07 · FORMULE

Notations et significations

Notation	Signification
$\mathcal{X}$	Espace des entrées : features, prédicteurs.
$\mathcal{Y}$	Espace des sorties : réponse, étiquette.
$X,\ Y$	Variables aléatoires prenant leurs valeurs dans $\mathcal{X}$ et $\mathcal{Y}$.
(X, Y)	Couple aléatoire décrivant un individu observé.
D_n	Échantillon aléatoire d'apprentissage de n couples.
(x_i, y_i)	Réalisation observée du couple (X_i, Y_i).
f	Fonction de prévision candidate ; $\hat{f}$ désigne celle apprise sur les données.
$y_i,\ \hat{y}_i$	Sortie observée et sortie prédite : $\hat{y}_i = \hat{f}(x_i)$.
$g(x)$	Score réel d'un classifieur ; une règle de décision le transforme en classe $\hat{y}$.
ℓ	Fonction de perte : mesure le coût d'une erreur de prévision.
$\mathcal{R}(f)$	Risque : perte moyenne sur la population.

$$
\begin{gathered}
X \in \mathcal{X}, \qquad Y \in \mathcal{Y}, \\
D_n = \{(X_1, Y_1), \ldots, (X_n, Y_n)\}, \\
f : \mathcal{X} \longrightarrow \mathcal{Y}, \\
\mathcal{R}(f) = \mathbb{E}[\ell(Y, f(X))].
\end{gathered}
$$

Lire la formule –

Les majuscules désignent les variables aléatoires. Les minuscules désignent leurs valeurs observées. Le cadre de départ suppose les couples de D_n indépendants et identiquement distribués.

DIAPO 08 · NOTION

Problème d'apprentissage supervisé

On dispose d'une variable de sortie — **variable dépendante, réponse ou cible** — et d'un vecteur de p **variables explicatives**, également appelées entrées, prédicteurs, covariables ou features.

- En **régression**, la cible est quantitative : un prix ou une tension artérielle, par exemple.
- En **discrimination**, elle prend des valeurs dans un ensemble fini et non ordonné : survie/mort, chiffre de 0 à 9, classe de tissu.

Les couples entrée–sortie disponibles sont les observations, exemples ou instances à partir desquels l'algorithme apprend.

DIAPO 09 · NOTION

Apprentissage non supervisé

Il n'y a pas de variable de sortie fournie : seules les mesures ou caractéristiques des observations sont disponibles. L'objectif est exploratoire.

- Trouver des groupes d'observations qui se ressemblent.
- Trouver des variables qui se comportent de manière similaire.
- Trouver des combinaisons linéaires de variables capturant une grande part de la variance.

L'absence de vérité terrain rend l'évaluation plus difficile. Une méthode non supervisée peut aussi servir de prétraitement, par exemple une réduction de dimension avant une classification supervisée.

DIAPO 10 · EXERCICE

Le prix Netflix

La compétition commence en **octobre 2006**. Netflix fournit environ **100 millions de notes**, de **480 000 clients** pour près de **18 000 films**. Les notes vont de **1 à 5** ; près de **99 %** des cases de la matrice client–film sont vides.

Les participants prédisent environ **3 millions de notes réservées** : une moitié sert au classement public, l'autre au **test final**.

Le RMSE de référence sur le test est **0,9525**, soit environ **0,953**. Une réduction de **10 %** permet de remporter **un million de dollars**.

À VOUS DE JOUER

Le prix Netflix · question du cours

S'agit-il d'un problème supervisé ou non supervisé ? Identifier les entrées, la sortie et les exemples observés.

▼ Solution commentée

La tâche de prédiction des notes est **supervisée** : chaque note connue fournit une sortie observée associée à un couple client–film. Les entrées décrivent le client et le film ; la sortie est une note numérique. On peut donc la traiter comme une tâche de régression. Le grand nombre de couples sans note ne transforme pas cette tâche en apprentissage non supervisé.

▼ Précision

Le RMSE est la **racine** de la MSE, dans la même unité que les notes. Le RMSE de référence du classement public est 0,9514 ; celui du test final est 0,9525.

Sources : Bennett et Lanning, Netflix, 2007 ; analyse statistique du concours.

DIAPO 11 · FORMULE

Régression vs discrimination · données et objectifs

$$d_n = \{(x_1, y_1), \dots, (x_n, y_n)\},$$
$$x_i \in \mathcal{X}, \qquad y_i \in \mathcal{Y}.$$

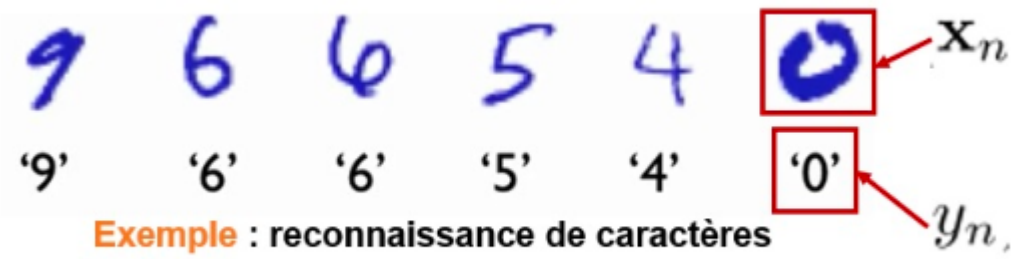
Lire la formule –

d_n désigne les données observées. n est le nombre d'exemples disponibles ; chaque entrée x_i est associée à une sortie y_i.

Objectifs

1. **Expliquer** les mécanismes liant les entrées aux sorties.
2. **Prédire « au mieux »** la sortie associée à une nouvelle entrée.

Une fonction de prévision est choisie en fonction d'un critère de qualité. Ce critère sera formalisé par une fonction de perte.



Reconnaissance de caractères : l'image est l'entrée, le chiffre identifié est la sortie.

Chapitre 01 · Régression vs Discrimination

DIAPO 12 · NOTION

Régression vs discrimination · vocabulaire

Vocabulaire

Lorsque la variable à expliquer est **quantitative**, on parle de **régression**. Lorsqu'elle est qualitative, avec un ensemble fini de classes, on parle de **discrimination** ou de **classification supervisée** (*classification*).

La nature des entrées peut être variée : quantitative, qualitative, ordinale, image ou autre représentation. C'est la nature de la **sortie** qui détermine cette distinction.

Sortie y_i	Entrée x_i	Problème
Chiffre	Image	Discrimination
Prix de voiture	Caractéristiques du véhicule	Régression

Chapitre 01 · Régression vs Discrimination

NOUVEAU NOTION

Fil rouge · chats et chiens

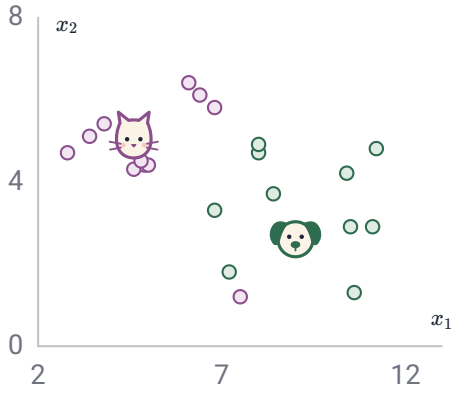
Un animal est décrit par deux mesures : son poids x_{i1} et la longueur de son pelage x_{i2}. Prédire l'**espèce** $y_i \in \{\text{chat}, \text{chien}\}$ est un problème de **discrimination**. Prédire le **poids** à partir du pelage serait une **régression**.

ANIMAL → MESURES → ÉTIQUETTE

→ $x = (4{,}6\,;\,5{,}0)$ → $y = 0$ · **chat**

→ $x = (9{,}0\,;\,2{,}6)$ → $y = 1$ · **chien**

Le dessin sert seulement à reconnaître l'animal à l'écran ; le modèle ne reçoit que les nombres x_1 et x_2.



Chaque animal devient un point du plan ; la couleur porte l'étiquette.

DIAPO 13 · FORMULE

Un début de formalisation mathématique

Les données observées sont une réalisation d'un n**-échantillon** de loi inconnue. Le plus souvent, nous supposerons les couples indépendants et identiquement distribués selon une même loi, notée $\mathbb{P}$.

À partir de ces observations, on cherche une fonction qui relie les entrées aux sorties. Il faut ensuite préciser un critère permettant de comparer les fonctions de prévision : une **fonction de perte**.

$$D_n = \{(X_i, Y_i) : i = 1, \dots, n\},$$
$$(X_i, Y_i) \overset{\text{i.i.d.}}{\sim} \mathbb{P},$$
$$f : \mathcal{X} \longrightarrow \mathcal{Y}, \qquad f(x_i) \approx y_i.$$

Lire la formule –

La loi $\mathbb{P}$ est inconnue. L'ajustement sur les exemples observés est une première exigence ; la généralisation à de nouvelles observations reste l'objectif.

DIAPO 14 · FORMULE

Fonction de prévision et paramètres

En outre…

Une fonction de prévision dépend des paramètres du modèle, notés θ. Dans les **exemples affines ci-dessous**, $\theta = (w, b)$: coefficients et terme constant.

$$\hat{y} = \hat{f}(x), \qquad \hat{f} = f_\theta, \quad \theta = (w, b)$$

Lire la formule –

Dans ces modèles affines, w contient les coefficients et b le terme constant ; l'apprentissage les détermine. Pour la décision SVM, on prend $\hat{y} = +1$ lorsque $g(x) = 0$.

Modèle	Fonction de prévision	Paramètres
Régression linéaire	$\hat{y} = w^\top x + b$	$\theta = (w, b)$
SVM binaire	$\hat{y} = \operatorname{sign}(g(x)), \quad g(x) = w^\top x + b$; à score nul, choisir $+1$.	$\theta = (w, b)$

DIAPO 15 · FORMULE

Fonction de perte

Définition

Une **fonction de perte** mesure le coût d'une prévision. Elle est mesurable, non négative et, dans les exemples suivants, nulle lorsque la prévision est exacte.

$$\ell : \mathcal{Y} \times \mathcal{Y} \longrightarrow \mathbb{R}^+,$$
$$\ell(y, y) = 0, \qquad \ell(y, \hat{y}) > 0 \text{ si } y \neq \hat{y}.$$

Lire la formule –
y est observé ; $\hat{y}$ est prédit. Ici la perte compare deux sorties ; la perte charnière du SVM compare l'étiquette au score réel $g(x)$.

▼ Précision
Dans la définition, la première égalité est $\ell(y, y) = 0$. Elle ne dit pas que toutes les paires cible–prévision ont une perte nulle.

$$\ell_p(y, \hat{y}) = \frac{1}{p}|y - \hat{y}|^p, \qquad p \geq 1$$

Lire la formule –
En régression réelle, le support introduit les pertes L^p avec le facteur $1/p$. Ce facteur est conservé pour les cas particuliers ci-dessous.

Valeur de p	Perte	Expression
$p = 1$	Perte absolue	$\lvert y - \hat{y}\rvert$
$p = 2$	Perte quadratique	$\frac{1}{2}(y - \hat{y})^2$

$$\mathcal{Y} = \{-1, +1\}, \qquad \ell(y, \hat{y}) = \mathbf{1}_{\{y \neq \hat{y}\}}$$

Lire la formule –
En discrimination binaire, la perte 0–1 vaut 0 si la classe est correcte et 1 si elle est incorrecte.

DIAPO 16 · FORMULE

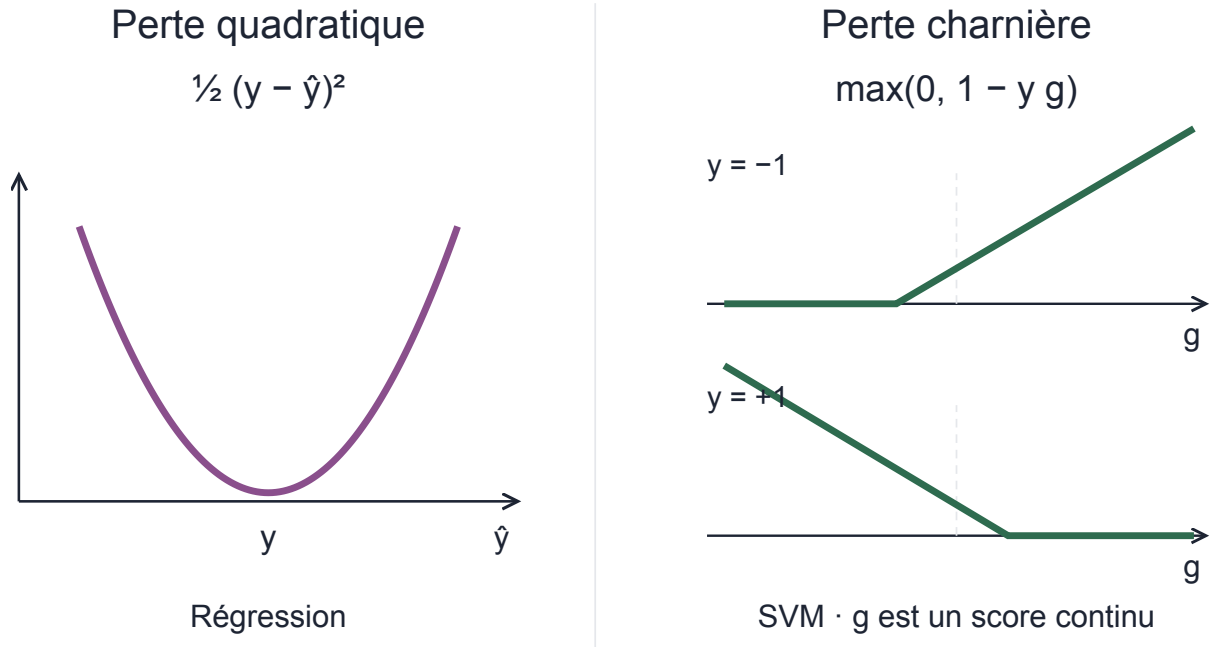
Choix de la fonction de perte

Modèle	Prévision ou décision	Perte d'entraînement
Régression linéaire	$\hat{y} = w^\top x + b$	$\frac{1}{2}(y - \hat{y})^2$
SVM	Classe : $\operatorname{sign}(g(x))$; score : $g(x) = w^\top x + b$	$\max(0,\, 1 - y\, g(x))$

$$g(x) = w^\top x + b, \qquad \hat{y} = \operatorname{sign}(g(x)),$$
$$\ell_{\text{hinge}}(y, g(x)) = \max(0, 1 - y\, g(x)).$$

Lire la formule –
y est observé ; $g(x)$ est le score ; $\hat{y} \in \{-1, +1\}$ est prédit. On choisit $+1$ lorsque le score est nul : c'est notre convention pour la décision par signe.

▼ Précision
Dans la ligne SVM, le score $g(x)$ entre dans la perte charnière ; le signe sert à décider la classe. Utiliser uniquement la classe ferait disparaître l'information de marge.



Demi-perte quadratique en régression et perte charnière appliquée au score continu g du SVM.

DIAPO 17 · FORMULE

Risque

On s'intéresse au **comportement moyen** de la fonction de perte. Pour une fonction de prévision fixée, sa performance est mesurée par l'espérance de la perte sur un couple entrée–sortie de la population cible.

$$\mathcal{R}(f) = \mathbb{E}\big[\ell(Y, f(X))\big]$$

Lire la formule –
$\mathcal{R}(f)$ est appelé risque ou erreur de généralisation. Le couple futur (X, Y) suit la même loi $\mathbb{P}$ que les données d'apprentissage et est indépendant de cet échantillon.

DIAPO 18 · FORMULE

Fonction de prévision optimale

Aspect théorique : pour une perte donnée, chercher la fonction ayant le plus petit risque. Une telle fonction, si elle existe, est une fonction de prévision optimale.

$$f^* \in \arg\min_f \mathcal{R}(f),$$
$$\mathcal{R}(f^*) \leq \mathcal{R}(f) \quad \text{pour toute } f.$$

Lire la formule –
Le choix optimal dépend de la perte et, le plus souvent, de la loi inconnue $\mathbb{P}$. Il constitue une référence théorique.

Aspect pratique

La loi étant inconnue, nous ne pouvons généralement pas calculer directement la fonction optimale. Nous cherchons un estimateur construit à partir des données dont le risque est proche de celui de l'oracle.

$$\hat{f} = \hat{f}(\cdot; D_n),$$
$$\mathcal{R}(\hat{f}) \approx \mathcal{R}(f^*).$$

Lire la formule –
$\hat{f}$ est apprise sur D_n ; f^* est la référence optimale. Un autre échantillon peut donner une autre $\hat{f}$.

DIAPO 19 · FORMULE

Intuition

À une valeur d'entrée fixée, plusieurs valeurs de la sortie peuvent être observées. Quelle prévision représente alors une bonne valeur ? Pour la perte quadratique, la réponse est la **moyenne conditionnelle** de la sortie sachant cette entrée.

$$m^*(x) = \mathbb{E}[Y \mid X = x]$$

Lire la formule –

L'espérance conditionnelle est la valeur moyenne de Y lorsque $X = x$. Elle est optimale sous perte quadratique ; cette propriété dépend du choix de la perte.

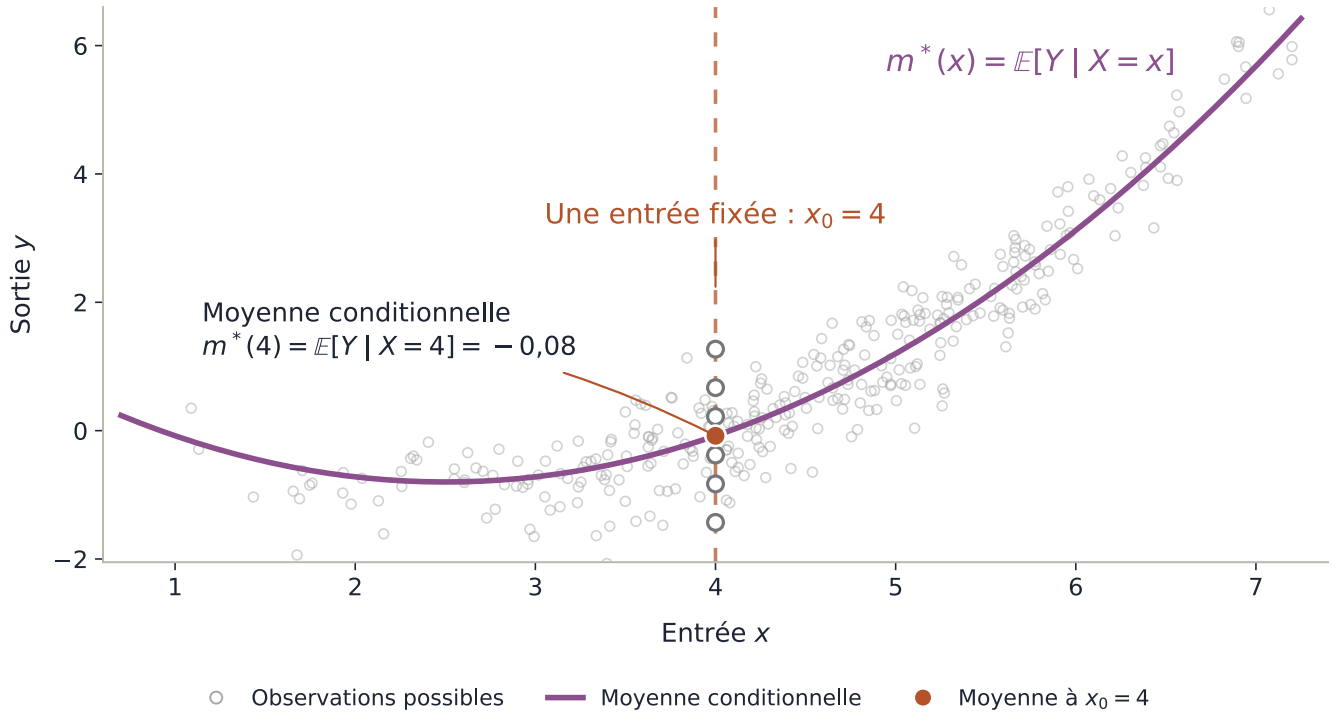


Illustration synthétique : la courbe est la vraie moyenne conditionnelle, pas une estimation.

Illustration synthétique redessinée : à $x_0 = 4$, plusieurs sorties sont possibles. La courbe mauve représente $m^*(x) = \mathbb{E}[Y \mid X = x]$, optimale sous perte quadratique.

DIAPO 20 · FORMULE

Cas de la régression

$$\mathcal{Y} = \mathbb{R}, \qquad f : \mathcal{X} \longrightarrow \mathbb{R},$$
$$\mathcal{R}(f) = \mathbb{E}[(Y - f(X))^2],$$
$$m^*(x) = \mathbb{E}[Y \mid X = x].$$

Lire la formule –

f est une fonction candidate ; sous perte quadratique, l'optimum f^* est m^*, la moyenne conditionnelle généralement inconnue. On suppose des moments d'ordre deux finis.

▼ Précision

Cette partie écrit le risque quadratique **sans le facteur** $\frac{1}{2}$. Multiplier toute la perte par une constante positive change les valeurs du risque, mais pas le prédicteur qui le minimise.



À VOTRE AVIS ?

Question du cours

Comment écrire le risque en discrimination ? Utiliser la perte 0–1.

Réponse

La perte vaut 1 si la classe est incorrecte, 0 sinon :

$$\mathcal{R}(f) = \mathbb{E}[\mathbf{1}_{\{f(X) \neq Y\}}] = \mathbb{P}(f(X) \neq Y).$$

Le prédicteur optimal choisit une classe de probabilité conditionnelle maximale :

$$f^*(x) \in \operatorname*{argmax}_{k \in \mathcal{Y}} \mathbb{P}(Y = k \mid X = x).$$

En cas d'égalité, on fixe une convention de départage.

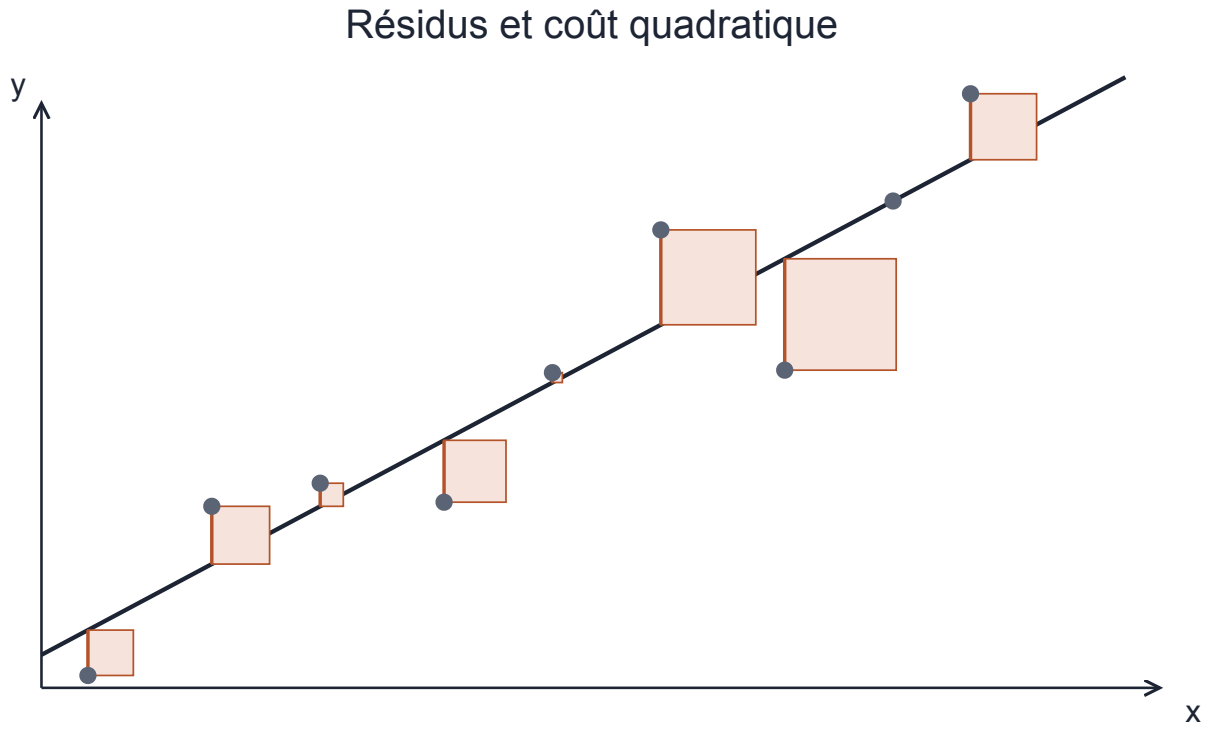


Schéma illustratif redessiné : chaque carré représente le carré d'un résidu vertical.

Chapitre 01 · Risque

DIAPO 21 · NOTION

Récapitulatif

Recap

Objet	Rôle
Données d_n	Observations issues d'un échantillon i.i.d. de loi inconnue $\mathbb{P}$.
Prédicteur f	Transformer une entrée en prévision.
Coût $\ell(Y, f(X))$	Mesurer la perte sur un couple entrée–sortie.
Risque $\mathcal{R}(f)$	Moyenner ce coût sur la population.
Oracle f*	Minimiser le risque ; dépend de la loi inconnue.

Chapitre 01 · Risque

DIAPO 22 · NOTION

Objectif d'apprentissage

Objectif

Construire un algorithme de prévision qui **généralise bien sur de nouvelles données** : le risque du prédicteur appris doit se rapprocher du risque optimal.

Ses performances dépendent du **choix du modèle et de sa complexité**, de la **quantité de données disponibles** et du **compromis biais–variance**.

DIAPO 23 · FORMULE

Décomposition de l'erreur : biais, variance et bruit

Pour une entrée fixée, l'erreur quadratique attendue se décompose en **biais au carré**, **variance** et **bruit**.

m^* est la vraie moyenne conditionnelle ; $\hat{f}$ est le prédicteur appris. On suppose un bruit de variance constante, des moments d'ordre deux finis et une cible future indépendante de l'apprentissage.

$$m^*(x) = \mathbb{E}[Y \mid X = x],$$
$$Y = m^*(X) + \varepsilon, \qquad \mathbb{E}[\varepsilon \mid X] = 0.$$

Lire la formule –
Y est une sortie aléatoire, $m^*(x)$ une moyenne théorique et $\hat{f}(x)$ une prédiction apprise.

$$\mathbb{E}\Big[(Y - \hat{f}(X))^2 \mid X = x\Big] = \underbrace{\Big(m^*(x) - \mathbb{E}[\hat{f}(x)]\Big)^2}_{\text{biais au carré}} + \underbrace{\mathbb{E}\Big[(\hat{f}(x) - \mathbb{E}[\hat{f}(x)])^2\Big]}_{\text{variance}} + \underbrace{\operatorname{Var}(\varepsilon)}_{\text{bruit}}.$$

Lire la formule –
Les espérances impliquant $\hat{f}$ portent sur les échantillons d'apprentissage possibles. La variance du bruit est supposée constante.

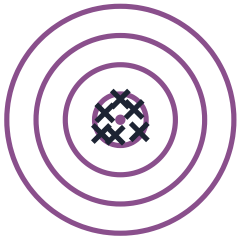
▼ Précision
Si la variance du bruit dépend de l'entrée, le terme de bruit au point considéré est $\operatorname{Var}(Y \mid X = x)$. La formule avec $\operatorname{Var}(\varepsilon)$ correspond au cas d'une variance conditionnelle constante.

DIAPO 24 · NOTION

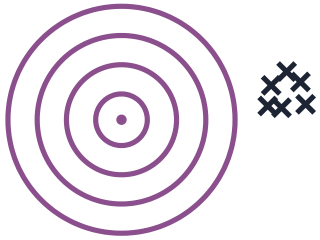
Compromis biais–variance

Compromis Bias-Variance · Biais

Le **biais** est la différence entre la prévision moyenne du modèle et la valeur réelle qu'il cherche à estimer. Un modèle trop restrictif peut garder un décalage systématique même lorsque l'on répète l'apprentissage.



Biais faible



Biais élevé

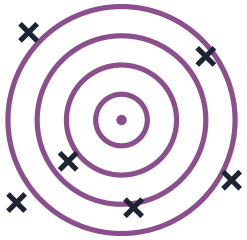
Biais faible ou élevé : comparer la position moyenne des impacts au centre de la cible.

Compromis Bias-Variance · Variance

La **variance** mesure à quel point les prévisions changent lorsque les données d'apprentissage changent. On compare des modèles appris sur différents échantillons provenant du même problème.



Variance faible

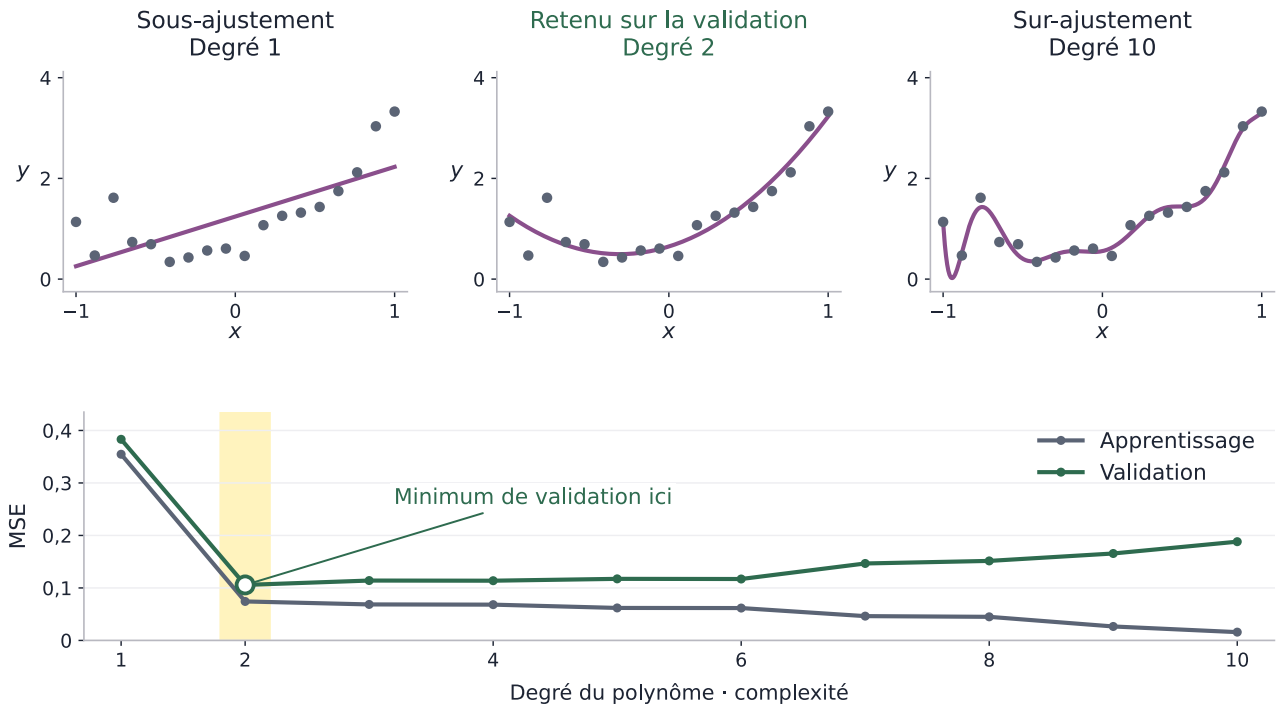


Variance élevée

Variance faible ou élevée : comparer la dispersion des impacts, indépendamment de leur centrage.

DIAPO 25 · NOTION

Sous-ajustement et sur-ajustement



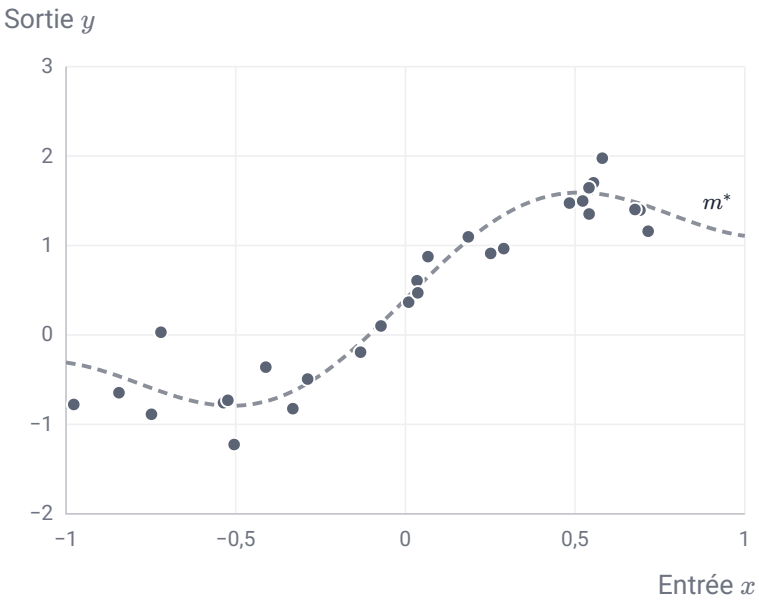
Mêmes 18 observations d’apprentissage dans les trois ajustements · 90 observations de validation

Exemple synthétique : ces courbes illustrent un cas, pas une règle de diagnostic universelle.

Exemple synthétique : trois polynômes appris sur les mêmes données. La validation retient ici le degré 2 ; une faible erreur d’apprentissage ne suffit pas.

NOUVEAU EXPÉRIENCE

Une relation, du bruit



MODÈLE DES DONNÉES

$$y = m^*(x) + \varepsilon$$

BRUIT

$$\sigma^2 = 0{,}078$$

Erreur quadratique attendue sur une nouvelle réponse : au moins σ^2.

Un échantillon de 28 points

Les pointillés représentent m^*, la relation moyenne réelle, inconnue en pratique.

Les 28 points suivent la relation moyenne réelle m^* (pointillés), avec du bruit. Un autre tirage donnerait d’autres points.

Cette relation est connue ici parce que les données sont simulées.

Détails · Le modèle des données

On simule $y = m^*(x) + \varepsilon$, avec $m^*(x) = 0{,}4 + 1{,}2x + 0{,}65\sin(4x)$. Le bruit est gaussien, centré, indépendant de x, et sa variance vaut $\sigma^2 = 0{,}28^2$.

Chaque échantillon contient 28 points. En pratique, la relation m^* et le bruit ne sont pas connus.

À votre avis ?

Avec un autre échantillon, obtiendrait-on le même modèle ?

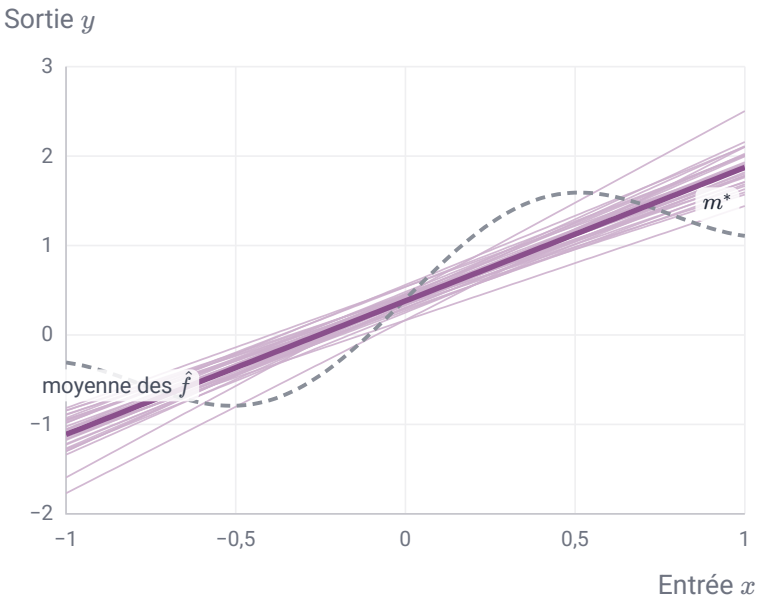
▼ **Réponse**

Non : le modèle appris dépend des points tirés. La variance mesure cette dépendance.

Mêmes données que l’expérience « Répéter l’apprentissage » : 30 échantillons indépendants de 28 points, $m^*(x) = 0{,}4 + 1{,}2x + 0{,}65\sin(4x)$, bruit gaussien d’écart type $0{,}28$. Variance calculée avec division par 30.

NOUVEAU EXPÉRIENCE

Un modèle simple, trente fois





En $x_0 = 0{,}25$, degré 1.

Degré 1 : $\text{biais}^2 = 0{,}243$**, variance** $0{,}011$
Au point $x_0 = 0{,}25$, sur 30 apprentissages.

Trente échantillons, trente droites apprises $\hat{f}$. Elles se ressemblent : **variance faible**.

Leur moyenne (trait épais) reste loin de m^* : **biais élevé**. Comparez le trait épais aux pointillés.

Détails · Pourquoi la droite reste biaisée

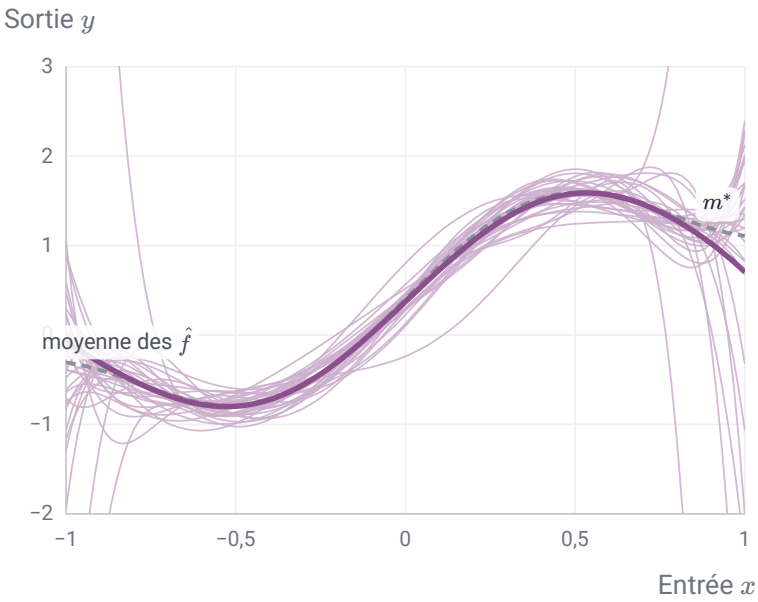
Le degré 1 ne peut pas représenter la relation non linéaire m^*. Davantage de données stabilisent la droite apprise, mais ne donnent pas à ce modèle la souplesse nécessaire pour reproduire m^*.

La moyenne et la dispersion affichées sont estimées sur 30 apprentissages.

Mêmes données que l'expérience « Répéter l'apprentissage » : 30 échantillons indépendants de 28 points, $m^*(x) = 0{,}4 + 1{,}2x + 0{,}65\sin(4x)$, bruit gaussien d'écart type $0{,}28$. Variance calculée avec division par 30.

NOUVEAU EXPÉRIENCE

Un modèle souple, trente fois



biais^2 0,003

variance 0,035

En $x_0 = 0{,}25$, degré 7.

Degré 7 : $\text{biais}^2 = 0{,}003$**, variance** $0{,}035$

Au point $x_0 = 0{,}25$, sur 30 apprentissages.

Au degré 7, la moyenne suit mieux m^* : le **biais baisse**.

Les trente courbes apprises $\hat{f}$ s'écartent davantage, surtout aux bords : la **variance augmente**. Comparez leur dispersion.

Détails · Lire la variance

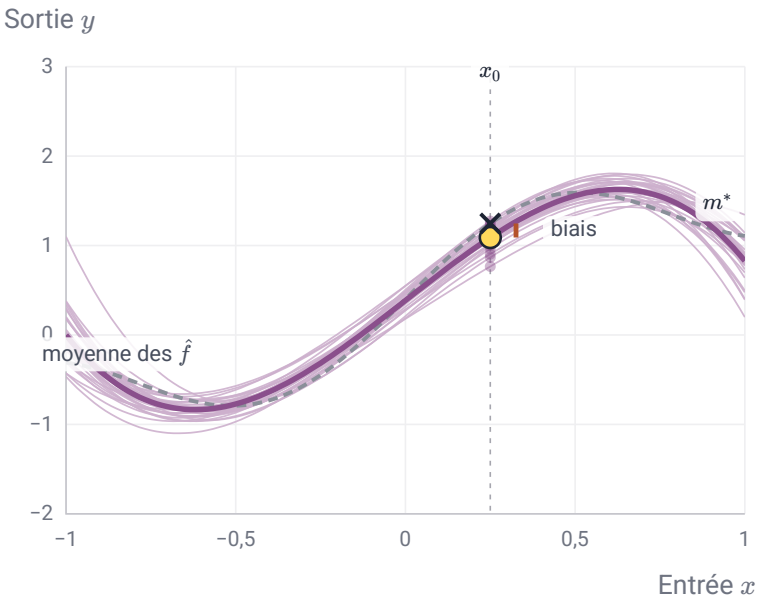
Chaque courbe $\hat{f}$ est apprise sur son propre échantillon. La variance mesure la dispersion des prévisions $\hat{f}(x)$ entre ces apprentissages, pour une même entrée x.

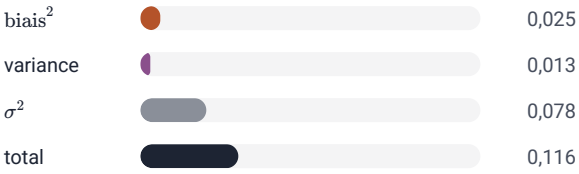
Une faible erreur d'apprentissage ne suffit pas à conclure que la variance est faible.

Mêmes données que l'expérience « Répéter l'apprentissage » : 30 échantillons indépendants de 28 points, $m^*(x) = 0{,}4 + 1{,}2x + 0{,}65\sin(4x)$, bruit gaussien d'écart type $0{,}28$. Variance calculée avec division par 30.

NOUVEAU EXPÉRIENCE

Décomposer l’erreur en un point





Le bruit σ^2 reste le même pour tous les degrés.

Degré 3 : $\text{biais}^2 = 0{,}025$**, variance** $0{,}013$
Au point $x_0 = 0{,}25$, sur 30 apprentissages.

En $x_0 = 0{,}25$, l’erreur attendue réunit **biais au carré, variance et bruit**.

Changez le degré et comparez les barres. Les valeurs affichées sont estimées avec trente modèles.

Détails · La décomposition et les valeurs

Pour une nouvelle sortie $Y = m^*(x_0) + \varepsilon$, indépendante de l’échantillon d’apprentissage, avec un bruit centré de variance σ^2 :

$$\mathbb{E}\big[(Y - \hat{f}(x_0))^2\big] = \text{biais}^2 + \text{variance} + \sigma^2.$$

Le biais compare $\mathbb{E}[\hat{f}(x_0)]$ à $m^*(x_0)$. La variance mesure la dispersion de $\hat{f}(x_0)$ entre les échantillons.

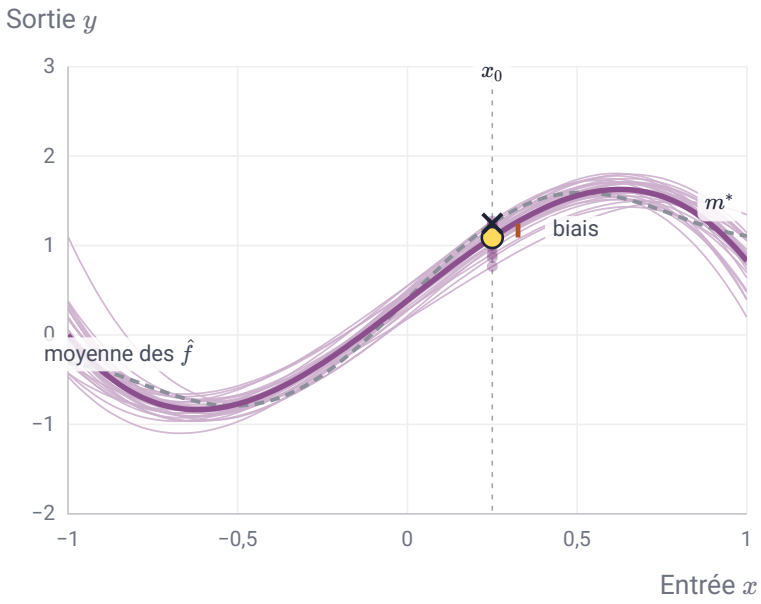
Degré 1 : $\text{biais}^2 = 0{,}243$, variance $0{,}011$. Degré 7 : $0{,}003$ et $0{,}035$. Le bruit reste $\sigma^2 = 0{,}28^2$.

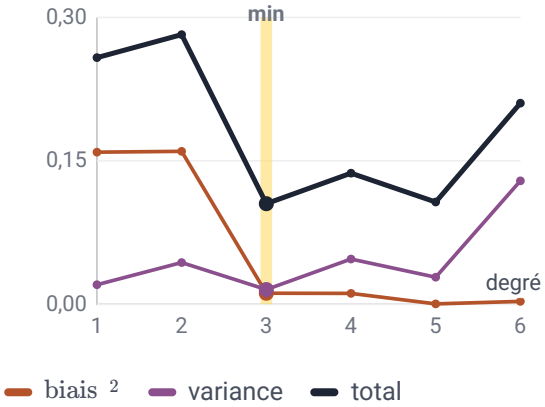
Ces estimations sur 30 modèles ne varient pas nécessairement de façon monotone avec le degré.

Mêmes données que l’expérience « Répéter l’apprentissage » : 30 échantillons indépendants de 28 points, $m^*(x) = 0{,}4 + 1{,}2x + 0{,}65\sin(4x)$, bruit gaussien d’écart type $0{,}28$. Variance calculée avec division par 30.

NOUVEAU EXPÉRIENCE

Le compromis





biais ^{2} variance total

Moyennes sur $x \in [-0{,}95\,;\,0{,}95]$.

Degré 3 : erreur moyenne $0{,}105$

biais^2 $0{,}011$ + variance $0{,}015$ + bruit $0{,}078$, moyennés sur x.

Changez le degré et cherchez la plus faible **erreur moyenne** : elle combine biais, variance et bruit.

Avec trente tirages, les courbes ne sont pas monotones.

Détails · Ce que moyenne le graphique

Pour chaque degré, on moyenne le biais au carré et la variance sur 39 positions $x \in [-0{,}95\,;\,0{,}95]$, puis on ajoute σ^2.

Un modèle plus souple peut réduire le biais tout en augmentant la variance. Le compromis dépend des données ; les estimations obtenues avec 30 tirages ne garantissent pas une baisse ou une hausse à chaque degré.

À votre avis ?

Comment choisir le degré sans connaître m^* ?

▼ **Réponse**

En estimant l’erreur sur des données non utilisées pour apprendre : validation, ou validation croisée (partie suivante).

Mêmes données que l’expérience « Répéter l’apprentissage » : 30 échantillons indépendants de 28 points, $m^*(x) = 0{,}4 + 1{,}2x + 0{,}65\sin(4x)$, bruit gaussien d’écart type $0{,}28$. Variance calculée avec division par 30.

DIAPO 26 · FORMULE

Estimation du risque

La loi du couple entrée–sortie étant inconnue, on ne peut pas calculer directement le risque du prédicteur appris. Une première approche consiste à remplacer l'espérance par une moyenne sur les observations : le **risque empirique**.

$$\mathcal{R}_n(\hat{f}) = \frac{1}{n}\sum_{i=1}^{n} \ell(y_i, \hat{f}(x_i))$$

Lire la formule –
D_n a déjà servi à construire $\hat{f}$. L'erreur sur ce même échantillon peut être trop optimiste pour mesurer la généralisation.

> **Solution**
>
> Évaluer les prévisions sur des observations qui n'ont pas servi à ajuster le modèle. La validation simple et la validation croisée mettent en œuvre ce principe.

DIAPO 27 · FORMULE

Validation ou hold-out

On sépare les données : **apprentissage** pour ajuster, **validation** pour comparer. Les indices sont notés $\mathcal{A}$ et $\mathcal{V}$.

Les prétraitements sont appris sur l'apprentissage seulement. Pour des observations liées par sujet ou par date, le découpage doit respecter ces groupes ou l'ordre du temps.

$$\begin{aligned}
\mathcal{A} \cap \mathcal{V} &= \varnothing, \\
\mathcal{A} \cup \mathcal{V} &= \{1, \dots, n\}, \\
\mathcal{D}_{\text{app}} &= \{(x_i, y_i) : i \in \mathcal{A}\}, \\
\mathcal{D}_{\text{valid}} &= \{(x_i, y_i) : i \in \mathcal{V}\}.
\end{aligned}$$

Lire la formule –
$\mathcal{V}$ désigne la validation, $\mathcal{A}$ l'apprentissage. Ils sont disjoints ; le test final reste réservé à l'évaluation.

Algorithme · Validation ou Hold-Out

1. **Ajuster le modèle et les prétraitements** sur l'apprentissage seulement.
2. Noter le prédicteur appris $\hat{f}_{\text{app}} = \hat{f}(\cdot; \mathcal{D}_{\text{app}})$.

3. **Prédire** les observations de validation avec ces prétraitements et ce modèle fixes.
4. **Calculer** leur perte moyenne.

$$\widehat{\mathcal{R}}_{\text{valid}} = \frac{1}{|\mathcal{V}|} \sum_{i \in \mathcal{V}} \ell\big(y_i, \hat{f}_{\text{app}}(x_i)\big).$$

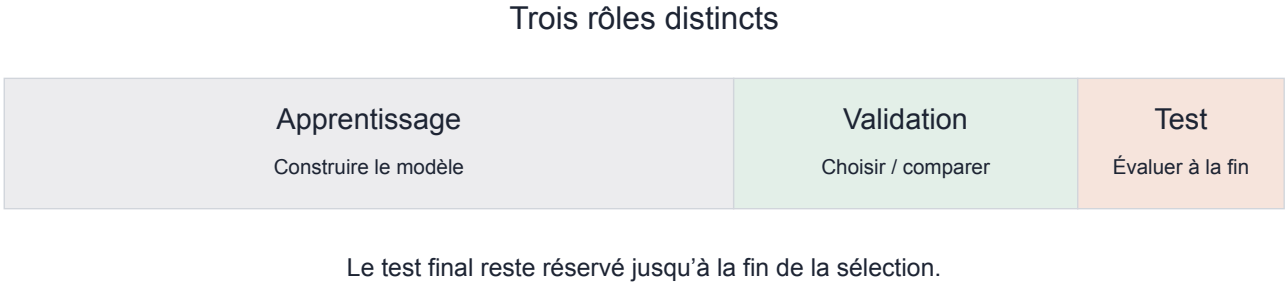
Lire la formule –
Chaque terme utilise une prévision obtenue sans la réponse de validation correspondante. La taille de la partie de validation détermine aussi la précision de cette estimation.

Chapitre 01 · Estimation du risque

DIAPO 28 · NOTION

Illustration de la séparation des données

Illustration



Apprentissage : ajuster ; validation : choisir ; test final : évaluer. $\mathcal{V}$ désigne les indices de validation.

> **Commentaires**
>
> Il faut suffisamment d'observations dans la partie d'apprentissage pour ajuster le modèle, et dans la partie de validation pour estimer convenablement son erreur. Ces deux besoins se partagent un même nombre total d'observations.

Chapitre 01 · Estimation du risque

DIAPO 29 · FORMULE

Validation croisée K-blocs

À chaque pli, apprendre sur les autres blocs, puis prédire et mesurer la perte sur le bloc exclu. On moyenne les K pertes.

Réapprendre aussi les prétraitements dans chaque pli : les apprendre avant le découpage provoquerait une fuite d'information.

$$\{B_1, \dots, B_K\} \text{ partitionne } \{1, \dots, n\},$$
$$\mathcal{B}_k = \{(x_i, y_i) : i \notin B_k\},$$
$$\hat{f}^{(-k)} = \hat{f}(\cdot; \mathcal{B}_k).$$

Lire la formule –
$\hat{f}^{(-k)}$ est appris sans le bloc B_k, puis évalué sur ce bloc. L'exposant $(-k)$ indique les données exclues.

$$\widehat{\mathcal{R}}_k = \frac{1}{|B_k|} \sum_{i \in B_k} \ell(y_i, \hat{f}^{(-k)}(x_i)),$$
$$\widehat{\mathcal{R}}_{\mathrm{CV}} = \frac{1}{K} \sum_{k=1}^{K} \widehat{\mathcal{R}}_k.$$

Lire la formule –
La formule du support accorde le même poids à chaque bloc. Si les blocs ont la même taille, elle revient aussi à moyenner les pertes des observations, chacune ayant été prédite hors de son apprentissage.

Chapitre 01 · Estimation du risque

DIAPO 30 · NOTION

Illustration et choix de K

Commentaires

- Le choix de K appartient à l'utilisateur ; le support cite notamment $K = 10$.
- La répétition évite de dépendre d'une unique séparation apprentissage–validation.
- Elle demande davantage de **temps de calcul**, car le modèle doit être réajusté pour chaque bloc.

▼ Précision
La validation croisée n'est pas toujours plus stable ou plus précise qu'une séparation simple : cela dépend notamment de K, des données et de l'algorithme. Si elle sert à choisir un modèle, le score du candidat retenu ne remplace pas une évaluation finale réservée.

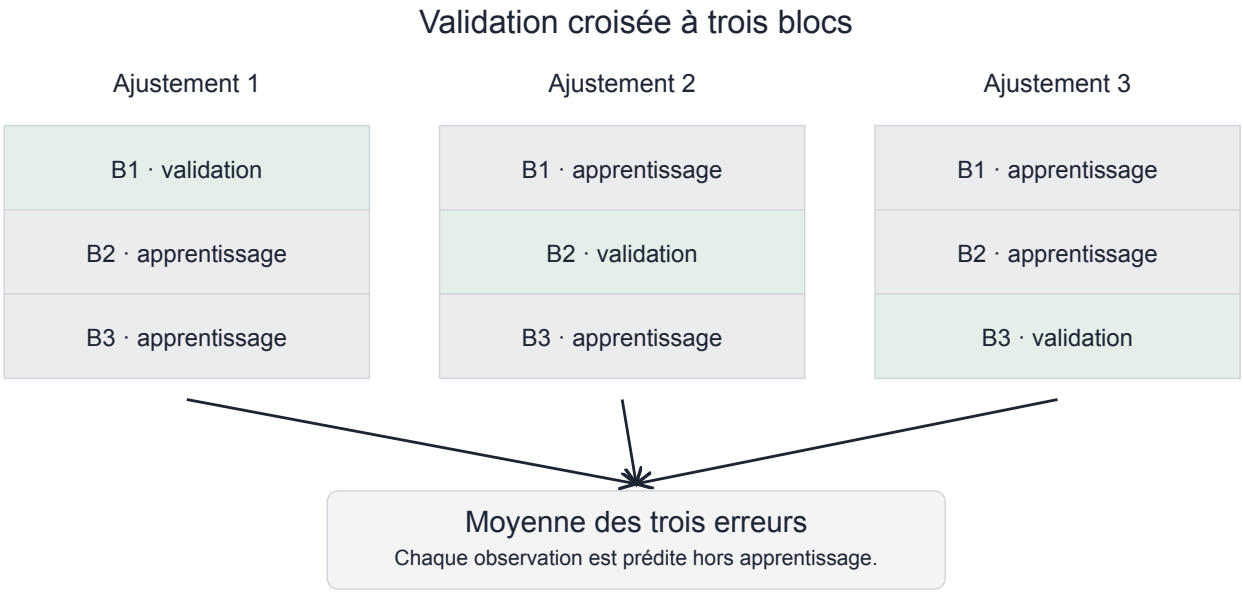
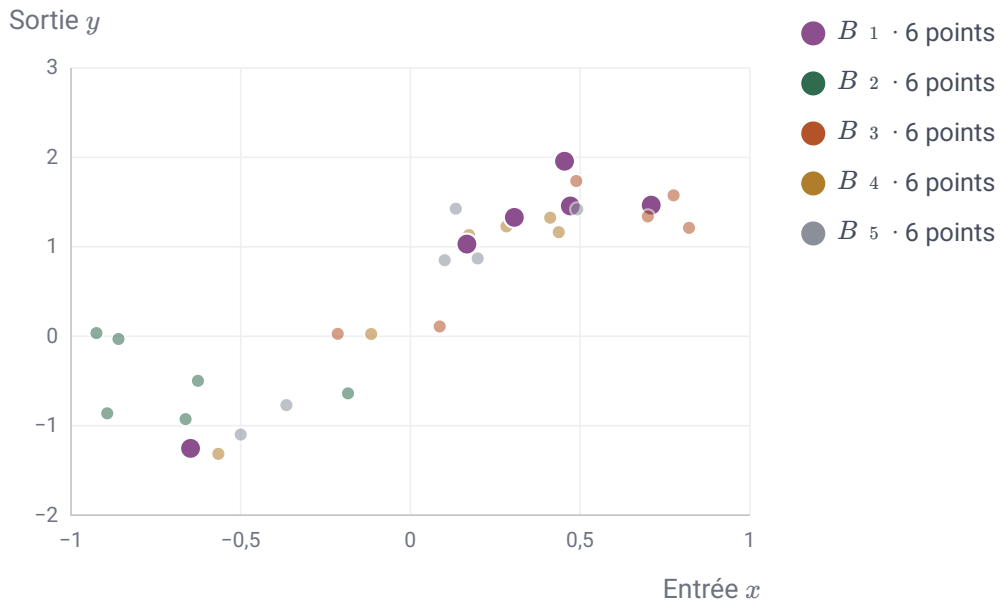


Illustration à trois blocs : apprendre sans B_1, puis sans B_2, puis sans B_3, et agréger les pertes obtenues.

Chapitre 01 · Estimation du risque

NOUVEAU EXPÉRIENCE

Découper en cinq blocs



$K = 5$ blocs de 6 observations

Chaque observation appartient à un seul bloc.

Les 30 points forment **cinq blocs de six**, repérés par leur couleur.

Le découpage reste fixe. Chaque bloc servira une fois à valider.

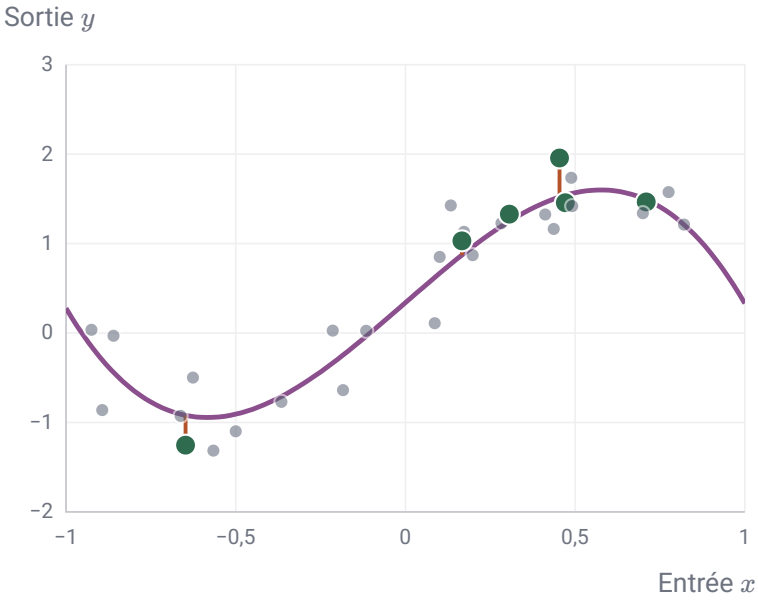
Détails · Les blocs de validation

On note les blocs $B_1, \ldots, B_5$, avec $K = 5$. Ils sont disjoints et réunissent les 30 observations. Leur composition est fixée avant l'apprentissage.

Mêmes 30 observations que l'expérience « Parcourir les blocs » ; blocs fixés avant tout apprentissage (6 observations chacun). Perte : erreur quadratique moyenne (MSE).

NOUVEAU EXPÉRIENCE

Apprendre sans B_1, valider sur B_1





MSE de validation par pli, degré 3.

Pli 1 : MSE de validation $0{,}057$

Modèle de degré 3 appris sur 24 points, évalué sur les 6 points de B_1.

Le modèle apprend sur **24 points**, sans B_1. Il est évalué sur les **six points de** B_1.

Les segments brique montrent leurs erreurs de prévision.

Détails · Calculer l'erreur du premier pli

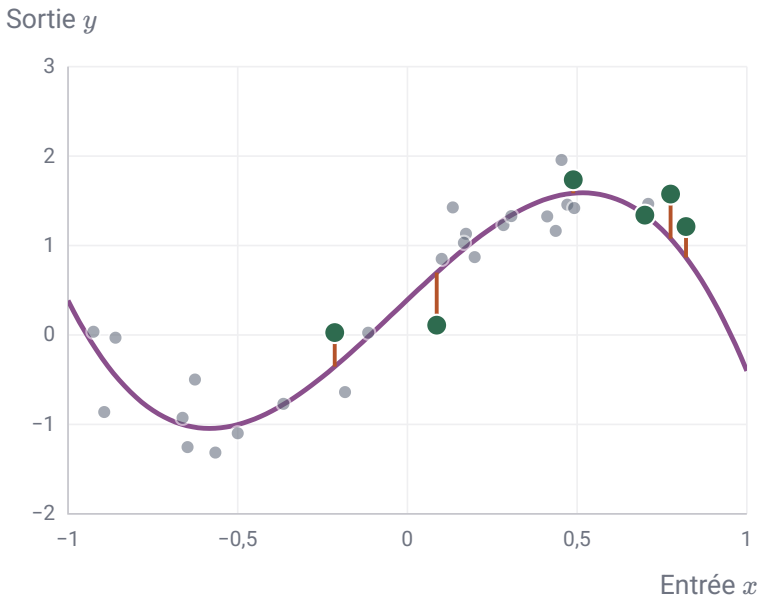
Le modèle $\hat{f}^{(-1)}$ est appris sans B_1, sur $B_2, \ldots, B_5$. Les résidus $y_i - \hat{f}^{(-1)}(x_i)$ du bloc B_1 donnent sa MSE de validation :

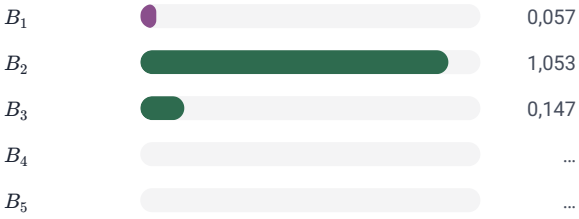
$$\widehat{\mathcal{R}}_1 = \frac{1}{6} \sum_{i \in B_1} (y_i - \hat{f}^{(-1)}(x_i))^2.$$

Mêmes 30 observations que l'expérience « Parcourir les blocs » ; blocs fixés avant tout apprentissage (6 observations chacun). Perte : erreur quadratique moyenne (MSE).

NOUVEAU EXPÉRIENCE

Chaque bloc à son tour





MSE de validation par pli, degré 3.

Pli 3 : MSE de validation $0{,}147$

Modèle de degré 3 appris sur 24 points, évalué sur les 6 points de B_3.

Choisissez un autre bloc : il devient la validation, les quatre autres servent à apprendre.

Le modèle est **réappris à chaque pli** : cinq modèles, cinq erreurs.

Détails · Pourquoi réapprendre cinq fois

Au pli k, on apprend sans B_k, puis on évalue sur B_k. Les points d'apprentissage et de validation changent : les cinq erreurs peuvent donc différer.

À votre avis ?

Pourquoi les cinq erreurs diffèrent-elles ?

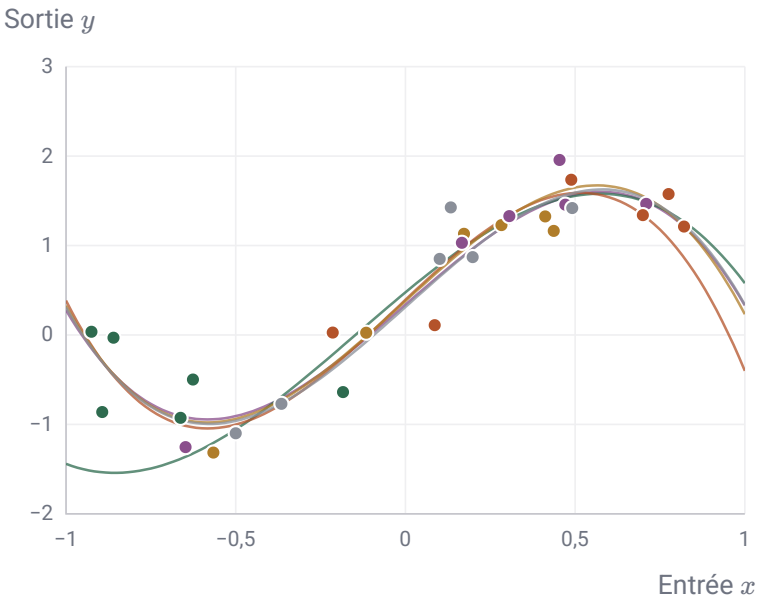
▼ **Réponse**

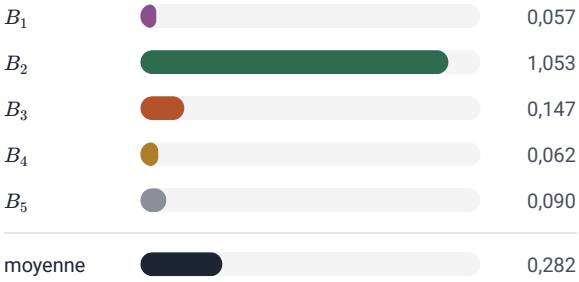
Chaque pli apprend et valide sur des points différents : l'estimation dépend du découpage.

Mêmes 30 observations que l'expérience « Parcourir les blocs » ; blocs fixés avant tout apprentissage (6 observations chacun). Perte : erreur quadratique moyenne (MSE).

NOUVEAU EXPÉRIENCE

Moyenner les cinq erreurs





MSE de validation par pli, degré 3.

$\widehat{\mathcal{R}}_{\mathrm{CV}} = 0{,}282$

Moyenne des cinq MSE, degré 3.

La moyenne des cinq erreurs estime le risque. Chaque bloc pèse autant puisqu'il contient six points.

Chaque observation est prédite par un modèle qui **ne l'a pas vue**.

Détails · La formule de validation croisée

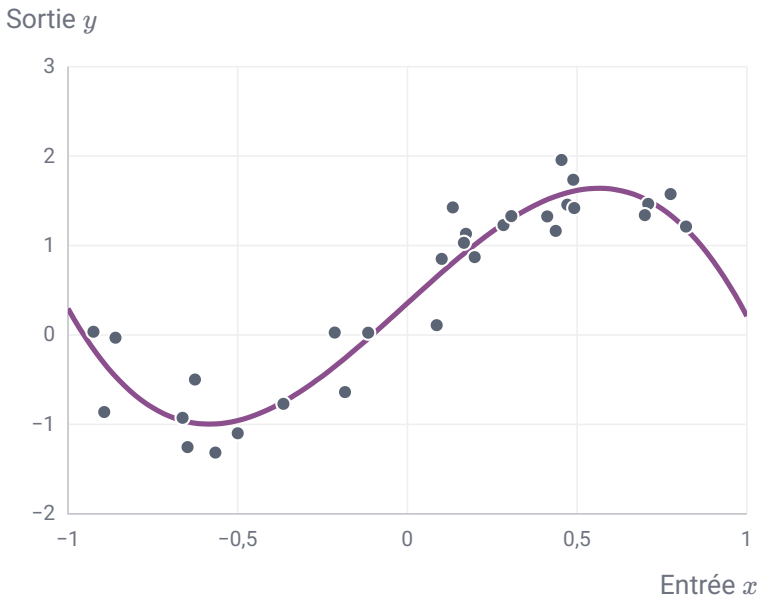
$$\widehat{\mathcal{R}}_{\mathrm{CV}} = \frac{1}{K}\sum_{k=1}^{K} \widehat{\mathcal{R}}_k.$$

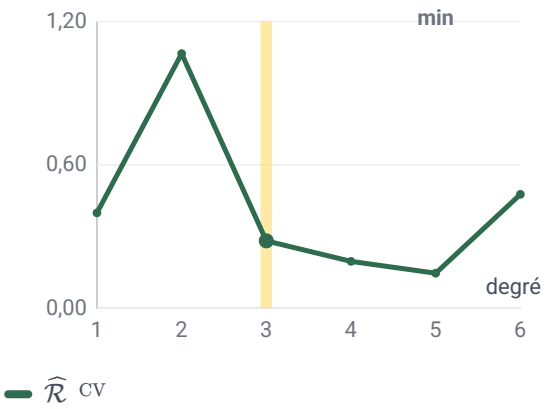
Ici, $K = 5$ et les blocs ont la même taille : cette moyenne correspond aussi à la MSE des 30 prévisions hors apprentissage.

Mêmes 30 observations que l'expérience « Parcourir les blocs » ; blocs fixés avant tout apprentissage (6 observations chacun). Perte : erreur quadratique moyenne (MSE).

NOUVEAU EXPÉRIENCE

Choisir le degré





Erreur de validation croisée selon le degré.

Degré 3 : $\widehat{\mathcal{R}}_{\mathrm{CV}} = 0{,}282$
Le trait mauve est réappris sur les 30 points.

Comparez les degrés et retenez la plus faible erreur de validation croisée. Réapprenez ce degré sur les 30 points.

Un test final reste nécessaire : le score ayant servi au choix peut être optimiste.

Détails · Sélection et évaluation finale

Chaque degré est évalué sur les mêmes cinq blocs. On sélectionne celui qui minimise $\widehat{\mathcal{R}}_{\mathrm{CV}}$, puis on le réapprend sur toutes les données d'apprentissage.

Le score retenu a participé à la sélection : il peut sous-estimer l'erreur future. L'évaluation finale utilise des données réservées, absentes des apprentissages et des choix.

Mêmes 30 observations que l'expérience « Parcourir les blocs » ; blocs fixés avant tout apprentissage (6 observations chacun). Perte : erreur quadratique moyenne (MSE).

DIAPO 31 · FORMULE

Leave-One-Out

Lorsque $K = n$, chaque bloc contient une seule observation : c'est la validation croisée **leave one out** (LOO). Pour chaque indice, on apprend sur l'échantillon amputé de l'observation correspondante et on évalue cette observation.

$$K = n, \qquad D_n^{(-i)} = D_n \setminus \{(x_i, y_i)\},$$
$$\hat{f}^{(-i)} = \hat{f}(\cdot; D_n^{(-i)}),$$
$$\widehat{\mathcal{R}}_{\mathrm{LOO}} = \frac{1}{n} \sum_{i=1}^{n} \ell(y_i, \hat{f}^{(-i)}(x_i)).$$

Lire la formule –
$\hat{f}^{(-i)}$ est appris sans l'observation i. Le calcul demande n ajustements ; il est surtout adapté aux petits échantillons.

Chapitre 01 · Catégorisation

DIAPO 32 · NOTION

Catégorisation

Catégories des méthodes d'apprentissage

Supervision

Supervisé
Entrées et sorties connues
Classification · régression

Non supervisé
Sans étiquette de sortie
Clustering · réduction de dimension
Clustering : centroïdes, densité, hiérarchie…

Semi-supervisé
Quelques observations étiquetées
et de nombreuses non étiquetées

Paramétrisation

Paramétrique
Nombre de paramètres fixé
Pas nécessairement gaussien
Ex. : régression logistique, Bayes naïf, LDA

Non paramétrique
Complexité pouvant croître
avec les données
Des hypothèses restent nécessaires
Ex. : kNN, arbres ; SVM selon le noyau

Linéarité

Linéaire
Combinaison linéaire des variables
Frontière affine en classification
Séparation parfaite non requise
Ex. : régression linéaire, SVM linéaire

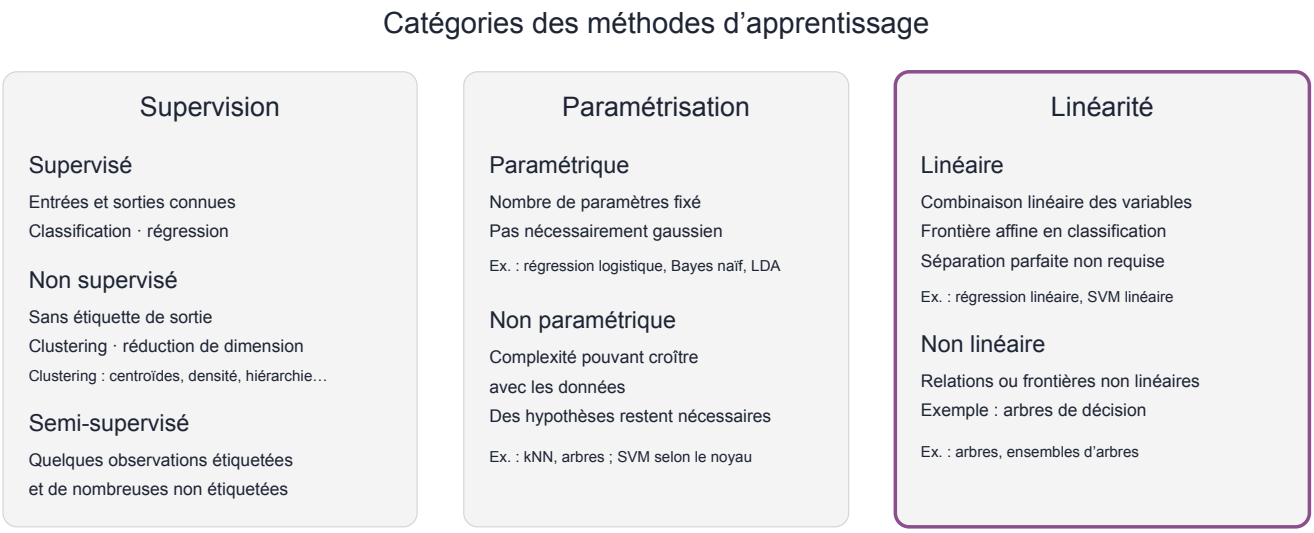
Non linéaire
Relations ou frontières non linéaires
Exemple : arbres de décision
Ex. : arbres, ensembles d'arbres

Ces trois axes de classement se combinent : ils ne sont pas exclusifs.

Carte redessinée d'après le support et The Illustrated Machine Learning (2023), avec les définitions précisées.

DIAPO 33 · NOTION

Notre perspective



Notre perspective : commencer par le linéaire, puis étudier le non linéaire.

Carte redessinée d'après le support et The Illustrated Machine Learning (2023), avec les définitions précisées.

▼ Précision

Paramétrique désigne un modèle décrit par un nombre fixé de paramètres ; cela n'impose pas une loi gaussienne. **Non paramétrique** ne signifie pas sans hypothèses, ni moins puissant par principe. Un **modèle linéaire** n'exige pas une séparation parfaite des classes.

DIAPO 34 · NOTION

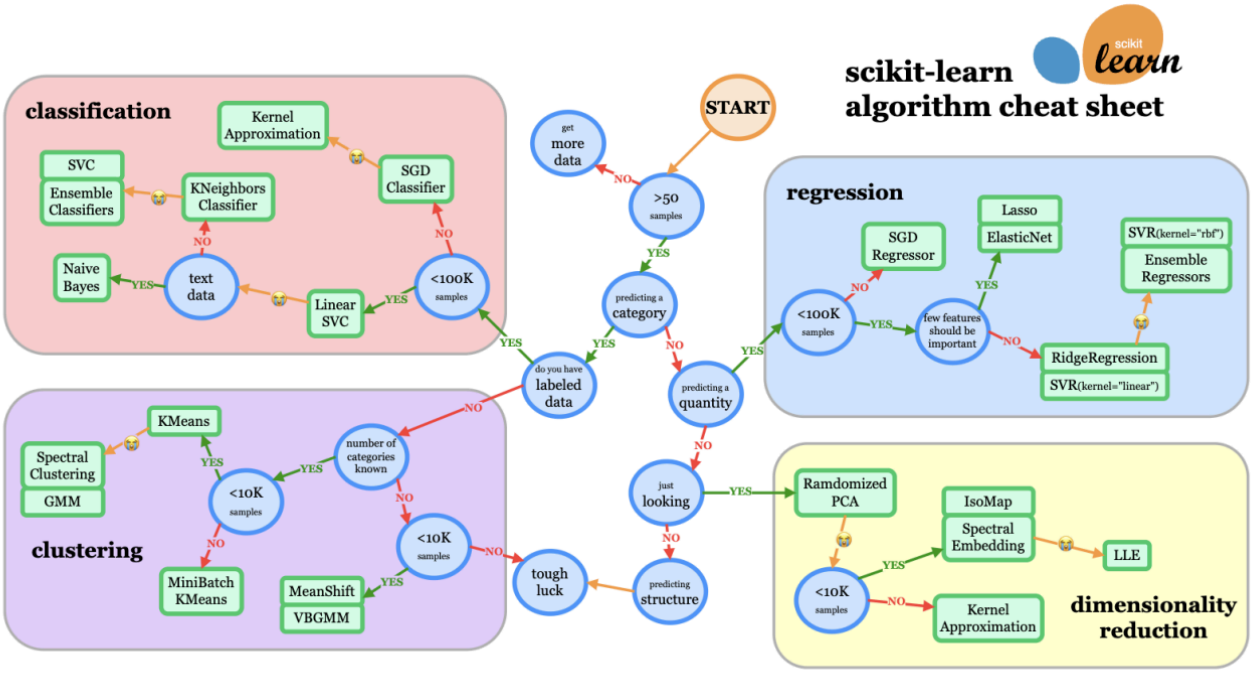
Pourquoi ce choix ?

Le classement **linéaire / non linéaire** aide à comprendre le compromis biais–variance et à choisir une complexité appropriée à la taille et à la structure des données.

Il permet une démarche progressive : commencer par un **modèle linéaire simple** pour poser les bases, puis aller vers un **modèle non linéaire** si les données le justifient.

DIAPO 35 · NOTION

Guide selon scikit-learn



Guide repris du support : situer les familles de méthodes selon la tâche et les données, puis confronter le choix à la validation.

DIAPO 36 · NOTION

Références

- **James, G., Witten, D., Hastie, T., Tibshirani, R., Taylor, J.** *An Introduction to Statistical Learning: with Applications in Python*, Springer, 2023. Site des auteurs et PDF.
- **Afshine Amidi et Shervine Amidi.** *CS229 — fiches de machine learning*, Fall 2018.
- **Laurent Rouvière.** *Introduction au machine learning*, Université Rennes 2, 2021.
- **Trevor Hastie, Robert Tibshirani, Jerome Friedman.** *The Elements of Statistical Learning*, Springer, 2001.

Pour approfondir

ISL avec Python · édition 2023, site des auteurs et PDF ↗

The Illustrated Machine Learning website ↗

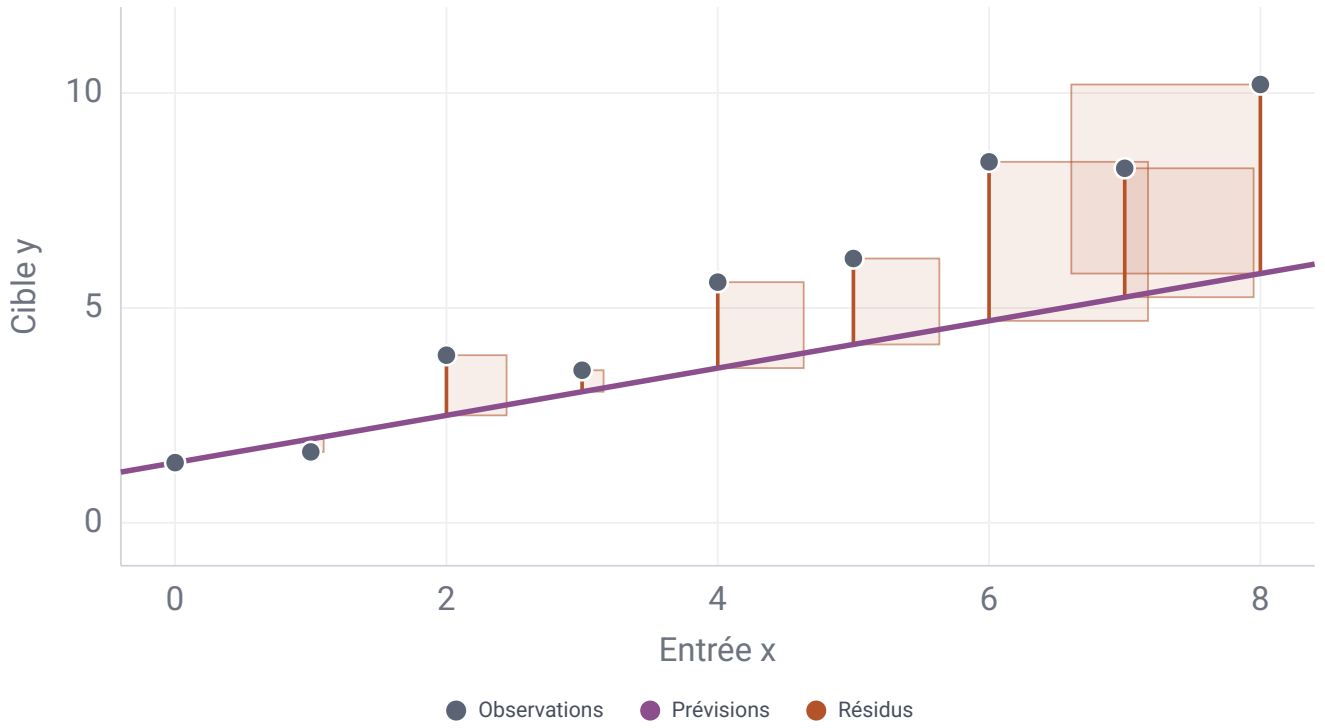
DIAPO 37 · NOTION

Algorithmes linéaires : la suite

> **Next : Algorithmes linéaires**
>
> Le chapitre suivant reprend ces notions pour étudier les **algorithmes linéaires** : leur géométrie, leurs fonctions de prévision et les critères utilisés pour apprendre.

COMPLÉMENT · EXPÉRIENCE

Manipuler la perte quadratique



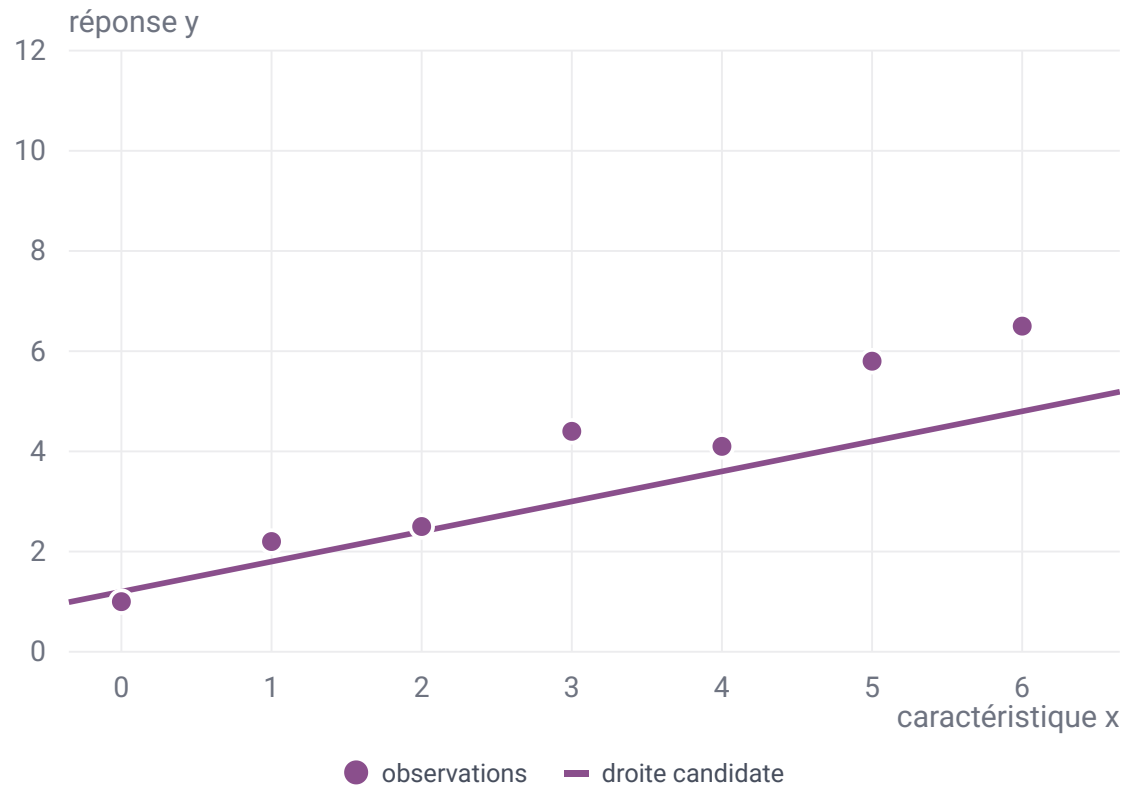
2,908	5,817	0,55	1,40
Risque empirique $= \frac{1}{2}\,\mathrm{MSE}$	$\mathrm{MSE} = \mathrm{RSS}/9$	Pente w	Ordonnée b

Déplacez la droite. Les segments sont les résidus verticaux ; la MSE est leur carré moyen ; avec la perte $\frac{1}{2}(y-\hat{y})^2$, le risque empirique vaut $\frac{1}{2}\,\mathrm{MSE}$. Chaque carré a pour aire le carré d'un résidu.

Données synthétiques. Déplacer la droite pour observer les résidus et leur coût moyen. La perte quadratique de cette partie utilise le facteur $\frac{1}{2}$; la MSE usuelle, lorsqu'elle est affichée séparément, utilise les carrés sans ce facteur.

COMPLÉMENT · EXPÉRIENCE

Une droite, deux paramètres



$\hat{y} \approx 0{,}60\,x + 1{,}20$

Changer b déplace toutes les prédictions du même écart.

La pente a règle l'inclinaison ; b décale la droite. Point mauve : observation ; trait mauve : prédiction.

Comment augmenter toutes les prédictions de la même quantité ?

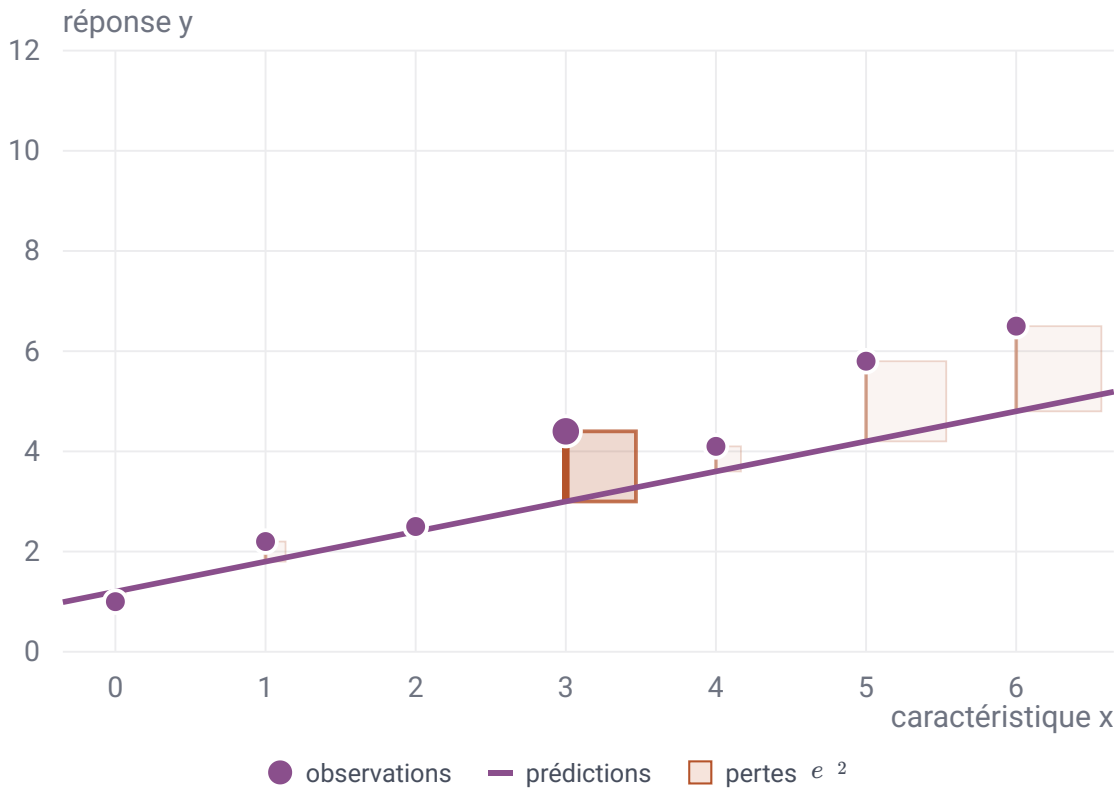
$$\widehat{y}_i = ax_i + b$$

Incliner ou déplacer : quel paramètre faut-il changer ?

Sept observations synthétiques, conservées d'une étape à l'autre. Les carrés sont schématiques ; leurs aires sont proportionnelles aux résidus au carré.

COMPLÉMENT · EXPÉRIENCE

Du résidu à la perte



Observation 4 : e **= 1,40** ; e^2 **= 1,96**.

1,124
MSE · moyenne des e²

0,562
½MSE · risque du cours

Le résidu est l'écart vertical entre observation et prédiction. Chaque carré représente sa perte. La MSE moyenne ces pertes ; le risque du cours vaut $\frac{1}{2}\,\mathrm{MSE}$.

Détails

Le résidu peut être positif ou négatif ; sa perte au carré est positive ou nulle. Chaque carré a une aire proportionnelle à cette perte.

Dans le cours, la perte $\frac{1}{2}e^2$ donne un risque empirique égal à $\frac{1}{2}\,\mathrm{MSE}$.

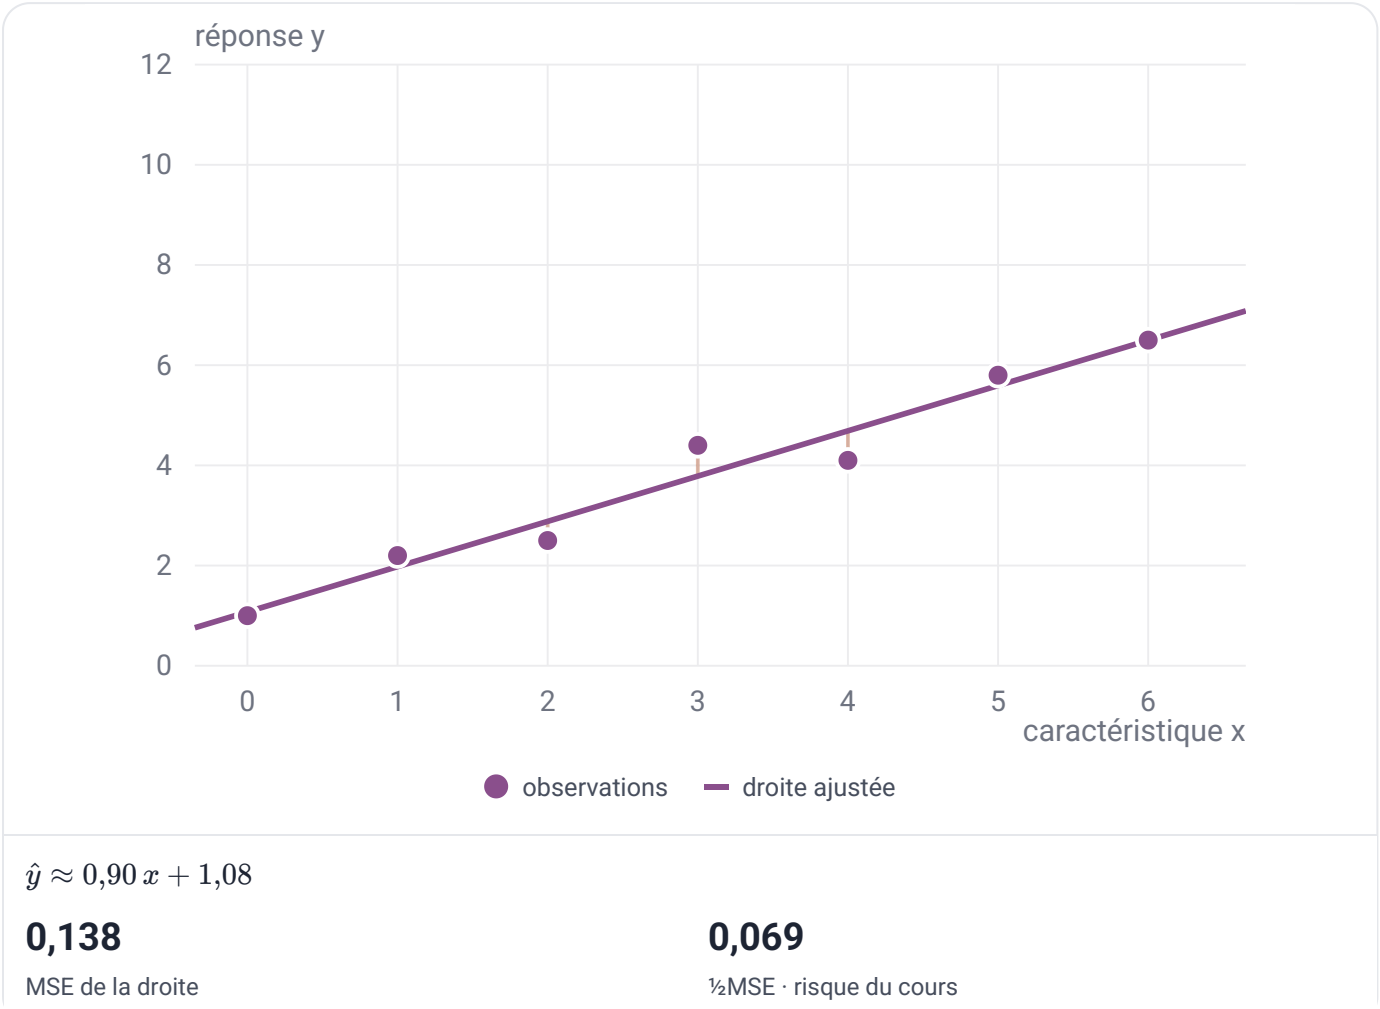
$$e_i = y_i - \hat{y}_i, \qquad \ell_i = e_i^2$$

Un résidu deux fois plus grand produit quelle perte ?

Sept observations synthétiques, conservées d'une étape à l'autre. Les carrés sont schématiques ; leurs aires sont proportionnelles aux résidus au carré.

COMPLÉMENT · EXPÉRIENCE

Révéler les moindres carrés



$\hat{y} \approx 0{,}90\,x + 1{,}08$

0,138
MSE de la droite

0,069
½MSE · risque du cours

Révélez la droite qui minimise la somme des carrés sur sept observations. Diviser la perte par n, ou par $2n$, conserve la droite optimale.

Détails

On ajuste les deux paramètres pour minimiser la somme des carrés. Les facteurs changent la valeur de la perte, pas son minimiseur.

L'animation relie la droite candidate à la solution calculée, sans simuler une descente de gradient.

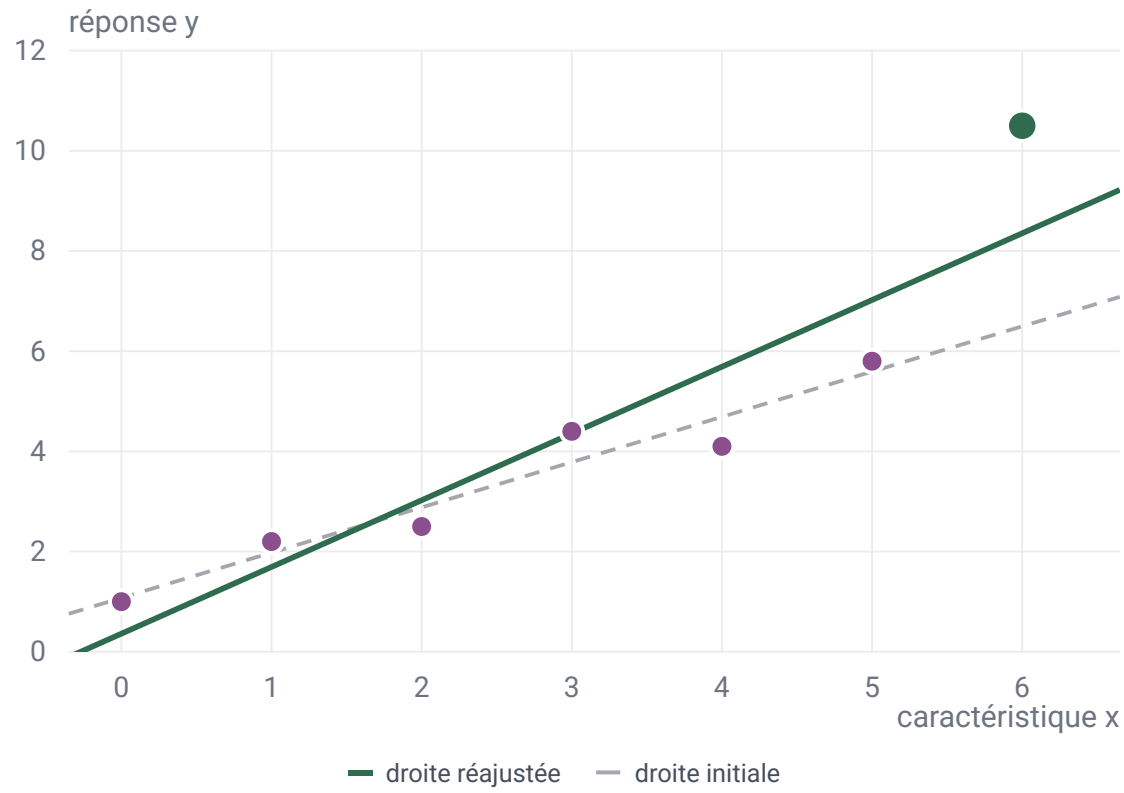
$$a^* = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sum_i (x_i - \bar{x})^2}$$
$$b^* = \bar{y} - a^* \bar{x}$$

Faut-il modifier la pente, l'ordonnée à l'origine, ou les deux ?

Sept observations synthétiques, conservées d'une étape à l'autre. Les carrés sont schématiques ; leurs aires sont proportionnelles aux résidus au carré.

COMPLÉMENT · EXPÉRIENCE

Un point peut tirer la droite



$\hat{y} \approx 1{,}33\,x + 0{,}36$

1,367
MSE de la droite

0,683
½MSE · risque du cours

Déplacez la dernière observation : la droite est réajustée à chaque mouvement. La droite grise garde l'ajustement initial. Un grand résidu peut fortement modifier la pente.

Détails

Le carré amplifie les grands résidus : ce point extrême peut modifier fortement la pente. Une faible MSE d'apprentissage ne garantit pas la généralisation.

$$\mathrm{MSE} = \frac{1}{n}\sum_{i}(y_i - \hat{y}_i)^2$$

Avant de déplacer le point : la droite montera-t-elle partout autant ?

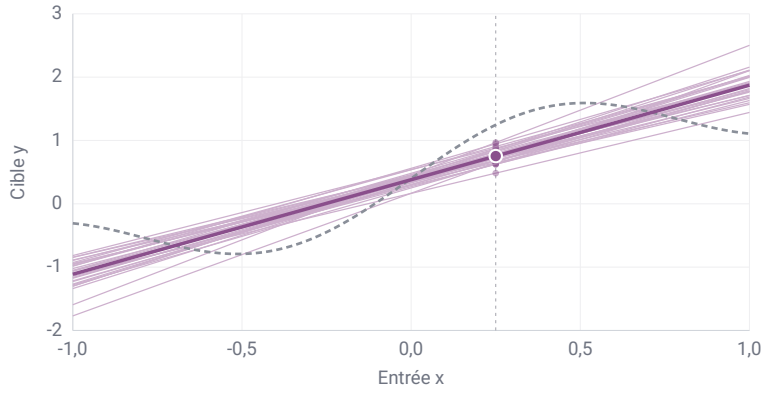
Sept observations synthétiques, conservées d'une étape à l'autre. Les carrés sont schématiques ; leurs aires sont proportionnelles aux résidus au carré.

COMPLÉMENT · EXPÉRIENCE

Répéter l’apprentissage

Simulation synthétique où la vraie relation est connue. Les courbes sont apprises sur plusieurs échantillons ; comparer leur moyenne et leur dispersion aux illustrations du support.

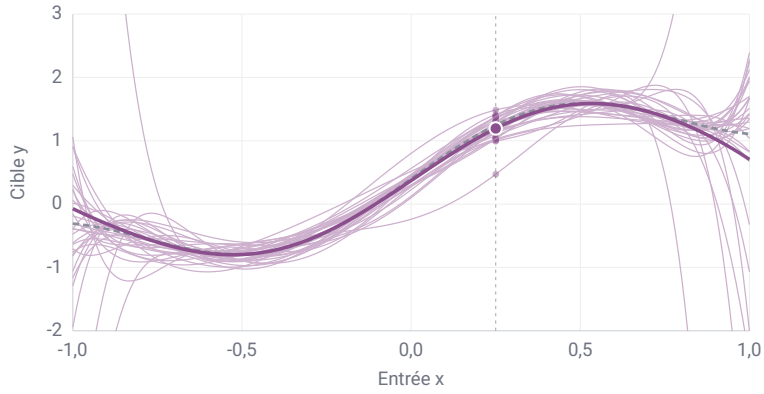
Degré 1



0,243	0,011	0,078	0,333
Biais^2 estimé	Variance estimée	Bruit σ^2	Somme des trois termes

Au point fixé $x = 0{,}25$, degré 1. Biais^2 et variance sont des estimations Monte-Carlo sur 30 apprentissages, avec division par 30. Le bruit vaut $0{,}28^2$. La somme estime l’erreur sur une nouvelle cible ; elle n’est pas une mesure sur les données d’apprentissage.

Degré 7



0,003	0,035	0,078	0,116
Biais^2 estimé	Variance estimée	Bruit σ^2	Somme des trois termes

Au point fixé $x = 0{,}25$, degré 7. Biais^2 et variance sont des estimations Monte-Carlo sur 30 apprentissages, avec division par 30. Le bruit vaut $0{,}28^2$. La somme estime l’erreur sur une nouvelle cible ; elle n’est pas une mesure sur les données d’apprentissage.

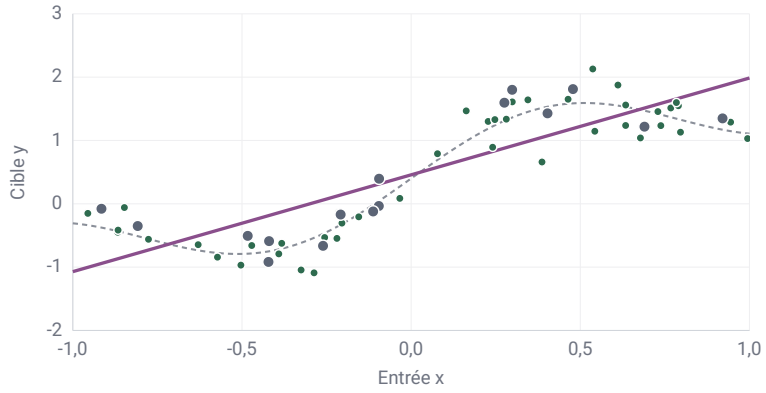
30 modèles appris · Prévision moyenne · Relation réelle m^*

COMPLÉMENT · EXPÉRIENCE

Faire varier la complexité

Données synthétiques. Comparer l’erreur d’apprentissage et l’erreur de validation lorsque le degré change. Le jeu utilisé pour comparer les degrés sert à la validation, pas au test final.

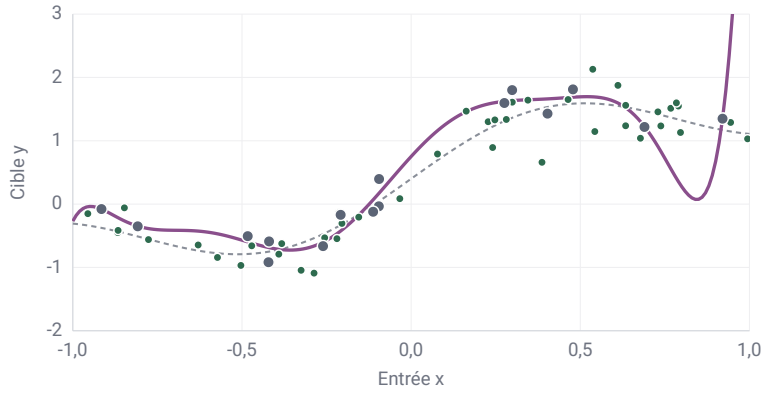
Degré 1



0,297	0,292	1
MSE apprentissage	MSE validation	Degré polynomial

16 observations d’apprentissage, 45 de validation ; degré 1, soit 2 coefficients. La courbe peut sortir du cadre : les scores utilisent toutes les valeurs, sans tronquer les prévisions.

Degré 9



0,023	1,255	9
MSE apprentissage	MSE validation	Degré polynomial

16 observations d’apprentissage, 45 de validation ; degré 9, soit 10 coefficients. La courbe peut sortir du cadre : les scores utilisent toutes les valeurs, sans tronquer les prévisions.

Apprentissage · Validation · Modèle · Relation réelle m^*

À retenir pour le complément visuel

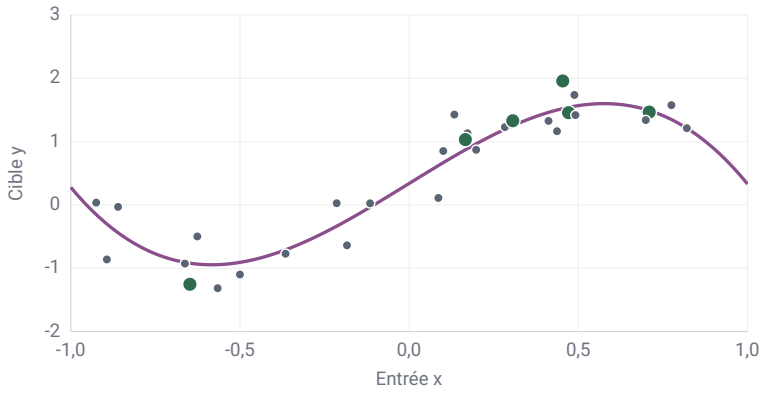
Les erreurs obtenues en faisant varier le degré dépendent de cet échantillon synthétique. Une baisse de l'erreur d'apprentissage n'implique pas une baisse de l'erreur de validation. L'allure de cette dernière, parfois en U, n'est pas universelle.

COMPLÉMENT · EXPÉRIENCE

Parcourir les blocs

Exemple synthétique à cinq blocs de même taille. Changer le bloc tenu à l'écart et observer le modèle appris sur les quatre autres. Chaque observation est évaluée une fois hors apprentissage.

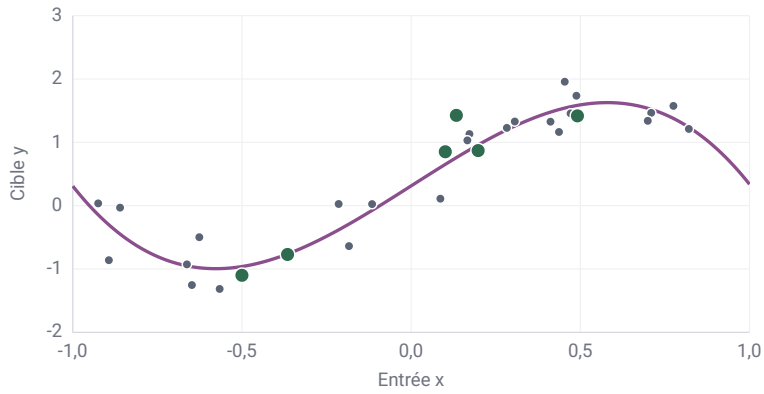
Pli 1 · degré 3



0,057	0,282	24 / 6
MSE du pli 1	MSE CV moyenne	Apprentissage / validation

Degré 3. MSE par pli : 1 : 0,057 · 2 : 1,053 · 3 : 0,147 · 4 : 0,062 · 5 : 0,090. Plis égaux : leur moyenne correspond à l'erreur sur les 30 prévisions hors apprentissage. Choisir le degré sur ces scores demande ensuite une évaluation finale réservée.

Pli 5 · degré 3



0,090
MSE du pli 5

0,282
MSE CV moyenne

24 / 6
Apprentissage / validation

Degré 3. MSE par pli : 1 : 0,057 · 2 : 1,053 · 3 : 0,147 · 4 : 0,062 · 5 : 0,090. Plis égaux : leur moyenne correspond à l'erreur sur les 30 prévisions hors apprentissage. Choisir le degré sur ces scores demande ensuite une évaluation finale réservée.

24 points d'apprentissage · 6 points de validation · Modèle réappris

Chapitre 01 · Estimation du risque

COMPLÉMENT · EXPÉRIENCE

Séparer avant d'apprendre



36 / 12 / 12

Une observation appartient à un seul lot.

Les mêmes 60 observations sont réparties une fois : 36 pour apprendre, 12 pour choisir, 12 pour évaluer à la fin.

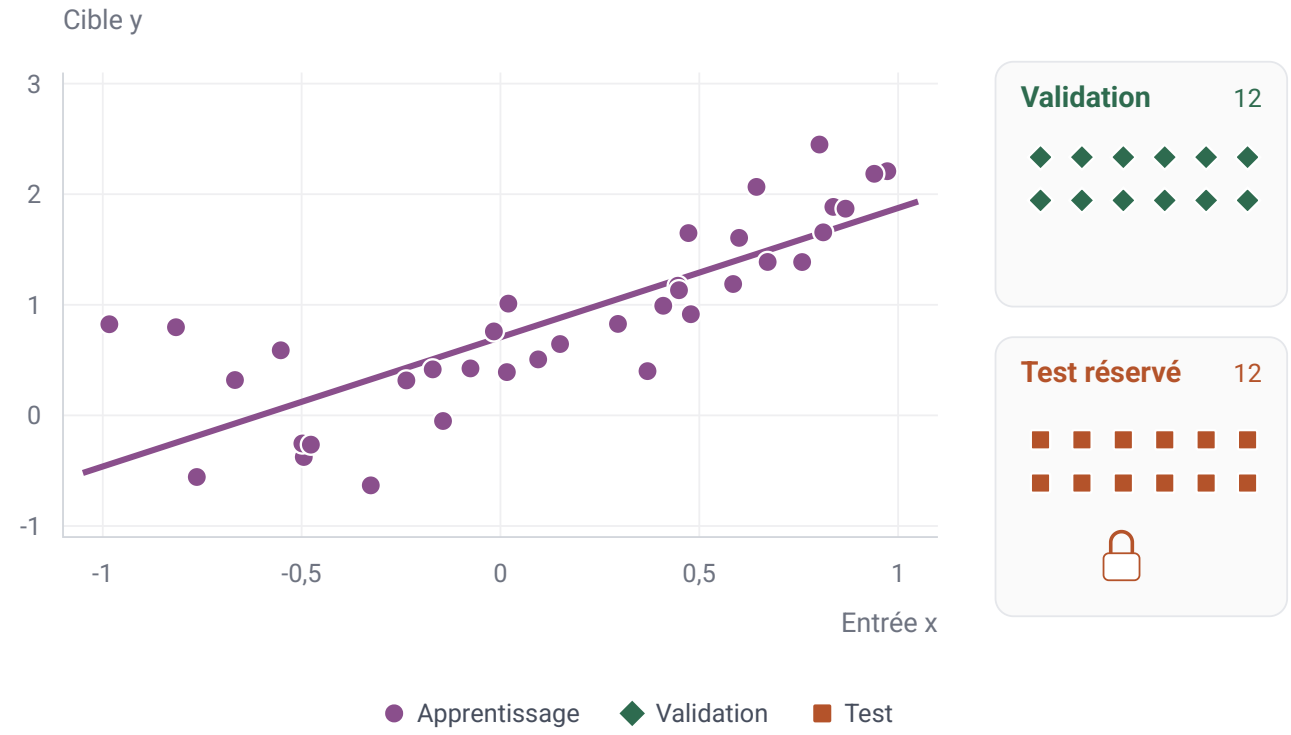
> **Quel lot doit rester fermé jusqu'au choix du modèle ?**

Exemple synthétique i.i.d. : même population, lots disjoints et fixes. Pour des séries temporelles ou des groupes liés, adapter la séparation.

COMPLÉMENT · EXPÉRIENCE

Apprendre sur un seul lot

Modèle candidat · degré 1



MSE apprentissage : 0,220

Degré 1 · paramètres ajustés sur 36 points.

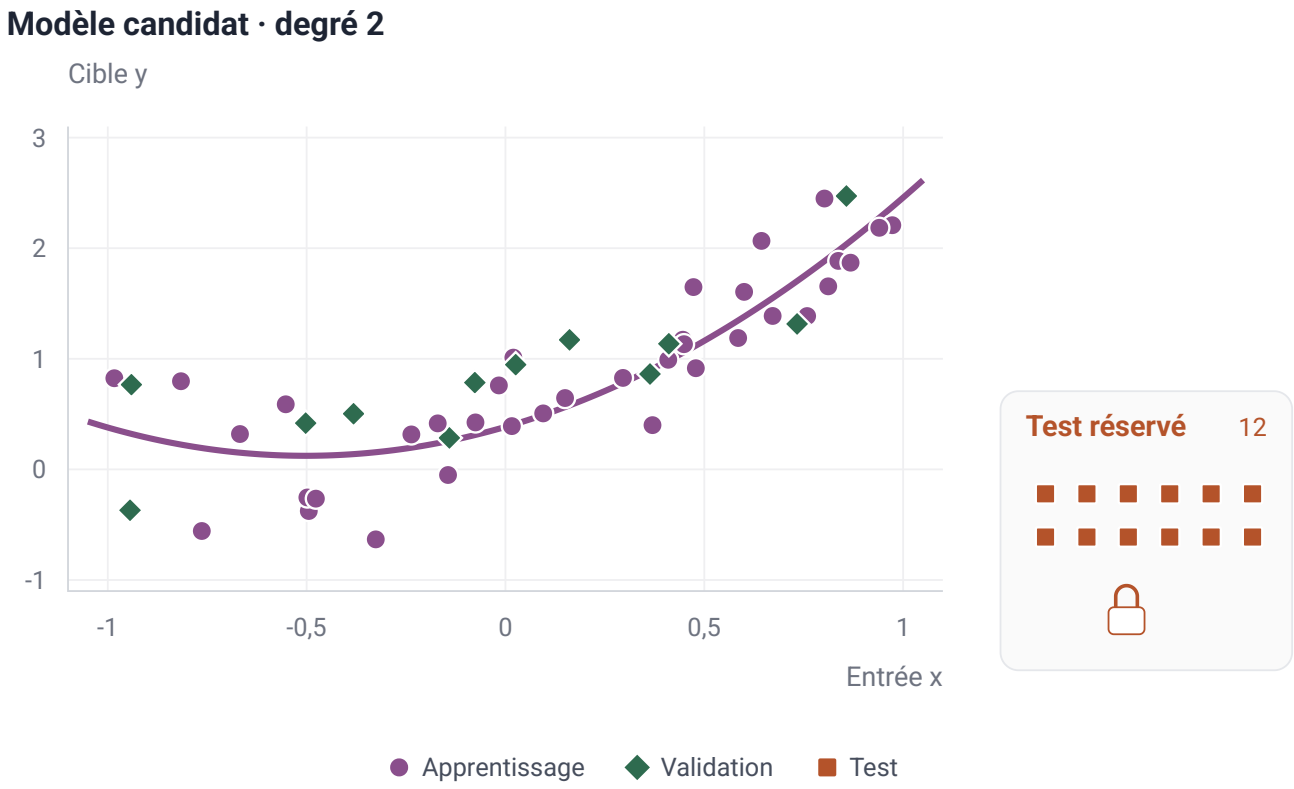
Chaque courbe minimise l'erreur sur les 36 points d'apprentissage. Le degré est encore un candidat, pas un choix définitif.

> **Une petite erreur d'apprentissage suffit-elle pour choisir ?**

Exemple synthétique i.i.d. : même population, lots disjoints et fixes. Pour des séries temporelles ou des groupes liés, adapter la séparation.

COMPLÉMENT · EXPÉRIENCE

La validation choisit le degré



MSE validation : 0,177

Degré 2 retenu sur la validation.

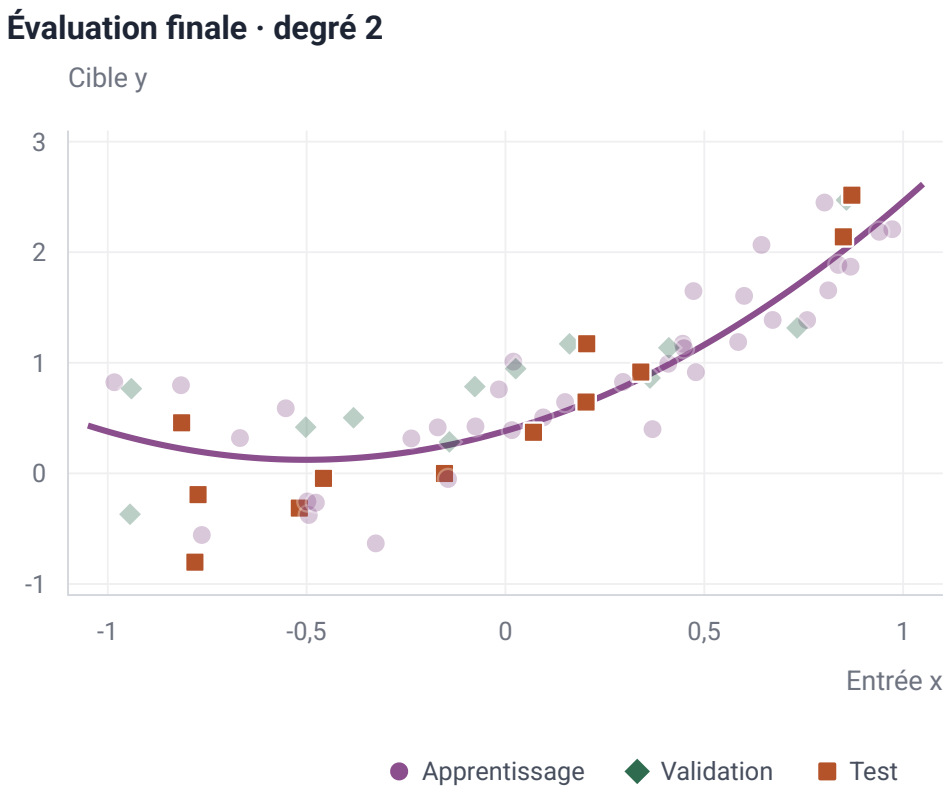
Les trois modèles déjà appris prédisent les 12 nouveaux points de validation. Comparez leurs MSE, puis figez un choix.

Quel degré a la plus petite MSE de validation ?

Exemple synthétique i.i.d. : même population, lots disjoints et fixes. Pour des séries temporelles ou des groupes liés, adapter la séparation.

COMPLÉMENT · EXPÉRIENCE

Ouvrir le test une seule fois



MSE test : 0,167

Degré 2 figé · estimation sur 12 nouveaux points.

Le modèle choisi reste fixe. Les 12 points de test servent maintenant à estimer son erreur sur de nouvelles observations.

> **Pourquoi ne faut-il plus changer de degré après avoir vu ce score ?**

Exemple synthétique i.i.d. : même population, lots disjoints et fixes. Pour des séries temporelles ou des groupes liés, adapter la séparation.