APPRENTISSAGE STATISTIQUE · 2026–2027

Algorithmes linéaires

Oumoukelthoum Sidenna

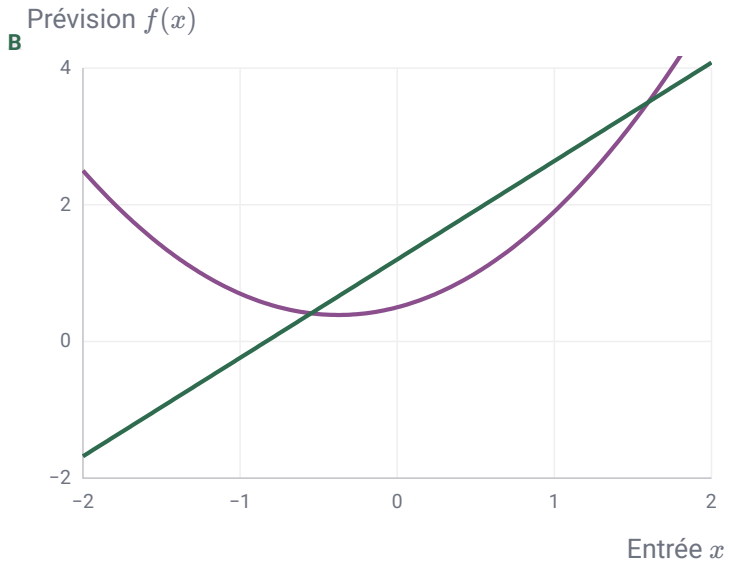
2e année du cycle ingénieur · 90 min · Notes de cours complètes

Plan du chapitre

1. Modèles linéaires · 10 min
2. Régression linéaire et logistique · 30 min
3. SVM : marge dure · 17 min
4. SVM : marge souple · 16 min
5. SVMs pour la discrimination multi-class · 7 min
6. ACP : réduire sans étiquette · 10 min

NOUVEAU EXPÉRIENCE

Lequel est linéaire ?



	en x	en θ
A	?	?
B	?	?

Une courbe, une droite : lequel est linéaire ?

Répondez avant de continuer.

A : $f_\theta(x) = \theta_0 + \theta_1 x + \theta_2 x^2$, une courbe.

B : $f_\theta(x) = \theta^2 x + \theta$, une droite.

À votre avis ?

Lequel de ces deux modèles est linéaire ?

- A, la courbe
- B, la droite

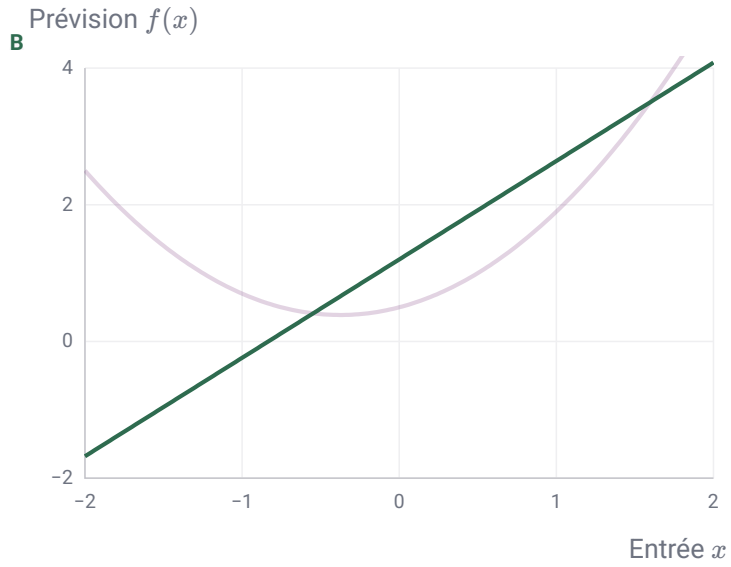
✓ Ça dépend : linéaire en quoi ?

B est linéaire (affine) en x ; A est linéaire en θ. Dans ce cours, un modèle linéaire est linéaire **en ses paramètres** : c'est A.

A : $f_\theta(x) = \theta_0 + \theta_1 x + \theta_2 x^2$. B : $f_\theta(x) = \theta^2 x + \theta$, avec $\theta = 1{,}2$.

NOUVEAU EXPÉRIENCE

Linéaire en x



	en x	en θ
A	non	?
B	**oui**	?

B est une droite en x

A ne l'est pas.

En x, « linéaire » veut dire que la prévision est une **droite** : $f(x) = a\,x + c$.

B l'est ; A ne l'est pas, à cause de x^2.

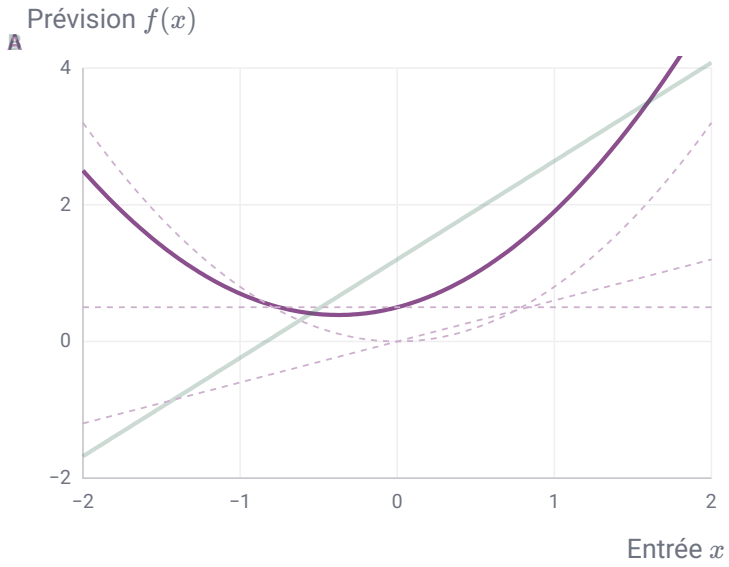
Détails · Le test

Linéaire en x : $f(\alpha x + \beta x') = \alpha f(x) + \beta f(x')$ (à la constante près, on dit affine).

A : $f_\theta(x) = \theta_0 + \theta_1 x + \theta_2 x^2$. B : $f_\theta(x) = \theta^2 x + \theta$, avec $\theta = 1{,}2$.

NOUVEAU EXPÉRIENCE

Linéaire en θ



	en x	en θ
A	non	**oui**
B	**oui**	non

$f_\theta(x) = 0{,}5 + 0{,}6x + 0{,}8x^2$

Toujours une somme « paramètre × nombre » : linéaire en θ.

En θ : à x fixé, la prévision est une somme « paramètre × nombre » : $f_\theta(x) = \theta^\top \phi(x)$.

A s'écrit $\theta_0 \cdot 1 + \theta_1 \cdot x + \theta_2 \cdot x^2$: linéaire en θ. Bougez θ_1 et θ_2.

Détails · Pourquoi c'est le bon sens ici

Linéaire en θ, la perte quadratique se minimise par moindres carrés, comme une régression linéaire : la régression polynomiale est un modèle linéaire. B, avec θ^2, ne s'écrit pas $\theta^\top \phi(x)$.

A : $f_\theta(x) = \theta_0 + \theta_1 x + \theta_2 x^2$. B : $f_\theta(x) = \theta^2 x + \theta$, avec $\theta = 1{,}2$.

Chapitre 02 · Modèles linéaires

NOUVEAU FORMULE

Un modèle linéaire

Exemple : prédire le poids d'un animal à partir de son pelage avec $\hat{y} = \theta_0 + \theta_1 x$.

On peut ajouter d'autres termes, x^2, $\sin x$… Tant que chaque paramètre **multiplie** un terme, le modèle est linéaire.

$$\hat{y} = \theta_0 + \theta_1 x + \theta_2 x^2$$

Lire la formule –

Chapitre 02 · Modèles linéaires

NOUVEAU FORMULE

Régression ou classification

Un même score $g(x)$ sert aux deux.

Régression : la prévision est le score lui-même. **Classification** : on regarde seulement son **signe**.

$$g(x) = w^\top x + b \qquad \hat{y} = \begin{cases} \text{chien} & \text{si } g(x) \geq 0 \\ \text{chat} & \text{sinon} \end{cases}$$

Lire la formule –

Chapitre 02 · Modèles linéaires

NOUVEAU FORMULE

Apprendre, c'est réduire les erreurs

Chaque point a un **résidu** : l'écart entre la vraie valeur et la prévision.

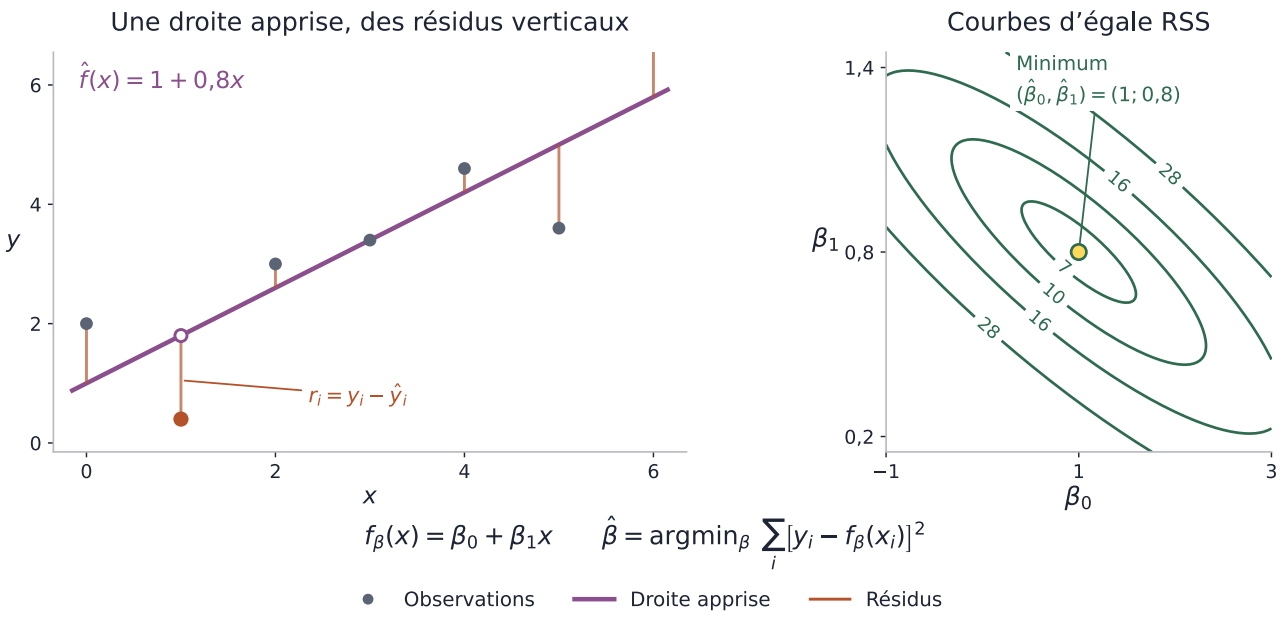
On choisit les paramètres qui rendent la somme des résidus au carré la plus petite : les **moindres carrés**.

$$\min_{\theta} \sum_{i} \left(y_i - \hat{y}_i\right)^2$$

Lire la formule –

DIAPO 10 · NOTION

Moindres carrés · droite, résidus et objectif



7 observations synthétiques · RSS minimale = 6,24 · les données ne proviennent pas du jeu TV

Illustration synthétique des moindres carrés : droite apprise, résidus verticaux et courbes d'égale RSS. Minimum en $\hat{\beta} = (1\,;\,0{,}8)$, avec RSS $= 6{,}24$.

NOUVEAU NOTION

Un algorithme = un modèle + une perte

Comme au chapitre 1 : on choisit une **perte**, puis on minimise le **risque empirique**, sa moyenne sur les données. Chaque algorithme de ce chapitre est un choix de modèle et de perte.

Algorithme	Modèle	Perte ℓ
Régression linéaire	$\hat{y} = w^\top x + b$	quadratique $\frac{1}{2}(y - \hat{y})^2$
Régression logistique	$\hat{p} = \sigma(w^\top x + b)$	entropie croisée $-y \log \hat{p} - (1 - y) \log(1 - \hat{p})$
SVM	$g(x) = w^\top x + b$, classe = signe	charnière $\max\big(0,\ 1 - y\, g(x)\big)$, plus $\frac{1}{2}\|w\|^2$

NOUVEAU NOTION

Régression linéaire · les données

Six élèves : heures de révision X et note sur 20 Y.

But : estimer la note moyenne attendue pour x heures, $E(Y \mid X = x)$.

Heures X	1	2	3	4	5	6
Note Y	8	9	11	12	14	15

Chapitre 02 · Régression linéaire et logistique

NOUVEAU FORMULE

Le modèle et ses hypothèses

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$$

Lire la formule –

1. **Linéarité** : $E(Y \mid X = x) = \beta_0 + \beta_1 x$.
2. **Indépendance** des erreurs ε_i.
3. **Variance constante** : $\mathrm{Var}(\varepsilon_i) = \sigma^2$.
4. Souvent : $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$, utile pour les intervalles et les tests.

Chapitre 02 · Régression linéaire et logistique

NOUVEAU FORMULE

La perte : les moindres carrés

$$J(\beta) = \frac{1}{n} \sum_{i=1}^{n} \big(y_i - \beta_0 - \beta_1 x_i\big)^2$$

Lire la formule –

On cherche la droite qui rend les résidus au carré les plus petits.

Lien avec la suite : si les erreurs sont gaussiennes, minimiser J revient à **maximiser la vraisemblance**. La logistique fera la même chose avec une autre loi.

Chapitre 02 · Régression linéaire et logistique

NOUVEAU FORMULE

La solution

$$\hat\beta_1 = \frac{\sum_i (x_i - \bar x)(y_i - \bar y)}{\sum_i (x_i - \bar x)^2}, \qquad \hat\beta_0 = \bar y - \hat\beta_1 \bar x$$

Lire la formule –

Ici $\bar x = 3{,}5$, $\bar y = 11{,}5$: $\hat\beta_1 \approx 1{,}46$ point par heure, $\hat\beta_0 \approx 6{,}4$.

NOUVEAU NOTION

Prédire

Un élève révise 7 heures : $\hat{y} = 6{,}4 + 1{,}46 \times 7 \approx 16{,}6$.

La prévision est une valeur réelle, sans limite : parfait pour une note, pas pour un oui/non.

NOUVEAU NOTION

1 · Que modélise-t-on ?

Heures X	1	2	3	4	5	6
Réussi Y	0	0	0	1	1	1

$Y \in \{0, 1\}$. On veut estimer $p(x) = P(Y = 1 \mid X = x)$.

Comme Y vaut 0 ou 1, $E(Y \mid X = x) = p(x)$: on modélise encore une espérance conditionnelle, comme en régression linéaire, mais avec une autre forme.

NOUVEAU FORMULE

2 · Choisir une loi

$$Y_i \mid X_i = x_i \sim \text{Bernoulli}(p_i), \qquad P(Y_i = y_i) = p_i^{y_i}(1 - p_i)^{1 - y_i}$$

Lire la formule –

Si $p_i = 0{,}8$: 80 % de chances de réussir, 20 % d'échouer.

Pas encore de sigmoïde : on a seulement choisi la loi de la réponse.

> **Pourquoi Bernoulli, et pas une autre loi ?**
>
> Parce que Y ne prend que **deux valeurs**, 0 ou 1. Toute loi sur $\{0, 1\}$ est entièrement décrite par un seul nombre, $p = P(Y = 1)$: c'est exactement la loi de Bernoulli. Ce n'est pas un choix, c'est la seule possibilité.
>
> - **Gaussienne** (régression linéaire) : elle donne des valeurs comme 0,37 ou −1,2, impossibles pour réussi/échoué.
> - **Binomiale** : nombre de réussites sur n essais ; avec un seul essai, $n = 1$, c'est Bernoulli.
> - **Poisson** : des comptages 0, 1, 2, 3… sans limite, pas un oui/non.

NOUVEAU FORMULE

3 · Relier X à la probabilité

Un score linéaire $z_i = \beta_0 + \beta_1 x_i$, et l'hypothèse : les **log-odds** valent ce score.

$$\ln \frac{p_i}{1 - p_i} = z_i \iff p_i = \sigma(z_i) = \frac{1}{1 + e^{-z_i}}$$

Lire la formule –

Le calcul du modèle : $x \to$ score z (n'importe quel réel) $\to$ sigmoïde $\to p \in (0, 1) \to$ éventuellement une classe avec un seuil.

NOUVEAU FORMULE

Pourquoi les odds ?

L'intuition : un pari

Parmi 5 animaux de 9 kg, 4 sont des chiens et 1 est un chat. On dit que les **odds** sont de **4 contre 1** : $\hat{p} = 0{,}8$, odds $= \dfrac{0{,}8}{0{,}2} = 4$.

Les odds disent « combien de fois plus probable que l'inverse ».

$\hat{p}$	**odds** $\hat{p}/(1-\hat{p})$	**log-odds**	**lecture**
0,2	0,25	−1,39	1 contre 4 : plutôt chat
0,5	1	0	autant de chances
0,8	4	+1,39	4 contre 1 : plutôt chien
0,99	99	+4,6	presque sûr

Pourquoi ça arrange tout

$\hat{p}$ est coincée entre 0 et 1 ; les odds vont de 0 à l'infini ; les **log-odds** vont de $-\infty$ à $+\infty$, comme une droite, et sont symétriques (chat $-1{,}39$, chien $+1{,}39$).

On peut donc écrire les log-odds comme un score linéaire, puis revenir à $\hat{p}$ par la sigmoïde.

$$\log \frac{\hat{p}}{1 - \hat{p}} = w^\top x + b$$

Lire la formule –

Un kilo de plus ajoute w aux log-odds, donc multiplie les odds par e^w.

NOUVEAU FORMULE

4 · La perte : de la vraisemblance à la log loss

$$L(\beta) = \prod_{i=1}^{n} p_i^{y_i} (1 - p_i)^{1 - y_i}$$

Lire la formule –
Observations supposées indépendantes : on multiplie.

On cherche les β qui rendent les données observées les plus probables. On prend le logarithme, puis le signe moins : maximiser la vraisemblance revient à minimiser

$$J(\beta) = -\frac{1}{n} \sum_{i=1}^{n} \left[y_i \ln p_i + (1 - y_i) \ln(1 - p_i) \right]$$

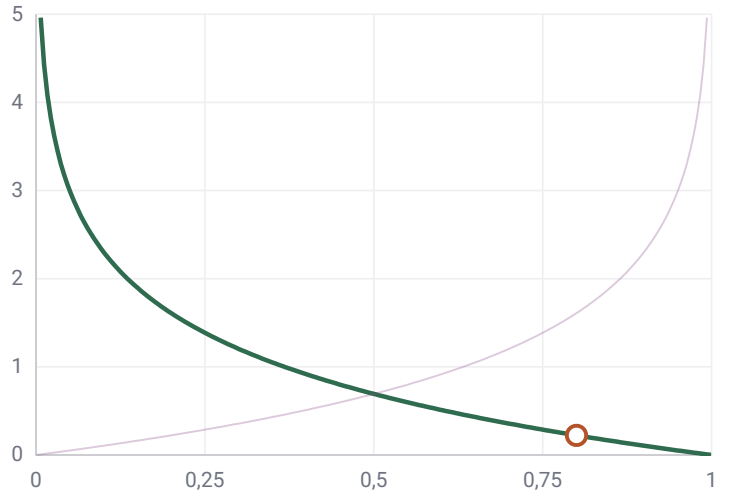
Lire la formule –
C'est l'entropie croisée binaire, ou log loss.

Chapitre 02 · Régression linéaire et logistique

NOUVEAU EXPÉRIENCE

Explorer la log loss

Pénalité



Probabilité prédite p

LOG LOSS
0,223

Bonne prédiction : faible pénalité.

$y = 1$, $p = 0{,}80$ **: perte** $= -\ln 0{,}80 = 0{,}223$
Bonne prédiction : faible pénalité.

Choisissez la vraie étiquette et la probabilité prédite.

Si $y = 1$, la perte vaut $-\ln p$; si $y = 0$, elle vaut $-\ln(1 - p)$. Une erreur **confiante** coûte très cher.

NOUVEAU FORMULE

5 · Entraîner : trouver les meilleurs paramètres

$$\frac{\partial J}{\partial \beta_0} = \frac{1}{n}\sum_i (p_i - y_i), \qquad \frac{\partial J}{\partial \beta_1} = \frac{1}{n}\sum_i (p_i - y_i)\, x_i$$

Lire la formule –

1. Initialiser β_0, β_1, par exemple à 0.
2. Calculer les scores z_i, puis $p_i = \sigma(z_i)$.
3. Calculer la log loss.
4. Calculer les gradients, puis $\beta_j \leftarrow \beta_j - \alpha\, \partial J / \partial \beta_j$.
5. Recommencer jusqu'à convergence.

Les logiciels utilisent souvent Newton ou L-BFGS plutôt que la descente de gradient simple.

NOUVEAU NOTION

6 · Prédire pour un nouvel élève

L'entraînement a donné $\hat{\beta}_0 = -4$, $\hat{\beta}_1 = 1$. Un élève a révisé 5 heures.

1. Score : $z = -4 + 1 \times 5 = 1$.
2. Probabilité : $p = \dfrac{1}{1 + e^{-1}} \approx 0{,}731$, soit 73,1 % de chances de réussir.
3. Classe avec le seuil 0,5 : $p \geq 0{,}5$, donc **réussi**.

Le seuil est une règle de décision, pas une partie du modèle de probabilité.

NOUVEAU NOTION

7 · Entraînement ou prédiction

Étape	Entraînement	Prédiction
Entrée	$X_{\text{train}}, Y_{\text{train}}$	nouveau X
Paramètres	appris, mis à jour	fixés
Score et sigmoïde	calculés	calculés
Perte et gradients	calculés	inutiles
Sortie	coefficients estimés	probabilité ou classe

NOUVEAU NOTION

8 · Linéaire ou logistique

	Régression linéaire	Régression logistique
On modélise	$E(Y \mid X)$	$P(Y = 1 \mid X) = E(Y \mid X)$
Hypothèse linéaire	$E(Y \mid X) = X^\top \beta$	$\text{logit}(p) = X^\top \beta$
Loi de la réponse	souvent gaussienne	Bernoulli
Prévision	$X^\top \beta$	$\sigma(X^\top \beta)$
Perte	erreur quadratique	log loss
Estimation	moindres carrés	maximum de vraisemblance

NOUVEAU FORMULE

Le modèle complet en deux lignes

$$Y_i \mid X_i = x_i \sim \text{Bernoulli}(p_i), \qquad \text{logit}(p_i) = x_i^\top \beta$$

Lire la formule –

La première ligne dit comment Y est distribuée sachant X ; la seconde, comment la probabilité dépend de X.

On n’entraîne pas le modèle à prédire des odds : les log-odds sont une échelle commode et linéaire, que l’on transforme en probabilités, comparées aux étiquettes par la vraisemblance.

NOUVEAU EXPÉRIENCE

Un animal devient un point





↓

MESURES

$$x = (4{,}6\,;\,5{,}0)$$

↓

POINT ÉTIQUETÉ

$$y = 0$$

· chat

Le dessin identifie l’animal ; le modèle ne lit que x.

Chat 6

$x = (4{,}6\,;\,5{,}0)$, $y = 0$ (chat). Cliquez un autre animal.

Le modèle reçoit deux mesures : **poids** et **longueur du pelage**. L’étiquette vaut 0 pour un chat, 1 pour un chien.

Cliquez un animal pour voir ses mesures.

Détails · Mesures et étiquette

L’animal i est décrit par $x_i = (x_{i1}, x_{i2})$, avec son étiquette y_i. Le modèle lit ces nombres, pas le dessin.

Les classes se chevauchent : deux mesures ne suffisent pas toujours à reconnaître l’espèce.



À votre avis ?

Deux animaux aux mesures identiques peuvent-ils porter des étiquettes différentes ?

- Non : les mesures déterminent l’espèce

✓ **Oui**

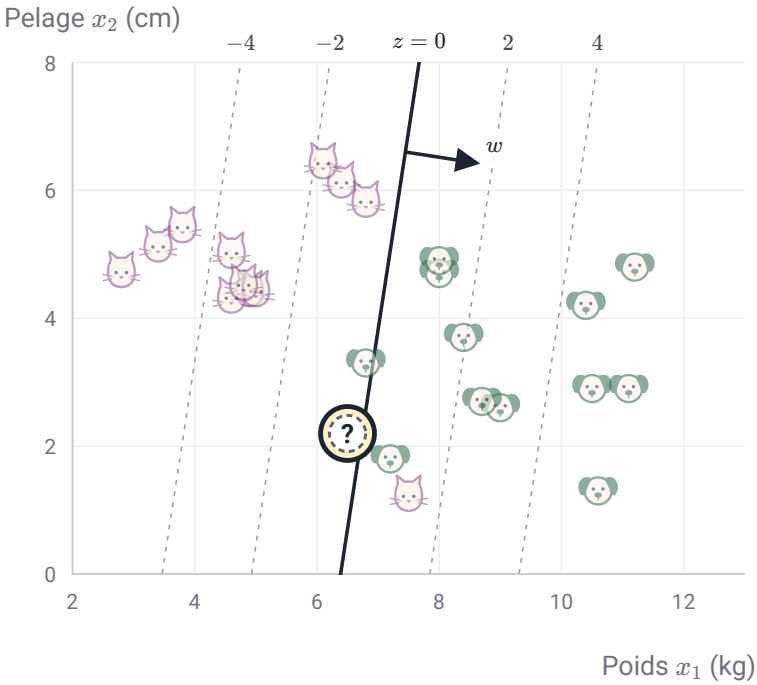
- Seulement si l’un des deux est mal mesuré

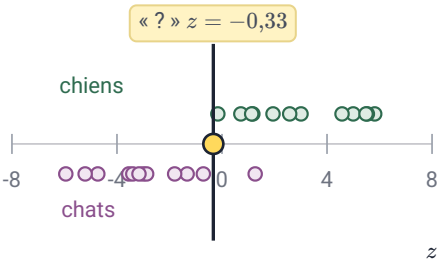
Oui. Les mesures ne déterminent pas l’espèce : c’est pourquoi on estime une probabilité $P(Y = 1 \mid X = x)$ plutôt qu’une règle infaillible.

Données synthétiques : 40 animaux inventés, deux mesures chacun. Les dessins servent seulement à reconnaître les animaux à l'écran ; le modèle ne reçoit que les nombres x_1 et x_2. Paramètres arrondis à 10^{-2}, appris sur les 24 animaux d'apprentissage avec $C = 1$.

NOUVEAU EXPÉRIENCE

Un score linéaire





Chaque animal se résume à un nombre z. Les deux classes se recouvrent autour de $z = 0$.

Animal « ? » : $z = -0{,}33$

Calcul : $z = 1{,}37 \times 6{,}5 - 0{,}22 \times 2{,}2 - 8{,}75 = -0{,}33$. Les paramètres restent fixes.

$g(x) = w_1 x_1 + w_2 x_2 + b$ donne un **score réel**. Pour l'animal choisi, on écrit $z = g(x)$.

Déplacez « ? » et regardez le score changer.

Détails · Le score et sa géométrie

$z = g(x) = w^\top x + b$. g est la fonction ; z est sa valeur pour un animal. Les paramètres w, b sont appris sur les données.

Les droites $g(x) = \text{constante}$ sont parallèles. Le vecteur w leur est orthogonal.

À votre avis ?

Le score z peut-il valoir 5 ? et -12 ?

✓ **Oui, pour les deux**

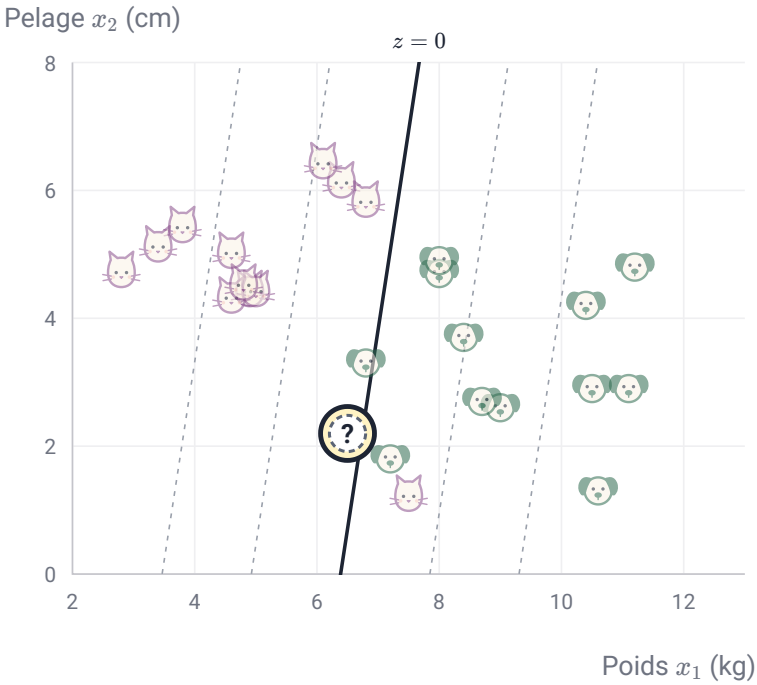
- Non : z est entre 0 et 1
- 5 oui, -12 non : un score est positif

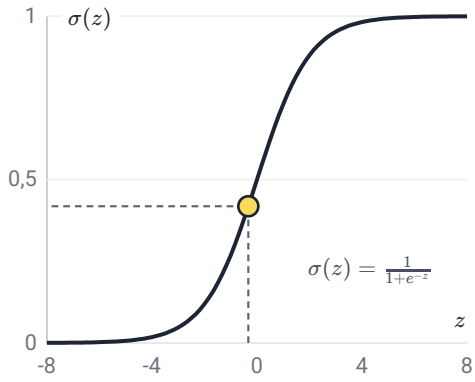
Oui : $z \in \mathbb{R}$ n'est pas borné. Ce n'est pas encore une probabilité.

Données synthétiques : 40 animaux inventés, deux mesures chacun. Les dessins servent seulement à reconnaître les animaux à l'écran ; le modèle ne reçoit que les nombres x_1 et x_2. Paramètres arrondis à 10^{-2}, appris sur les 24 animaux d'apprentissage avec $C = 1$.

NOUVEAU EXPÉRIENCE

La sigmoïde comprime le score





Le point jaune suit l'animal sélectionné.

$\sigma(-0{,}33) = 0{,}42$

$\sigma(-0{,}33) = \dfrac{1}{1 + e^{0{,}33}}$ · Animal « ? ».

La **sigmoïde** transforme le score en un nombre entre 0 et 1 : $\sigma(z) = \frac{1}{1+e^{-z}}$.

Déplacez « ? » : le point suit la courbe.

Détails · Lire la sigmoïde

$\sigma(0) = 0{,}5$. Un score très positif donne une valeur proche de 1 ; un score très négatif, une valeur proche de 0. La fonction est croissante et ses valeurs restent dans $(0, 1)$.

À votre avis ?

Que vaut $\sigma(z) + \sigma(-z)$?

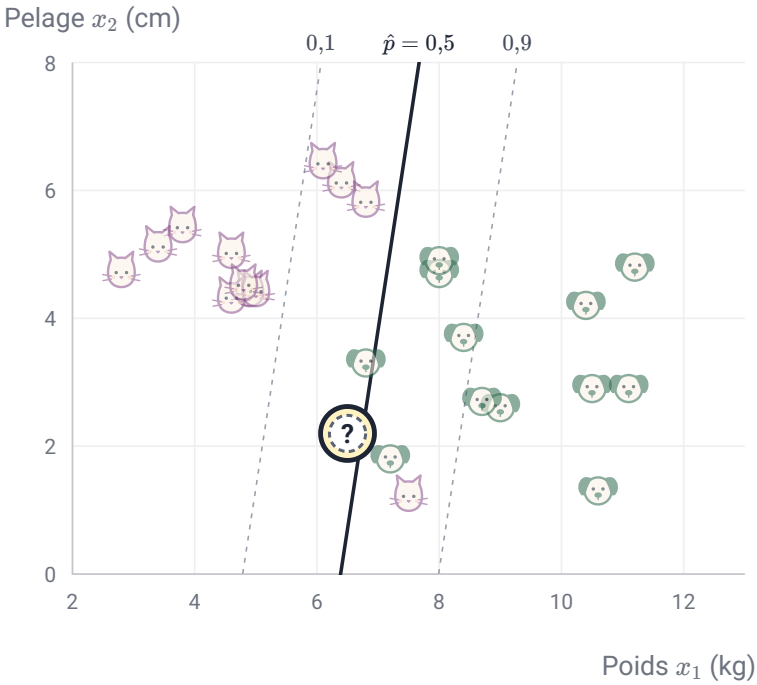
- 0
- $2\sigma(z)$
- ✓ 1

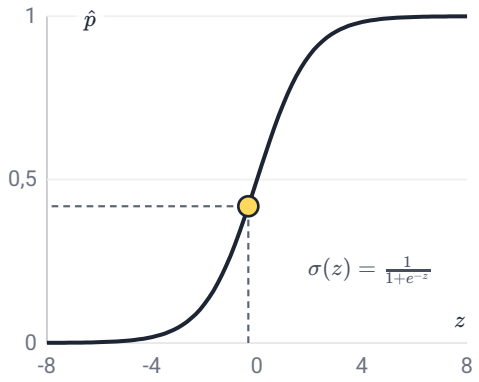
$1 : \sigma(-z) = \dfrac{e^{-z}}{1 + e^{-z}} = 1 - \sigma(z)$. La courbe est symétrique autour de $(0\,;\,0{,}5)$.

Données synthétiques : 40 animaux inventés, deux mesures chacun. Les dessins servent seulement à reconnaître les animaux à l'écran ; le modèle ne reçoit que les nombres x_1 et x_2. Paramètres arrondis à 10^{-2}, appris sur les 24 animaux d'apprentissage avec $C = 1$.

NOUVEAU EXPÉRIENCE

Score, probabilité et classe





$\hat{p}$ estime $P(Y = 1 \mid X = x)$; ce n'est pas encore une décision.

SCORE	PROBABILITÉ	CLASSE ($T = 0{,}50$)
$z = -0{,}33$	$\hat{p} = 0{,}42$	$\hat{y} = 0$
réel	dans $(0, 1)$	chat

Animal « ? »

$\hat{p} = \sigma(z)$ estime la **probabilité d'être un chien**. Par exemple, $0{,}8$ signifie $80\,\%$ selon le modèle.

Une probabilité estimée n'est pas encore une classe.

Détails · Trois objets différents

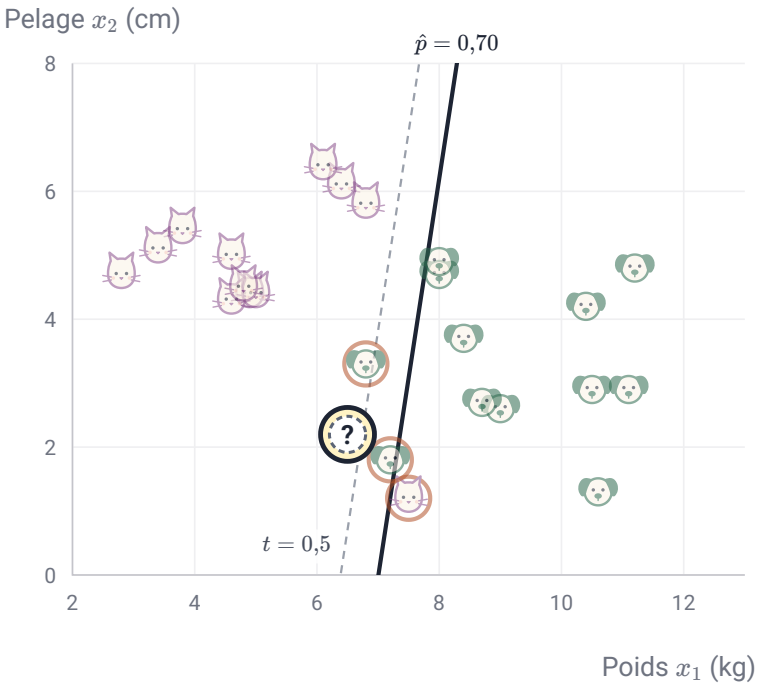
$z = g(x) \in \mathbb{R}$ est un score ; $\hat{p} \in (0, 1)$ une probabilité estimée ; $\hat{y} \in \{0, 1\}$ une classe prédite. L'étiquette observée est y.

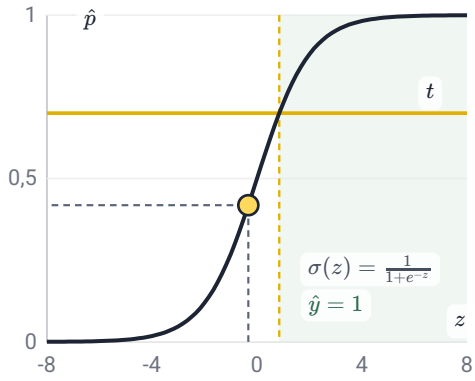
$\hat{p}(x) = \sigma(g(x))$ estime $P(Y = 1 \mid X = x)$, sans garantir la vraie probabilité. Les lignes correspondent ici à $\hat{p} = 0{,}1$, $0{,}5$ et $0{,}9$.

Données synthétiques : 40 animaux inventés, deux mesures chacun. Les dessins servent seulement à reconnaître les animaux à l'écran ; le modèle ne reçoit que les nombres x_1 et x_2. Paramètres arrondis à 10^{-2}, appris sur les 24 animaux d'apprentissage avec $C = 1$.

NOUVEAU EXPÉRIENCE

Le seuil de décision





Le seuil t coupe la courbe : à droite de $z = \log \frac{t}{1-t}$, $\hat{y} = 1$.

SCORE	PROBABILITÉ	CLASSE ($T = 0{,}70$)
$z = -0{,}33$	$\hat{p} = 0{,}42$	$\hat{y} = 0$
réel	dans $(0, 1)$	chat

Animal « ? »

Apprentissage : **3** erreurs sur 24 avec $t = 0{,}70 \cdot w$ et b inchangés.

On prédit **chien** si $\hat{p} \geq t$, sinon **chat**.

Changez le seuil t : la frontière bouge, mais les paramètres w, b restent fixes.

Détails · La frontière du seuil

Pour $0 < t < 1$, la décision $\hat{p} \geq t$ équivaut à $z \geq \log \frac{t}{1-t}$. La frontière se déplace parallèlement à elle-même, sans réapprentissage.

À votre avis ?

Si confondre un chien avec un chat coûte cher, faut-il monter ou baisser t ?

- Monter t

✓ **Baisser t**

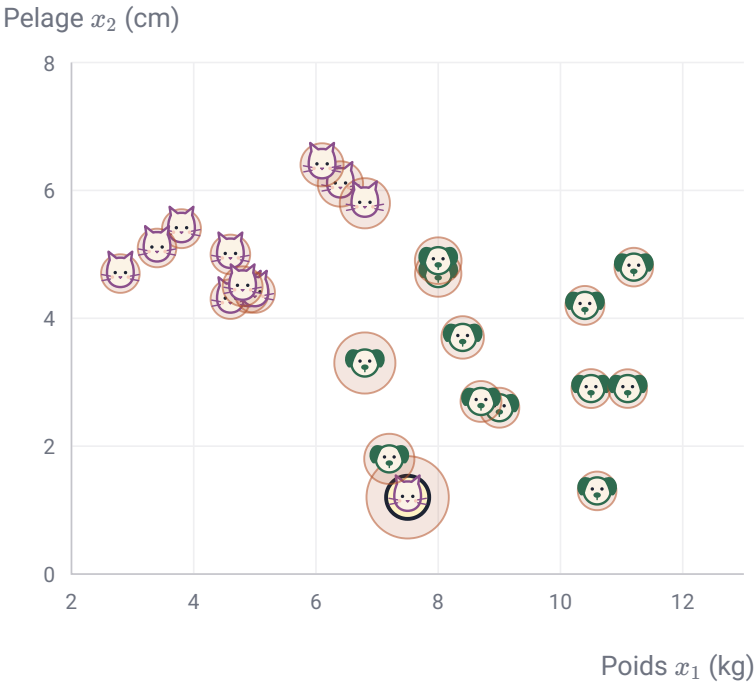
- Ne pas toucher t : seul le modèle compte

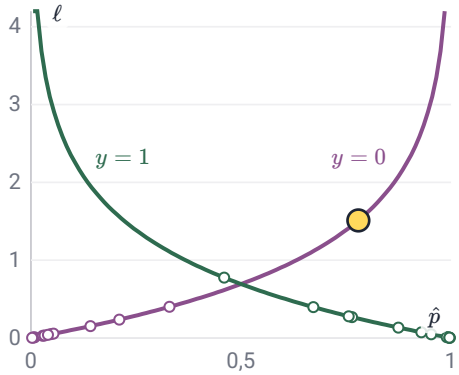
Baisser t : davantage d'animaux sont classés chiens. On réduit les chiens manqués, au prix de chats pris pour des chiens.

Données synthétiques : 40 animaux inventés, deux mesures chacun. Les dessins servent seulement à reconnaître les animaux à l'écran ; le modèle ne reçoit que les nombres x_1 et x_2. Paramètres arrondis à 10^{-2}, appris sur les 24 animaux d'apprentissage avec $C = 1$.

NOUVEAU EXPÉRIENCE

L'entropie croisée binaire





Pour un chien ($y = 1$), $\ell = -\log \hat{p}$; pour un chat, $\ell = -\log(1 - \hat{p})$. Petits points : les 24 animaux.

Chat 16 : perte $\ell = 1{,}51$

$y = 0$, $\hat{p} = 0{,}78$, $\ell = -\log(1 - 0{,}78)$. Moyenne : $\frac{1}{24}\sum_i \ell_i = 0{,}189$.

La perte pénalise une faible probabilité donnée à la **vraie classe**. Une erreur très confiante coûte cher.

Cliquez un animal pour voir sa contribution à la perte.

Détails · Perte et objectif appris

$$\ell(y, \hat{p}) = -y \log \hat{p} \\ - (1 - y) \log(1 - \hat{p}).$$

Dans cet exemple, on minimise $\frac{1}{2}\|w\|^2 + C\sum_i \ell(y_i, \hat{p}_i)$, avec $C = 1$. Le biais b n'est pas pénalisé. Le seuil ne participe pas à cet apprentissage.

Le chat de 7,5 kg reçoit $\hat{p} \approx 0{,}78$: $\ell = -\log(1 - 0{,}78) \approx 1{,}5$.

Données synthétiques : 40 animaux inventés, deux mesures chacun. Les dessins servent seulement à reconnaître les animaux à l'écran ; le modèle ne reçoit que les nombres x_1 et x_2. Paramètres arrondis à 10^{-2}, appris sur les 24 animaux d'apprentissage avec $C = 1$.

NOUVEAU EXPÉRIENCE

Trois groupes fixés avant d'apprendre



Groupe	Chats	Chiens	Rôle
Apprentissage	12	12	ajuster w, b
Validation	4	4	choisir C
Test	4	4	évaluer à la fin

Mêmes proportions de chats et de chiens dans chaque groupe.

24 / 8 / 8

Chaque animal appartient à un seul groupe.

Trois groupes fixes : **24 pour apprendre, 8 pour choisir, 8 pour tester**.

Le test reste fermé pendant les choix. Appuyez sur « Répartir les animaux ».

À votre avis ?

Pourquoi répartir avant de regarder les performances ?

- ✓ **Pour que les scores mesurent la performance sur des animaux nouveaux**
- Pour aller plus vite
- Pour avoir plus d'animaux d'apprentissage

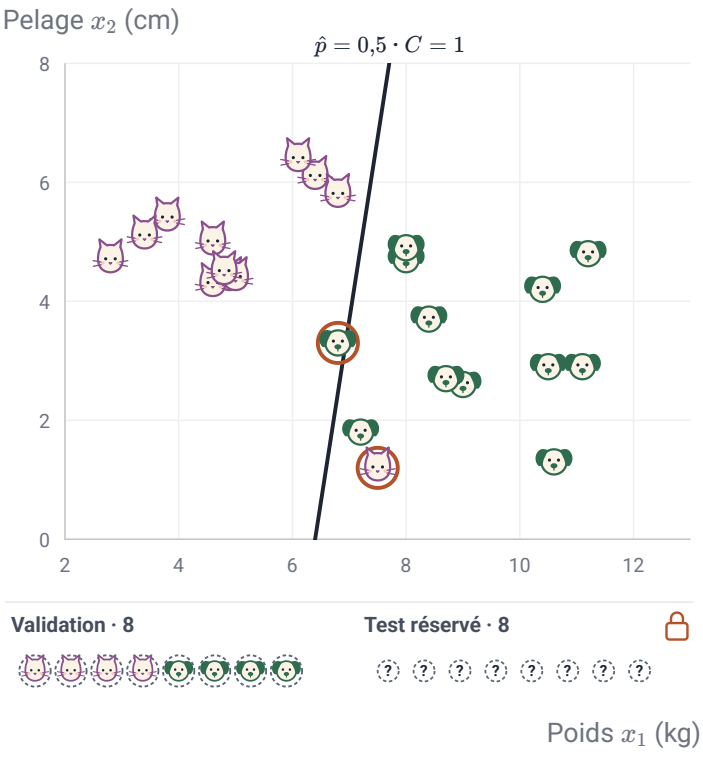
Sinon, le choix des groupes peut favoriser un modèle : les scores ne mesureraient plus la performance sur des animaux nouveaux.

Répartition stratifiée tirée une fois pour toutes : 12 + 4 + 4 animaux de chaque classe. Avec 8 animaux, un score de validation ou de test reste très incertain ; l'exemple illustre les rôles, pas la précision d'une estimation.

Chapitre 02 · Régression linéaire et logistique

NOUVEAU EXPÉRIENCE

Apprendre les paramètres



Un modèle appris par valeur de C

C	$\hat{w}_1$	$\hat{w}_2$	$\hat{b}$	**BCE appr.**
$0{,}01$	0,18	−0,06	−1,00	0,519
$0{,}1$	0,63	−0,20	−3,61	0,287
1	**1,37**	**−0,22**	**−8,75**	**0,189**
10	2,24	−0,11	−15,39	0,165

Paramètres appris $\hat{w}, \hat{b}$; C est fixé avant l'apprentissage.

$C = 1$ · **BCE apprentissage :** $0{,}189$

$\hat{w} = (1{,}37\,;\, -0{,}22),\ \hat{b} = -8{,}75.$

Le modèle apprend w, b sur les **24 animaux d'apprentissage**.

Déplacez-en un : le modèle est réappris et la frontière bouge.

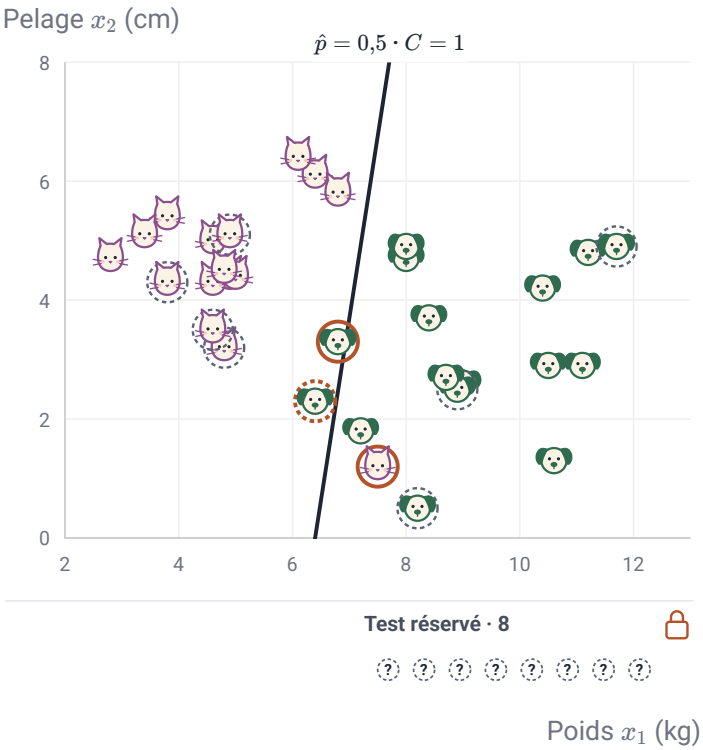
Détails · Ce qui est appris

Pour C fixé, on minimise $\frac{1}{2}\|w\|^2 + C\sum_i \ell(y_i, \hat{p}_i)$ sur l'apprentissage. C est un hyperparamètre choisi séparément. Une petite valeur pénalise davantage la norme de w.

Répartition stratifiée tirée une fois pour toutes : 12 + 4 + 4 animaux de chaque classe. Avec 8 animaux, un score de validation ou de test reste très incertain ; l'exemple illustre les rôles, pas la précision d'une estimation.

NOUVEAU EXPÉRIENCE

Valider sans réapprendre



Un modèle appris par valeur de C

C	$\hat{w}_1$	$\hat{w}_2$	$\hat{b}$	BCE appr.	BCE valid.
0,01	0,18	−0,06	−1,00	0,519	0,509
0,1	0,63	−0,20	−3,61	0,287	0,248
1	**1,37**	**−0,22**	**−8,75**	**0,189**	**0,159**
10	2,24	−0,11	−15,39	0,165	0,206

Ligne surlignée : plus petite BCE de validation.

BCE validation ($C = 1$) : $0{,}159$ · exactitude $7/8$

La validation compare des modèles déjà appris.

Déplacez un animal de **validation** (anneau pointillé) : le modèle reste fixe, la perte de validation change.

Comparez les valeurs de C, puis retenez-en une.

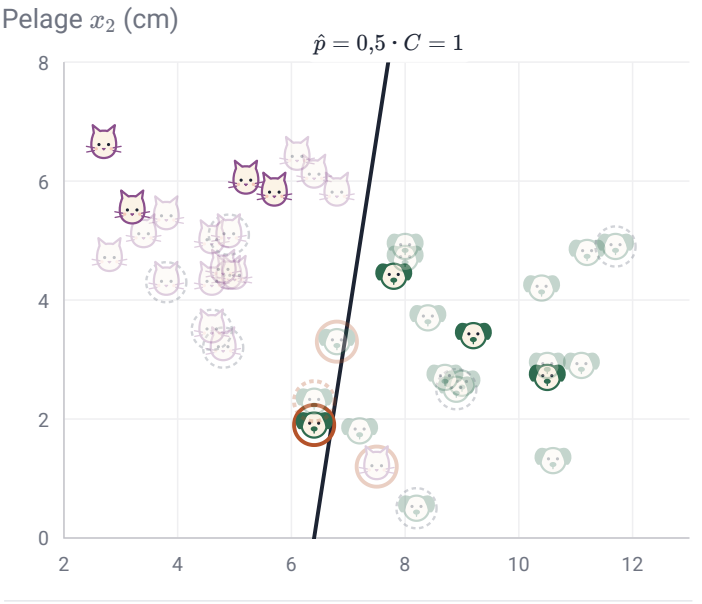
Détails · Apprendre ou choisir

Ces 8 animaux ne servent pas à ajuster w, b. Leur perte compare les modèles déjà appris. Choisir uniquement sur la perte d'apprentissage ne mesure pas leur performance sur de nouvelles données.

Répartition stratifiée tirée une fois pour toutes : 12 + 4 + 4 animaux de chaque classe. Avec 8 animaux, un score de validation ou de test reste très incertain ; l'exemple illustre les rôles, pas la précision d'une estimation.

NOUVEAU EXPÉRIENCE

Ouvrir le test une seule fois



Un modèle appris par valeur de C

C	$\hat{w}_1$	$\hat{w}_2$	$\hat{b}$	BCE appr.	BCE valid.	BCE test
0,01	0,18	−0,06	−1,00	0,519	0,509	—
0,1	0,63	−0,20	−3,61	0,287	0,248	—
1	**1,37**	**−0,22**	**−8,75**	**0,189**	**0,159**	**0,183**
10	2,24	−0,11	−15,39	0,165	0,206	—

Seul le modèle retenu est évalué sur le test.

Test ($C = 1$) : BCE $0{,}183$ · exactitude $7/8$

Estimation sur 8 animaux jamais utilisés auparavant.

Après le choix, ouvrez les **8 animaux de test**. Leur perte estime l'erreur sur de nouveaux animaux.

Elle ne sert plus à choisir un modèle.

À votre avis ?

Le score de test vous déçoit. Peut-on revenir choisir un autre C ?

- Oui, si on ne le fait qu'une fois
- Oui : c'est le rôle du test

✓ **Non**

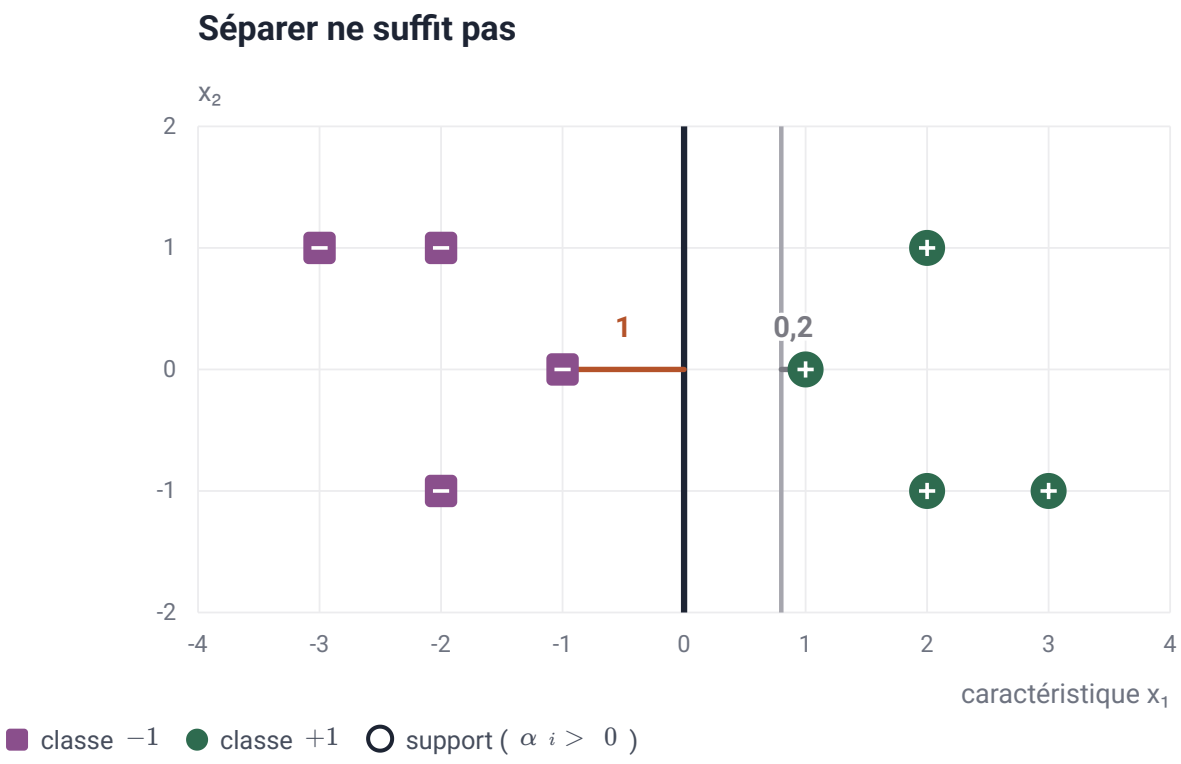
Non. Utiliser le test pour choisir en ferait un second jeu de validation : son score deviendrait optimiste.

Répartition stratifiée tirée une fois pour toutes : 12 + 4 + 4 animaux de chaque classe. Avec 8 animaux, un score de validation ou de test reste très incertain ; l'exemple illustre les rôles, pas la précision d'une estimation.

Chapitre 02 · SVM : marge dure

EXPÉRIENCE

Séparer ne suffit pas



Distance minimale : droite noire **1** · droite grise **0,2**

01 / 06

Plusieurs droites classent correctement ces points. Le SVM maximise la plus petite distance signée aux observations.

Détails

La droite grise passe près d'un point ; la noire laisse davantage d'espace.

En défilant, une droite candidate parcourt plusieurs positions ; le segment brique mesure sa distance au point le plus proche.

$$\gamma = \min_i \frac{y_i(w \cdot x_i + b)}{\|w\|}$$

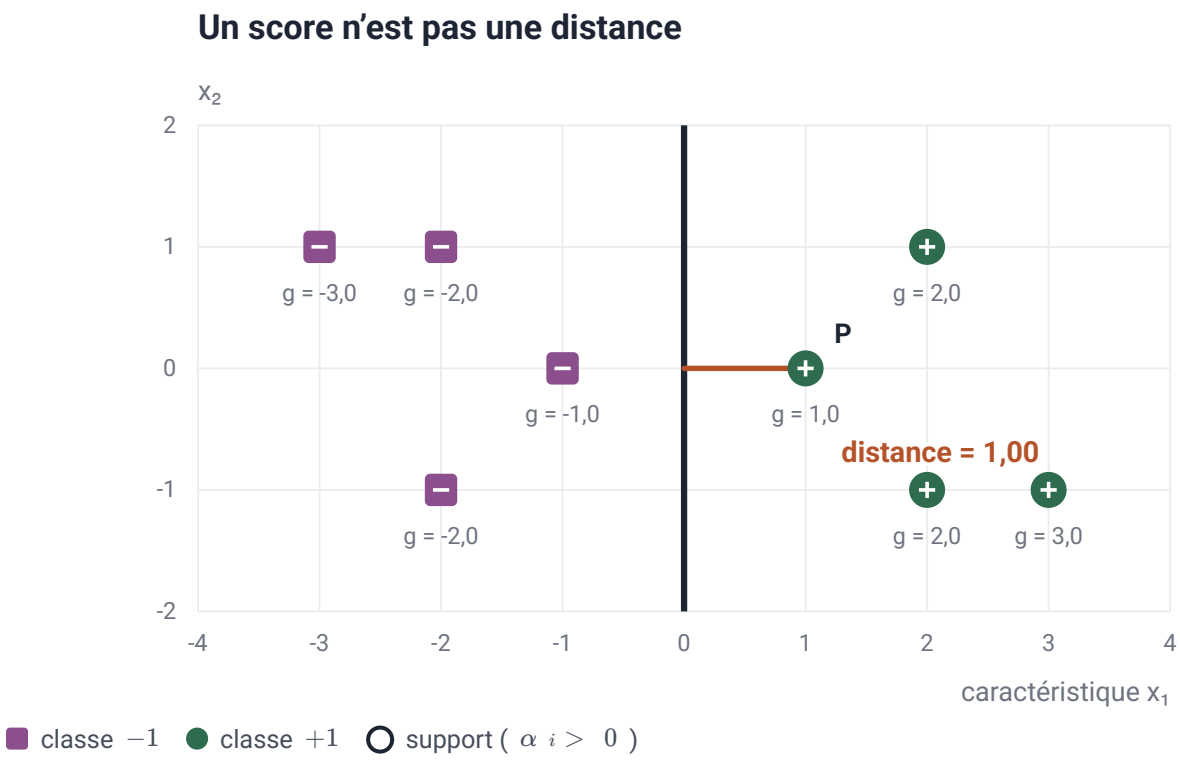
Quelle droite laisse le plus de place au point le plus proche ?

Données synthétiques en unités fixées. SVM linéaire : hinge loss, biais libre, pénalité L2 sur w. Formulation et référence ↗

Chapitre 02 · SVM : marge dure

EXPÉRIENCE

Un score n'est pas une distance



Score de P : **1,00** · norme : **1,00** · distance : **1**

02 / 06

Changez l'échelle du score : la frontière et la distance géométrique restent fixes. Seul le score change.

Détails

Multiplier w et b par le même nombre positif conserve la frontière et les classes prédites. Les scores changent ; la distance géométrique reste identique.

Le produit par le label rend la distance positive du bon côté, négative du mauvais côté.

$$g(x) = w \cdot x + b, \quad \gamma_i = \frac{y_i g(x_i)}{\|w\|}$$

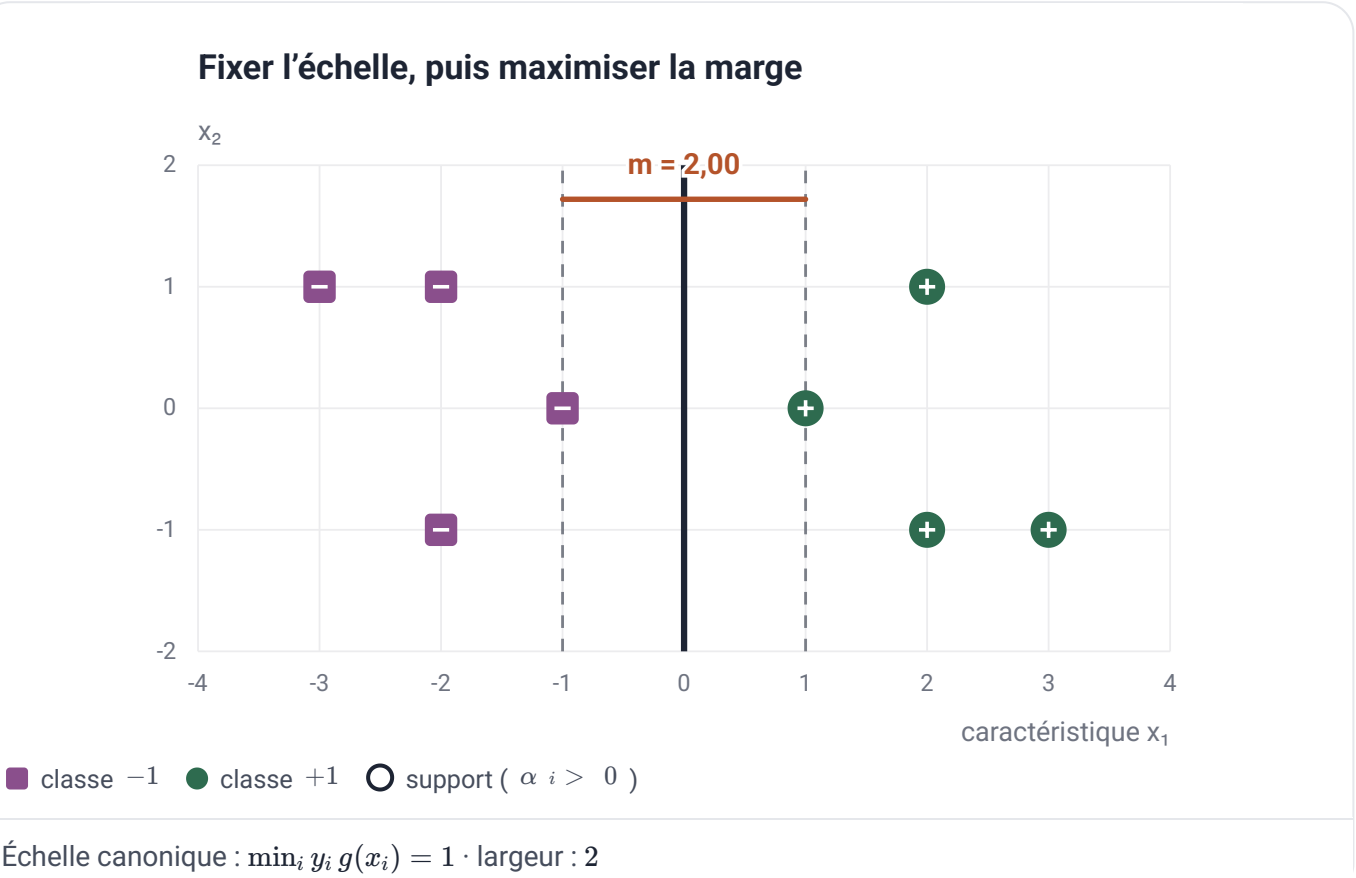
Si le score est multiplié par 3, la distance triple-t-elle ?

Données synthétiques en unités fixées. SVM linéaire : hinge loss, biais libre, pénalité L2 sur w. Formulation et référence ↗

Chapitre 02 · SVM : marge dure

EXPÉRIENCE

Fixer l'échelle, puis maximiser la marge



Échelle canonique : $\min_i y_i\, g(x_i) = 1$ · largeur : 2

03 / 06

En séparation stricte, fixez $\min_i y_i g(x_i) = 1$. Les bords sont aux niveaux -1 et $+1$: la largeur vaut $2/\|w\|$.

Détails

Pour une séparation stricte, on choisit l'échelle telle que $\min_i y_i g(x_i) = 1$. Les deux bords portent alors les niveaux -1 et $+1$.

Maximiser la largeur $2/\|w\|$ revient à minimiser $\frac{1}{2}\|w\|^2$, tout en imposant $y_i g(x_i) \geq 1$.

En défilant, la bande s'ouvre jusqu'aux niveaux -1 et $+1$.

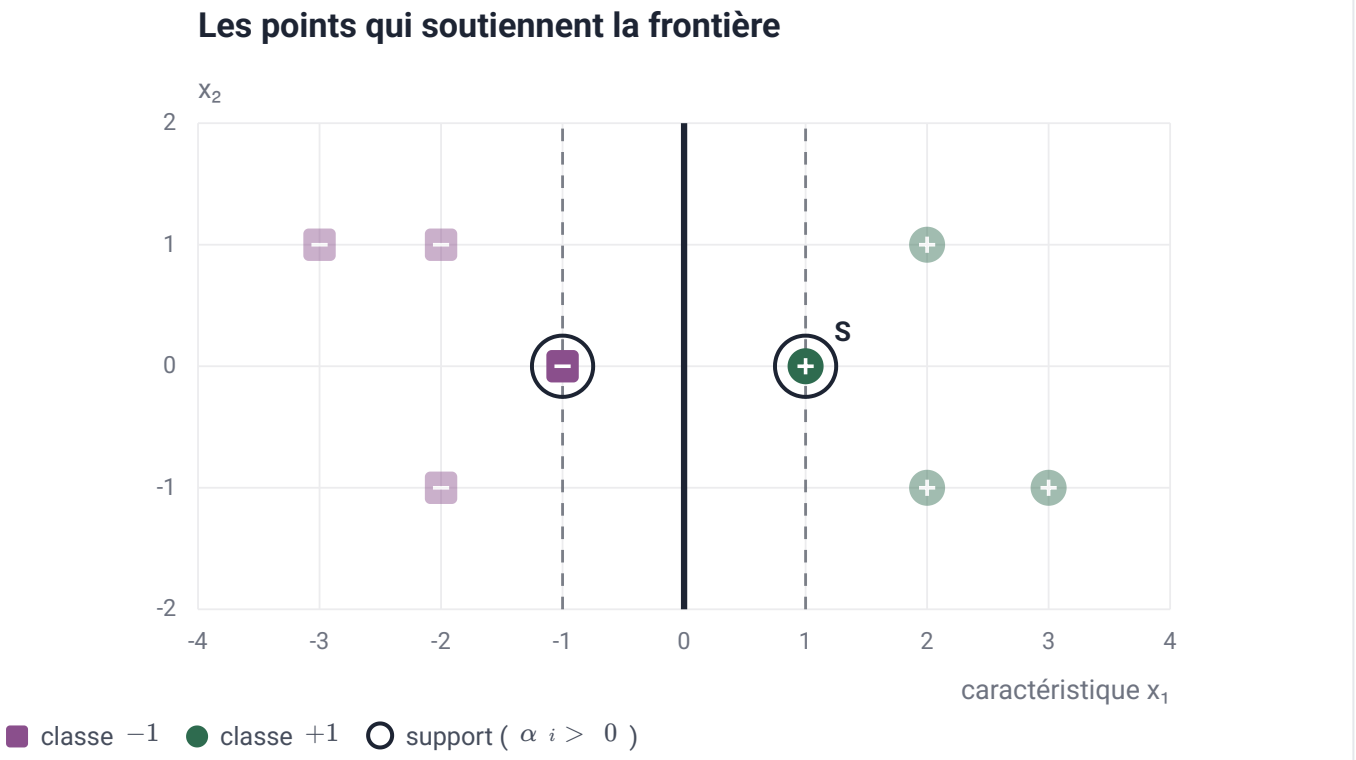
$$(w', b') = \frac{(w, b)}{\min_i y_i g(x_i)}, \qquad m = \frac{2}{\|w'\|}$$

Pourquoi ne peut-on pas réduire w sans conserver les contraintes ?

Données synthétiques en unités fixées. SVM linéaire : hinge loss, biais libre, pénalité L2 sur w. Formulation et référence ↗

EXPÉRIENCE

Les points qui soutiennent la frontière



Supports : **2** · b = **0,00** · largeur = **2,00**

04 / 06

Déplacez le support : la frontière change. Retirer le point éloigné ne change rien. Seuls les points avec $\alpha_i > 0$ contribuent à w.

Détails

Les cercles repèrent les points dont $\alpha_i > 0$: seuls ceux-ci contribuent à w. En marge dure, ils sont sur les bords.

Retirer ici le point éloigné ne change rien ; déplacer le support déplace la frontière. Un point sur un bord peut avoir $\alpha_i = 0$ dans un cas dégénéré.

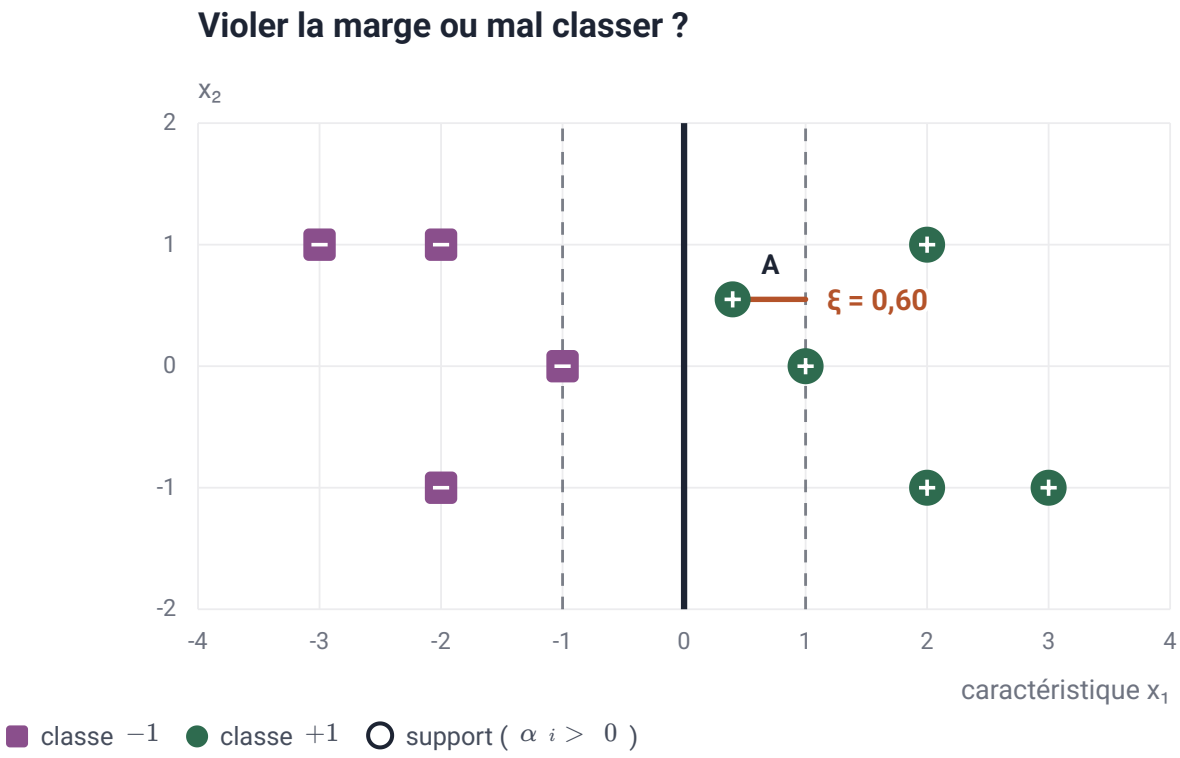
$$w = \sum_i \alpha_i y_i x_i, \qquad b = y_s - w \cdot x_s$$

Quel point faut-il déplacer pour faire bouger la frontière ?

Données synthétiques en unités fixées. SVM linéaire : hinge loss, biais libre, pénalité L2 sur w. Formulation et référence ↗

EXPÉRIENCE

Violer la marge ou mal classer ?



$y = +1 \cdot g(A)$ = **0,40** · ξ = **0,60**
Classe correcte · marge violée

05 / 06

Déplacez le point de label $+1$. Il peut être correctement classé tout en violant la marge. La perte charnière mesure cette violation.

Détails

Le score positif classe correctement le point de label $+1$, même s'il est trop proche de la frontière.

$\xi_i = \max(0,\ 1 - y_i g(x_i))$: 0 au-delà du bord ; entre 0 et 1 pour un point bien classé dans la marge ; 1 sur la frontière ; supérieur à 1 du mauvais côté.

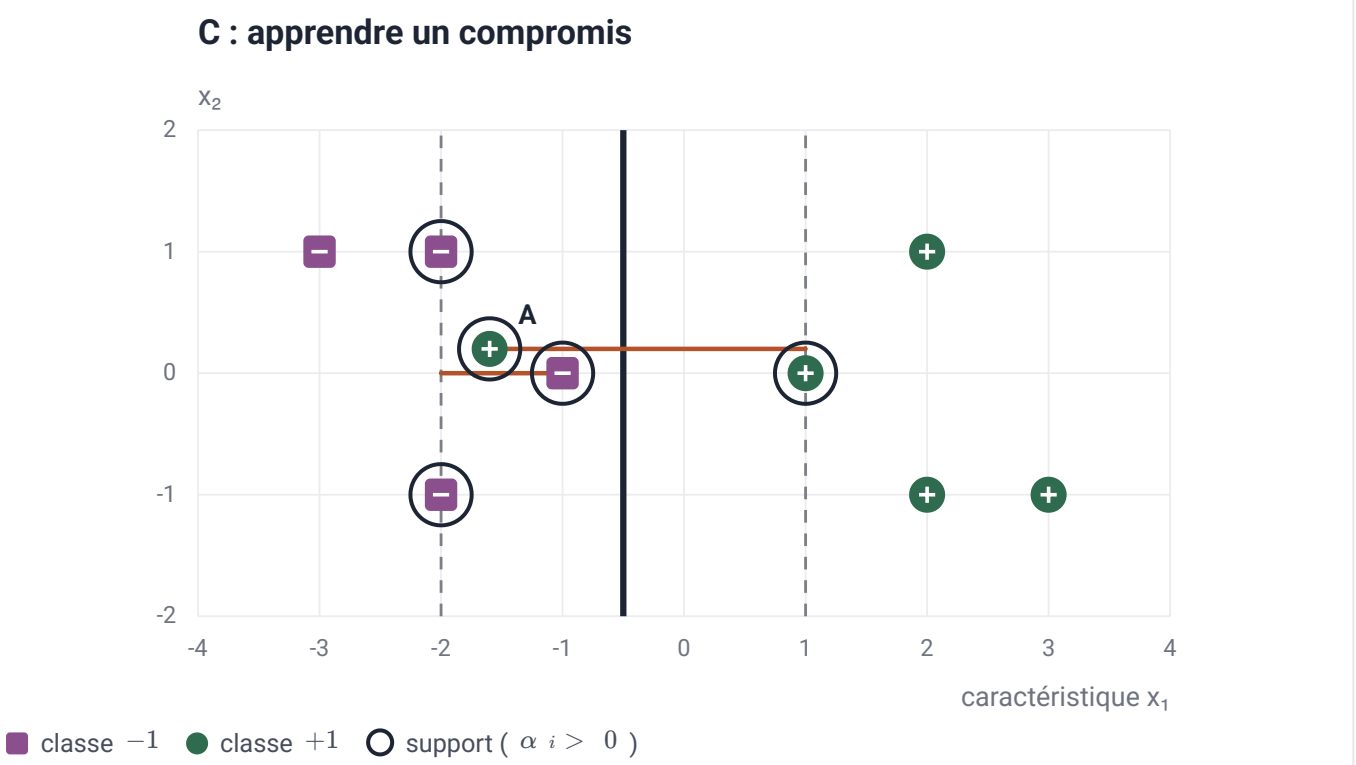
$$\xi_i^* = \max(0, 1 - y_i g(x_i)), \qquad \ell_{\text{hinge}} = \xi_i^*$$

Pour un score de $+0{,}4$, quelle classe et quelle perte ?

Données synthétiques en unités fixées. SVM linéaire : hinge loss, biais libre, pénalité L2 sur w. Formulation et référence ↗

EXPÉRIENCE

C : apprendre un compromis



C = 1,000 · $\frac{1}{2}\|w\|^2$ = **0,22** · $\sum_i \xi_i$ = **2,40** · erreurs : **1**
$C \sum_i \xi_i$ = 2,40 · objectif = 2,62 · optimum vérifié

06 / 06

Déplacez A. Le modèle est réappris à chaque réglage. C pondère les violations de marge par rapport à la norme. Choisissez C par validation.

Détails

Le point A traverse le nuage de classe -1. Lorsqu'il est à l'intérieur de son enveloppe convexe, aucune droite ne sépare parfaitement les classes.

Le modèle est réappris à chaque réglage. C pondère la somme des pertes charnières ; il ne compte pas uniquement les erreurs de classe. Choisir C par validation, après mise à l'échelle des caractéristiques.

$$\min_{w,b} \frac{1}{2}\|w\|^2 + C\sum_i \max(0, 1 - y_i g(x_i))$$

Que coûte davantage un grand C : la norme ou les violations ?

Données synthétiques en unités fixées. SVM linéaire : hinge loss, biais libre, pénalité L2 sur w. Formulation et référence ↗

NOUVEAU FORMULE

Équation d'une droite

D'une droite à sa forme générale

Au lycée, une droite s'écrit $x_2 = m\,x_1 + c$: pente m, ordonnée à l'origine c.

On passe tout du même côté : $m\,x_1 - x_2 + c = 0$. C'est la **forme générale** $w_1 x_1 + w_2 x_2 + b = 0$, avec $w = (m, -1)$ et $b = c$.

$$x_2 = -2x_1 + 1 \iff 2x_1 + x_2 - 1 = 0, \qquad w = (2, 1),\ b = -1$$

Lire la formule –

La forme générale marche aussi pour une droite verticale ($w_2 = 0$), et elle donne directement le vecteur normal w et le score $g(x) = w^\top x + b$.

NOUVEAU NOTION

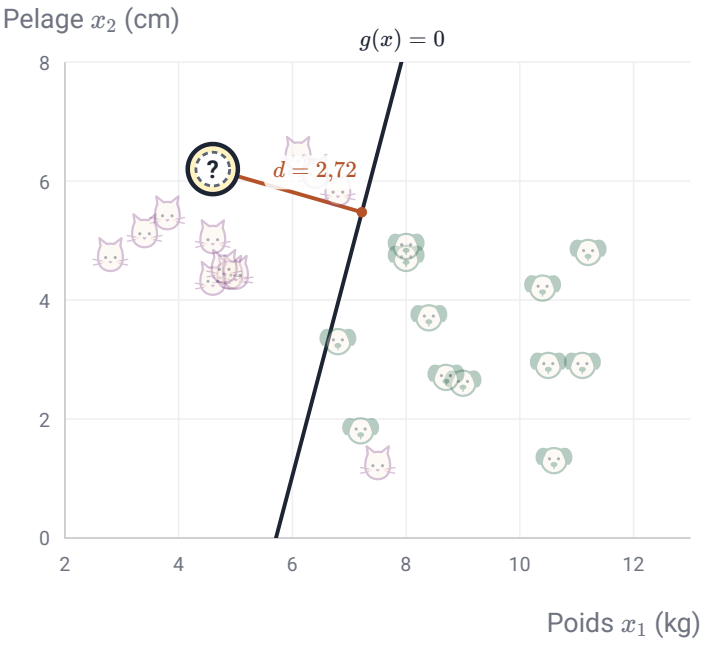
Exemple pas à pas

Distance et marge, la droite $2x_1 + x_2 = 0$

1. Forme générale : $w = (2, 1)$, $b = 0$, donc $g(x) = 2x_1 + x_2$.
2. Point $A = (3, 4)$: $g(A) = 2 \times 3 + 4 = 10 > 0$, côté positif.
3. Norme : $\|w\| = \sqrt{2^2 + 1^2} = \sqrt{5} \approx 2{,}24$.
4. Distance : $d(A) = \dfrac{|g(A)|}{\|w\|} = \dfrac{10}{\sqrt{5}} = 2\sqrt{5} \approx 4{,}47$.
5. Bords $g(x) = \pm 1$: largeur de la marge $\dfrac{2}{\|w\|} = \dfrac{2}{\sqrt{5}} \approx 0{,}89$.

NOUVEAU EXPÉRIENCE

La distance à la droite



$g(x)$	$-2{,}84$
$\|w\|$	$1{,}04$
d	$2{,}72$

$$d = \frac{|g(x)|}{\|w\|} = \frac{2{,}84}{1{,}04} = 2{,}72$$

Côté chat.

La distance de x à la droite vaut $d = \dfrac{|g(x)|}{\|w\|}$.

Déplacez « ? » : le segment brique est cette distance.

À votre avis ?

Si l'on double w et b, la distance de « ? » à la droite…

- double
- est divisée par 2

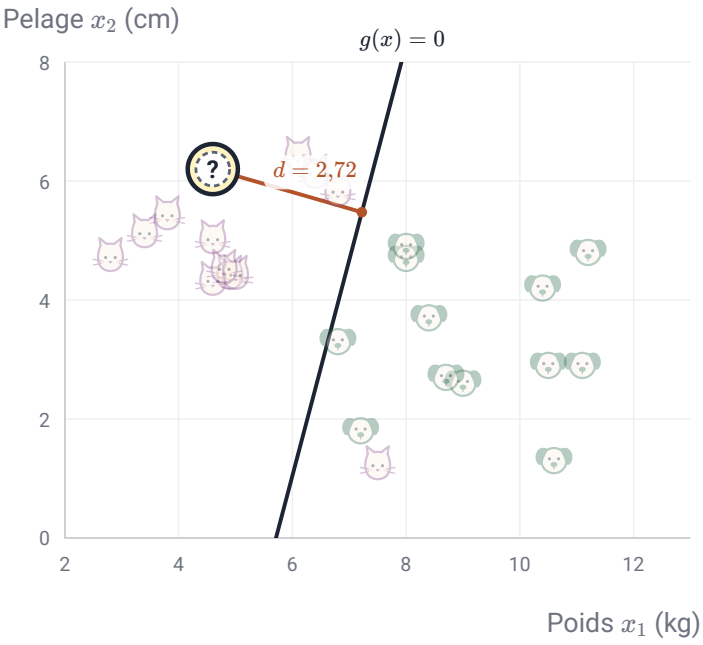
✓ ne change pas

$\dfrac{|2g(x)|}{\|2w\|} = \dfrac{|g(x)|}{\|w\|}$: la distance est géométrique, indépendante de l'échelle de (w, b).

Droite du SVM à marge souple appris sur les 24 animaux ($C = 1$). Les axes n'ont pas la même unité (kg, cm) : en pratique, on standardise les variables avant de mesurer des distances.

NOUVEAU EXPÉRIENCE

Changer d'échelle



k	$g(x)$	$\|w\|$	d
1	−2,84	1,04	2,72
2	−5,68	2,09	2,72
5	−14,20	5,22	2,72

$$d = \frac{|g(x)|}{\|w\|} = \frac{5{,}68}{2{,}09} = 2{,}72$$

Côté chat.

Multipliez w et b par k : le **score** change, la **distance** non.

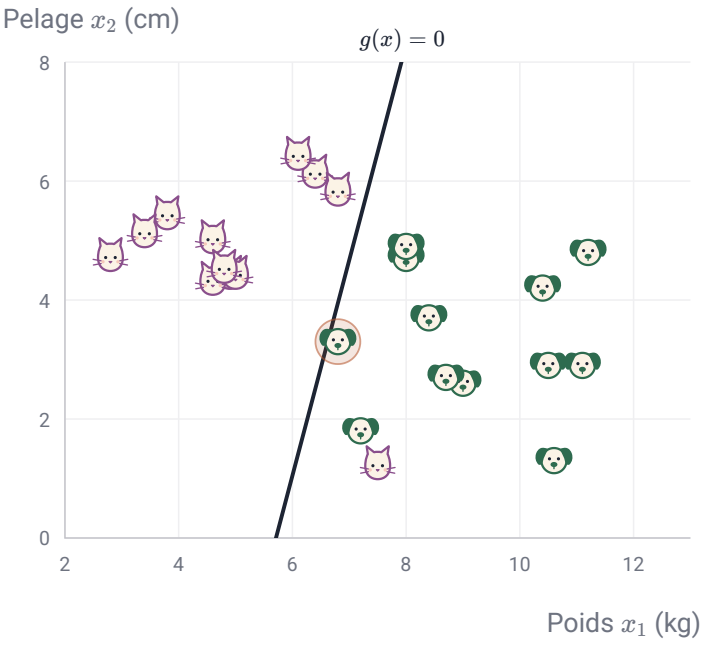
Détails · Marge fonctionnelle et marge géométrique

$y\,g(x)$ est la marge fonctionnelle : elle dépend de l'échelle. $y\,g(x)/\|w\|$ est la marge géométrique : elle n'en dépend pas.

Droite du SVM à marge souple appris sur les 24 animaux ($C = 1$). Les axes n'ont pas la même unité (kg, cm) : en pratique, on standardise les variables avant de mesurer des distances.

NOUVEAU EXPÉRIENCE

Le point le plus proche



Animal	distance
Chien 30	0,17
Chat 19	0,49
Chien 39	0,90
Chien 38	0,96

Les quatre animaux les plus proches de la droite.

Plus petite distance : 0,17 (Chien 30)

Le SVM maximise cette plus petite distance.

Parmi les 24 animaux, l'un est le **plus proche** de la droite.

Le SVM cherche la droite qui rend cette plus petite distance la plus grande possible : c'est la **marge**.

Droite du SVM à marge souple appris sur les 24 animaux ($C = 1$). Les axes n'ont pas la même unité (kg, cm) : en pratique, on standardise les variables avant de mesurer des distances.

NOUVEAU FORMULE

La marge

On trace deux droites parallèles à la frontière, où le score vaut $+1$ et -1.

La bande entre elles est la **marge**. Sa largeur ne dépend que de $\|w\|$.

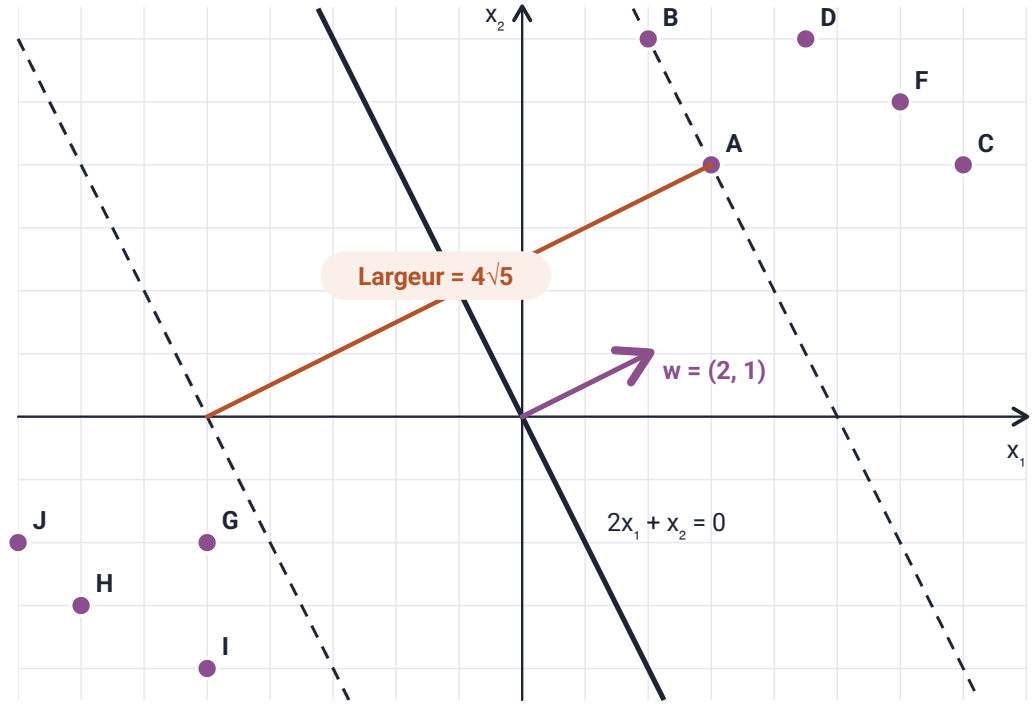
$$\text{largeur} = \frac{2}{\|w\|}$$

Lire la formule –

Chapitre 02 · SVM : marge dure

NOUVEAU FORMULE

Marge dure · le problème



Frontières parallèles : $2x_1 + x_2 = -10$ et $2x_1 + x_2 = 10$.

Frontière $w \cdot x + b = 0$, bords $w \cdot x + b = \pm 1$.

$$\min_{w,b} \ \tfrac{1}{2}\|w\|^2 \quad \text{sous} \quad y_i(w \cdot x_i + b) \geq 1, \ \ \forall i \in [1, m]$$

Lire la formule –

> **Pourquoi c'est « facile »**
>
> Les contraintes sont **affines** et l'objectif est **convexe** : les conditions KKT s'appliquent, on introduit des **multiplicateurs de Lagrange**.

NOUVEAU NOTION

Primal ou dual ?

On peut résoudre le problème sous sa forme **primale** (en w, b) ou **duale** (en α).

- $n \gg p$ (beaucoup d'exemples, peu de variables) : plutôt le **primal**.
- $p \gg n$: plutôt le **dual**.

Dans scikit-learn, $\mathrm{LinearSVC}(\mathrm{dual}=\text{"auto"})$ choisit selon les dimensions.

> **Comme en programmation linéaire… mais pas tout à fait**
>
> En PL, le dual échange objectif et contraintes. Ici, c'est de l'**optimisation convexe** : on passe par le Lagrangien.

NOUVEAU FORMULE

Comment le résoudre ? Le Lagrangien

Idée : transformer un problème **avec contraintes** en un problème **sans contraintes**. Chaque contrainte reçoit un multiplicateur $\alpha_i \geq 0$.

$$\mathcal{L}(w, b, \alpha) = \tfrac{1}{2}\|w\|^2 - \sum_{i=1}^{m} \alpha_i \big[y_i (w \cdot x_i + b) - 1 \big]$$

Lire la formule –

NOUVEAU FORMULE

Les conditions KKT

$$\begin{aligned} \nabla_w \mathcal{L} = w - \textstyle\sum_i \alpha_i y_i x_i = 0 &\implies w = \textstyle\sum_i \alpha_i y_i x_i \\ \nabla_b \mathcal{L} = -\textstyle\sum_i \alpha_i y_i = 0 &\implies \textstyle\sum_i \alpha_i y_i = 0 \\ \forall i,\ \alpha_i \big[y_i (w \cdot x_i + b) - 1 \big] = 0 &\implies \alpha_i = 0 \text{ ou } y_i (w \cdot x_i + b) = 1 \end{aligned}$$

Lire la formule –

Ces trois conditions donnent la solution (w^*, b^*, α^*). La dernière dit : soit $\alpha_i = 0$, soit le point est **sur le bord** — un vecteur de support.

NOUVEAU FORMULE

Obtenir le dual en 3 étapes

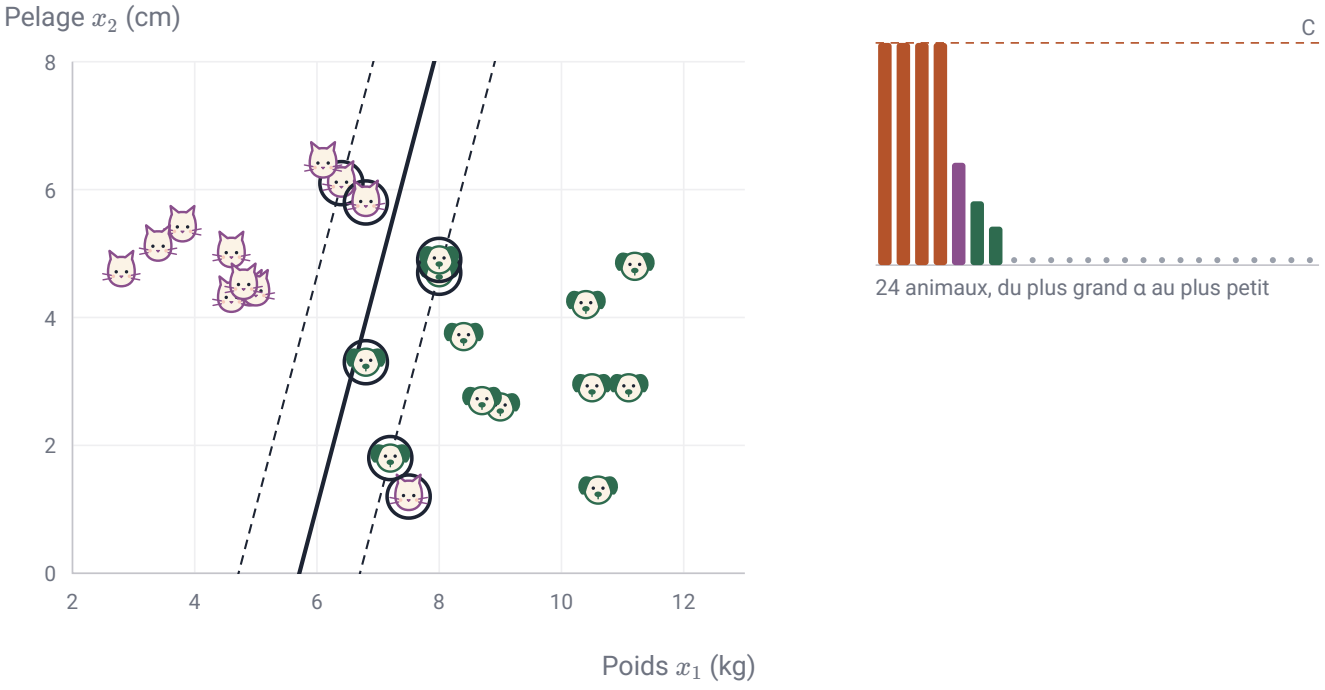
1. **Introduire** un multiplicateur $\alpha_i \geq 0$ par contrainte : $\mathcal{L} = \text{objectif} - \sum_i \alpha_i \, (\text{contrainte}_i)$.
2. **Minimiser** en (w, b) : on obtient $w = \sum_i \alpha_i y_i x_i$ et $\sum_i \alpha_i y_i = 0$. En remplaçant, $\|w\|^2 = \sum_{i,j} \alpha_i \alpha_j y_i y_j \, (x_i \cdot x_j)$ et le terme en b disparaît.
3. **Maximiser** en α ce qui reste.

$$\max_{\alpha} \sum_i \alpha_i - \tfrac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j \, (x_i \cdot x_j) \quad \text{sous} \quad \alpha_i \geq 0, \;\; \textstyle\sum_i \alpha_i y_i = 0$$

Lire la formule –

NOUVEAU EXPÉRIENCE

Un α_i par animal



7 animaux sur 24 ont $\alpha_i > 0$

Les vecteurs de support. Les 17 autres ont $\alpha_i = 0$.

Le dual associe un **multiplicateur** $\alpha_i \geq 0$ à chaque animal.

La plupart valent 0. Ceux qui sont strictement positifs désignent les **vecteurs de support**, cerclés.

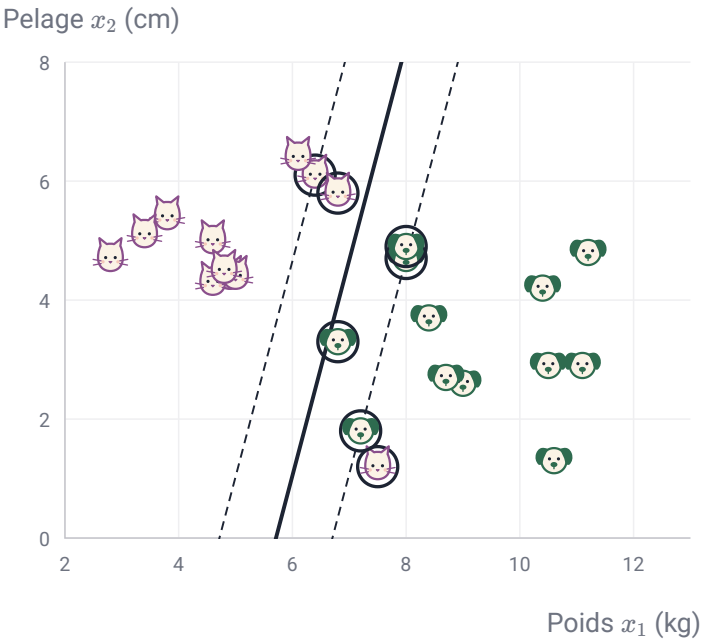
Détails · D'où vient α

α_i est le multiplicateur de Lagrange de la contrainte $y_i \, g(x_i) \geq 1 - \xi_i$. Il est nul quand la contrainte n'est pas active.

Solution du problème dual du cours sur les 24 animaux d'apprentissage (marge souple). Au deuxième temps, tous les animaux se déplacent : le SVM est réappris à chaque mouvement.

NOUVEAU EXPÉRIENCE

Seuls les supports comptent



Support	α_i	y_i
Chat 16	1,000	−1
Chat 19	1,000	−1
Chien 30	1,000	+1
Chien 39	1,000	+1
Chat 13	0,460	−1
Chien 38	0,287	+1
Chien 32	0,173	+1

$\sum_i \alpha_i y_i x_i = (1{,}01\,;\,-0{,}28) = w$

Défi Déplacez un animal sans faire bouger la frontière.

$w = (1{,}01\,;\,-0{,}28)$, $b = -5{,}75$

7 vecteurs de support. Réinitialiser remet les animaux en place.

$w = \sum_i \alpha_i y_i x_i$: seuls les animaux avec $\alpha_i > 0$ y contribuent.

Déplacez un animal : la frontière ne bouge que s'il est (ou devient) un vecteur de support.

À votre avis ?

On éloigne un chat de la frontière, sans qu'il entre dans la marge. w…

- change un peu
- ✓ **ne change pas**
- change beaucoup

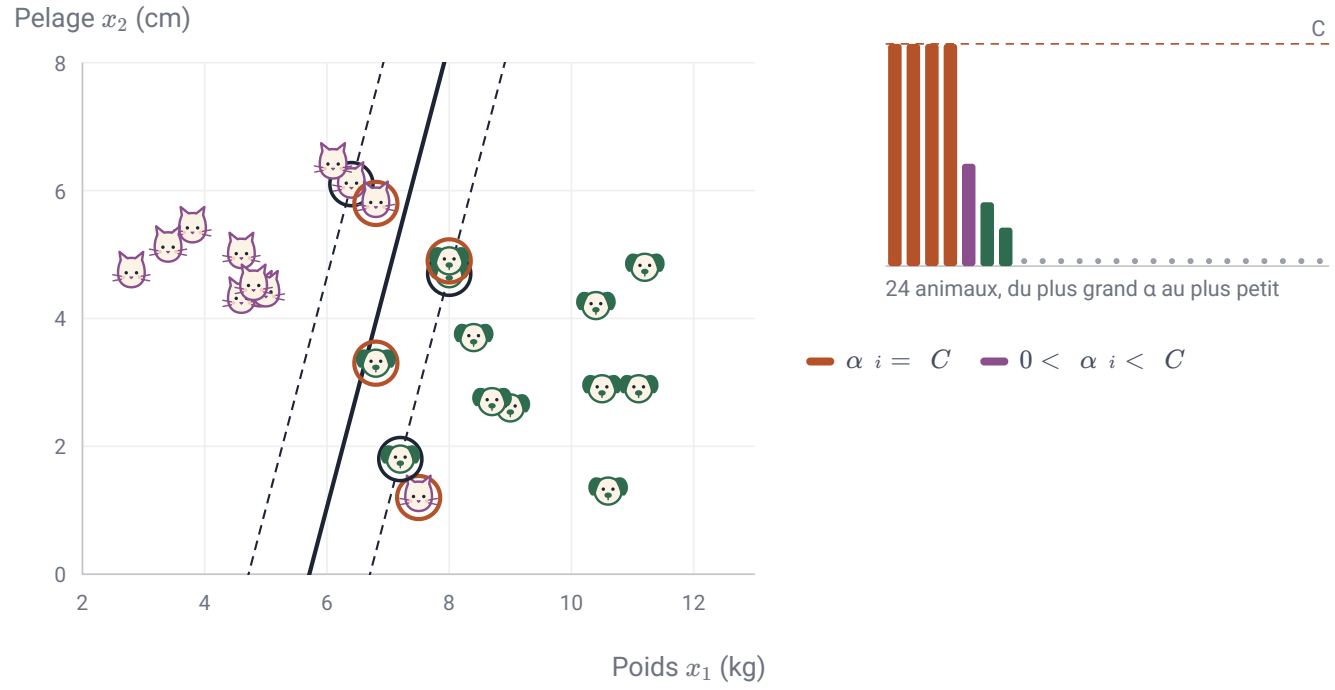
Un animal hors de la marge garde $\alpha_i = 0$: ni w ni b ne changent. Essayez en déplaçant un animal loin de la frontière.

Solution du problème dual du cours sur les 24 animaux d'apprentissage (marge souple). Au deuxième temps, tous les animaux se déplacent : le SVM est réappris à chaque mouvement.

Chapitre 02 · SVM : marge dure

NOUVEAU EXPÉRIENCE

α_i est borné par C



$C = 1$ **: 4 animaux avec** $\alpha_i = C$**, 3 avec** $0 < \alpha_i < C$

$\sum_i \alpha_i y_i = 0{,}000$, comme l'exige le dual.

En marge souple, $0 \leq \alpha_i \leq C$.

$0 < \alpha_i < C$: sur un bord. $\alpha_i = C$ (en brique) : dans la marge ou mal classé.

À votre avis ?

Un animal a $\alpha_i = C$. Il est…

- sur le bord de la marge
- loin de la frontière

✓ **dans la marge ou du mauvais côté**

Si $\alpha_i = C$, les conditions KKT donnent $y_i\, g(x_i) \leq 1$: l'animal ne respecte pas strictement la marge. Ici, ce sont les animaux dans la marge ou mal classés.

Solution du problème dual du cours sur les 24 animaux d'apprentissage (marge souple). Au deuxième temps, tous les animaux se déplacent : le SVM est réappris à chaque mouvement.

Chapitre 02 · SVM : marge dure

NOUVEAU FORMULE

Seuls quelques animaux comptent

Le SVM se résume aux animaux **sur le bord ou dans la marge** : les **vecteurs de support**.

Les autres peuvent bouger sans rien changer.

$$w = \sum_{i \,\in\, \text{supports}} \alpha_i\, y_i\, x_i$$

Lire la formule –

Chapitre 02 · SVM : marge dure

NOUVEAU NOTION

Exemple pas à pas

Le dual sur deux points

1. Données : $x_1 = (2, 0)$, $y_1 = +1$; $x_2 = (0, 0)$, $y_2 = -1$.
2. $\sum_i \alpha_i y_i = 0$ donne $\alpha_1 = \alpha_2 = \alpha$, puis $w = \alpha x_1 - \alpha x_2 = (2\alpha, 0)$.
3. Les deux points sont sur les bords : $g(x_1) = 4\alpha + b = 1$ et $g(x_2) = b = -1$.
4. Donc $b = -1$, $\alpha = \frac{1}{2}$, $w = (1, 0)$: la frontière est la droite $x_1 = 1$.
5. Marge : $2/\|w\| = 2$, exactement la distance entre les deux points.

NOUVEAU FORMULE

Pourquoi relâcher la marge ?

Avec de vraies données, chats et chiens se chevauchent : **aucune droite** ne les sépare parfaitement. La marge dure n'a alors aucune solution.

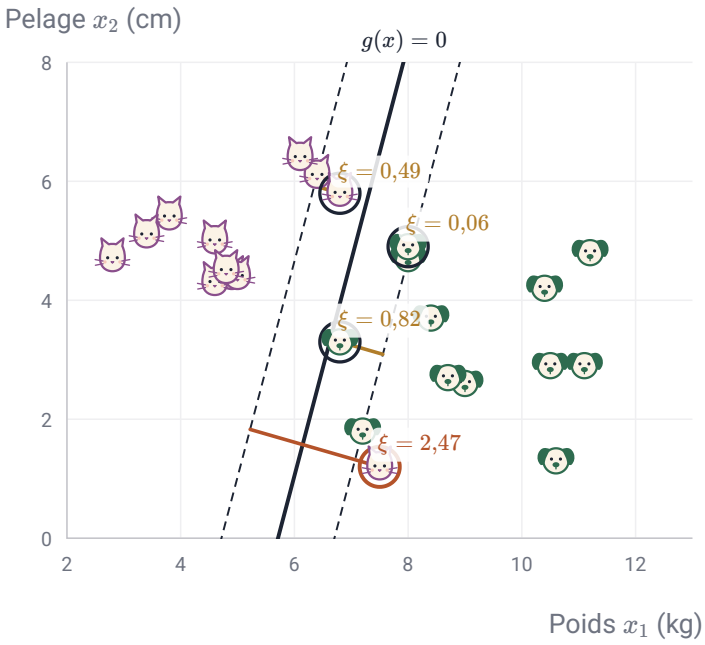
On autorise donc chaque animal à dépasser son bord d'un peu, ξ_i, et on fait payer ce dépassement.

$$y_i\, g(x_i) \geq 1 - \xi_i, \qquad \xi_i \geq 0$$

Lire la formule –

NOUVEAU EXPÉRIENCE

Des animaux dans la marge



Animal	$y_i\, g(x_i)$	ξ_i
Chat 16	−1,47	2,47
Chien 30	0,18	0,82
Chat 19	0,51	0,49
Chien 39	0,94	0,06

4 violations de marge · 1 du mauvais côté

$C = 1$, largeur $2/\|w\| = 1{,}91$, $\sum_i \xi_i = 3{,}83$.

Les données se chevauchent : certains animaux sont **dans la marge**, voire du mauvais côté.

Chacun reçoit un **relâchement** $\xi_i \geq 0$: ce qui lui manque pour atteindre son bord $y_i\, g(x_i) = 1$.

Détails · La contrainte relâchée

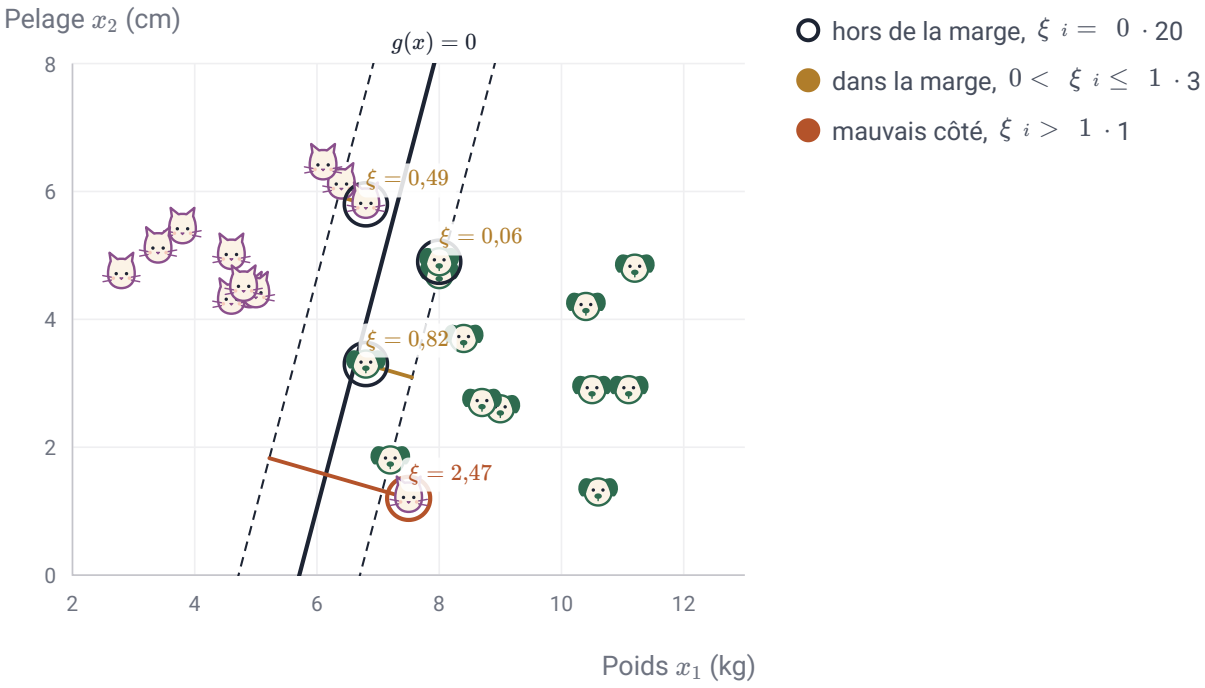
On remplace $y_i\, g(x_i) \geq 1$ par $y_i\, g(x_i) \geq 1 - \xi_i$, avec $\xi_i \geq 0$. Hors de la marge, $\xi_i = 0$.

SVM linéaire à marge souple sur les 24 animaux d'apprentissage. ξ_i se lit en unités de score : la longueur dessinée vaut $\xi_i / \|w\|$.

Chapitre 02 · SVM : marge souple

NOUVEAU EXPÉRIENCE

Trois situations



4 violations de marge · 1 du mauvais côté

$C = 1$, largeur $2/\|w\| = 1{,}91$, $\sum_i \xi_i = 3{,}83$.

$\xi_i = 0$: hors de la marge. $0 < \xi_i \leq 1$: **dans la marge**, encore du bon côté. $\xi_i > 1$: **mauvais côté**.

À votre avis ?

Un chat bien classé, mais à l'intérieur de la marge, a un relâchement ξ…

- égal à 0

✓ **entre 0 et 1**

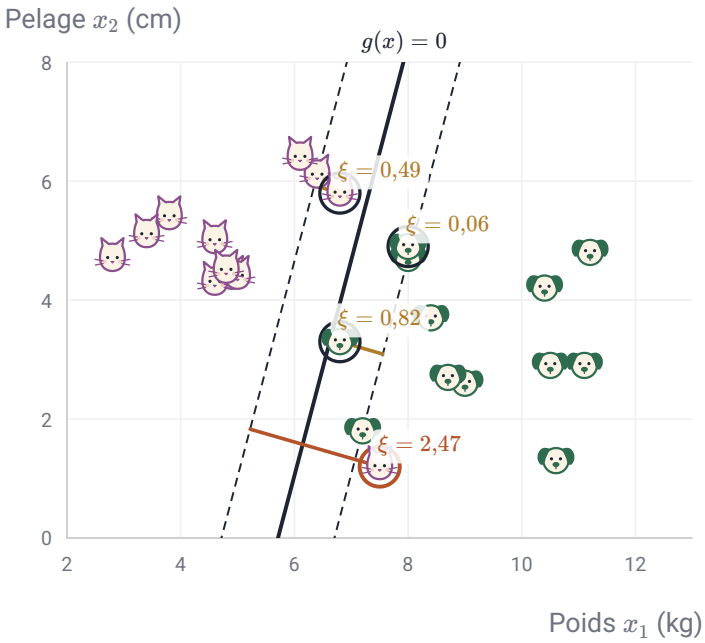
- plus grand que 1

Bien classé : $y\, g(x) > 0$. Dans la marge : $y\, g(x) < 1$. Donc $\xi = 1 - y\, g(x) \in (0, 1)$: une violation de marge n'est pas forcément une erreur.

SVM linéaire à marge souple sur les 24 animaux d'apprentissage. ξ_i se lit en unités de score : la longueur dessinée vaut $\xi_i / \|w\|$.

NOUVEAU EXPÉRIENCE

Le rôle de C



C	**largeur** $2/\|w\|$	$\sum \xi_i$	**violations**
0,01	7,00	9,83	17
0,10	3,36	4,95	8
1	1,91	3,83	4
10	1,39	3,73	2

4 violations de marge · 1 du mauvais côté

$C = 1$, largeur $2/\|w\| = 1{,}91$, $\sum_i \xi_i = 3{,}83$.

C règle le prix des violations dans $\frac{1}{2}\|w\|^2 + C\sum_i \xi_i$.

Changez C et regardez la largeur de la marge.

À votre avis ?

Quand C augmente, la marge…

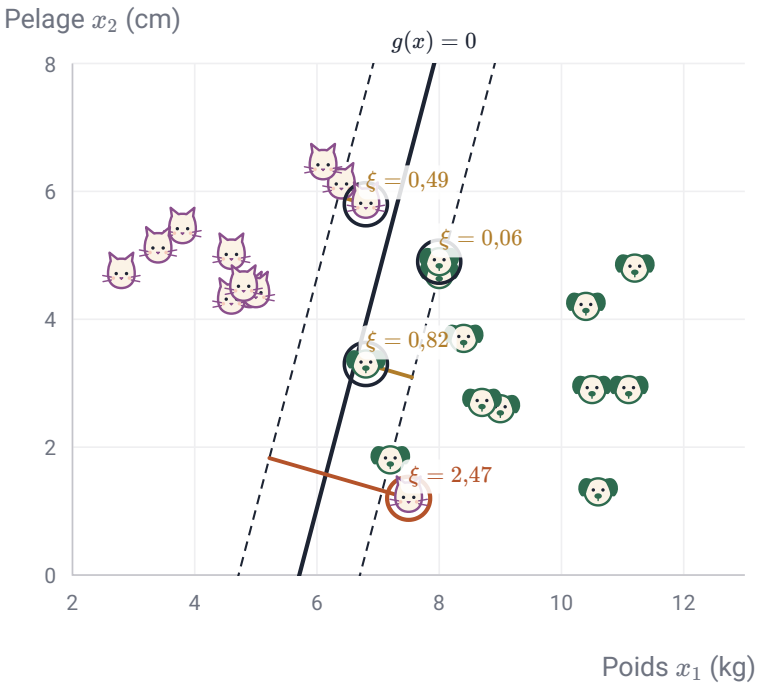
- s'élargit
- ✓ **se rétrécit**
- ne change pas

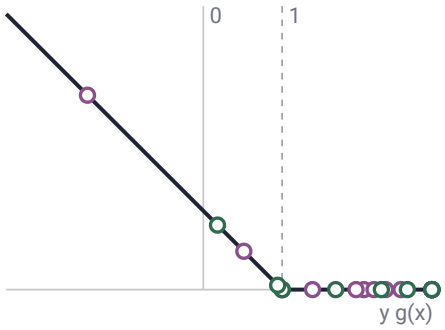
Ici, la largeur $2/\|w\|$ passe d'environ $7{,}0$ à $1{,}4$ quand C va de $0{,}01$ à 10. Un grand C pénalise davantage les violations.

SVM linéaire à marge souple sur les 24 animaux d'apprentissage. ξ_i se lit en unités de score : la longueur dessinée vaut $\xi_i / \|w\|$.

NOUVEAU EXPÉRIENCE

ξ_i est la perte charnière





Points à droite de 1 : $\xi_i = 0$. À gauche de 0 : mauvais côté.

$$\xi_i = \max\left(0,\ 1 - y_i\, g(x_i)\right)$$

$\sum_i \xi_i = 3{,}83$ pour $C = 1$.

À w, b fixés, le meilleur relâchement vaut $\xi_i = \max\left(0,\ 1 - y_i\, g(x_i)\right)$: la **perte charnière**.

Chaque animal est un point sur cette courbe.

Détails · Le SVM souple, sans contraintes

Le problème devient $\min_{w,b}\ \frac{1}{2}\|w\|^2 + C\sum_i \max\left(0, 1 - y_i\, g(x_i)\right)$: une régularisation plus une perte charnière.

SVM linéaire à marge souple sur les 24 animaux d'apprentissage. ξ_i se lit en unités de score : la longueur dessinée vaut $\xi_i / \|w\|$.

NOUVEAU FORMULE

Marge souple · le problème

$$\min_{w,b,\xi} \ \tfrac{1}{2}\|w\|^2 + C\sum_{i=1}^{n}\xi_i \quad \text{sous} \quad y_i(w\cdot x_i + b) \geq 1-\xi_i, \ \ \xi_i \geq 0$$

Lire la formule –

Chaque point peut entrer dans la marge, ou même passer de l'autre côté, de ξ_i ; C fixe le prix de ces violations.

NOUVEAU FORMULE

Le compromis C

On accepte quelques animaux dans la marge, mais chacun coûte ξ_i.

C **grand** : les erreurs coûtent cher, marge étroite. C **petit** : marge large, plus d'erreurs tolérées.

Au mieux, $\xi_i = \max(0, 1 - y_i\, g(x_i))$: c'est la **perte charnière** du SVM.

$$\min_{w,b} \ \tfrac{1}{2}\|w\|^2 + C\sum_{i}\xi_i$$

Lire la formule –

NOUVEAU FORMULE

Deux familles de multiplicateurs

Deux types de contraintes, donc deux multiplicateurs : $\alpha_i \geq 0$ pour $y_i(w\cdot x_i + b) \geq 1-\xi_i$, et $\mu_i \geq 0$ pour $\xi_i \geq 0$.

$$L(w,b,\xi,\alpha,\mu) = \tfrac{1}{2}\|w\|^2 + C\sum_i \xi_i - \sum_i \alpha_i\big(y_i(w\cdot x_i + b) - 1 + \xi_i\big) - \sum_i \mu_i\xi_i$$

Lire la formule –

NOUVEAU FORMULE

Annuler les dérivées

$$\frac{\partial L}{\partial w} = 0 \Rightarrow w = \sum_i \alpha_i y_i x_i \qquad \frac{\partial L}{\partial b} = 0 \Rightarrow \sum_i \alpha_i y_i = 0 \qquad \frac{\partial L}{\partial \xi_i} = 0 \Rightarrow \alpha_i + \mu_i = C$$

Lire la formule –

Comme $\alpha_i \geq 0$, $\mu_i \geq 0$ et $\alpha_i + \mu_i = C$: $0 \leq \alpha_i \leq C$. C'est la seule différence avec la marge dure.

NOUVEAU FORMULE

Finalement

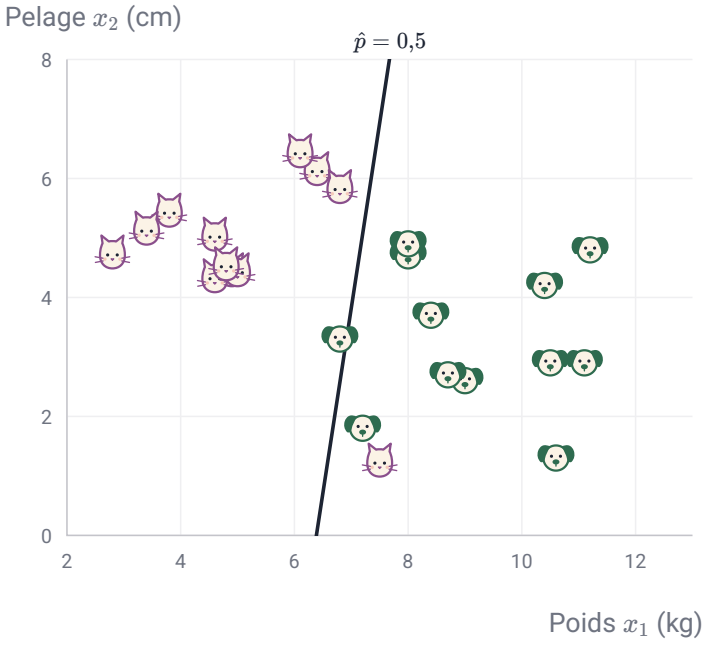
$$\max_{\alpha} \sum_i \alpha_i - \tfrac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j \, (x_i \cdot x_j) \quad \text{sous} \quad 0 \leq \alpha_i \leq C, \;\; \textstyle\sum_i \alpha_i y_i = 0$$

Lire la formule –

Même dual qu'en marge dure, avec une borne supérieure C sur chaque α_i.

NOUVEAU EXPÉRIENCE

Mêmes animaux, étiquettes -1 et $+1$



	Logistique	SVM
chat	$y = 0$	$y = -1$
chien	$y = 1$	$y = +1$
sortie	$\hat{p} \in (0, 1)$	$g(x) \in \mathbb{R}$
perte	entropie croisée	charnière

$y^{\pm} = 2y - 1$: même information, autre codage.

Frontière logistique $\hat{p} = 0{,}5$

Même nuage que dans la partie sur la régression logistique.

Mêmes animaux, nouveau codage : **chat** -1**, chien** $+1$ pour le SVM.

Score positif ou nul : chien. Score négatif : chat.

Détails · Passer de 0/1 à −1/+1

On passe de $0/1$ à $-1/+1$ par $y_i^{\pm} = 2y_i - 1$. Dans ce récit SVM, y_i désigne ensuite le codage ± 1.

$y_i g(x_i) > 0$ signifie que le point est du bon côté de la frontière. Les modèles logistique et SVM ont chacun leurs propres w, b, donc des fonctions de score différentes.



À votre avis ?

Un chien a $g(x) = -0{,}4$. Que vaut $y\, g(x)$? Est-il bien classé ?

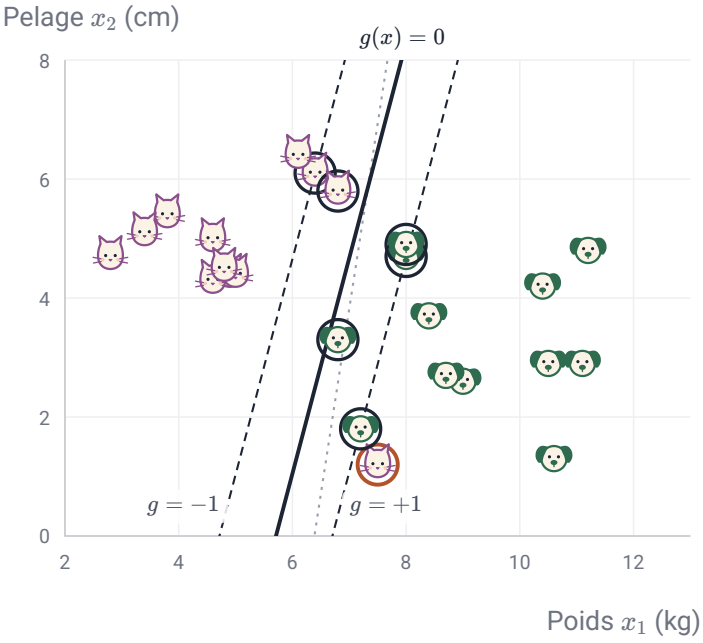
- $y\, g(x) = 0{,}4$: bien classé
- ✓ $y\, g(x) = -0{,}4$ **: mal classé**
- $y\, g(x) = -0{,}4$: bien classé, car proche de la frontière

$y = +1$, donc $y\, g(x) = -0{,}4 < 0$: il est du mauvais côté de la frontière.

Mêmes 24 animaux d'apprentissage, mêmes axes. SVM linéaire à marge souple résolu par le dual du cours ; régression logistique de référence avec $C = 1$. Les deux mesures ont des unités différentes : la largeur de marge dépend de cette échelle.

NOUVEAU EXPÉRIENCE

Marge et vecteurs de support



w	$(1{,}01\,;\,-0{,}28)$
b	$-5{,}75$
largeur $2/\|w\|$	$1{,}91$
vecteurs de support	7 sur 24

Dans ce jeu, SVM avec $C = 1$. Pointillés : bords $g(x) = \pm 1$.

7 vecteurs de support

$\|w\| = 1{,}04$ · écart primal-dual $< 10^{-4}$.

Le SVM cherche une **marge large**. Les supports sont cerclés ; la frontière logistique est grise.

Échelle importante : en pratique, standardiser sur l'apprentissage seulement. Ici, les unités restent fixées pour l'illustration.

Détails · Lire les marges

La frontière vaut $g(x) = 0$, les bords $g(x) = \pm 1$. Les supports sont sur un bord, dans la marge ou du mauvais côté. Un point strictement hors marge, sans multiplicateur actif, peut rester sans effet s'il est déplacé tout en restant hors marge.

La frontière grise correspond à $\hat{p} = 0{,}5$. Les deux modèles ont des objectifs différents.

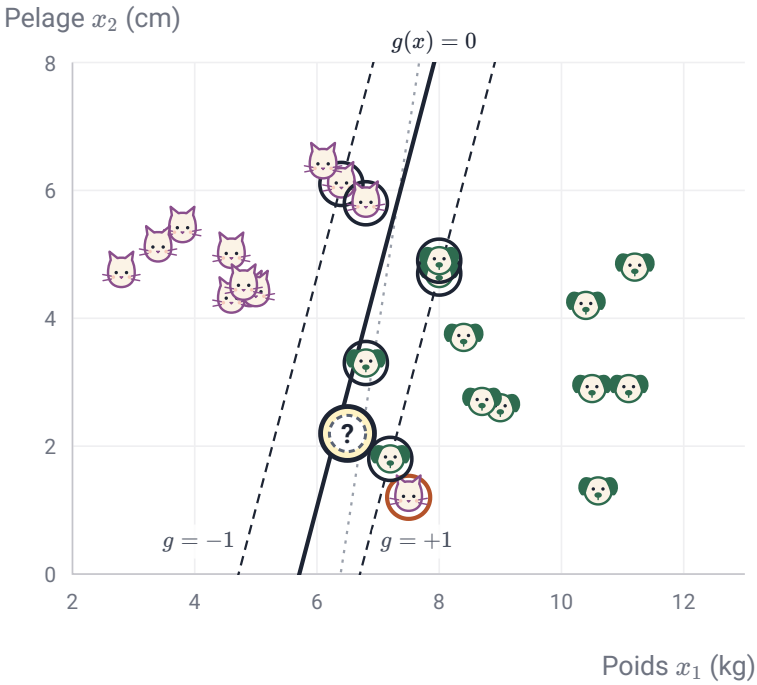
Les moyennes et écarts types de standardisation sont appris sur l'apprentissage, puis réutilisés sur la validation et le test. En validation croisée, les réapprendre dans chaque pli.

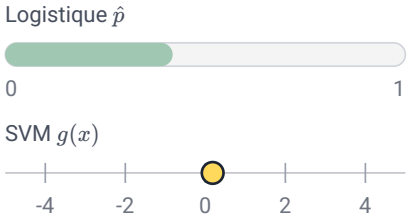
Mêmes 24 animaux d’apprentissage, mêmes axes. SVM linéaire à marge souple résolu par le dual du cours ; régression logistique de référence avec $C = 1$. Les deux mesures ont des unités différentes : la largeur de marge dépend de cette échelle.

Chapitre 02 · SVM : marge souple

NOUVEAU EXPÉRIENCE

Un score SVM n’est pas une probabilité





Même animal, deux lectures : une probabilité bornée, un score non borné.

$\hat{p} = 0{,}42$ **(logistique)** · $g(x) = 0{,}18$ **(SVM)**

Distance signée à la frontière SVM : $g(x)/\|w\| = 0{,}18$. Classes prédites : chat / chien.

Déplacez « ? » et comparez : **probabilité** pour la régression logistique, **score** pour le SVM.

Un score SVM de 2 n’est pas une probabilité.

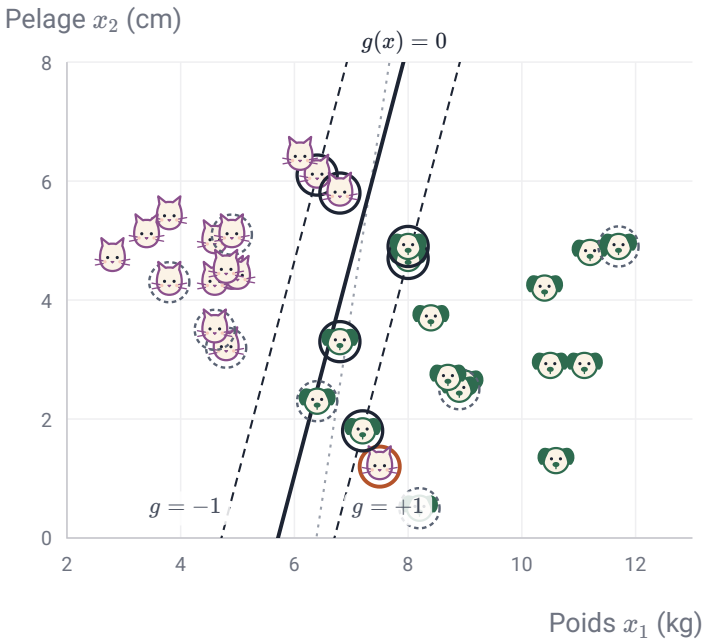
Détails · Score et distance

$\hat{p} \in (0, 1)$, mais $g(x) \in \mathbb{R}$. La distance signée SVM vaut $g(x)/\|w\|$. Transformer un score SVM en probabilité demande une calibration supplémentaire, par exemple celle de Platt.

Mêmes 24 animaux d’apprentissage, mêmes axes. SVM linéaire à marge souple résolu par le dual du cours ; régression logistique de référence avec $C = 1$. Les deux mesures ont des unités différentes : la largeur de marge dépend de cette échelle.

NOUVEAU EXPÉRIENCE

Choisir C sur la validation



Paramètres appris pour chaque C

C	$\hat{w}$	$\hat{b}$	supports	charnière valid.	erreurs
0,01	$(0{,}27; -0{,}10)$	−1,53	19	0,369	1/8
0,1	$(0{,}51; -0{,}31)$	−2,15	11	0,129	0/8
1	$(1{,}01; -0{,}28)$	**−5,75**	**7**	**0,118**	**0/8**
10	$(1{,}40; -0{,}36)$	−8,41	5	0,162	1/8

Dans ce jeu, un petit C donne une marge plus large et davantage de supports. Ce nombre ne suit pas une règle universelle.

Défi réussi $C = 1$ donne la plus petite perte charnière de validation.

$C = 1$ · **7 vecteurs de support**

$w = (1{,}01\,;\, -0{,}28)$, $b = -5{,}75$. Choix figé.

Pour chaque C, le SVM apprend w, b sur les 24 animaux.

Comparez les pertes de **validation**, puis choisissez C. Le test reste fermé.

Détails · Le rôle de C

C règle le compromis entre norme de w et violations de marge. C'est un hyperparamètre : la validation le choisit, puis l'apprentissage fournit w, b.

Le tableau compare la perte charnière moyenne sur la validation. Après sélection, le modèle reste figé.

À votre avis ?

Pourquoi ne pas choisir C qui minimise l'objectif d'apprentissage ?

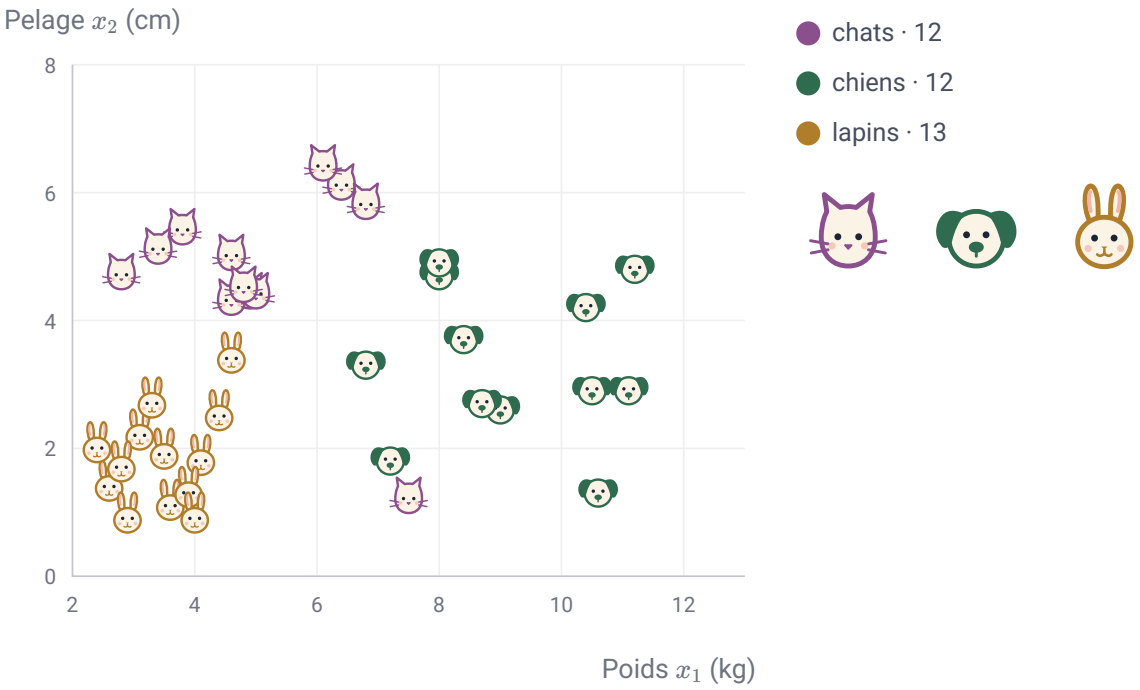
- On peut : c'est la méthode habituelle
- ✓ **L'objectif dépend de C et des animaux d'apprentissage**
- Parce que l'objectif est toujours minimal pour $C = 1$

Parce que l'objectif dépend de C lui-même et des données ayant servi à apprendre : il ne mesure pas l'erreur sur de nouveaux animaux.

Mêmes 24 animaux d'apprentissage, mêmes axes. SVM linéaire à marge souple résolu par le dual du cours ; régression logistique de référence avec $C = 1$. Les deux mesures ont des unités différentes : la largeur de marge dépend de cette échelle.

NOUVEAU EXPÉRIENCE

Trois espèces



$K = 3$ classes

12 chats, 12 chiens, 13 lapins d'apprentissage.

Aux chats et aux chiens s'ajoutent des **lapins**.

Pour reconnaître ces trois espèces, combinons plusieurs **SVM binaires**. Chacun oppose deux groupes.

Détails · Des décisions binaires à trois classes

Avec $K = 3$ classes, OvR apprend un modèle par classe ; OvO apprend un modèle par paire. Ces deux stratégies utilisent trois SVM binaires ici.

Chaque modèle est appris sur les mesures des animaux : poids et longueur du pelage.

À votre avis ?

Combien de classifieurs binaires faut-il pour trois classes ?

- 3 avec OvR, 6 avec OvO
- ✓ **3 avec OvR, 3 avec OvO**
- 2 avec OvR, 3 avec OvO

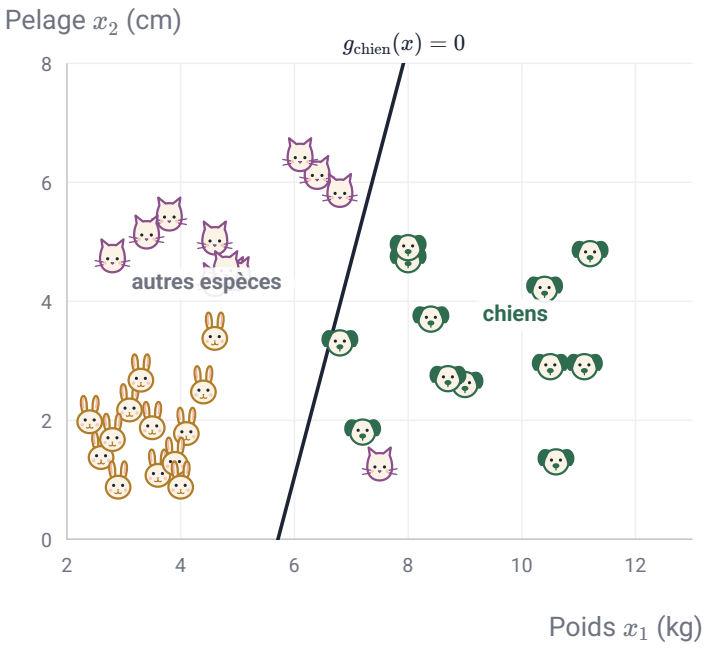
Trois avec OvR (un par classe) ; trois aussi avec OvO (un par paire). Pour quatre classes : 4 contre 6.

Les 24 chats et chiens d'apprentissage du fil rouge, plus 13 lapins synthétiques. Chaque classifieur binaire est un SVM linéaire à marge souple, $C = 1$.

Chapitre 02 · SVMs pour la discrimination multi-class

NOUVEAU EXPÉRIENCE

OvR : une classe contre les autres



$+1$	chiens
-1	les deux autres espèces
w	$(1{,}01\,;\,-0{,}28)$
vecteurs de support	7

SVM « chien contre les autres »

Un des trois classifieurs OvR.

Un SVM oppose **une espèce aux deux autres**. Choisissez laquelle.

La droite sépare les scores positifs des scores négatifs. Elle ne représente pas encore la décision finale entre trois espèces.

Détails · Les étiquettes et les scores OvR

Pour chaque classe k, les animaux de k reçoivent l'étiquette $+1$, tous les autres -1. Le SVM fournit un score $g_k(x)$; sa frontière binaire est $g_k(x) = 0$.

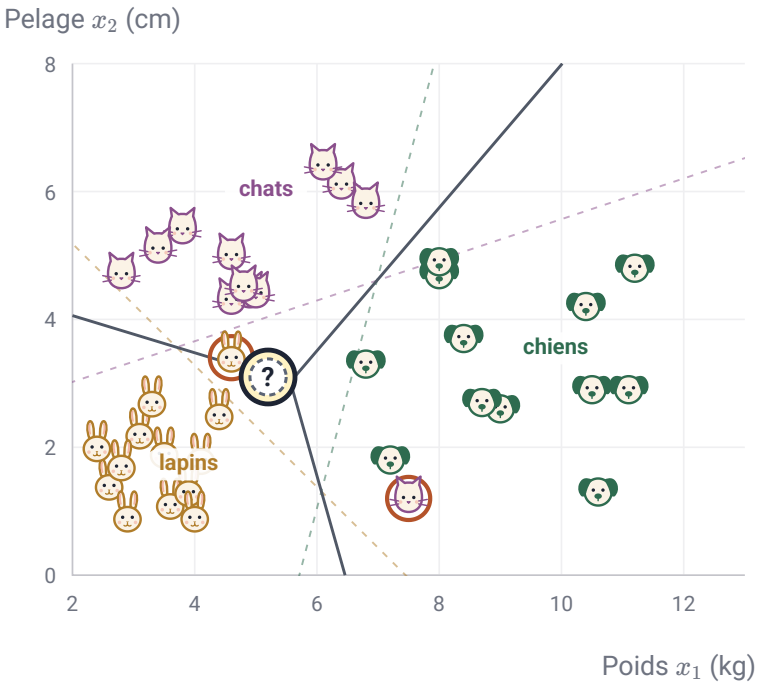
Les trois modèles utilisent les mêmes animaux d'apprentissage, avec des étiquettes différentes.

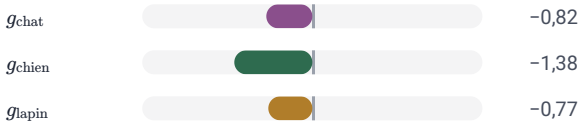
Les 24 chats et chiens d'apprentissage du fil rouge, plus 13 lapins synthétiques. Chaque classifieur binaire est un SVM linéaire à marge souple, $C = 1$.

Chapitre 02 · SVMs pour la discrimination multi-class

NOUVEAU EXPÉRIENCE

OvR : le plus grand score





Le plus grand score décide, même s'il est négatif.

Prédiction OvR : lapin

$\hat{y} = \arg\max_k g_k(x)$ pour $x = (5{,}2\,;\,3{,}1)$.

Déplacez l'animal « ? » : **le plus grand des trois scores gagne**, même s'ils sont tous négatifs.

Les traits noirs séparent les prédictions finales.

Détails · La règle de décision OvR

$$\hat{y} = \arg\max_k g_k(x).$$

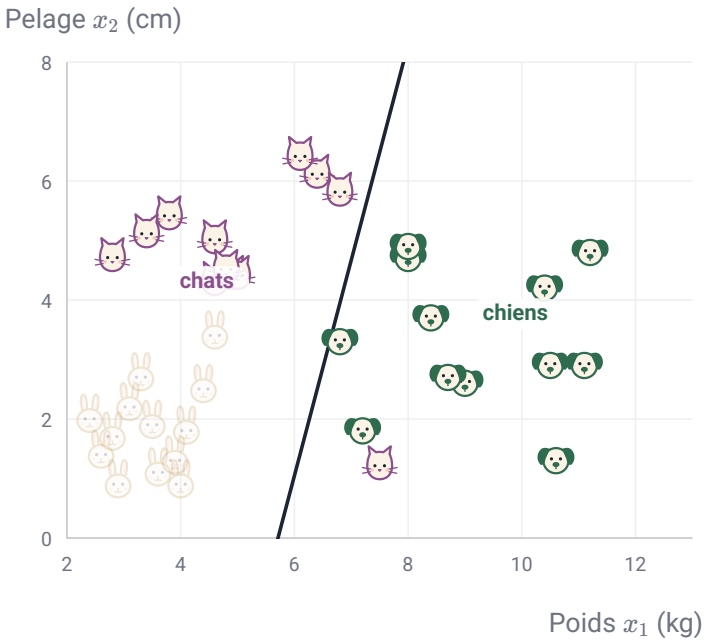
Une frontière finale apparaît là où deux scores égaux dépassent le troisième. Les droites binaires $g_k(x) = 0$ ne suffisent donc pas à découper les régions finales.

Si les scores maximaux sont exactement égaux, cet exemple retient la première espèce dans l'ordre chat, chien, lapin.

Les 24 chats et chiens d'apprentissage du fil rouge, plus 13 lapins synthétiques. Chaque classifieur binaire est un SVM linéaire à marge souple, $C = 1$.

NOUVEAU EXPÉRIENCE

OvO : un duel par paire



$+1$	chats
-1	chiens
ignorés	lapins
vecteurs de support	7

Duel chat contre chien

Appris sur 24 animaux seulement.

Choisissez un duel : **chat contre chien**, chat contre lapin, ou chien contre lapin.

Ce SVM apprend uniquement sur les deux espèces du duel. La troisième est ignorée.

Détails · Combien de modèles faut-il ?

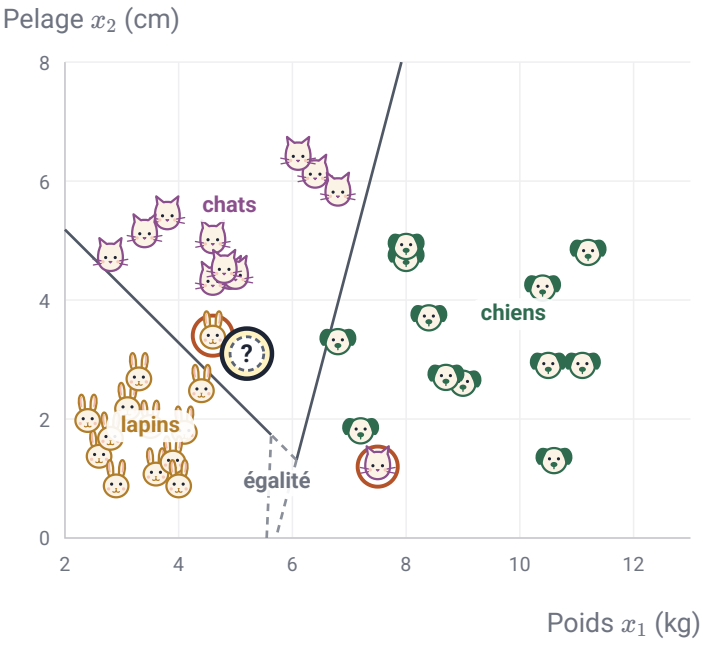
Pour K classes, OvR utilise K modèles ; OvO en utilise $K(K-1)/2$. Pour $K = 4$: quatre modèles contre six.

Chaque duel reçoit l'étiquette $+1$ pour sa première espèce et -1 pour sa seconde. Ici, tous les modèles sont des SVM linéaires à marge souple, avec $C = 1$.

Les 24 chats et chiens d'apprentissage du fil rouge, plus 13 lapins synthétiques. Chaque classifieur binaire est un SVM linéaire à marge souple, $C = 1$.

NOUVEAU EXPÉRIENCE

OvO : le vote



Animal « ? » : $x = (5{,}2\,;\,3{,}1)$

Duel	Score	Vote
chat / chien	$1{,}38$	chat
chat / lapin	$0{,}77$	chat
chien / lapin	$-0{,}44$	lapin

Score ≥ 0 : première espèce ; sinon, seconde.
Votes : chat 2 · chien 0 · lapin 1

Défi Placez « ? » dans la zone d'égalité (1 / 1 / 1).

Prédiction OvO : chat

Dessins : espèces observées. Régions : prédictions ; erreurs cerclées en brique.

Déplacez « ? » et comptez les votes : **deux votes désignent l'espèce** ; $1/1/1$ laisse une égalité.

Dessins : espèces observées. Régions : prédictions. Les pointillés bordent la zone sans majorité, laissée indécise ici.

Détails · Lire les votes et les frontières

Chaque duel donne un vote : un score positif ou nul favorise la première espèce, un score négatif la seconde. Avec trois espèces, chacune participe à deux duels.

Les traits pleins séparent les prédictions finales. Les pointillés délimitent la zone où chaque espèce gagne un duel : $1/1/1$. Un classifieur complet doit fixer une convention pour départager cette égalité, par exemple à partir des scores.

Les dessins indiquent les espèces observées, pas les prédictions du modèle. Les erreurs de classification sont cerclées en brique.

Les 24 chats et chiens d'apprentissage du fil rouge, plus 13 lapins synthétiques. Chaque classifieur binaire est un SVM linéaire à marge souple, $C = 1$.

DIAPO 19 · FORMULE

SVMs pour la discrimination multiclasse

One vs Rest — OvR

Pour chaque classe k, un SVM sépare **la classe k de toutes les autres**. On prédit le plus grand des K scores.

$$N_{\text{OvR}} = K, \qquad \hat{y}(x) = \underset{k \in \{1,\dots,K\}}{\operatorname{argmax}}\, g_k(x)$$

Lire la formule –
Score du classifieur « classe k contre les autres » ; convention en cas d'égalité.

One vs One — OvO

Un SVM par paire (k, l), comme un duel. Vote : on retient la classe qui gagne le plus de duels.

$$N_{\text{OvO}} = \binom{K}{2} = \frac{K(K-1)}{2}$$

Lire la formule –
Un modèle par paire non ordonnée. Pour $K = 4$: 4 modèles en OvR, 6 en OvO.

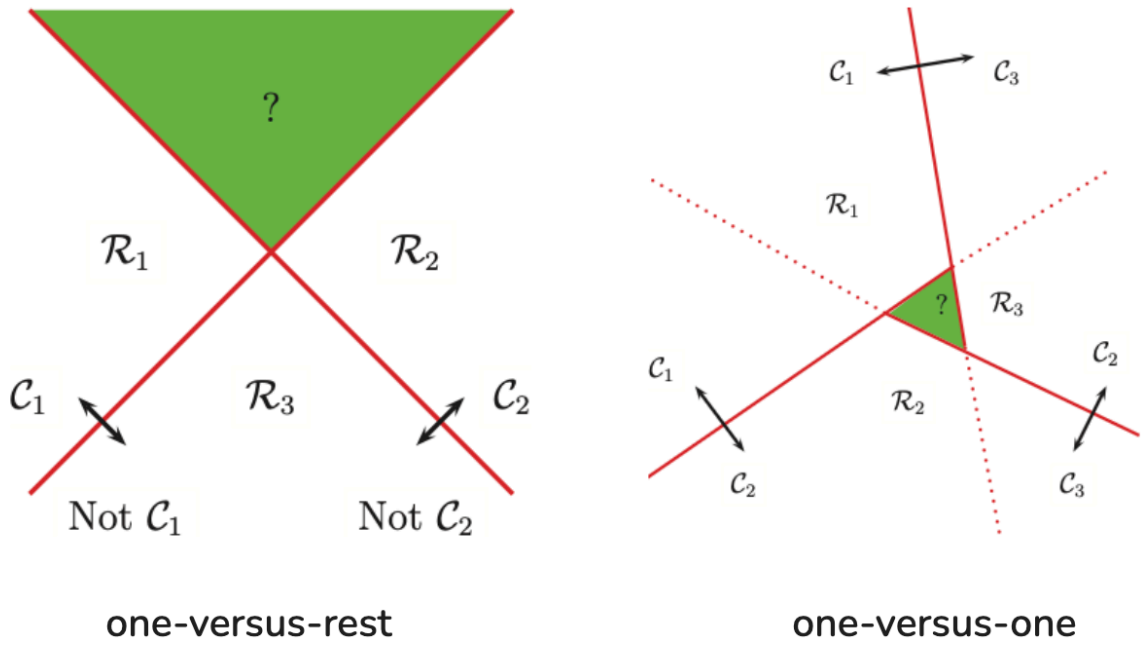
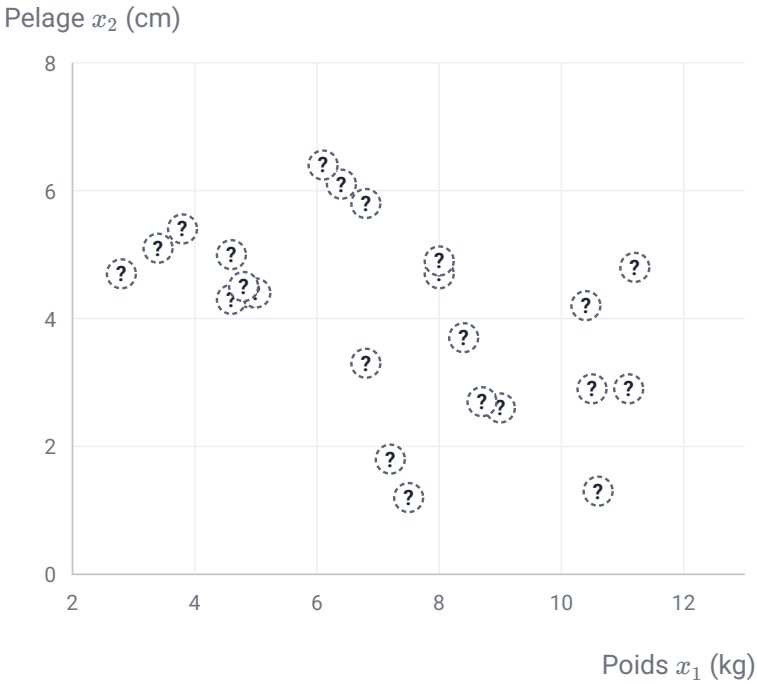


Figure historique : les signes seuls laissent des zones ambiguës ; en OvR, le plus grand score tranche.

Chapitre 02 · ACP : réduire sans étiquette

EXPÉRIENCE

Des points sans étiquette



24 animaux, 2 mesures chacun, aucune étiquette.

Deux nombres par animal

Peut-on n’en garder qu’un ?

On n’a que les mesures, sans savoir qui est chat ou chien.

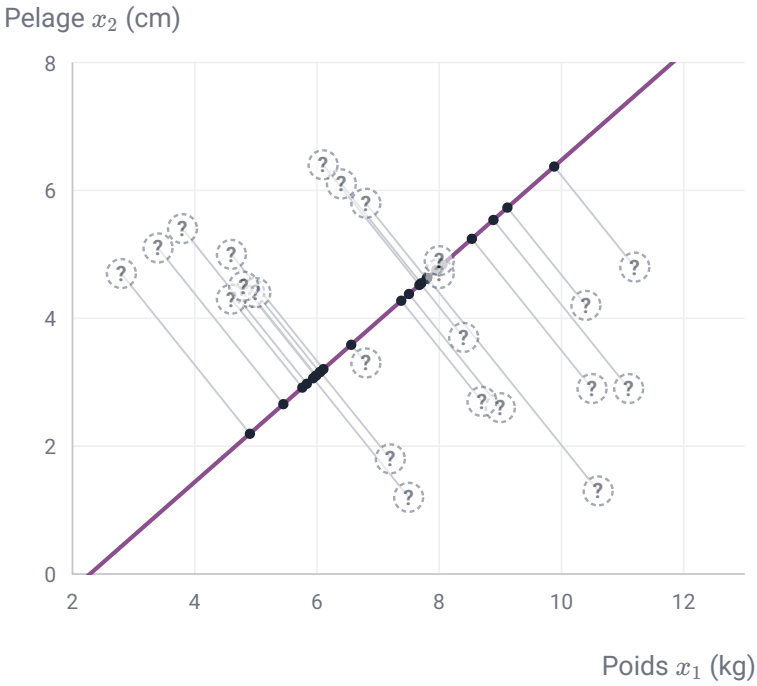
Question : peut-on résumer chaque animal par **un seul nombre** sans perdre l’essentiel ?

ACP sur les 24 animaux d’apprentissage, variables brutes (kg, cm). En pratique on standardise souvent les variables avant l’ACP, pour qu’aucune unité ne domine.

Chapitre 02 · ACP : réduire sans étiquette

EXPÉRIENCE

Choisir une direction



variance gardée 34 %

Défi Défi : garder plus de 82 % de la variance.

Variance des projections : 2,79

Sur un total de 8,18.

On projette chaque animal sur une droite qui passe par le centre du nuage.

Tournez la droite : plus les projections sont **étalées**, plus on garde d’information.

À votre avis ?

Quelle direction garde le plus d’information ?

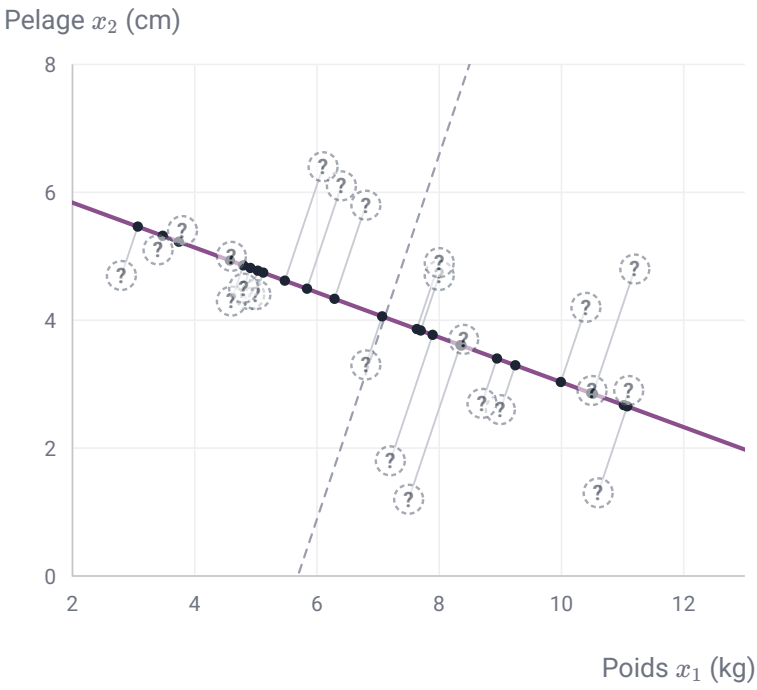
- celle où les projections sont le plus serrées
- ✓ **celle où les projections sont le plus étalées**
- n’importe laquelle, cela revient au même

On garde la direction de **variance maximale** : c’est le premier axe principal.

ACP sur les 24 animaux d’apprentissage, variables brutes (kg, cm). En pratique on standardise souvent les variables avant l’ACP, pour qu’aucune unité ne domine.

EXPÉRIENCE

Le premier axe



variance gardée 83 %

Défi Axe 1 : 83 % de la variance.

Variance des projections : 6,80

Sur un total de 8,18.

La meilleure direction est le **premier axe principal**. Le second lui est perpendiculaire.

Ici, le premier axe garde environ **83 %** de la variance totale.

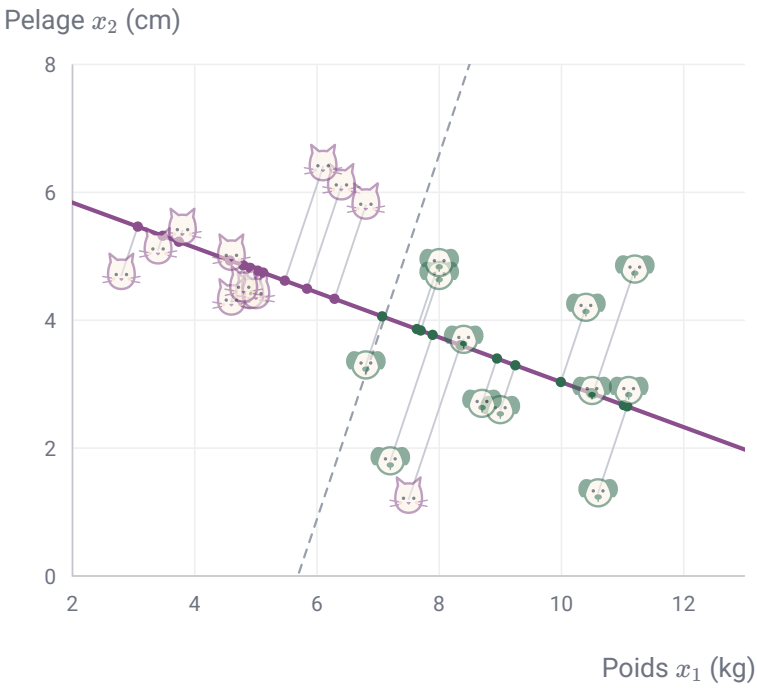
Détails · Comment on le calcule

On centre les données, on calcule leur matrice de covariance Σ, et on prend son vecteur propre de plus grande valeur propre λ_1. La part de variance gardée vaut $\lambda_1/(\lambda_1+\lambda_2)$.

ACP sur les 24 animaux d'apprentissage, variables brutes (kg, cm). En pratique on standardise souvent les variables avant l'ACP, pour qu'aucune unité ne domine.

EXPÉRIENCE

Un seul nombre par animal



Chats d'un côté, chiens de l'autre : l'axe 1 suit surtout le poids.

Un nombre par animal : sa coordonnée sur l'axe 1

83 % de l'information gardée.

Chaque animal devient sa coordonnée sur le premier axe.

Révélez les espèces : chats et chiens se séparent déjà, **sans qu'on ait utilisé les étiquettes**.

ACP sur les 24 animaux d'apprentissage, variables brutes (kg, cm). En pratique on standardise souvent les variables avant l'ACP, pour qu'aucune unité ne domine.

FORMULE

Pourquoi l'ACP ?

Quand on a beaucoup de mesures, on veut les **voir**, les **compresser** ou enlever le bruit.

L'ACP fabrique quelques nouvelles variables, des combinaisons linéaires des anciennes, qui gardent le plus de variance possible. Pas besoin d'étiquette : c'est un algorithme **non supervisé**.

Sa perte : l'**erreur de reconstruction** $\|x - \hat{x}\|^2$. Garder la variance maximale revient à la rendre minimale.

$$z = u^\top (x - \bar{x}) \qquad \text{avec } u \text{ la direction de variance maximale}$$

Lire la formule –

NOTION

Exemple pas à pas

Une matrice de covariance 2 × 2

1. Données centrées de covariance $\Sigma = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$.
2. Valeurs propres : $(2-\lambda)^2 - 1 = 0$, donc $\lambda_1 = 3$ et $\lambda_2 = 1$.
3. Premier axe : $\Sigma u = 3u$ donne $u = \frac{1}{\sqrt{2}}(1,1)$, la diagonale.
4. Information gardée : $\dfrac{\lambda_1}{\lambda_1 + \lambda_2} = \dfrac{3}{4} = 75\,\%$.
5. Le point centré $x = (1,3)$ devient $z = u^\top x = \dfrac{1+3}{\sqrt{2}} \approx 2{,}83$.

COMPLÉMENT · FORMULE

Modèles linéaires supervisés

On prédit Y à partir de X par une combinaison linéaire ; la méthode dépend de la réponse et de l'objectif.

$$Y \approx \beta_0 + \beta_1 X_1 + \cdots + \beta_d X_d$$

Lire la formule –
Deux écritures des mêmes coefficients : $\beta_0 = b$ et $\beta_j = w_j$.

Méthode	Réponse / objectif
Régression linéaire	Y réelle.
Régression logistique	$Y \in \{0,1\}$; log-odds linéaires.
SVM linéaire	Marge maximale, relâchée si nécessaire.

COMPLÉMENT · FORMULE

Régression

Prévision affine $f_\beta(x)$. L'apprentissage donne $\hat\beta$, puis le prédicteur $\hat f = f_{\hat\beta}$.

$$\hat{\beta} \in \operatorname*{argmin}_{\beta} \frac{1}{n} \sum_{i=1}^{n} \ell(y_i, f_\beta(x_i)),$$

$$\hat{f}(x) = f_{\hat{\beta}}(x) = \hat{\beta}_0 + \sum_{j=1}^{d} \hat{\beta}_j x_j,$$

$$\hat{y} = \hat{f}(x).$$

Lire la formule –
β : coefficients candidats ; $\hat{\beta}$: coefficients appris ; $\hat{y}$: prévision numérique.

Chapitre 02 · Modèles linéaires

COMPLÉMENT · FORMULE

Discrimination binaire

On apprend une **fonction de décision linéaire** ; son signe donne la classe prédite.

$$g(x) = w \cdot x + b, \qquad \hat{y} = \operatorname{sign}(g(x))$$

Lire la formule –
$g(x)$: score réel ; décision $\hat{y} \in \{-1, +1\}$, $+1$ à score nul ; y : classe observée.

Ce qui distingue les méthodes	Exemples
Fonction de perte	Perte logistique, hinge loss.
Régularisation	Pénalité L1 ou L2 (norme, marge).

Chapitre 02 · Modèles linéaires

COMPLÉMENT · FORMULE

Minimiser les erreurs

Régression linéaire sous perte quadratique : minimiser la somme des résidus au carré, dont la moyenne est la MSE.

$$f_\beta(x) = \beta_0 + \sum_{j=1}^{d} \beta_j x_j,$$

$$\hat{\beta} \in \operatorname*{argmin}_{\beta} \sum_{i=1}^{n} (y_i - f_\beta(x_i))^2,$$

$$\hat{y}_i = f_{\hat{\beta}}(x_i), \quad \mathrm{MSE} = \frac{1}{n} \sum_{i=1}^{n} (y_i - \hat{y}_i)^2.$$

Lire la formule –
$\hat{y}_i$ utilise $\hat{\beta}$; diviser l'objectif par n ne change pas les minimiseurs.

Chapitre 02 · Modèles linéaires

COMPLÉMENT · FORMULE

Linéarité et modèles

L'idée générale

Beaucoup d'algorithmes reposent sur une **approximation linéaire** :

- avec Y : combinaison des caractéristiques approchant Y ;
- sans Y : représentation linéaire des données.

$$y \approx w \cdot x + b$$

Lire la formule –
w pondère les caractéristiques de x ; b est le terme constant.

Cadre	Intuition géométrique
Régression	Ajuster un hyperplan aux observations.
Discrimination binaire	Séparer deux classes par un hyperplan.
Non supervisé	Axes linéaires portant la variance.

> **Ce que permet la linéarité**
>
> La linéarité simplifie l'apprentissage, mais restreint les relations représentables.

COMPLÉMENT · FORMULE

Hyperplan · définition

Dans un espace E de dimension n, un **hyperplan** est un sous-espace affine de dimension $n-1$.

$$H = \{x \in \mathbb{R}^n : w \cdot x + b = 0\}, \qquad w \in \mathbb{R}^n \setminus \{0\}, \quad b \in \mathbb{R}$$

Lire la formule –
w : vecteur normal ; b : décalage. Si $b = 0$: passage par l'origine (sous-espace vectoriel).

Espace	Hyperplan affine	Hyperplan vectoriel
$\mathbb{R}^2$	Une droite.	$\mathrm{Vect}(a)$, $a \neq 0$.
$\mathbb{R}^3$	Un plan.	$\mathrm{Vect}(a, b)$, a et b non colinéaires.
$\mathbb{R}^1$	Un point.	Le point 0.

COMPLÉMENT · FORMULE

Hyperplan · score et décision

Lien avec les modèles linéaires

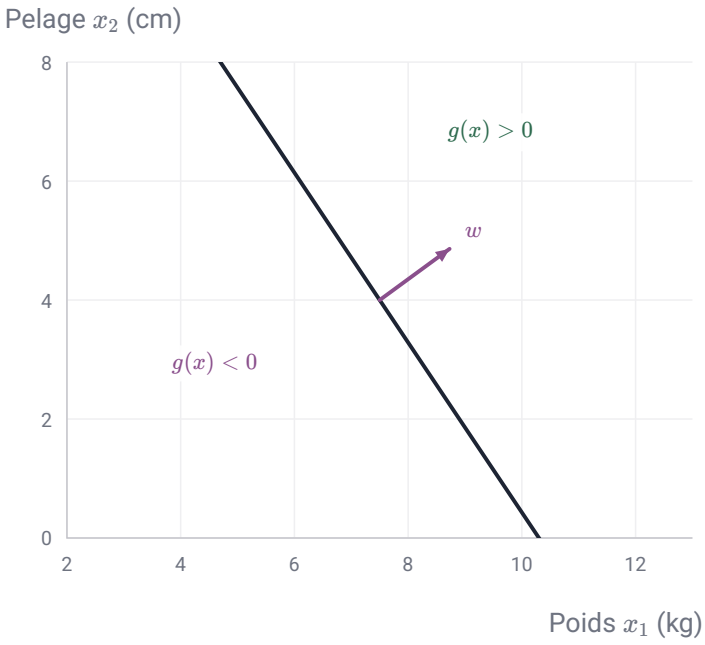
- Apprendre : déterminer (w, b).
- w fixe l'**orientation**, b le **positionnement**.
- En discrimination, le signe du score donne le côté.

$$\begin{cases} w \cdot x + b > 0 & \text{un côté de l'hyperplan,} \\ w \cdot x + b < 0 & \text{l'autre côté,} \\ w \cdot x + b = 0 & \text{sur l'hyperplan.} \end{cases}$$

Lire la formule –
À coefficients fixés, le signe donne une règle de discrimination binaire.

NOUVEAU COMPLÉMENT · EXPÉRIENCE

Une droite, un vecteur normal



w	$(0{,}82\,;\,0{,}57)$
b	$-8{,}44$
$\|w\|$	$1{,}00$

$$g(x) = 0{,}82\,x_1 + 0{,}57\,x_2 - 8{,}44$$

La droite est l'ensemble des points où $g(x) = 0$.

La droite $g(x) = w^\top x + b = 0$ coupe le plan en deux. Le vecteur w lui est **perpendiculaire**.

Tournez w : la droite tourne. Changez b : elle glisse sans tourner.

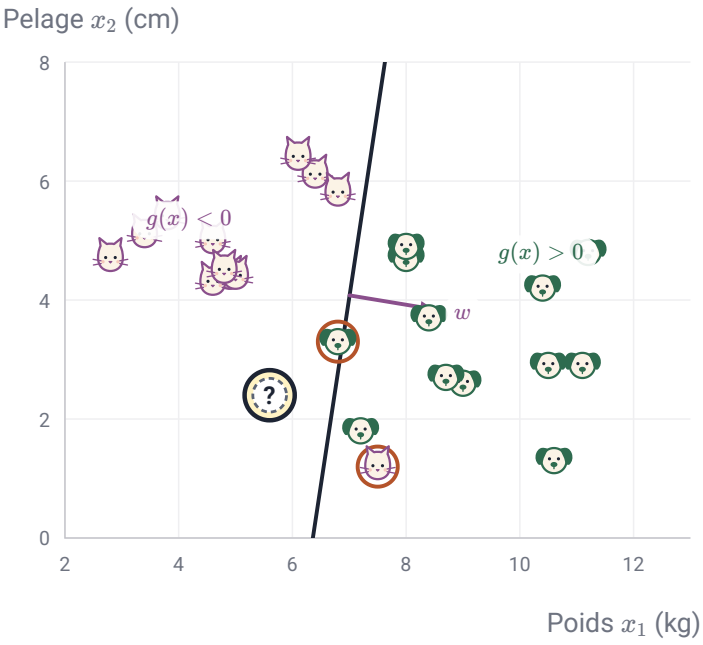
Détails · Pourquoi w est normal

Si x et x' sont sur la droite, $w^\top x + b = w^\top x' + b = 0$, donc $w^\top (x - x') = 0$: w est orthogonal à toute direction de la droite.

Dans le plan des mesures (poids, pelage), un hyperplan est une droite. Ici $w = k(\cos\theta, \sin\theta)$ et la droite passe par un point qu'on fait glisser le long de w.

NOUVEAU COMPLÉMENT · EXPÉRIENCE

Le signe du score classe



w	$(0{,}99\,;\,-0{,}16)$
b	$-6{,}28$
$\|\|w\|\|$	$1{,}00$

Défi réussi 2 erreurs seulement.

Animal « ? » : $g(x) = -1{,}13 \rightarrow$ **chat**

Erreurs cerclées en brique : 2 sur 24.

Chaque animal reçoit un score $g(x)$: **positif, chien** ; négatif, chat.

Défi : placez la droite pour faire au plus **2 erreurs**.

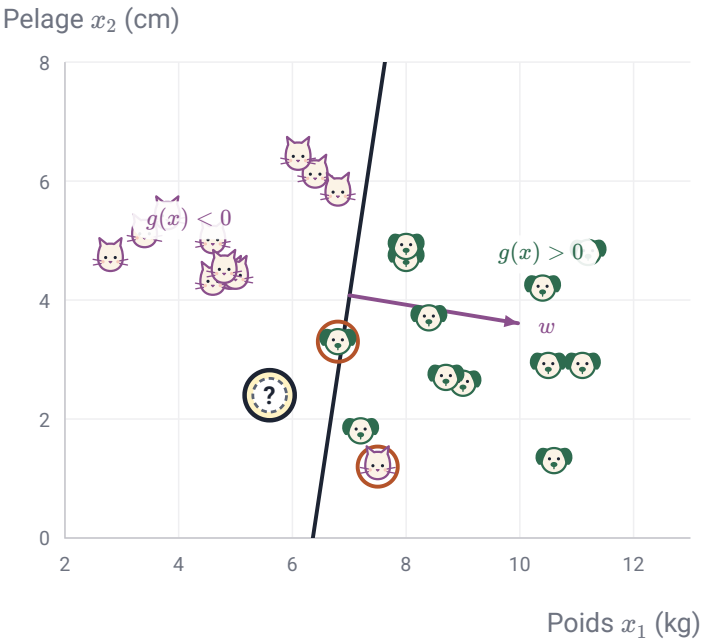
Détails · Lire le score

Du côté où pointe w, $g(x) > 0$. Sur la droite, $g(x) = 0$. Déplacez « ? » pour lire son score.

Dans le plan des mesures (poids, pelage), un hyperplan est une droite. Ici $w = k(\cos\theta, \sin\theta)$ et la droite passe par un point qu'on fait glisser le long de w.

NOUVEAU COMPLÉMENT · EXPÉRIENCE

Multiplier w et b



k	$g(?)$	**droite**
0,5	−0,56	identique
1	−1,13	identique
2	−2,25	identique

$k = 2$: $g(?) = -2{,}25$

La flèche w s'allonge ; la droite reste la même.

Multiplions w et b par un même nombre $k > 0$.

Les scores changent d'échelle… et la droite ?

À votre avis ?

On multiplie w et b par 2. La droite $g(x) = 0$…

- tourne

✓ **ne bouge pas**

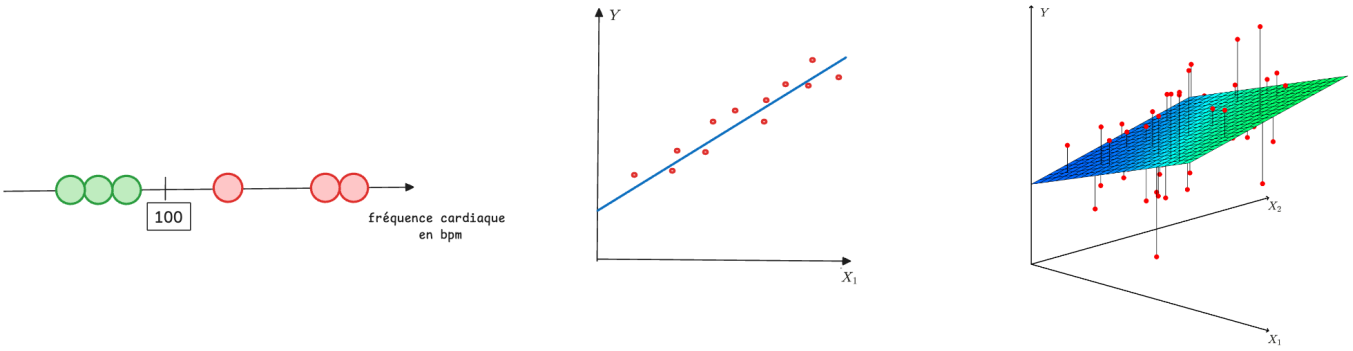
- glisse vers l'origine

$2w^\top x + 2b = 0 \iff w^\top x + b = 0$: la droite ne bouge pas, seuls les scores sont multipliés par 2. Le SVM devra donc fixer une échelle.

Dans le plan des mesures (poids, pelage), un hyperplan est une droite. Ici $w = k(\cos\theta, \sin\theta)$ et la droite passe par un point qu'on fait glisser le long de w.

COMPLÉMENT · EXERCICE

À faire · le vecteur normal



Seuil en dimension 1, droite et plan de régression.



À VOUS DE JOUER

Exercice

Soit $w = (2, -1)$ et un hyperplan passant par l'origine.

1. Écrire l'équation de la droite.
2. De quel côté sont $x_1 = (1, 1)$ et $x_2 = (1, 3)$?
3. Interpréter le signe du score.

▼ **Solution commentée**

1. Origine : $b = 0$. Droite : $2x_1 - x_2 = 0$, soit $x_2 = 2x_1$.
2. Score en $(1, 1)$: $2 - 1 = 1$; en $(1, 3)$: $2 - 3 = -1$.
3. Signes opposés : points de part et d'autre de la droite. Le vecteur $(2, -1)$ lui est perpendiculaire.

COMPLÉMENT · NOTION

Théorème du No Free Lunch

Tout modèle simplifie la réalité par des hypothèses. Hypothèse linéaire : réponse = combinaison linéaire des caractéristiques + résidus.

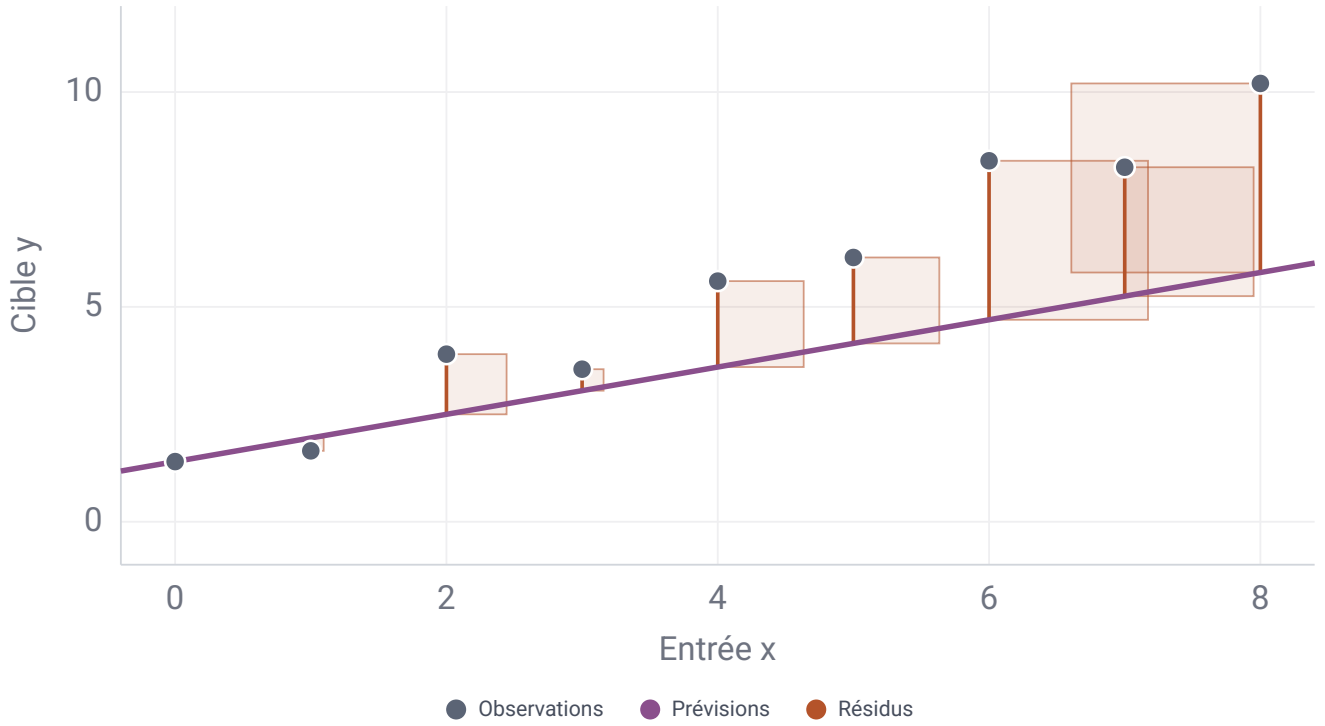
Wolpert, 1996 — message du No Free Lunch

Sans hypothèse sur les données, aucun modèle n'est universellement meilleur qu'un autre. Chaque modèle est utile dans un contexte.

Le théorème ne dit pas que tous se valent sur un jeu de données précis.

COMPLÉMENT · EXPÉRIENCE

Déplacer la droite



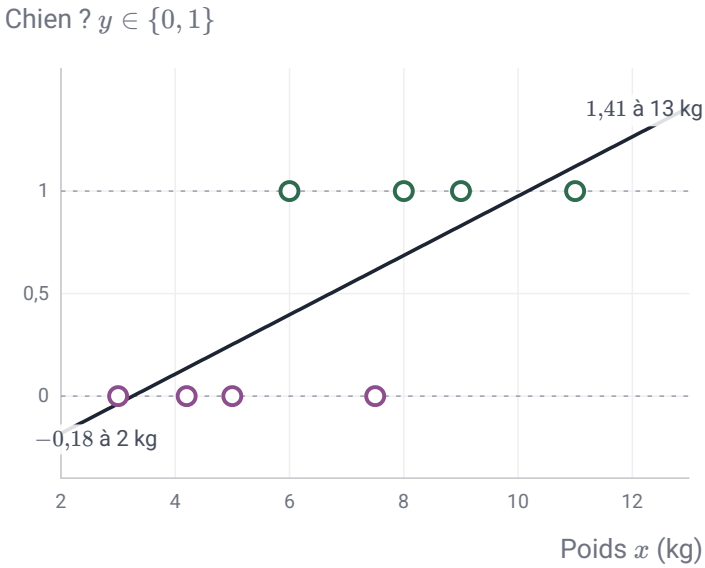
5,817	5,817	0,55	1,40
Risque empirique $= \frac{1}{2}\,\mathrm{MSE}$	$\mathrm{MSE} = \mathrm{RSS}/9$	Pente w	Ordonnée b

Déplacez la droite. Les segments sont les résidus verticaux ; la MSE est leur carré moyen ; avec la perte $\frac{1}{2}(y-\hat{y})^2$, le risque empirique vaut $\frac{1}{2}\,\mathrm{MSE}$. Chaque carré a pour aire le carré d'un résidu.

Exemple synthétique complémentaire. Déplacez une droite pour voir les résidus et leur MSE ; la figure de régression du cours reste le point de référence.

NOUVEAU COMPLÉMENT · EXPÉRIENCE

Une droite sur des 0 et des 1



pente	0,145
à 2 kg	−0,18
à 13 kg	1,41

$\hat{y} = 0{,}145\, x - 0{,}47$

Une droite sort de $[0, 1]$.

Chat $= 0$, chien $= 1$. Traçons la droite des moindres carrés, comme en régression linéaire.

Que vaut-elle loin des données ?

À votre avis ?

Pour un animal de 13 kg, que prédit la droite ?

- exactement 1

✓ $1{,}41$ **: plus que 1**

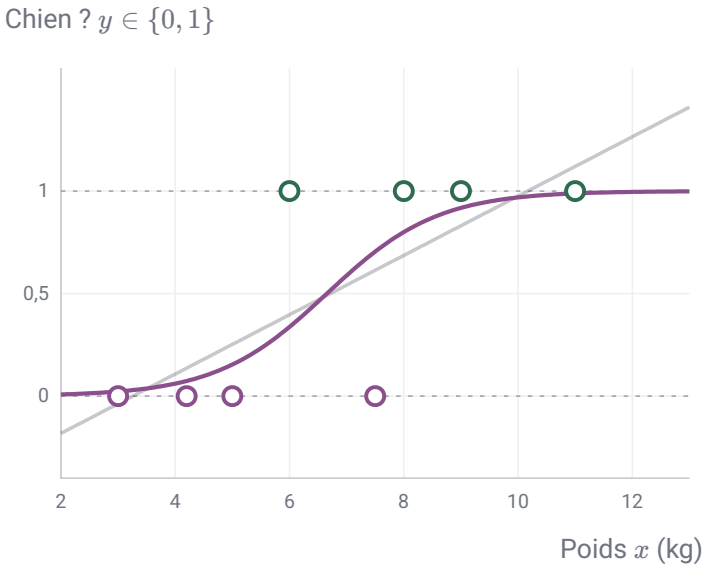
- $0{,}5$

$1{,}41$ n'est pas une probabilité, et à 2 kg la droite donne $-0{,}18$. Il faut une courbe qui reste entre 0 et 1.

Huit animaux : chats à 3 ; 4,2 ; 5 ; 7,5 kg, chiens à 6 ; 8 ; 9 ; 11 kg. Droite des moindres carrés, puis régression logistique sans pénalité, ajustées sur ces huit points.

NOUVEAU COMPLÉMENT · EXPÉRIENCE

Une courbe en S



w	1,03
b	−6,85
$\hat{p} = 0{,}5$	6,65 kg

$$\hat{p} = \sigma(1{,}03x - 6{,}85)$$

Toujours entre 0 et 1.

La régression logistique garde le score linéaire $z = wx + b$, puis le passe dans la sigmoïde : $\hat{p} = \sigma(z) = \dfrac{1}{1 + e^{-z}}$.

La courbe reste entre 0 et 1.

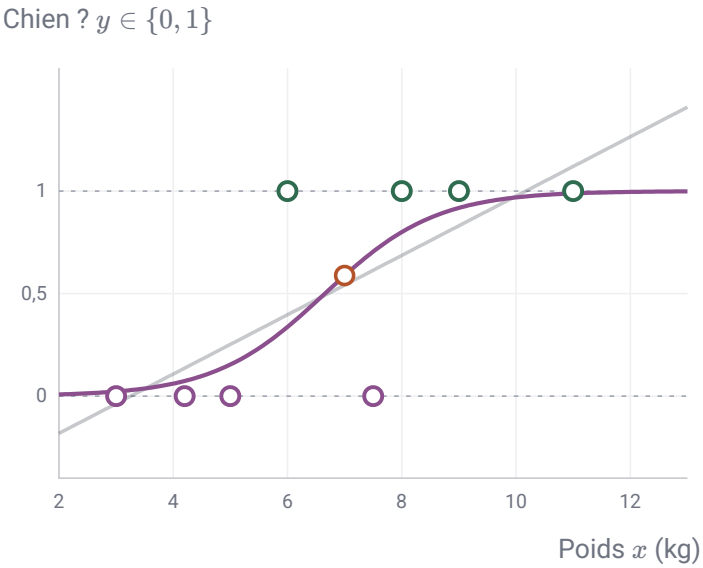
Détails · Les coefficients appris

Ici $w \approx 1{,}03$ et $b \approx -6{,}85$: $\hat{p} = 0{,}5$ quand $z = 0$, soit $x = -b/w \approx 6{,}65$ kg.

Huit animaux : chats à 3 ; 4,2 ; 5 ; 7,5 kg, chiens à 6 ; 8 ; 9 ; 11 kg. Droite des moindres carrés, puis régression logistique sans pénalité, ajustées sur ces huit points.

NOUVEAU COMPLÉMENT · EXPÉRIENCE

Odds et log-odds



poids	score z	$\hat{p}$	odds
7,0 kg	0,36	0,59	1,43

$$\log \frac{0{,}59}{0{,}41} = 0{,}36 = 1{,}03 \times 7{,}0 - 6{,}85$$

Les log-odds sont le score linéaire.

Les **odds** comparent les chances : $\frac{\hat{p}}{1-\hat{p}}$. Des odds de 2 : deux fois plus de chances d'être un chien qu'un chat.

Son logarithme, les **log-odds**, valent exactement le score linéaire $wx + b$. Choisissez un poids.

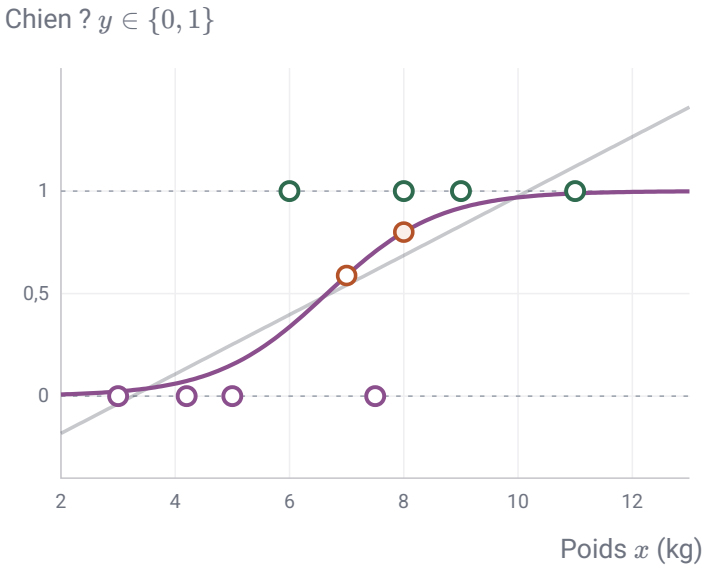
Détails · Pourquoi log-odds = score

Si $\hat{p} = \sigma(z)$, alors $1 - \hat{p} = \sigma(-z)$ et $\frac{\hat{p}}{1-\hat{p}} = e^z$, donc $\log \frac{\hat{p}}{1-\hat{p}} = z = wx + b$.

Huit animaux : chats à 3 ; 4,2 ; 5 ; 7,5 kg, chiens à 6 ; 8 ; 9 ; 11 kg. Droite des moindres carrés, puis régression logistique sans pénalité, ajustées sur ces huit points.

NOUVEAU COMPLÉMENT · EXPÉRIENCE

Lire le coefficient



poids	score z	$\hat{p}$	odds
7,0 kg	0,36	0,59	1,43
8,0 kg	1,39	0,80	4,00

Odds : 1,43 → 4,00, rapport 2,80

$e^{w} = e^{1{,}03} \approx 2{,}80$, quel que soit le poids de départ.

Un kilo de plus ajoute w au score, donc **multiplie les odds par** e^{w}.

Ici $e^{1{,}03} \approx 2{,}8$: chaque kilo multiplie par 2,8 les odds d'être un chien.

Huit animaux : chats à 3 ; 4,2 ; 5 ; 7,5 kg, chiens à 6 ; 8 ; 9 ; 11 kg. Droite des moindres carrés, puis régression logistique sans pénalité, ajustées sur ces huit points.

NOUVEAU COMPLÉMENT · FORMULE

Pourquoi une probabilité ?

Pour une réponse binaire $y \in \{0, 1\}$, une droite de régression peut prédire $1{,}4$ ou $-0{,}3$: ce ne sont pas des probabilités. La **régression logistique** garde un **score linéaire** et le transforme en probabilité.

$$\log \frac{P(Y=1 \mid X=x)}{1-P(Y=1 \mid X=x)} = w^\top x + b,$$
$$P(Y=1 \mid X=x) = \sigma(w^\top x + b) = \frac{1}{1+e^{-(w^\top x+b)}}.$$

Lire la formule –

Le logarithme des odds (log-odds) est linéaire en x : c'est l'hypothèse annoncée dans le tableau des modèles linéaires supervisés.

> **Fil rouge jusqu'aux SVM**
>
> Les mêmes 40 animaux synthétiques servent dans tout le chapitre : poids x_1, pelage x_2, chat $= 0$, chien $= 1$.

Chapitre 02 · Régression linéaire et logistique

NOUVEAU COMPLÉMENT · NOTION

Notations du fil rouge

Symbole	Signification
$x_i = (x_{i1}, x_{i2})$	Entrée : les mesures de l'animal i, poids x_{i1} (kg) et pelage x_{i2} (cm).
y_i	Vraie étiquette de l'animal : $0/1$ en logistique, $-1/+1$ en SVM.
$\hat{y}_i$	Classe prédite par le modèle ; elle peut différer de y_i.
$w,\ b$	Paramètres appris : vecteur normal et biais.
$g(x) = w^\top x + b$	Fonction de score, à valeurs réelles. Pour un animal donné, on abrège sa valeur par $z = g(x)$.
$\sigma(z) = \frac{1}{1+e^{-z}}$	Sigmoïde : transforme un score réel en nombre de $(0, 1)$.
$\hat{p}(x) = \sigma(g(x))$	Probabilité estimée d'être un chien ; elle estime $P(Y=1 \mid X=x)$, pas la classe elle-même.
t	Seuil de décision : $\hat{y} = 1$ si $\hat{p} \geq t$.
$\ell(y, \hat{p})$	Perte ; ici l'entropie croisée binaire $-[y \log \hat{p} + (1-y)\log(1-\hat{p})]$.
C	Hyperparamètre de régularisation, choisi sur la validation (régression logistique et SVM).

NOUVEAU COMPLÉMENT · EXERCICE

À faire · un calcul à la main



À VOUS DE JOUER

Exercice

On reprend $w = (1{,}37\,;\,-0{,}22)$ et $b = -8{,}75$. Un animal pèse $x_1 = 7$ kg et son pelage mesure $x_2 = 2$ cm.

1. Calculer le score z.
2. En déduire $\hat{p}$; on donne $\sigma(0{,}40) \approx 0{,}60$.
3. Donner la classe prédite pour $t = 0{,}5$, puis pour $t = 0{,}7$.
4. C'est en fait un chat. Calculer sa perte ℓ.

▼ Solution commentée

$z = 1{,}37 \times 7 - 0{,}22 \times 2 - 8{,}75 = 9{,}59 - 0{,}44 - 8{,}75 = 0{,}40$, donc $\hat{p} = \sigma(0{,}40) \approx 0{,}60$.

Avec $t = 0{,}5$: $\hat{p} \geq t$, donc $\hat{y} = 1$ (chien). Avec $t = 0{,}7$: $\hat{y} = 0$ (chat). Le modèle n'a pas changé, seule la règle de décision a changé.

Pour un chat, $y = 0$: $\ell = -\log(1 - \hat{p}) = -\log 0{,}40 \approx 0{,}92$.

COMPLÉMENT · FORMULE

Support Vector Machines

L'idée des SVM

Les **Support Vector Machines** apprennent une frontière linéaire qui maximise une marge.

$$g(x) = w \cdot x + b, \qquad \hat{y} = \operatorname{sign}(g(x))$$

Lire la formule –
g : score réel, pas une probabilité. Frontière $g(x) = 0$; on prédit $+1$ si $g(x) \geq 0$, -1 sinon.

Variante	Problème
SVC — discrimination	Séparer deux classes $Y \in \{-1, +1\}$.
SVR — régression	Approcher une réponse numérique à une tolérance près.

COMPLÉMENT · FORMULE

Principe géométrique du SVM linéaire

La distance d'un point à une droite se mesure perpendiculairement : valeur absolue du score divisée par la norme du vecteur normal.

$$ax + by + c = 0,$$
$$d\big((x_0, y_0), H\big) = \frac{|ax_0 + by_0 + c|}{\sqrt{a^2 + b^2}}.$$

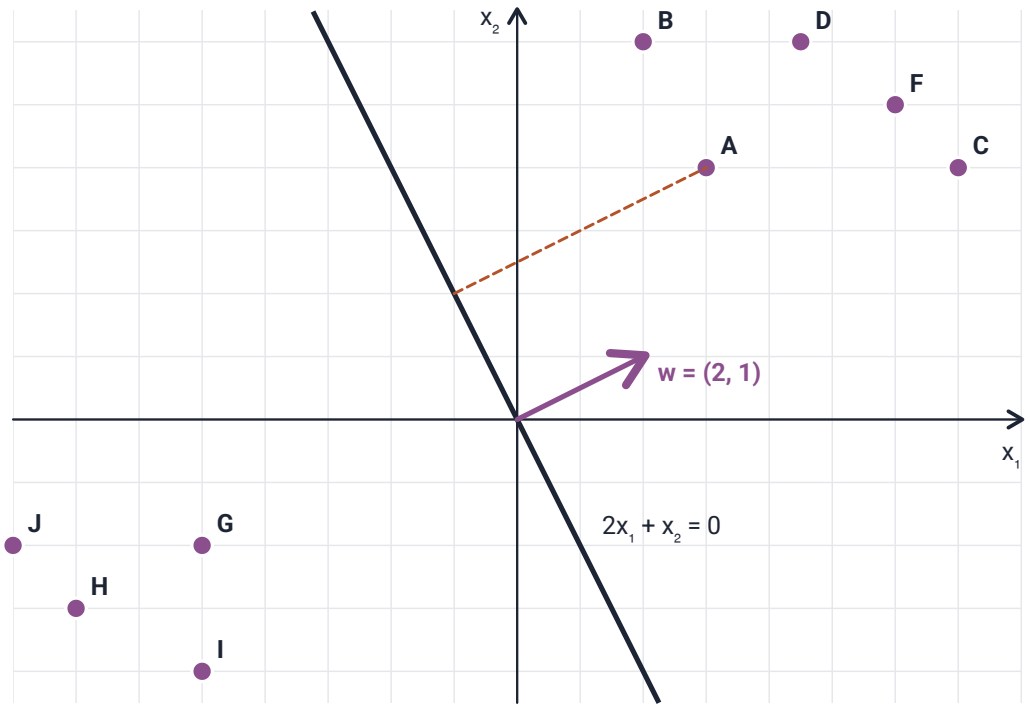
Lire la formule –
a et b non tous deux nuls ; b : coefficient de y (pas le biais) ; c : terme constant.

Exemple — la droite $y = -2x$

Forme $2x + y = 0$: $a = 2$, $b = 1$, $c = 0$. Point $A = (3, 4)$.

$$d(A, H) = \frac{|2(3) + 1(4) + 0|}{\sqrt{2^2 + 1^2}} = \frac{10}{\sqrt{5}} = 2\sqrt{5}$$

Lire la formule –
Distance du seul point A : pas encore la marge de l'échantillon.



A = (3, 4) · distance à la frontière : 2√5

Même exemple du cours : $A = (3, 4)$, normale $w = (2, 1)$, distance à l'hyperplan $2\sqrt{5}$.

Chapitre 02 · SVM : marge dure

NOUVEAU COMPLÉMENT · FORMULE

Étiquettes du SVM

Des étiquettes $0/1$ aux étiquettes ± 1

La logistique code chat 0, chien 1. Le SVM code chat -1, chien $+1$: $y_i^{\pm} = 2y_i - 1$.

Dans les formules SVM qui suivent, y_i désigne ce codage ± 1. $g(x_i)$ reste un score, et $\hat{y}_i$ la classe prédite.

$$y_i \, g(x_i) > 0 \iff \text{l'observation } i \text{ est du bon côté de } g(x) = 0$$

Lire la formule –

Avec $0/1$, il faudrait distinguer deux cas : $g(x) > 0$ si $y = 1$ et $g(x) < 0$ si $y = 0$.

Chapitre 02 · SVM : marge dure

COMPLÉMENT · FORMULE

Notion de marge

Pour une séparation correcte, la **marge symétrique** vaut deux fois la **distance minimale** des observations à la frontière. En marge dure, cette bande est vide.

$$d_{\min} = \min_i d(x_i, H), \qquad m = 2d_{\min}$$

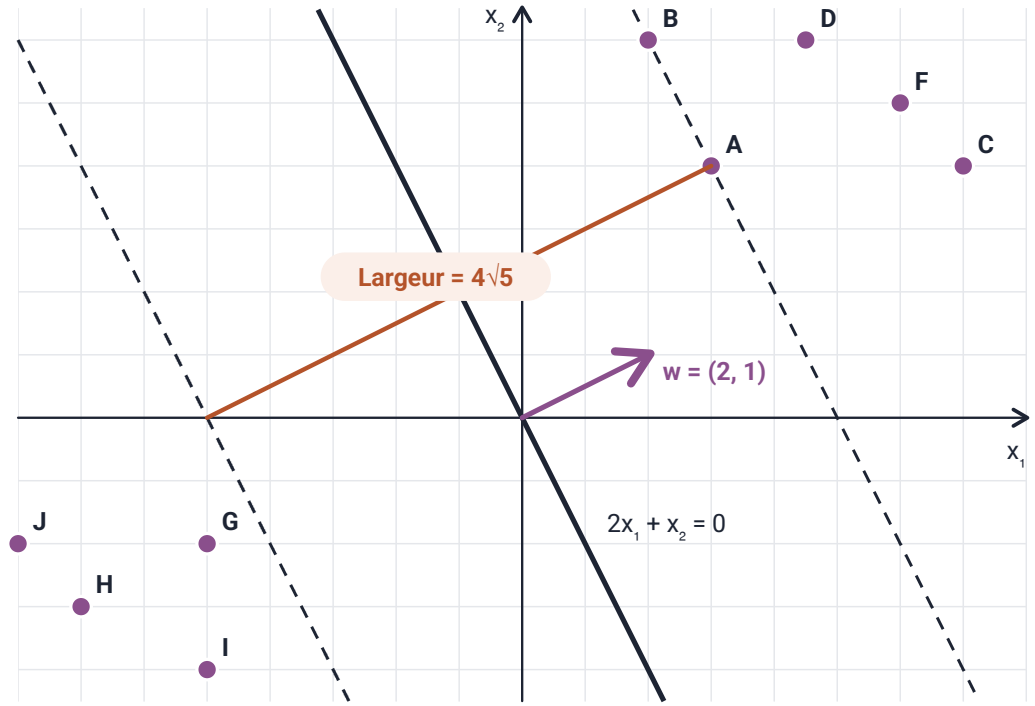
Lire la formule –
Le minimum est essentiel : doubler la distance d'un point quelconque ne suffit pas.

Exemple du cours : quand $d = 2\sqrt{5}$

Si $2\sqrt{5}$ est la **distance minimale**, la bande a la largeur ci-dessous. Cela ne prouve pas que la marge est maximale.

$$m = 2 \times 2\sqrt{5} = 4\sqrt{5}$$

Lire la formule –
Valable seulement si ce point est parmi les plus proches de la frontière.



Frontières parallèles : $2x_1 + x_2 = -10$ et $2x_1 + x_2 = 10$.

$A = (3, 4)$ et $B = (2, 6)$ sont les plus proches : distance minimale $2\sqrt{5}$, largeur de bande $4\sqrt{5}$. La mesure est perpendiculaire aux droites.

Chapitre 02 · SVM : marge dure

COMPLÉMENT · FORMULE

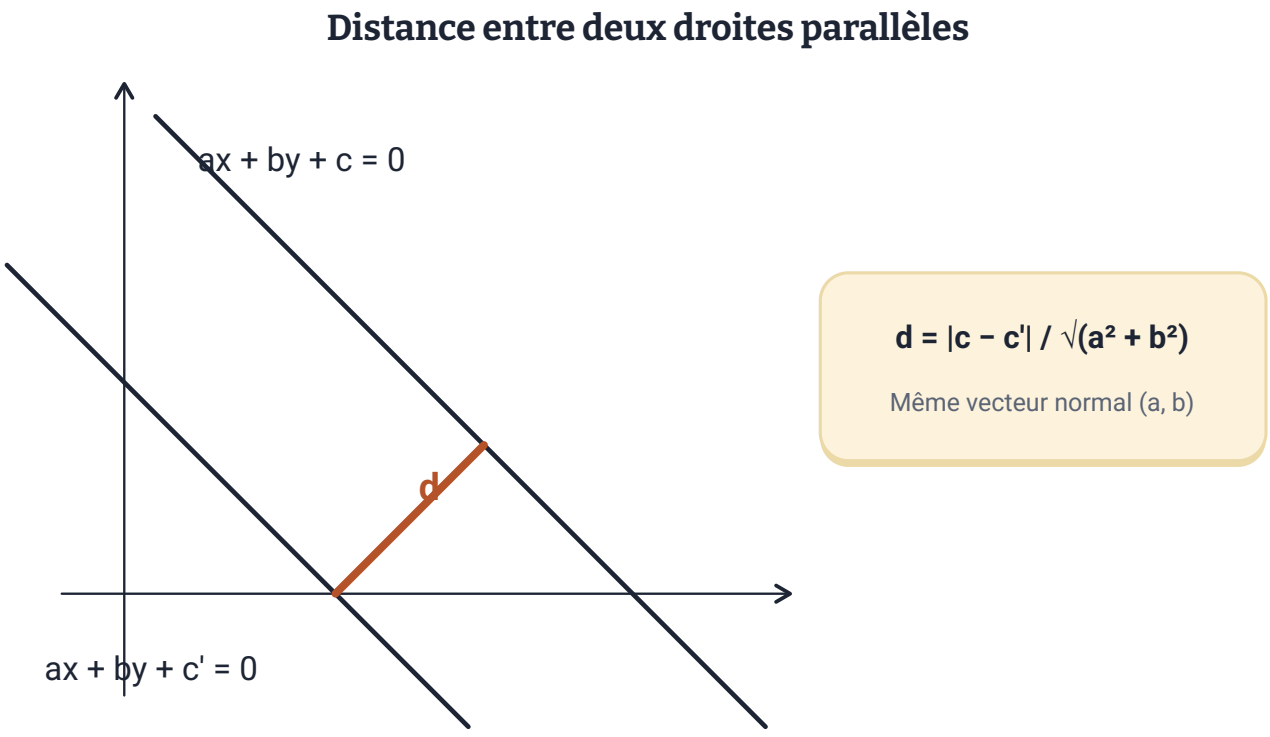
Marge maximale dans les SVM

- (w, b) multiplié par un réel positif : même frontière, autres scores.

- Séparation stricte : on fixe $\min_i y_i\, g(x_i) = 1$.
- Niveaux $+1$ et -1 : bords de la marge.

$$
\begin{aligned}
H_1 &: \; w \cdot x + b = 1, \\
H_2 &: \; w \cdot x + b = -1, \\
m &= \frac{2}{\|w\|}.
\end{aligned}
$$

Lire la formule –
Après normalisation, maximiser m revient à minimiser la norme de w.



Droites parallèles de mêmes coefficients normaux (a, b). Bords du SVM : niveaux distants de 2.

Chapitre 02 · SVM : marge dure

COMPLÉMENT · FORMULE

Formulation du problème

Avec $y_i \in \{-1, +1\}$, la contrainte $y_i\, g(x_i) \geq 1$ impose la bonne classe et une distance d'au moins $1/\|w\|$. Sans séparation linéaire stricte : problème **irréalisable**.

$$\begin{aligned} \min_{w,b} \quad & \frac{1}{2}\|w\|^2 \\ \text{sous les contraintes} \quad & y_i(w \cdot x_i + b) \geq 1, \qquad \forall i. \end{aligned}$$

Lire la formule –

Primal à marge dure : maximiser la marge équivaut à cet objectif quadratique.

Convexité et solution

Problème quadratique convexe. Données linéairement séparables, deux classes présentes : solution primale (w, b) unique.

Chapitre 02 · SVM : marge dure

COMPLÉMENT · FORMULE

Vecteurs de support et solution duale

Principe du Lagrangien

En marge dure, on associe un multiplicateur $\alpha_i \geq 0$ à chaque contrainte.

$$\begin{aligned} L(w, b, \alpha) = \frac{1}{2}\|w\|^2 \\ - \sum_{i=1}^{n} \alpha_i [y_i(w \cdot x_i + b) - 1], \\ \alpha_i \geq 0. \end{aligned}$$

Lire la formule –

Signe « – » : contraintes $y_i(w \cdot x_i + b) \geq 1$. Dual : minimiser en w et b, puis maximiser en α.

Problème dual

Le dual dépend des multiplicateurs α et des produits scalaires entre observations.

$$\begin{aligned} \max_{\alpha} \quad & \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) \\ \text{sous les contraintes} \quad & \alpha_i \geq 0, \qquad \forall i, \\ & \sum_i \alpha_i y_i = 0. \end{aligned}$$

Lire la formule –

Dual de la marge dure : aucune borne supérieure C sur les multiplicateurs.

$$w = \sum_i \alpha_i y_i x_i$$

Lire la formule –
Seules les observations avec $\alpha_i > 0$ contribuent : les vecteurs de support.

> **Interpréter les vecteurs de support**
>
> Seuls les points avec $\alpha_i > 0$ interviennent dans w : ce sont les **vecteurs de support**, situés sur les bords en marge dure.

Chapitre 02 · SVM : marge dure

COMPLÉMENT · FORMULE

Détails de la solution duale

Pourquoi les observations apparaissent dans w

Stationnarité en w et b : w devient une combinaison d'observations, et les multiplicateurs s'équilibrent.

$$\begin{aligned} \nabla_w L = w - \sum_i \alpha_i y_i x_i = 0, \\ \frac{\partial L}{\partial b} = -\sum_i \alpha_i y_i = 0, \\ \Longrightarrow \quad w = \sum_i \alpha_i y_i x_i, \qquad \sum_i \alpha_i y_i = 0. \end{aligned}$$

Lire la formule –
Valable pour un score affine, à biais b libre.

$$g(x) = \sum_i \alpha_i y_i (x_i \cdot x) + b$$

Lire la formule –
Même score linéaire, écrit avec les observations de support.

> **Justification facultative — complémentarité**
>
> Complémentarité : un multiplicateur positif impose une contrainte de marge active. En marge souple, en plus $\alpha_i \leq C$.

$$\begin{aligned}
\text{Marge dure :} \quad & \alpha_i \big[y_i (w \cdot x_i + b) - 1 \big] = 0, \\
\alpha_i > 0 \quad & \Longrightarrow \quad y_i (w \cdot x_i + b) = 1, \\
\text{Marge souple :} \quad & 0 \le \alpha_i \le C.
\end{aligned}$$

Lire la formule –
Support : sur un bord en marge dure ; en marge souple, aussi dans la marge ou mal classé.

Chapitre 02 · SVM : marge dure

COMPLÉMENT · FORMULE

Marge souple · conditions KKT et biais

Pourquoi α est borné par C en marge souple

- Multiplicateurs $\mu_i \ge 0$ pour les contraintes $\xi_i \ge 0$.
- Stationnarité en ξ_i : $C - \alpha_i - \mu_i = 0$, donc $0 \le \alpha_i \le C$.
- Même objectif dual, avec $\sum_i \alpha_i y_i = 0$.

$$\begin{aligned}
\alpha_i [y_i g(x_i) - 1 + \xi_i] = 0, \\
(C - \alpha_i) \xi_i = 0.
\end{aligned}$$

Lire la formule –
Complémentarité en marge souple, ξ_i minimal. Si $0 < \alpha_i < C$, alors $\xi_i = 0$ et $y_i \, g(x_i) = 1$.

Multiplicateur	À l'optimum
$\alpha_i = 0$	$y_i \, g(x_i) \ge 1$: pas de contribution à w.
$0 < \alpha_i < C$	$y_i \, g(x_i) = 1$: support sur un bord.
$\alpha_i = C$	$y_i \, g(x_i) \le 1$: sur le bord, dans la marge ou mal classé.

Retrouver le biais b

- Marge dure : un support $\alpha_s > 0$ donne $b = y_s - w \cdot x_s$.
- Marge souple : **support libre** requis, $0 < \alpha_s < C$; moyenner sur plusieurs.
- Aucun support libre : les inégalités KKT encadrent seulement b ; ne pas utiliser un support quelconque.
- Le w optimal est unique ; en marge souple, b et les multiplicateurs peuvent ne pas l'être.

COMPLÉMENT · FORMULE

Cas non parfaitement séparables

Données bruitées ou non linéaires

Chaque observation reçoit une variable de relâchement $\xi_i \geq 0$, qui l'autorise à violer la marge.

$$y_i(w \cdot x_i + b) \geq 1 - \xi_i, \qquad \xi_i \geq 0$$

Lire la formule –
Si $\xi_i = 0$: contrainte de marge dure. Une valeur positive la relâche.

Problème régularisé — SVM souple

C pondère violations et norme. À w et b fixés, le relâchement minimal est la **perte charnière** : $\xi_i = \max(0,\, 1 - y_i\, g(x_i))$.

$$\begin{aligned} \min_{w,b,\xi} \quad & \frac{1}{2}\|w\|^2 + C\sum_{i=1}^{n}\xi_i \\ \text{sous les contraintes} \quad & y_i(w \cdot x_i + b) \geq 1 - \xi_i, \\ & \xi_i \geq 0, \qquad \forall i, \qquad C > 0. \end{aligned}$$

Lire la formule –
Grand C : violations coûteuses. Petit C : priorité à la minimisation de la norme.



Une violation de marge n'est pas toujours une erreur

- Bon côté, mais dans la marge : bien classé, relâchement positif.
- Mauvais côté : relâchement minimal supérieur à 1.

Chapitre 02 · SVM : marge souple

COMPLÉMENT · FORMULE

Du relâchement à la perte charnière

- Comme $C > 0$, minimiser en ξ rend chaque relâchement minimal.
- D'où un problème équivalent : somme des pertes charnières + pénalité quadratique sur w.
- Remplacer $g(x)$ par $\operatorname{sign}(g(x))$ effacerait l'information de marge.
- Perte charnière : convexe, non dérivable en $y_i\, g(x_i) = 1$.

$$\min_{w,b} \ \frac{1}{2}\|w\|^2 + C\sum_i \max(0, 1 - y_i g(x_i))$$

Lire la formule –

Objectif sans ξ. Le biais b est libre, non pénalisé.

Choisir C sans fuite d'information

- Mise à l'échelle apprise sur l'apprentissage seul ; C par validation croisée ; test final pour l'évaluation.
- C dépend de l'échelle et de la convention (somme ou moyenne des pertes) : avec $\frac{\lambda}{2}\|w\|^2 + \text{moyenne des pertes}$, même solution si $\lambda = 1/(nC)$.
- Un grand C ne garantit ni zéro erreur ni meilleure généralisation.

Chapitre 02 · SVM : marge souple

COMPLÉMENT · EXERCICE

Lire les variables de relâchement

$$\xi_i^{\min} = \max(0,\ 1 - y_i(w \cdot x_i + b))$$

Lire la formule –

À w et b fixés, relâchement minimal = hinge loss du score continu, pas de la classe prédite.

Marge signée $y_i\, g(x_i)$	**Position**	**Relâchement minimal** ξ_i
Au moins 1	Bien classé, sur le bord ou au-delà.	0
Entre 0 et 1	Bien classé, dans la marge.	Entre 0 et 1
0	Sur la frontière.	1
Négative	Mal classé.	Supérieur à 1



À VOUS DE JOUER

Vérification facultative — lire un relâchement

Un point de label $+1$ a pour score $0{,}4$.

1. Est-il bien classé ?
2. Respecte-t-il la marge dure ?
3. Quel est le plus petit relâchement compatible ?

▼ Solution commentée

1. Score positif : bien classé.
2. Marge signée $0{,}4 < 1$: il viole la marge dure.
3. $\xi \geq 1 - 0{,}4 = 0{,}6$: relâchement minimal $0{,}6$.

COMPLÉMENT · FORMULE

Hard margin vs. soft margin

Ce qui détermine la frontière

Le SVM s'exprime à partir des **vecteurs de support**. Maximiser la marge normalisée revient à minimiser la norme du vecteur normal, ce qui contrôle la complexité du score.

▼ Tableau de comparaison

Formulation	Contraintes	Situation
Hard margin	Aucune violation de marge.	Données linéairement séparables.
Soft margin	Relâchées par des $\xi_i \geq 0$.	Violations autorisées et pénalisées.

$$\min_{w,b} \frac{1}{2}\|w\|^2$$
$$\text{sous } y_i(w \cdot x_i + b) \geq 1, \quad \forall i.$$

Lire la formule –
Pas de relâchement : aucune observation dans la marge.

$$\min_{w,b,\xi} \frac{1}{2}\|w\|^2 + C\sum_{i=1}^{n} \xi_i$$
$$\text{sous } y_i(w \cdot x_i + b) \geq 1 - \xi_i,$$
$$\xi_i \geq 0, \quad \forall i.$$

Lire la formule –

Violations mises en balance avec la norme de w : points possibles dans la marge ou mal classés.

Le paramètre C règle le compromis

Grand C : violations plus coûteuses. **Petit** C : davantage de relâchement toléré pour réduire la norme de w. Ce compromis ne garantit pas une meilleure généralisation.

> **Et si on a plusieurs classes ?**
>
> Pour plusieurs classes : combiner des problèmes binaires avec **OvR** ou **OvO**.

Chapitre 02 · SVMs pour la discrimination multi-class

COMPLÉMENT · NOTION

Pour approfondir les SVM

Pour approfondir

Stanford CS229 · SVM, Lagrangien et dual (PDF) ↗

Cornell 2026 · SVM, géométrie et optimisation (PDF) ↗